

UNIVERSIDADE DE SÃO PAULO
Programa de Post-Graduação em Estatística

Katerine Zuniga Lastra, Marília de Melo Sombra, Alex Monito Nhamcololo

Lista 01 – Semestre de 2024-II – Prof. Silvia Ferrari

5) Admita que X tem distribuição arco-seno com parâmetros $\mu \in \mathcal{R}$ e $\sigma \in \mathcal{R}_+$ e densidade:

$$p(x; \mu, \sigma) = \frac{1}{\pi \sqrt{(x - \mu)(\mu + \sigma - x)}}, \quad x \in (\mu, \mu + \sigma). \quad (1)$$

Mostre que a classe de possíveis distribuições de X é uma família de localização-escala.

Resolução:

Uma classe de possíveis distribuições da variável aleatória (v.a.) X pertencerá à família de localização-escala se puder ser escrita na forma $X = \mu + \sigma U$, ou seja,

$$P(X \leq x) = F\left(\frac{x - \mu}{\sigma}\right) \text{ ou } f_X(x) = \frac{1}{\sigma} \cdot f_U\left(\frac{x - \mu}{\sigma}\right), \text{ onde, } f_X(x) = \frac{\partial}{\partial x} F\left(\frac{x - \mu}{\sigma}\right),$$

U é uma v.a. com função densidade (massa) de probabilidade $f_U(\cdot)$ conhecida (fixa), $\mu \in \mathcal{R}$ é o parâmetro de localização, e $\sigma \in \mathcal{R}_+$ é o parâmetro de escala.

Assim, tomando $\mu = 0$ e $\sigma = 1$, e substituindo na distribuição arco-seno (1), obtém-se a distribuição arco-seno padrão, dada por:

$$\begin{aligned} p(x; \mu = 0, \sigma = 1) &= f_U(x; \mu = 0, \sigma = 1) = \frac{1}{\pi \sqrt{(x - 0)(0 + 1 - x)}}, \quad x \in (0, 0 + 1) \\ &= \frac{1}{\pi \sqrt{x(1 - x)}}, \quad x \in (0, 1). \end{aligned} \quad (2)$$

Considerando a expressão $f_X(x) = \frac{1}{\sigma} \cdot f_U\left(\frac{x - \mu}{\sigma}\right)$, tem-se:

$$\begin{aligned} f_X(x) &= \frac{1}{\sigma} \cdot \frac{1}{\pi \sqrt{\left(\frac{x - \mu}{\sigma}\right) \left(1 - \left(\frac{x - \mu}{\sigma}\right)\right)}}, \text{ substituindo } x \text{ por } \frac{x - \mu}{\sigma} \text{ na eq. (2)} \\ &= \frac{1}{\sigma} \cdot \frac{1}{\pi \sqrt{\left(\frac{x - \mu}{\sigma}\right) \left(\frac{\sigma - x + \mu}{\sigma}\right)}}, \text{ igualando denominadores de } 1 - \frac{x - \mu}{\sigma} \\ &= \frac{1}{\sigma} \cdot \frac{1}{\pi \sqrt{\frac{(x - \mu)(\sigma - x + \mu)}{\sigma^2}}} \\ &= \frac{1}{\cancel{\sigma} \cdot \frac{\pi \sqrt{(x - \mu)(\mu + \sigma - x)}}{\cancel{\sigma}}} \\ &= \frac{1}{\pi \sqrt{(x - \mu)(\mu + \sigma - x)}}, \quad x \in (\mu, \mu + \sigma) \\ &= p(x; \mu, \sigma), \text{ apresentada na equação 1.} \end{aligned}$$

Logo, conclui-se que $p(x; \mu, \sigma)$ é da família de localização-escala.

- 9) A partir de propriedades da família exponencial (eq: 3) encontre as funções geradoras de momentos e de cumulantes, a média e o segundo, o terceiro e o quarto momento central da distribuição Gama(a, b).

$$p_{\theta}(x) = \exp \left[\sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right] \cdot h(x) \quad (3)$$

Resolução

A função distribuição gama pode ser expressa por:

$$\begin{aligned} f(x; a, b) &= \frac{1}{\Gamma(a)b^a} x^{a-1} \exp \left[-\frac{x}{b} \right], \quad a > 0, b > 0 \\ &= \frac{1}{\Gamma(a)} \exp \left[\log \left(\frac{1}{b^a} \right) \right] x^{a-1} \exp \left[-\frac{x}{b} \right], \quad \frac{1}{b^a} > 0, \text{ e } a \text{ conhecido (fixo)} \\ &= \frac{1}{\Gamma(a)} \exp [\log (b^{-a})] x^{a-1} \exp \left[-\frac{x}{b} \right] \\ &= \frac{1}{\Gamma(a)} \exp [-a \log (b)] x^{a-1} \exp \left[-\frac{x}{b} \right], \quad b > 0 \\ &= \frac{1}{\Gamma(a)} x^{a-1} \exp \left[-a \log (b) - \frac{x}{b} \right] \\ &= \frac{1}{\Gamma(a)} x^{a-1} \exp \left[-\frac{1}{b} x - a \log (b) \right], \quad \text{que corresponde a família exponencial, com} \end{aligned}$$

$$h(x) = \frac{1}{\Gamma(a)} x^{a-1}, \quad T(x) = x, \quad \eta_i(\theta) = -\frac{1}{b}, \quad B(\theta) = a \log (b)$$

A função exponencial da eq. (3), quando escrita na forma canônica $\eta_i(\theta) = \eta$ e $B(\theta) = \mathcal{A}(\eta)$. Assim, sob esta notação, $\eta = -\frac{1}{b} \Leftrightarrow b = -\frac{1}{\eta}$ e $\mathcal{A}(\eta) = a \log (b) = a \log \left(-\frac{1}{\eta} \right) = -a \log (-\eta)$.

Função geradora dos momentos

$$\begin{aligned} M_X(u) &= \frac{\exp [\mathcal{A}(\eta + u)]}{\exp [\mathcal{A}(\eta)]} = \frac{\exp [-a \log (-\eta + u)]}{\exp [-a \log (-\eta)]} = \frac{\exp [\log (-\eta + u)^{-a}]}{\exp [\log (-\eta)^{-a}]} = \frac{(-\eta + u)^{-a}}{(-\eta)^{-a}} = \\ &= \left(\frac{-\eta + u}{-\eta} \right)^{-a} = \left(\cancel{\frac{-\eta}{-\eta}} + \left(\frac{1}{-\eta} \right) (-u) \right)^{-a} = (1 + b(-u))^{-a} = (1 - bu)^{-a} = \left(\frac{1}{1 - bu} \right)^a, \quad bu \neq 1 \end{aligned}$$

Função geradora de cumulantes

$$K_X(u) = \log (M_X(u)) = \log (1 - bu)^{-a} = -a \log (1 - bu), \quad bu > 1$$

Média

$$\begin{aligned} \mu = E(X) &= \frac{\partial}{\partial u} K_X(u) \Big|_{u=0} \\ &= \frac{\partial}{\partial u} [-a \log (1 - bu)] \Big|_{u=0} \\ &= \frac{-a(-b)}{1 - bu} \Big|_{u=0} \\ &= \frac{ab}{1 - b \cdot 0} \\ &= ab \end{aligned}$$

Segundo momento centrado

$$\begin{aligned}\mu_2 &= \frac{\partial^2}{\partial u^2} K_X(u) \Big|_{u=0} = \frac{\partial}{\partial u} \left(\frac{\partial}{\partial u} K_X(u) \right) \Big|_{u=0} = \frac{\partial}{\partial u} \left(\frac{ab}{1-bu} \right) \Big|_{u=0} = ab \frac{\partial}{\partial u} (1-bu)^{-1} \Big|_{u=0} = \\ &= ab(-1)(1-bu)^{-2}(-b) \Big|_{u=0} = ab^2(1-bu)^{-2} \Big|_{u=0} = ab^2(1-b \cdot 0)^{-2} \xrightarrow{1} \\ &= ab^2\end{aligned}$$

Terceiro momento centrado

$$\begin{aligned}\mu_3 &= \frac{\partial^3}{\partial u^3} K_X(u) \Big|_{u=0} = \frac{\partial}{\partial u} \left(\frac{\partial^2}{\partial u^2} K_X(u) \right) \Big|_{u=0} = \frac{\partial}{\partial u} [ab^2(1-bu)^{-2}] \Big|_{u=0} = -2ab^2(1-bu)^{-3}(-b) \Big|_{u=0} = \\ &= 2ab^3(1-bu)^{-3} \Big|_{u=0} = 2ab^3(1-b \cdot 0)^{-3} \xrightarrow{1} \\ &= 2ab^3\end{aligned}$$

Quarto momento centrado

$$\begin{aligned}\mu_4 &= \kappa_4 + 3\mu_2^2 = \frac{\partial^4}{\partial u^4} K_X(u) \Big|_{u=0} + 3\mu_2^2 = \frac{\partial}{\partial u} \left(\frac{\partial^3}{\partial u^3} K_X(u) \right) \Big|_{u=0} + 3\mu_2^2 = \frac{\partial}{\partial u} [2ab^3(1-bu)^{-3}] \Big|_{u=0} + 3\mu_2^2 = \\ &= 2ab^3(-3)(1-bu)^{-4}(-b) \Big|_{u=0} + 3\mu_2^2 = 2ab^3(3b)(1-b \cdot 0)^{-4} \xrightarrow{1} + 3\mu_2^2 = 6ab^4 + 3[ab^2]^2 = \\ &= 6ab^4 + 3a^2b^4 \\ &= (6a + 3a^2)b^4\end{aligned}$$

11) Considere a distribuição de série de potências com função de probabilidade

$$f_\theta(x) = p_\theta(X = x) = \frac{a(x)\theta^x}{C(\theta)}, \quad x = 0, 1, 2, \dots; a(x) > 0; \theta > 0 \quad (4)$$

a) Mostre que a distribuição (a faz parte da família exponencial (eq: 3) unidimensional.

Resolução

$$\begin{aligned}f_\theta(x) &= \frac{a(x)\theta^x}{C(\theta)}, \quad x = 0, 1, 2, \dots; a(x) \geq 0; \theta > 0 \\ &= a(x) \exp \left[\log \left(\frac{\theta^x}{C(\theta)} \right) \right], \quad \frac{\theta^x}{C(\theta)} > 0, C(\theta) \neq 0 \\ &= a(x) \exp [\log(\theta^x) - \log(C(\theta))], \quad \theta^x > 0, C(\theta) > 0 \\ &= a(x) \exp [x \log(\theta) - \log(C(\theta))], \quad \theta > 0, C(\theta) > 0\end{aligned}$$

Logo, $f_\theta(x)$ pertence a família exponencial (eq:3) unidimensional (s=1), onde, $T(x) = x$, $h(x) = a(x)$, $\eta = \log(\theta)$, e, $\mathcal{A}(\eta) = \log(C(\theta))$

b) Mostre que sua função geradora de momentos é $M_X(u) = \frac{C(\theta e^u)}{C(\theta)}$

Resolução

$$\begin{aligned}\eta &= \log(\theta) \Leftrightarrow e^\eta = \theta, \quad \theta > 0 \\ \mathcal{A}(\eta) &= \log(C(\theta)) \Leftrightarrow \mathcal{A}(\eta) = \log(C(e^\eta)), \quad C(e^\eta) > 0, C(\theta) > 0 \\ M_X(u) &= \frac{e^{\mathcal{A}(\eta+u)}}{e^{\mathcal{A}(\eta)}} \\ &= \frac{e^{\log[C(e^{\eta+u})]}}{e^{\log[C(e^\eta)]}} \\ &= \frac{C(e^{\eta+u})}{C(e^\eta)} \\ &= \frac{C(e^\eta \cdot e^u)}{C(e^\eta)} \\ &= \frac{C(\theta e^u)}{C(\theta)}\end{aligned}$$

- c) Mostre que as distribuições binomial, binomial negativa e Poisson são casos especiais da distribuição de série de potências e determine $a(x)$ e $C(\theta)$.

Resolução

c.1) Distribuição binomial

Se $X \sim \text{Bin}(p, n)$, $x = 0, 1, 2, \dots, n$,

$$\begin{aligned}
 f_X(x) &= \binom{n}{x} p^x (1-p)^{n-x}, \quad 0 \leq p \leq 1, n \in \mathcal{N} \\
 &= \binom{n}{x} \exp\{\log [p^x (1-p)^{n-x}]\}, \quad p^x (1-p)^{n-x} > 0 \\
 &= \binom{n}{x} \exp\{\log (p^x) + \log [(1-p)^{n-x}]\}, \quad p^x > 0, (1-p)^{n-x} > 0 \\
 &= \binom{n}{x} \exp\{x \log (p) + (n-x) \log (1-p)\}, \quad p > 0, 1-p > 0 \\
 &= \binom{n}{x} \exp\{x \log (p) + n \log (1-p) - x \log (1-p)\}, \quad p > 0, 1-p > 0 \\
 &= \binom{n}{x} \exp\{x [\log (p) - \log (1-p)] + n \log (1-p)\} \\
 &= \binom{n}{x} \exp\{x \log \left(\frac{p}{1-p} \right) + n \log (1-p)\}, \quad \frac{p}{1-p} > 0, 1-p \neq 0
 \end{aligned}$$

$$\begin{aligned}
 T(x) &= x, h(x) = a(x) = \binom{n}{x}, \eta = \log(\theta) = \log \left(\frac{p}{1-p} \right), e, \\
 \mathcal{A}(\eta) &= \log [C(\theta)] = -n \log (1-p) = \log [(1-p)^{-n}], \quad (1-p)^{-n} > 0 \\
 C(\theta) &= (1-p)^{-n} = \left(\frac{1}{1-p} \right)^n, \quad 1-p \neq 0
 \end{aligned}$$

c.2) Distribuição binomial negativa

Se $X \sim \text{BN}(p, m)$, $x = 0, 1, 2, \dots$ $0 \leq p \leq 1$,

$$\begin{aligned}
 f_X(x) &= \binom{m+x-1}{m-1} p^m (1-p)^x, \quad m \geq 1, 0 \leq p \leq 1 \\
 &= \binom{m+x-1}{m-1} \exp\{\log [p^m (1-p)^x]\}, \quad p^m (1-p)^x > 0 \\
 &= \binom{m+x-1}{m-1} \exp\{\log (p^m) + \log [(1-p)^x]\}, \quad p^m > 0, (1-p)^x > 0 \\
 &= \binom{m+x-1}{m-1} \exp\{x \log (1-p) + \log (p^m)\}, \quad p^m > 0, (1-p) > 0
 \end{aligned}$$

$$\begin{aligned}
 T(x) &= x, h(x) = a(x) = \binom{m+x-1}{m-1}, \eta = \log(\theta) = \log (1-p), e, \\
 \mathcal{A}(\eta) &= \log [C(\theta)] = -\log (p^m) = \log (p^{-m}), \\
 C(\theta) &= p^{-m} = \left(\frac{1}{p} \right)^m, \quad p \neq 0
 \end{aligned}$$

c.3) Distribuição Poisson

Se $X \sim \text{Poisson}(\lambda)$, $x = 0, 1, 2, \dots$ $\lambda > 0$,

$$\begin{aligned}
 f_X(x) &= \frac{1}{x!} \lambda^x \exp\{-\lambda\} \\
 &= \frac{1}{x!} \exp\{\log (\lambda^x)\} \exp\{-\lambda\}, \quad \lambda^x > 0 \\
 &= \frac{1}{x!} \exp\{\log (\lambda^x) - \lambda\} \\
 &= \frac{1}{x!} \exp\{x \log (\lambda) - \log (\exp\{\lambda\})\}, \quad \lambda > 0, \exp\{\lambda\} > 0
 \end{aligned}$$

$$\begin{aligned}
T(x) &= x, \quad h(x) = a(x) = \frac{1}{x!}, \quad \eta = \log(\theta) = \log(\lambda), \quad e, \\
\mathcal{A}(\eta) &= \log[C(\theta)] = \log(\exp\{\lambda\}) \\
C(\theta) &= \exp\{\lambda\}
\end{aligned}$$

13) Seja $T(X) = (T_1(X), \dots, T_s(X))'$ e considere a densidade (3)

$$13.1) \text{ Mostre para } s = 1 \text{ que } \mathbb{E}_\theta[T(X)] = \frac{B'(\theta)}{\eta'(\theta)} \text{ e } \text{Var}_\theta[T(X)] = \frac{B''(\theta)}{[\eta'(\theta)]^2} - \frac{\eta''(\theta)B'(\theta)}{[\eta'(\theta)]^3}.$$

Resolução

$$\mathbb{E}_\theta[T(X)] = \int_{-\infty}^{+\infty} T(x) \exp[\eta(\theta)T(x) - B(\theta)] h(x) dx$$

A densidade (3), é de dimensão s , se $s = 1$, esta, pode ser rescrita do seguinte modo:

$$\begin{aligned}
p_\theta(x) &= \exp[\eta(\theta)T(x) - B(\theta)] \cdot h(x) \\
&= \exp[\eta T(x) - \mathcal{A}(\eta)] \cdot h(x), \quad \text{para } \eta(\theta) = \eta \text{ e } B(\theta) = \mathcal{A}(\eta) = \mathcal{A}(\eta(\theta)) \\
p_\theta(x) &= \exp[\eta(\theta)T(x) - \mathcal{A}(\eta(\theta))] \cdot h(x) \\
p_\theta(x) &= \exp[\eta(\theta)T(x)] \cdot \exp[-\mathcal{A}(\eta(\theta))] \cdot h(x) \\
p_\theta(x) &= \exp[\eta(\theta)T(x) - \mathcal{A}(\eta(\theta))] \cdot h(x) \\
\exp[\mathcal{A}(\eta(\theta))] \cdot p_\theta(x) &= \exp[\eta(\theta)T(x)] \cdot \exp[-\mathcal{A}(\eta(\theta))] \cdot h(x) \cdot \exp[\mathcal{A}(\eta(\theta))] \\
\exp[\mathcal{A}(\eta(\theta))] \cdot p_\theta(x) &= \exp[\eta(\theta)T(x)] \cdot \exp[-\cancel{\mathcal{A}(\eta(\theta))} + \mathcal{A}(\eta(\theta))] \cdot h(x) \\
\exp[\mathcal{A}(\eta(\theta))] \cdot p_\theta(x) &= \exp[\eta(\theta)T(x)] \cdot h(x), \quad \exp[0] = 1 \\
\int_{-\infty}^{+\infty} \exp[\mathcal{A}(\eta(\theta))] \cdot p_\theta(x) dx &= \int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] \cdot h(x) dx \\
\exp[\mathcal{A}(\eta(\theta))] \int_{-\infty}^{+\infty} p_\theta(x) dx &= \int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx, \text{ integrando em } x \text{ } \exp[\mathcal{A}(\eta(\theta))] \text{ é constante} \\
\exp[\mathcal{A}(\eta(\theta))] &= \int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx, \quad p_\theta \text{ é fdp}^1, \text{ logo, } \int_{-\infty}^{+\infty} p_\theta(x) dx = 1, \quad (**) \\
\log[\exp[\mathcal{A}(\eta(\theta))]] &= \log\left[\int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx\right] \\
\mathcal{A}(\eta(\theta)) &= \log\left[\int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx\right] \\
\frac{\partial \mathcal{A}(\eta(\theta))}{\partial \eta(\theta)} &= \frac{\partial}{\partial \eta(\theta)} \log\left[\int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx\right] \\
\frac{\partial \mathcal{A}(\eta(\theta))}{\partial \theta} \frac{\partial \theta}{\partial \eta(\theta)} &= \frac{\frac{\partial}{\partial \eta(\theta)} \int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx}{\int_{-\infty}^{+\infty} \exp[\eta(\theta)T(x)] h(x) dx}, \text{ deriv. em } \eta(\theta), \text{ o que não é } \eta(\cdot), \text{ é constante} \\
\frac{\frac{\partial \mathcal{A}(\eta(\theta))}{\partial \theta}}{\frac{\partial \eta(\theta)}{\partial \theta}} &= \frac{\int_{-\infty}^{+\infty} T(x) \exp[\eta(\theta)T(x)] h(x) dx}{\exp[\mathcal{A}(\eta(\theta))]}, \text{ expressão (**)} \\
\frac{\frac{\partial B(\theta)}{\partial \theta}}{\frac{\partial \eta(\theta)}{\partial \theta}} &= \exp[-\mathcal{A}(\eta(\theta))] \int_{-\infty}^{+\infty} T(x) \exp[\eta(\theta)T(x)] h(x) dx, \quad \mathcal{A}(\eta(\theta)) = B(\theta), \quad \left(e^{[\mathcal{A}(\eta(\theta))]} \right)^{-1} = e^{[-\mathcal{A}(\eta(\theta))]} \\
\frac{B'(\theta)}{\eta'(\theta)} &= \int_{-\infty}^{+\infty} T(x) \exp[-\mathcal{A}(\eta(\theta))] \exp[\eta(\theta)T(x)] h(x) dx, \quad \text{integ. em } x, \exp[-\mathcal{A}(\eta(\theta))] \text{ é constante} \\
\frac{B'(\theta)}{\eta'(\theta)} &= \int_{-\infty}^{+\infty} T(x) \exp[\eta(\theta)T(x) - \mathcal{A}(\eta(\theta))] h(x) dx \\
\frac{B'(\theta)}{\eta'(\theta)} &= \int_{-\infty}^{+\infty} T(x) \exp[\eta(\theta)T(x) - B(\theta)] h(x) dx, \quad \text{pois, } \mathcal{A}(\eta(\theta)) = B(\theta) \\
\frac{B'(\theta)}{\eta'(\theta)} &= \mathbb{E}_\theta[T(x)]
\end{aligned}$$

$$13.2) \text{ Var}_\theta [T(X)] = \frac{B''(\theta)}{[\eta'(\theta)]^2} - \frac{\eta''(\theta)B'(\theta)}{[\eta'(\theta)]^3}.$$

$$\text{Var}_\theta [T(x)] = \mathbb{E}_\theta [T(x)]^2 - \mathbb{E}_\theta^2 [T(x)] \text{ e } \mathbb{E}_\theta [T(x)] = \frac{B'(\theta)}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x) - B(\theta)] h(x)dx, \quad (p.1)$$

$$\mathbb{E}_\theta^2 [T(x)] = \int_{-\infty}^{+\infty} T^2(x) \exp [\eta(\theta)T(x) - B(\theta)] h(x)dx, \quad (p.2)$$

$$\frac{B'(\theta)}{\eta'(\theta)} = \frac{\frac{\partial \mathcal{A}(\eta(\theta))}{\partial \theta}}{\frac{\partial \eta(\theta)}{\partial \theta}} = \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x) - \mathcal{A}(\eta(\theta))] h(x)dx$$

$$\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] \exp [-\mathcal{A}(\eta(\theta))] h(x)dx$$

$$\exp [\mathcal{A}(\eta(\theta))] \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] \exp [-\mathcal{A}(\eta(\theta))] \exp [\mathcal{A}(\eta(\theta))] h(x)dx$$

$$\exp [\mathcal{A}(\eta(\theta))] \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] \exp [-\cancel{\mathcal{A}(\eta(\theta))} + \cancel{\mathcal{A}(\eta(\theta))}] h(x)dx$$

$$\exp [\mathcal{A}(\eta(\theta))] \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} = \int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx, \quad (***)$$

$$\log \left[\exp [\mathcal{A}(\eta(\theta))] \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right] = \log \left[\int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx \right]$$

$$\log (\exp [\mathcal{A}(\eta(\theta))]) + \log \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right] = \log \left[\int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx \right]$$

$$\frac{\partial}{\partial \eta(\theta)} \left[\mathcal{A}(\eta(\theta)) + \log \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right] \right] = \frac{\partial}{\partial \eta(\theta)} \log \left[\int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx \right]$$

$$\frac{\partial}{\partial \eta(\theta)} \mathcal{A}(\eta(\theta)) + \frac{\partial}{\partial \eta(\theta)} \log \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right] = \frac{\frac{\partial}{\partial \eta(\theta)} \left[\int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx \right]}{\int_{-\infty}^{+\infty} T(x) \exp [\eta(\theta)T(x)] h(x)dx}$$

$$\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} + \frac{\frac{\partial}{\partial \eta(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]}{\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}} = \frac{\int_{-\infty}^{+\infty} T(x)T(x) \exp [\eta(\theta)T(x)] h(x)dx}{\exp [\mathcal{A}(\eta(\theta))] \frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}}, \text{ ver 13.1) e (***)}$$

$$\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} + \frac{\frac{\partial}{\partial \eta(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]}{\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}} \right] = \exp [-\mathcal{A}(\eta(\theta))] \int_{-\infty}^{+\infty} T^2(x) \exp [\eta(\theta)T(x)] h(x)dx$$

$$\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} + \frac{\frac{\partial}{\partial \eta(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]}{\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}} \right] = \exp [-\mathcal{A}(\eta(\theta))] \int_{-\infty}^{+\infty} T^2(x) \exp [\eta(\theta)T(x)] h(x)dx$$

$$\left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]^2 + \cancel{\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}} \left[\frac{\frac{\partial}{\partial \eta(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]}{\cancel{\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)}}} \right] = \int_{-\infty}^{+\infty} T^2(x) \exp [-\mathcal{A}(\eta(\theta))] \exp [\eta(\theta)T(x)] h(x)dx$$

$$\frac{\partial}{\partial \eta(\theta)} \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right] = \int_{-\infty}^{+\infty} T^2(x) \exp [\eta(\theta)T(x) - \mathcal{A}(\eta(\theta))] h(x)dx - \left[\frac{\mathcal{A}'(\eta(\theta))}{\eta'(\theta)} \right]^2$$

$$\frac{\frac{\partial}{\partial \eta(\theta)} \left[\mathcal{A}'(\eta(\theta)) \right] \cdot \eta'(\theta) - \frac{\partial}{\partial \eta(\theta)} \left[\eta'(\theta) \right] \cdot \mathcal{A}'(\eta(\theta))}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2, \quad (p.1) \text{ e } (p.2)$$

Continuação do exercício 13.2)

$$\begin{aligned}
& \frac{\frac{\partial}{\partial \eta(\theta)} [\mathcal{A}'(\eta(\theta))] \cdot \eta'(\theta) - \frac{\partial}{\partial \eta(\theta)} [\eta'(\theta)] \cdot \mathcal{A}'(\eta(\theta))}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2, \quad (\text{p.1}) \text{ e } (\text{p.2}) \\
& \frac{\left[\frac{\partial \mathcal{A}'(\eta(\theta))}{\partial \theta} \frac{\partial \theta}{\partial \eta(\theta)} \right] \cdot \eta'(\theta) - \left[\frac{\partial \eta'(\theta)}{\partial \theta} \frac{\partial \theta}{\partial \eta(\theta)} \right] \cdot \mathcal{A}'(\eta(\theta))}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2 \\
& \frac{\left[\frac{\partial B'(\theta)}{\partial \theta} \frac{\partial \theta}{\partial \eta(\theta)} \right] \cdot \eta'(\theta) - \left[\frac{\partial \eta'(\theta)}{\partial \theta} \frac{\partial \theta}{\partial \eta(\theta)} \right] \cdot B'(\theta)}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2, \quad \mathcal{A}'(\eta(\theta)) = B'(\theta) \\
& \frac{\left[\frac{\frac{\partial B'(\theta)}{\partial \theta}}{\frac{\partial \eta(\theta)}{\partial \theta}} \right] \cdot \eta'(\theta) - \left[\frac{\frac{\partial \eta'(\theta)}{\partial \theta}}{\frac{\partial \eta(\theta)}{\partial \theta}} \right] \cdot B'(\theta)}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2 \\
& \frac{\left[\frac{B''(\theta)}{\eta'(\theta)} \right] \cdot \eta'(\theta) - \left[\frac{\eta''(\theta)}{\eta'(\theta)} \right] \cdot B'(\theta)}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2 \\
& \frac{B''(\theta)}{[\eta'(\theta)]^2} - \frac{\frac{\eta''(\theta) \cdot B'(\theta)}{\eta'(\theta)}}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2 \\
& \frac{B''(\theta)}{[\eta'(\theta)]^2} - \frac{\eta''(\theta) \cdot B'(\theta)}{\eta'(\theta)} \frac{1}{[\eta'(\theta)]^2} = \mathbb{E}_\theta^2 [T(x)] - [\mathbb{E}_\theta [T(x)]]^2 \\
& \frac{B''(\theta)}{[\eta'(\theta)]^2} - \frac{\eta''(\theta) \cdot B'(\theta)}{[\eta'(\theta)]^3} = \text{Var}_\theta [T(x)], \quad (\text{p.1})
\end{aligned}$$

15) Seja T uma variável aleatória com momentos centrais (finitos) $\mu_j = \mu_j(T) = E[(T - E(T))^j]$, $j = 2, 3, \dots$, e cumulantes $\kappa_j = \kappa_j(T)$, $j = 1, 2, 3, \dots$ e seja a uma constante não nula. Mostre que

i) Se $T \sim N(\mu, \sigma^2)$, $\kappa_1(T) = \mu$, $\kappa_2(T) = \sigma^2$, $\kappa_j(T) = 0$, para $j = 3, 4, \dots$, $\text{skew}(T) = 0$ e $\text{kurt}(T) = 3$.

Sabemos que $M_T(u) = \sum_{j=0}^{\infty} \frac{\alpha_j u^j}{j!}$ e $K_T(u) = \sum_{j=0}^{\infty} \frac{\kappa_j u^j}{j!} = \log M_T(u)$. Fazendo $\kappa_0 = 0$, temos que $\kappa_1 = E(T)$, $\kappa_2 = \mu_2 = \text{Var}(T)$, $\kappa_3 = \mu_3$ e $\kappa_4 = \mu_4 - 3\mu_2^2$. Desse modo,

$$\text{skew}(T) = \frac{\mu_3(T)}{\mu_2(T)^{3/2}} = \frac{\kappa_3(T)}{\kappa_2(T)^{3/2}}$$

e

$$\text{kurt}(T) = \frac{\mu_4(T)}{\mu_2(T)^2} = \frac{\kappa_4(T) + 3\mu_2(T)^2}{\mu_2(T)^2} = \frac{\kappa_4(T)}{\mu_2(T)^2} + 3 = \frac{\kappa_4(T)}{\kappa_2(T)^2} + 3.$$

Assim, se $T \sim N(\mu, \sigma^2)$, então $\kappa_1(T) = E[T] = \mu$ e $\kappa_2(T) = \mu_2(T) = \text{Var}(T) = \sigma^2$. Assim,

$$\text{skew}(T) = \frac{\kappa_3(T)}{(\sigma^2)^{3/2}} = \frac{\kappa_3(T)}{\sigma^3} = 0, \quad \text{para } \kappa_3(T) = 0$$

e

$$\text{kurt}(T) = \frac{\kappa_4(T)}{(\sigma^2)^2} + 3 = \frac{\kappa_4(T)}{\sigma^4} = 3, \quad \text{para } \kappa_4(T) = 0.$$

24 Enuncie e prove resultados semelhantes aos do exercício 23 da lista 1 ano 2024 para famílias de localização e de escala.

Resolução

24.1 Família localização

Suponha que X_1, \dots, X_n sejam uma amostras aleatória de uma família de localização com função distribuição $F(x - \alpha)$, $\alpha \in \mathcal{R}$. Se $Y_j = \phi_j(X)$, para $j = 1, 2, 3, \dots, n$, são funções do vetor aleatório $X = X_1, \dots, X_n$, invariantes por localização, isto é,

$$\phi_j(x_1, \dots, x_n) = \phi_j[(x_1 - \alpha), (x_2 - \alpha), (x_3 - \alpha), \dots, (x_n - \alpha)], \quad \alpha \in \mathcal{R},$$

o vetor $Y = (Y_1, \dots, Y_n)$ é uma estatística ancilar.

Prova

Se $X = X_1, \dots, X_n$ pertence a família de localização, então existe uma variável aleatória U que não depende de nenhum parâmetro e, com função distribuição conhecida, tal que:

$$X = \alpha + U \Leftrightarrow X - \alpha = U, \quad \alpha \in \mathcal{R}$$

$$P(X \leq x) = P(\alpha + U \leq x) = P(U \leq x - \alpha) = F(x - \alpha)$$

Como $Y_j = \phi_j(X)$ e $\phi_j(x_1, \dots, x_n) = \phi_j[(x_1 - \alpha), (x_2 - \alpha), (x_3 - \alpha), \dots, (x_n - \alpha)]$, $j = 1, 2, 3, \dots, n$, tem-se que:

$$Y_1 = \phi_1[(x_1 - \alpha), (x_2 - \alpha), (x_3 - \alpha), \dots, (x_n - \alpha)]$$

$$Y_2 = \phi_2[(x_1 - \alpha), (x_2 - \alpha), (x_3 - \alpha), \dots, (x_n - \alpha)]$$

$$\vdots$$

$$Y_n = \phi_n[(x_1 - \alpha), (x_2 - \alpha), (x_3 - \alpha), \dots, (x_n - \alpha)]$$

Uma estatística $Y = \{Y_1, Y_2, \dots, Y_n\}$ qualquer, é ancilar se sua distribuição conjunta não depende de parâmetro, ou seja, $P(Y \leq y) = F(y)$ não depende de parâmetro.

$$P(Y \leq y) = P(Y_1, \dots, Y_n \leq y)$$

$$P(Y \leq y) = P(Y_1 \leq y, \dots, Y_n \leq y)$$

$$P(Y \leq y) = P(\phi_1[(x_1 - \alpha), \dots, (x_n - \alpha)] \leq y, \dots, \phi_n[(x_1 - \alpha), \dots, (x_n - \alpha)] \leq y)$$

$$P(Y \leq y) = P(\phi_1[(u_1 + \alpha - \alpha), \dots, (u_n + \alpha - \alpha)] \leq y, \dots, \phi_n[(u_1 + \alpha - \alpha), \dots, (u_n + \alpha - \alpha)] \leq y),$$

$$x_i = \alpha + u_i, \quad \alpha \in \mathcal{R}, \quad i = 1, \dots, n, \quad \text{por definição da família de localização}$$

$$P(Y \leq y) = P(\phi_1[(u_1), \dots, (u_n)] \leq y, \dots, \phi_n[(u_1), \dots, (u_n)] \leq y), \quad u_i = x_i - \alpha, \quad i = 1, \dots, n, \quad \alpha \in \mathcal{R}$$

$$P(Y \leq y) = P(\phi_1(U) \leq y, \dots, \phi_n(U) \leq y), \quad U = \{(u_1), \dots, (u_n)\}$$

(1) $\phi_i(U)$ é função de U e, U é um vetor de variáveis aleatória que seguem uma distribuição de probabilidade (conhecida) que não depende de parâmetro. (2) Como a distribuição de U não depende de nenhum parâmetro, ϕ_i também não dependerá de parâmetro. Como consequência de (1) e (2), $P(Y \leq y) = P(\phi_1(U) \leq y, \dots, \phi_n(U) \leq y)$ também não depende de parâmetro. Logo, o vetor $Y = (Y_1, Y_2, \dots, Y_n)$ é uma estatística ancilar.

24.2 Família escala

Suponha que X_1, \dots, X_n sejam uma amostras aleatória de uma família de escala com função distribuição $F(\frac{x}{b}), b > 0$. Se $Y_j = \phi_j(X)$, para $j = 1, 2, 3, \dots, n$, são funções do vetor aleatório $X = X_1, \dots, X_n$, invariantes por escala, isto é, $\phi_j(x_1, \dots, x_n) = \phi_j[(\frac{x_1}{b}), (\frac{x_2}{b}), (\frac{x_3}{b}), \dots, (\frac{x_n}{b})]$, $b > 0$, o vetor $Y = (Y_1, \dots, Y_n)$ é uma estatística ancilar.

Prova

Se $X = X_1, \dots, X_n$ pertence a família de escala, então existe uma variável aleatória U que não depende de nenhum parâmetro e, com função distribuição conhecida, tal que:

$$X = bU \Leftrightarrow \frac{X}{b} = U, \quad b > 0$$

$$P(X \leq x) = P(bU \leq x) = P(U \leq \frac{x}{b}) = F(\frac{x}{b})$$

Como $Y_j = \phi_j(X)$, e $\phi_j(x_1, \dots, x_n) = \phi_j[(\frac{x_1}{b}), (\frac{x_2}{b}), (\frac{x_3}{b}), \dots, (\frac{x_n}{b})]$, tem-se que:

$$\begin{aligned} Y_1 &= \phi_1 \left[\left(\frac{x_1}{b} \right), \left(\frac{x_2}{b} \right), \left(\frac{x_3}{b} \right), \dots, \left(\frac{x_n}{b} \right) \right] \\ &\vdots \\ Y_n &= \phi_n \left[\left(\frac{x_1}{b} \right), \left(\frac{x_2}{b} \right), \left(\frac{x_3}{b} \right), \dots, \left(\frac{x_n}{b} \right) \right] \end{aligned}$$

Uma estatística $Y = \{Y_1, Y_2, \dots, Y_n\}$ qualquer, é ancilar se sua distribuição conjunta não depende de parâmetro, ou seja, $P(Y \leq y) = F(y)$ não depende de parâmetro.

$$P(Y \leq y) = P(Y_1, \dots, Y_n \leq y)$$

$$P(Y \leq y) = P(Y_1 \leq y, \dots, Y_n \leq y)$$

$$P(Y \leq y) = P \left(\phi_1 \left[\left(\frac{x_1}{b} \right), \dots, \left(\frac{x_n}{b} \right) \right] \leq y, \dots, \phi_n \left[\left(\frac{x_1}{b} \right), \dots, \left(\frac{x_n}{b} \right) \right] \leq y \right)$$

$$P(Y \leq y) = P \left(\phi_1 \left[\left(\frac{bu_1}{b} \right), \dots, \left(\frac{bu_n}{b} \right) \right] \leq y, \dots, \phi_n \left[\left(\frac{bu_1}{b} \right), \dots, \left(\frac{bu_n}{b} \right) \right] \leq y \right), \quad bu_i = x_i, i = 1, \dots, n, b > 0$$

$$P(Y \leq y) = P(\phi_1[(u_1), \dots, (u_n)] \leq y, \dots, \phi_n[(u_1), \dots, (u_n)] \leq y), \quad u_i = \frac{x_i}{b}, i = 1, \dots, n, b > 0$$

$$P(Y \leq y) = P(\phi_1(U) \leq y, \dots, \phi_n(U) \leq y), \quad U = \{(u_1), \dots, (u_n)\}, \quad u_i = \frac{x_i}{b}, i = 1, \dots, n, b > 0$$

(1) $\phi_i(U)$ é função de U e, U é um vetor de variáveis aleatória que seguem uma distribuição de probabilidade (conhecida) que não depende de parâmetro. (2) Como a distribuição de U não depende de nenhum parâmetro, ϕ_i também não dependerá de parâmetro. Como consequência de (1) e (2), $P(Y \leq y) = P(\phi_1(U) \leq y, \dots, \phi_n(U) \leq y)$ também não depende de parâmetro. Logo, o vetor $Y = (Y_1, Y_2, \dots, Y_n)$ é uma estatística ancilar.

26) Seja $f : (-\infty, \infty) \rightarrow (0, \infty)$ uma função integrável. Seja $c(\theta) = 1/\int_{-\infty}^{\infty} f(x)dx$. Sejam X_1, \dots, X_n uma amostra aleatória da densidade $p_\theta(x) = c(\theta)f(x)$, para $x > \theta$, e $p_\theta(x) = 0$, caso contrário. Mostre que $X_{(1)} = \min(X_1, \dots, X_n)$ é uma estatística suficiente minimal.

Sejam X_1, \dots, X_n i.i.d. de densidade

$$p_\theta(x) = \begin{cases} c(\theta)f(x), & x \geq \theta \\ 0, & \text{c.c.} \end{cases}$$

$$\begin{aligned}
p_\theta(x) &= \prod_{i=1}^n c(\theta) f(x_i) I(x_i \geq \theta) \\
&= c(\theta)^n \prod_{i=1}^n f(x_i) I(x_i \geq \theta) \\
&= c(\theta)^n \prod_{i=1}^n f(x_i) \prod_{i=1}^n I(x_i \geq \theta) \\
&= c(\theta)^n I_{\{\min(X_1, \dots, X_n) \geq \theta\}} \prod_{i=1}^n f(x_i) \\
&= \underbrace{c(\theta)^n I_{\{X_{(1)} \geq \theta\}}}_{g_\theta(T(x))} \underbrace{\prod_{i=1}^n f(x_i)}_{h(x)}
\end{aligned}$$

Pelo teorema da fatoração temos que $T(x) = X_{(1)}$ é estatística suficiente para θ .

Temos que mostrar que $T(x)$ é estatística suficiente minimal.

Sejam $x, y \in \mathcal{X}$, $T(x) = T(y) \Leftrightarrow y \in D(x)$ onde,

$$\begin{aligned}
D(x) &= \{y = (Y_1, \dots, Y_n) \in \mathcal{X} : y_i > 0, \forall i = 1, \dots, n \\
&\text{e } P_\theta(y) = P_\theta(x) \cdot h(x, y), \forall \theta > 0 \text{ e } h(x, y) \geq 0\} \quad (\text{Teorema - Schervish}).
\end{aligned}$$

• (\Rightarrow)

$$\begin{aligned}
T(y) = T(x) &\Rightarrow Y_{(1)} = X_{(1)}, \forall \theta > 0 \\
&\Rightarrow p_\theta(y) = c(\theta)^n I_{\{Y_{(1)} \geq \theta\}} \prod_{i=1}^n f(y_i) = c(\theta)^n I_{\{X_{(1)} \geq \theta\}} \prod_{i=1}^n f(x_i) h(x, y) \\
&\Rightarrow p_\theta(y) = p_\theta(x) h(x, y), \forall \theta > 0, h(x, y) = 1 \\
&\Rightarrow \mathbf{y} \in D(x)
\end{aligned}$$

• (\Leftarrow)

$$\begin{aligned}
y \in D(x) &\Rightarrow p_\theta(y) = p_\theta(x) \cdot 1 \forall \theta > 0 \\
&\Rightarrow c(\theta)^n I_{\{Y_{(1)} \geq \theta\}} \prod_{i=1}^n f(y_i) = c(\theta)^n I_{\{X_{(1)} \geq \theta\}} \prod_{i=1}^n f(x_i) \quad (*)
\end{aligned}$$

A única forma de verificar a igualdade (*) é se os termos semelhantes forem iguais.

$$\begin{aligned}
\text{Assim, } c(\theta)^n &= c(\theta)^n, \prod_{i=1}^n f(y_i) = \prod_{i=1}^n f(x_i) \text{ e } I_{\{Y_{(1)} \geq \theta\}} = I_{\{X_{(1)} \geq \theta\}} \\
&\Rightarrow I_{\{Y_{(1)} \geq \theta\}} = I_{\{X_{(1)} \geq \theta\}} \frac{c(\theta)^n \prod_{i=1}^n f(x_i)}{c(\theta)^n \prod_{i=1}^n f(y_i)} \\
&\Rightarrow I_{\{Y_{(1)} \geq \theta\}} = I_{\{X_{(1)} \geq \theta\}} \\
&\quad T(x) = T(y)
\end{aligned}$$

Logo, $T(X) = X_{(1)} = \min(X_1, \dots, X_n)$ é uma estatística suficiente minimal.

27) Sejam $(X_1, Y_1), \dots, (X_n, Y_n)$ variáveis aleatórias bidimensionais i.i.d. com densidade $f_\theta(x, y) = 2/\theta^2$, para $x > 0, y > 0, x + y < \theta$, e $f_\theta(x, y) = 0$, caso contrário.

a) Encontre uma estatística suficiente minimal para θ .

Temos a densidade para $f_\theta(x, y)$:

$$f_\theta(x, y) = \frac{2}{\theta^2} I_{\{x>0, y>0, x+y<\theta\}}$$

$$f_\theta(x, y) = \frac{2}{\theta^2} I_{(0,\infty)}(x) I_{(0,\infty)}(y) I_{(0,\theta)}(x+y)$$

Sejam $(x_1, y_1), \dots, (x_n, y_n)$ variáveis aleatórias i.i.d. então a densidade conjunta é

$$\begin{aligned} p_\theta(x, y) &= \prod_{i=1}^n f_\theta(x_i, y_i) \\ &= \prod_{i=1}^n \frac{2}{\theta^2} I_{(0,\infty)}(x_i) I_{(0,\infty)}(y_i) I_{(0,\theta)}(x_i + y_i) \\ &= \left(\frac{2}{\theta^2}\right)^n \prod_{i=1}^n I_{(0,\theta)}(x_i + y_i) I_{(0,\infty)}(x_i) I_{(0,\infty)}(y_i) \\ &= \left(\frac{2}{\theta^2}\right)^n I_{(0,\theta)}(\max(X_1 + Y_1, \dots, X_n + Y_n)) \prod_{i=1}^n I_{(0,\infty)}(x_i) I_{(0,\infty)}(y_i) \\ &= \left(\frac{2}{\theta^2}\right)^n I_{(0,\theta)}([X + Y]_{(n)}) \prod_{i=1}^n I_{(0,\infty)}(x_i) I_{(0,\infty)}(y_i) \\ &= \underbrace{\frac{2^n}{\theta^{2n}} I_{(0,\theta)}([X + Y]_{(n)})}_{g_\theta(T(x,y))} \underbrace{\prod_{i=1}^n I_{(0,\infty)}(x_i) \prod_{i=1}^n I_{(0,\infty)}(y_i)}_{h(x,y)} \\ &= \underbrace{g_\theta([X + Y]_{(n)})}_{\text{função de } \theta} \cdot \underbrace{h(x, y)}_{\text{função de } x \text{ e } y} \end{aligned}$$

Pelo teorema da fatoração, temos que $T(x, y) = [X + Y]_{(n)} = \max(X_1 + Y_1, \dots, X_n + Y_n)$ é uma estatística suficiente para θ .

Temos que mostrar que $T(x, y)$ é estatística suficiente minimal.

Sejam $(x, y), (x', y') \in \mathcal{X}$, $T(x', y') = T(x, y) \Leftrightarrow (x', y') \in D(x, y)$ onde

$$D(x, y) = \{(x'_1, y'_1), \dots, (x'_n, y'_n)\} \in \mathcal{X} : p_\theta(x', y') = p_\theta(x, y) \cdot h((x, y), (x', y')), \forall \theta > 0\}$$

e $h((x, y), (x', y')) \geq 0$, (Teorema - Schervish)

• (\Rightarrow)

$$\begin{aligned} T(x', y') = T(x, y) &\Rightarrow (X' + Y')_{(n)} = (X + Y)_{(n)} \forall \theta > 0 \\ &\Rightarrow p_\theta(x', y') = \frac{2^n}{\theta^{2n}} I_{(0,\theta)}([X' + Y']_{(n)}) \prod_{i=1}^n I_{(0,\infty)}(x'_i) \prod_{i=1}^n I_{(0,\infty)}(y'_i) \\ &= \frac{2^n}{\theta^{2n}} I_{(0,\theta)}([X + Y]_{(n)}) \prod_{i=1}^n I_{(0,\infty)}(x_i) \prod_{i=1}^n I_{(0,\infty)}(y_i) h((x, y), (x', y')) \\ &\Rightarrow p_\theta(x', y') = p_\theta(x, y) \cdot h((x, y), (x', y')), \forall \theta > 0, h((x, y), (x', y')) = 1 \\ &\Rightarrow (x', y') \in D(x, y) \end{aligned}$$

• (\Leftarrow)

$$(\mathbf{x}', \mathbf{y}') \in D(x, y) \Rightarrow p_\theta(x', y') = p_\theta(x, y) \cdot h((x, y), (x', y')) \forall \theta > 0$$

$$\Rightarrow \frac{2^n}{\theta^{2n}} I_{(0, \theta)}((X' + Y')_{(n)}) \prod_{i=1}^n I_{(0, \infty)}(x'_i) \prod_{i=1}^n I_{(0, \infty)}(y'_i)$$

$$= \frac{2^n}{\theta^{2n}} I_{(0, \theta)}((X + Y)_{(n)}) \prod_{i=1}^n I_{(0, \infty)}(x_i) \prod_{i=1}^n I_{(0, \infty)}(y_i) \cdot 1$$

$$I_{(0, \theta)}((X' + Y')_{(n)}) \prod_{i=1}^n I_{(0, \infty)}(x'_i) \prod_{i=1}^n I_{(0, \infty)}(y'_i) = I_{(0, \theta)}((X + Y)_{(n)}) \prod_{i=1}^n I_{(0, \infty)}(x_i) \prod_{i=1}^n I_{(0, \infty)}(y_i)$$

$$\left\{ \begin{array}{l} \prod_{i=1}^n I_{(0, \infty)}(x'_i) \prod_{i=1}^n I_{(0, \infty)}(y'_i) = \prod_{i=1}^n I_{(0, \infty)}(x_i) \prod_{i=1}^n I_{(0, \infty)}(y_i) \\ I_{(0, \theta)}((X' + Y')_{(n)}) = I_{(0, \theta)}((X + Y)_{(n)}) \end{array} \right. , \quad \text{por semelhança .}$$

$$T(x', y') = T(x, y)$$

Assim $T(x, y) = [X + Y]_{(n)}$ é uma estatística suficiente minimal.

b) Encontre a distribuição da estatística suficiente minimal obtida em (a).

Temos que $T(x, y) = \max(X_1 + Y_1, \dots, X_n + Y_n)$, onde $(X_1, Y_1), \dots, (X_n, Y_n)$ são variáveis aleatórias iid com densidade

$$f_\theta(x, y) = \begin{cases} \frac{2}{\theta^2}, & x > 0, y > 0, x + y < \theta \\ 0, & \text{c.c.} \end{cases}$$

A função de distribuição acumulada é

$$F_T(t) = \mathbb{P}(T \leq t)$$

$$F_T(t) = \mathbb{P}(\max(x_1 + y_1, \dots, x_n + y_n) \leq t)$$

$$F_T(t) = \mathbb{P}(x_1 + y_1 \leq t, \dots, x_n + y_n \leq t)$$

$$F_T(t) = \prod_{i=1}^n \mathbb{P}(x_i + y_i \leq t)$$

Agora a $\mathbb{P}(x_i + y_i \leq t) = \int \int \frac{2}{\theta^2} dy dx$. Então a integral avalia a área da região definida para x e y como segue. $x + y \leq t \Rightarrow y = t - x, x > 0, y > 0$. Então $0 \leq x \leq t, 0 \leq y \leq t - x$ e $x + y \leq t$, no intervalo $t \leq \theta$.

$$\begin{aligned} \mathbb{P}(x_i + y_i \leq t) &= \frac{2}{\theta^2} \int_0^t \int_0^{t-x} dy dx = \frac{2}{\theta^2} \int_0^t y \Big|_0^{t-x} dx = \frac{2}{\theta^2} \int_0^t (t - x) dx \\ &= \frac{2}{\theta^2} \left(tx - \frac{x^2}{2} \right) \Big|_0^t = \frac{2}{\theta^2} \left(t^2 - \frac{t^2}{2} \right) = \frac{t^2}{\theta^2} = \left(\frac{t}{\theta} \right)^2, \quad \text{para } t \leq \theta. \end{aligned}$$

Então a função acumulada é

$$F_1(t) = \prod_{i=1}^n \left(\frac{t}{\theta} \right)^2 = \left[\left(\frac{t}{\theta} \right)^2 \right]^n = \left(\frac{t}{\theta} \right)^{2n}, \quad \text{para } t \leq \theta$$

E a função de densidade serão

$$f_T(t) = \frac{dF_T(t)}{dt} = \frac{d}{dt} \left(\frac{t}{\theta} \right)^{2n} = \frac{2n}{\theta^{2n}} \cdot t^{2n-1}, \quad \text{para } 0 < t < \theta.$$

32 Estatística suficiente completa se o espaço paramétrico é Ω , mas apenas suficiente (e não completa) se o espaço paramétrico é $\Omega_0 \subset \Omega$. Sejam X_1, X_2, \dots, X_n (com $n \geq 2$) variáveis aleatórias independentes com distribuição $U(0, \theta)$, onde $\theta \in \Omega = (0, +\infty)$. Sabemos que $X_{(n)} = \max(X_1, X_2, \dots, X_n)$ é uma estatística suficiente completa para θ quando o espaço paramétrico é Ω . Considere agora que o espaço paramétrico é $\Omega_0 = [1, +\infty)$. Mostre que $X_{(n)}$ é suficiente, mas não é completa para θ em Ω_0 .

Resolução Suficiência

Uma estatística $T(x)$ é suficiente para um θ , se contém toda informação do parâmetro e a distribuição de X dado $T(x)$ não depende do parâmetro θ .

Critério de Fatoração (C.F): A condição necessária e suficiente para $T(x)$ ser suficiente para o parâmetro θ é que existam funções $g_\theta[T(x)] \geq 0$ e $h(x) \geq 0$, tal que: $p_\theta(x) = g_\theta[T(x)]h(x)$.

Por definição, se $X \sim U(a, b)$, tem-se: $f(x) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & c.c \end{cases}$. Como, $a = 0$ e $b = \theta$, tem-se:

$$f(X = x; \theta) = \begin{cases} \frac{1}{\theta}, & 0 < x < \theta, \theta \in [1, +\infty) \\ 0, & c.c \end{cases} \text{ . Seja, } X = X_1, \dots, X_n, \text{ tomando a parte não nula,}$$

$$f(X_1, \dots, X_n; \theta) = f(X_1; \theta) \dots f(X_n; \theta) = \prod_{i=1}^n f(X_i; \theta), \text{ porque } X \text{ são iid.}$$

$$f(X; \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{\{0 < x < \theta\}} = \frac{1}{\theta^n} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \theta\}}, \quad X_{(1)} = \min(X_1, \dots, X_n), X_{(n)} = \max(X_1, \dots, X_n)$$

$$f(X; \theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{\{0 < x < \theta\}} = \frac{1}{\theta^n} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \theta\}}, \quad X_{(1)} = \min(X_1, \dots, X_n), X_{(n)} = \max(X_1, \dots, X_n)$$

$$f(X; \theta) = \underbrace{\frac{1}{\theta^n} \mathbb{I}_{\{X_{(n)} < \theta\}}}_{g_\theta[T(x)]} \underbrace{\mathbb{I}_{\{X_{(1)} > 0\}}}_{h(x)}, \quad \theta \in [1; +\infty]$$

Como $g_\theta[T(x)] = \frac{1}{\theta^n} \mathbb{I}_{\{X_{(n)} < \theta\}} > 0$ e $h(x) = \mathbb{I}_{\{X_{(1)} > 0\}} > 0$, pelo C.F, $T(x) = X_{(n)}$, para $X_{(n)} = \max(X_1, \dots, X_n)$, é uma estatística suficiente.

Completividade

Seja $T(x)$ uma estatística suficiente para um parâmetro θ . $T(x)$ é completa para θ se:

a) $E_\theta [g(T(x))] = 0, \forall \theta \in \Omega_0 \Rightarrow g[T(x)] = 0$

b) $P([g(T(x))] = 0] = 1$

$$E_\theta [g(T(x))] = \int_{S(x)} g[T(x)] f_{T(x)}(x) dx = 0, \quad S(x) \text{ é suporte de } x$$

$$f_{T(x)}(x) = \frac{\partial F_{T(x)}(x)}{dx}, \quad \text{por definição}$$

$$P(T(x) \leq x) = P(X_{(n)} \leq x), \quad T(x) = X_{(n)}$$

$$P(X_{(n)} \leq x) = P(\max(X_1, \dots, X_n \leq x))$$

$$P(X_{(n)} \leq x) = P(X_1 \leq x, \dots, X_n \leq x)$$

$$P(X_{(n)} \leq x) = P(X_1 \leq x) \cdot \dots \cdot P(X_n \leq x), \quad \text{prop. de independência}$$

$$P(X_{(n)} \leq x) = F(x) \cdot \dots \cdot F(x), \quad \text{porque } X \text{ são iid.}$$

$$P(X_{(n)} \leq x) = [F(x)]^n$$

$$P(X_{(n)} \leq x) = F_{X_{(n)}}(x) = [F(x)]^n$$

$$F(x) = \int_0^x f(X; \theta) dx = \int_0^x \frac{1}{\theta} dx = \frac{x}{\theta}, \quad 0 < x < \theta, \theta \in [1, +\infty)$$

$$F_{X_{(n)}}(x) = [F(x)]^n$$

$$F_{X_{(n)}}(x) = \left[\frac{x}{\theta} \right]^n, \quad 0 < x < \theta, \theta \in [1, +\infty)$$

$$f_{T(x)}(x) = f_{X_{(n)}}(x) = \frac{\partial F_{X_{(n)}}(x)}{dx} = \frac{\partial [F(x)]^n}{dx} = n \left(\frac{x}{\theta} \right)^{n-1} F'(x)$$

$$f_{T(x)}(x) = n \frac{x^{n-1}}{\theta^{n-1}} f(x) = n \frac{x^{n-1}}{\theta^{n-1}} \cdot \frac{1}{\theta}, \quad F'(x) = f(x) \text{ por definição}$$

$$f_{T(x)}(x) = \frac{n \cdot x^{n-1}}{\theta^n}, \quad 0 < x < \theta, \theta \in [1, +\infty)$$

$$E_{\theta} [g(T(x))] = \int_{S(x)} g [T(x)] f_{T(x)}(x) dx = 0, \quad S(x) = (0, \theta), \quad \theta \in [1, +\infty)$$

$$E_{\theta} [g(T(x))] = \int_0^{\theta} g [T(x)] \frac{n \cdot x^{n-1}}{\theta^n} dx = \frac{n}{\theta^n} \int_0^{\theta} g [T(x)] x^{n-1} dx = 0, \quad (*)$$

$$\frac{\partial \int_{k(x)}^{p(x)} L(t) dt}{\partial x} = L [p(x)] \cdot p'(x) - L [k(x)] \cdot k'(x), \quad \text{teor. fund. de cálculo (**)}$$

$$\frac{\frac{\partial}{\partial \theta} \int_0^{\theta} g [T(x)] x^{n-1} dx}{\partial \theta} = \frac{\partial \theta}{\partial \theta}, \quad \text{derivando ambos lados do (*)}$$

$$\frac{n \cdot \partial \theta^{-n}}{\partial \theta} \int_0^{\theta} g [T(x)] x^{n-1} dx + \frac{\partial \int_0^{\theta} g [T(x)] x^{n-1} dx}{\partial \theta} \cdot \frac{n}{\theta^n} = 0, \quad \text{derivada do produto}$$

$$-n^2 \cdot \theta^{-n-1} \int_0^{\theta} g [T(x)] x^{n-1} dx + \underbrace{g(\theta) \theta^{n-1} \cdot \frac{n}{\theta^n}}_{\text{aplicando (**)}} = 0$$

$$g(\theta) \theta^{n-1} \cdot \frac{n}{\theta^n} - \frac{n^2}{\theta^{n+1}} \cdot \int_0^{\theta} g [T(x)] x^{n-1} dx = 0$$

$$g(\theta) \theta^{n-1} \cdot \frac{n}{\theta^n} - \frac{n^2}{\theta^{n+1}} \cdot \int_0^{\theta} g [T(x)] x^{n-1} dx = 0$$

$$g(\theta) \cdot \frac{n}{\theta} - \frac{n}{\theta} \cdot \underbrace{\frac{n}{\theta^n} \int_0^{\theta} g [T(x)] x^{n-1} dx}_{E_{\theta} [g(T(x))]} = 0, \quad \text{ver (*)}$$

$$g(\theta) \cdot \frac{n}{\theta} - \frac{n}{\theta} \cdot E_{\theta} [g(T(x))] = 0$$

$$\cancel{\frac{n}{\theta}} \cdot E_{\theta} [g(T(x))] = \cancel{\frac{n}{\theta}} g(\theta)$$

$$E_{\theta} [g(T(x))] = g(\theta) \quad \text{a) sugere } E_{\theta} [g(T(x))] = 0, \text{ o que remete a } g(\theta) = 0$$

$$E_{\theta} [g(T(x))] = 0, \quad g(\theta) = 0, \quad \forall \theta \in [1; +\infty)$$

O fato de $E_{\theta} [g(T(x))] = 0, \forall \theta \in [1; +\infty)$ e $g(\theta) = 0$, não garante que $g[T(x)]$ seja sempre nulo, quase certamente, conforme apresentado abaixo.

A função $g[T(x)]$ é uma função genérica qualquer, escrita em função da estatística suficiente $T(x)$. Seja $g[T(x)]$, dado por:

$$g [T(x)] = \begin{cases} X_{(n)} - \frac{n\theta}{n+1}, & \text{se } 0 < X_{(n)} < \theta, \quad \theta \in [1; +\infty) \\ 0, & \text{c.c.} \end{cases}$$

Dizer $T(x) = X_{(n)} = \max(X_1, \dots, X_n)$, é o mesmo que dizer que $T(x)$ é um x , no entanto, o maior x dentre os n existentes. Isto é, $X_{(n)} = x$. Assim, pode-se rescrever $g [T(x)]$, do seguinte modo.

$$g [T(x)] = \begin{cases} x - \frac{n\theta}{n+1}, & \text{se } 0 < x < \theta, \quad \theta \in [1; +\infty) \\ 0, & \text{c.c.} \end{cases}$$

$$\mathbb{E} (g [T(x)]) = \int_0^{\theta} g [T(x)] f_{X_{(n)}}(x) dx,$$

$$\begin{aligned}
\mathbb{E}(g[T(x)]) &= \int_0^\theta \left(x - \frac{n\theta}{n+1}\right) \cdot n \frac{x^{n-1}}{\theta^n} dx = \int_0^\theta x \cdot n \cdot \frac{x^{n-1}}{\theta^n} dx - \int_0^\theta \frac{n\theta}{n+1} \cdot n \cdot \frac{x^{n-1}}{\theta^n} dx \\
\mathbb{E}(g[T(x)]) &= \frac{n}{\theta^n} \int_0^\theta x^n dx - \frac{n^2\theta}{n+1} \cdot \frac{1}{\theta^n} \int_0^\theta x^{n-1} dx \\
\mathbb{E}(g[T(x)]) &= \frac{n}{\theta^n} \frac{x^{n+1}}{(n+1)} \Big|_0^\theta - \frac{n^2\theta}{n+1} \cdot \frac{1}{\theta^n} \cdot \frac{x^n}{n} \Big|_0^\theta \\
\mathbb{E}(g[T(x)]) &= \frac{n}{\theta^n} \frac{\theta^{n+1}}{(n+1)} - \frac{n^2\theta}{n+1} \cdot \frac{1}{\theta^n} \cdot \frac{\theta^n}{n} \\
\mathbb{E}(g[T(x)]) &= \frac{n}{\theta^n} \frac{\theta^{n+1}}{(n+1)} - \frac{n \cdot \theta}{n+1} \\
\mathbb{E}(g[T(x)]) &= \frac{n \cdot \theta}{n+1} - \frac{n \cdot \theta}{n+1} \\
\mathbb{E}(g[T(x)]) &= 0
\end{aligned}$$

Como se pode observar, $\mathbb{E}(g[T(x)]) = 0$, mas $g[T(x)] \neq 0$. Logo $g[T(x)]$ não é zero quase certamente, isto é, $P([g(T(x))] = 0] \neq 1$, como consequência, $T(x) = X_{(n)}$ não é completa.

37) Use o Teorema de Basu para provar a independência dos seguintes pares de estatísticas:

b) $X_{(1)}$ e $P(X_i - X_{(1)})$, onde os X_i 's são iid com distribuição $E(a, b)$.

Primeiramente vamos mostrar que $X_{(1)}$ é suficiente e completa. Observe que, para $a > 0$ e um valor arbitrário de $b > 0$ fixado, temos

$$\begin{aligned}
f(x, a, b) &= \prod_{i=1}^n \frac{1}{b} \exp\left\{-\frac{1}{b}(x_i - a)\right\} I(x_i > a) \\
&= \frac{1}{b^n} \exp\left\{-\frac{1}{b} \sum_{i=1}^n (x_i - a)\right\} I(x_{(1)} > a), \quad x_{(1)} = \min(X_1, \dots, X_n) \\
&= \frac{1}{b^n} \exp\left\{-\frac{1}{b} \sum_{i=1}^n x_i\right\} \exp\left\{\frac{na}{b}\right\} I(x_{(1)} > a) \\
&= h(x) g_a(T(x)),
\end{aligned}$$

em que $h(x) = \frac{1}{b^n} \exp\left\{-\frac{1}{b} \sum_{i=1}^n x_i\right\}$ e $g_a(T(x)) = \exp\left\{\frac{na}{b}\right\} I(x_{(1)} > a)$. Assim, pelo Critério da Fatoração $T = X_{(1)} = \min(X_1, \dots, X_n)$ é uma estatística suficiente para $\theta = a$.

Para mostrar que $T = X_{(1)}$ é completa, temos que, dado

$$\begin{aligned}
P(X_{(1)} \geq x) &= \int_x^\infty \frac{1}{b} \exp\left\{-\frac{t-a}{b}\right\} dt = \exp\left\{\frac{a}{b}\right\} \int_x^\infty \frac{1}{b} \exp\left\{-\frac{t}{b}\right\} dt \\
&= \exp\left\{\frac{a}{b}\right\} \exp\left\{-\frac{x}{b}\right\} = \exp\left\{\frac{a-x}{b}\right\}
\end{aligned}$$

Logo,

$$\begin{aligned}
P(X_{(1)} \leq x) &= P(\min\{X_1, \dots, X_n\} \leq x) = 1 - P(\min\{X_1, \dots, X_n\} > x) \\
&= 1 - P(X_{(1)} > x) = 1 - [P(X_1 > x)]^n = 1 - \exp\left\{n \frac{a-x}{b}\right\}
\end{aligned}$$

para $x > 0$ e 0 caso contrário. Assim

$$P(X_{(1)} = x) = \frac{n}{b} \exp\left\{n \frac{a-x}{b}\right\} I(x > a)$$

Desse modo,

$$\begin{aligned} E[g(T)] &= \int_a^\infty g(t) \frac{n}{b} \exp\left\{n \frac{a-t}{b}\right\} dt = 0, \quad \forall a > 0 \\ \int_a^\infty g(t) \exp\left\{\frac{-nt}{b}\right\} dt &= 0, \quad \forall a > 0 \end{aligned}$$

Pelo Teorema Fundamental do Calculo, temos

$$\left[\lim_{h \rightarrow \infty} H(n) - H(a) \right] = \frac{\partial}{\partial a} \left[\lim_{h \rightarrow \infty} H(n) - H(a) \right] = g(a) \exp\left\{\frac{-na}{b}\right\}$$

Observe que $\frac{\partial}{\partial a} [\lim_{h \rightarrow \infty} H(n)] = \lim_{h \rightarrow \infty} [\frac{\partial}{\partial a} H(n)] = \lim_{h \rightarrow \infty} [g(n) \exp\{\frac{-nh}{b}\}] = 0$.

Assim,

$$\begin{aligned} g(a) \exp\left\{\frac{-na}{b}\right\} &= 0, \quad \forall a \\ g(a) &= 0, \quad \forall a \\ g(t) &= 0, \quad \forall t \end{aligned}$$

Portanto, $P_a(g(t) = 0) = 1$. Logo, $T = X_{(1)}$ é completa.

Além disso, para $U = (U_1, \dots, U_n)$, tal que U_i 's, com $i = 1, \dots, n$, são independentes com distribuição $E(0, b)$. Pode-se escrever X_i como $X_i = U_i + a$, $i = 1, \dots, n$ e $a > 0$. Com $X_{(1)} = U_{(1)} + a$, $a > 0$. Desse modo, a distribuição de $Y_i = X_i - X_{(1)}$, $i = 1, \dots, n$ é tal que

$$P(Y_i \leq y_i) = P(X_i - X_{(1)} \leq y_i) = P(U_i + a - (U_{(1)} + a) \leq y_i) = P(U_i - U_{(1)} \leq y_i)$$

que, pela invariância de localização, não depende de a . Portanto, $Y_i = X_i - X_{(1)}$, $i = 1, \dots, n$ é ancilar. Dado que X_i 's são iid, então $S = \sum_{i=1}^n X_i - X_{(1)}$ também é ancilar.

Pelo Teorema de Basu, se T é uma estatística suficiente e completa para $P = \{P_\theta, \theta \in \Theta\}$, então toda estatística ancilar S é independente de T . Assim, provamos que $X_{(1)}$ e $P(X_i - X_{(1)})$ são independentes.