

UNIVERSIDADE DE SÃO PAULO
Programa de Post-Graduação em Estatística

Katerine Zuniga Lastra, Marília de Melo Sombra, Alex Monito Nhancololo

Lista 02 – Semestre de 2024-II – Prof. Silvia Ferrari

- 3) Sejam X_1, \dots, X_n variáveis aleatórias independentes com $X_i \sim N(m_i\mu, m_i\sigma^2)$, para $i = 1, \dots, n$, em que m_1, \dots, m_n são inteiros positivos conhecidos, e $\mu \in \mathbb{R}$ e $\sigma^2 > 0$ são desconhecidos. Essa situação ocorre quando se observam os totais de n grupos, em que o i -ésimo grupo é formado de m_i observações independentes de $N(\mu, \sigma^2)$. Encontre os estimadores não viesados de variância uniformemente mínima de μ e σ^2 .

Obs. Na resolução de este exercício, considera-se $\mu \in \mathbb{R}$, $\sigma^2 > 0$, $m_i \in \mathbb{N}^*$ e $n > 0$.

Resolução

$$\begin{aligned} f(x; m_i\mu, m_i\sigma^2) &= \frac{1}{\sqrt{2\pi m_i\sigma^2}} \exp \left\{ -\frac{(x - m_i\mu)^2}{2m_i\sigma^2} \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \frac{1}{\sqrt{m_i\sigma^2}} \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{x_i^2 - 2x_i m_i\mu + m_i^2\mu^2}{2m_i\sigma^2} \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \exp \left\{ \log \left(\frac{1}{\sqrt{m_i\sigma^2}} \right) \right\} \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{x_i^2}{2m_i\sigma^2} + \frac{2x_i m_i\mu}{2m_i\sigma^2} - \frac{m_i^2\mu^2}{2m_i\sigma^2} \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \exp \left\{ -\log \left(\sqrt{m_i\sigma^2} \right) \right\} \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{x_i^2}{2m_i\sigma^2} + \frac{x_i\mu}{\sigma^2} - \frac{m_i\mu^2}{2\sigma^2} \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{x_i^2}{2m_i\sigma^2} + \frac{x_i\mu}{\sigma^2} - \frac{m_i\mu^2}{2\sigma^2} - \log \left(\sqrt{m_i\sigma^2} \right) \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{x_i^2}{2m_i\sigma^2} + \frac{x_i\mu}{\sigma^2} - \frac{m_i\mu^2}{2\sigma^2} - \log \left(\sqrt{m_i\sigma^2} \right) \right\} \\ f(x; m_i\mu, m_i\sigma^2) &= \underbrace{\frac{1}{\sqrt{2\pi}}}_{h(x)} \exp \left\{ \underbrace{-\frac{x_i^2}{2m_i\sigma^2} + \frac{x_i\mu}{\sigma^2}}_{\eta_i T(x)} - \underbrace{\left(\frac{m_i\mu^2}{2\sigma^2} + \log \left(\sqrt{m_i\sigma^2} \right) \right)}_{A(\eta)} \right\} \end{aligned}$$

Logo, $f(x; m_i\mu, m_i\sigma^2)$ pertence à família exponencial. Para encontrar o ENVVUM de μ , σ^2 terá de ser fixado e, para encontrar o ENVVUM de σ^2 , μ terá de ser fixado. Ou seja, $f(x; m_i\mu, m_i\sigma^2)$ para apenas σ^2 fixado pertencerá à família exponencial uniparamétrica, idem para apenas μ fixado. Pelo teorema de limite inferior de Cramér-Rao (LICR), se $f(\cdot)$ pertence à família exponencial uniparamétrica, então, existe uma estatística $g(x)$ não viesada cuja variância é igual ao limite inferior de Cramér-Rao e, essa estatística é um ENVVUM.

Atingindo o LICR, e satisfazendo todas as suas condições de regularidade, tem-se pela desigualdade de Cauchy-Schwarz, que, $g(x) - \tau(\theta)$ e $\frac{\partial}{\partial \tau(\theta)} \log L(\tau(\theta)|x)$ são proporcionais, sendo $L(\cdot)$ a função de verossimilhança de $f(\cdot)$ e $g(x)$ ENVVUM do parâmetro (função) $\tau(\theta)$. Ou seja,

$$\frac{\partial}{\partial \tau(\theta)} \log L(\tau(\theta)|x) = a(\theta) [g(x) - \tau(\theta)] \quad (1)$$

Se $f(\cdot)$ atinge o LICR, e o estimador de máxima verossimilhança (MV) $\hat{\tau}(\theta)_{MV}$, poder ser encontrado analiticamente (sem precisar de algum método numérico), tem-se:

$$Var[g(x)] = \frac{1}{a(\theta)} \text{ e, substituindo na (1), } \frac{\partial}{\partial \tau(\theta)} \log L(\tau(\theta)|x) = \frac{1}{Var[g(x)]} [g(x) - \tau(\theta)] \quad (2)$$

\Rightarrow Encontrando ENVVUM de μ

Seja $\tau(\theta) = \mu$ e $X = \{X_1, X_2, \dots, X_n\}$, vamos verificar se o $\hat{\mu}_{MV}$ pode ser encontrado analiticamente.

$$f(X; m_i \mu, m_i \sigma^2) = L(\mu, \sigma^2 | X) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi m_i \sigma^2}} \exp \left\{ -\frac{(x_i - m_i \mu)^2}{2 m_i \sigma^2} \right\}, \quad X_i \text{ são iid}$$

$$L(\mu, \sigma^2 | X) = \left(\frac{1}{\sqrt{2\pi m_i \sigma^2}} \right)^n \exp \left\{ \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)^2}{2 m_i \sigma^2} \right) \right\}$$

$$\ell(\mu, \sigma^2) = \log \left[\left(\frac{1}{\sqrt{2\pi m_i \sigma^2}} \right)^n \exp \left\{ \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)^2}{2 m_i \sigma^2} \right) \right\} \right]$$

$$\ell(\mu, \sigma^2) = \log \left[\left(\frac{1}{\sqrt{2\pi m_i \sigma^2}} \right)^n \right] + \log \left[\exp \left\{ \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)^2}{2 m_i \sigma^2} \right) \right\} \right]$$

$$\ell(\mu, \sigma^2) = -n \log \left(\sqrt{2\pi m_i \sigma^2} \right) + \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)^2}{2 m_i \sigma^2} \right) \quad (*)$$

\Rightarrow Procurando estimador de MV de μ

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)}{m_i \sigma^2} \cdot (-m_i) \right), \quad \sigma^2 \text{ é fixo}$$

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \frac{\sum_{i=1}^n (x_i - m_i \mu)}{\sigma^2} = \frac{\sum_{i=1}^n x_i - \sum_{i=1}^n m_i \mu}{\sigma^2} = \frac{\sum_{i=1}^n x_i - \mu \sum_{i=1}^n m_i}{\sigma^2}, \quad (**)$$

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = 0$$

$$\frac{\sum_{i=1}^n x_i - \mu \sum_{i=1}^n m_i}{\sigma^2} = 0, \quad \Leftrightarrow \sum_{i=1}^n x_i - \mu \sum_{i=1}^n m_i = 0 \Leftrightarrow \mu \sum_{i=1}^n m_i = \sum_{i=1}^n x_i$$

$$\hat{\mu}_{MV} = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i}, \quad \text{porque, } \frac{\partial^2}{\partial \mu^2} = -\sum_{i=1}^n m_i < 0$$

Note que $\hat{\mu}_{MV}$ não depende de μ , logo é estimável analiticamente e podemos usar (2) para encontrar o ENVVUM, aqui denotado por $g(x)$.

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \frac{1}{Var[g(x)]} [g(x) - \tau(\theta)]$$

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \frac{\sum_{i=1}^n x_i - \mu \sum_{i=1}^n m_i}{\sigma^2} \times \frac{\frac{1}{\sum_{i=1}^n m_i}}{\frac{1}{\sum_{i=1}^n m_i}}, \quad \text{vide (**)}$$

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \frac{\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} - \mu}{\frac{\sigma^2}{\sum_{i=1}^n m_i}}$$

$$\frac{\partial}{\partial \mu} \ell(\mu, \sigma^2) = \frac{\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} - \mu}{\frac{\sigma^2}{\sum_{i=1}^n m_i}} = \frac{1}{\frac{\sigma^2}{\sum_{i=1}^n m_i}} \left[\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} - \mu \right] = \frac{1}{Var[g(x)]} [g(x) - \tau(\theta)]$$

Logo, $g(x) = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i}$ é um ENVVUM de μ e $Var[g(x)] = \frac{\sigma^2}{\sum_{i=1}^n m_i} = LICR$, porque $f(\cdot)$ para σ^2 fixo, pertence à família exponencial uniparamétrica.

Assim, $g(x) \sim N\left(\mu, \frac{\sigma^2}{\sum_{i=1}^n m_i}\right)$

\Rightarrow Encontrando ENVVUM de σ^2 , tomando μ como fixo

$$\ell(\mu, \sigma^2) = -n \log \left(\sqrt{2\pi m_i \sigma^2} \right) + \sum_{i=1}^n \left(-\frac{(x_i - m_i \mu)^2}{2m_i \sigma^2} \right) \quad \text{vide } (*)$$

$$\ell(\mu, \sigma^2) = -n \log \left(\sqrt{2\pi m_i} \right) - n \log \left(\sqrt{\sigma^2} \right) - \frac{1}{\sigma^2} \sum_{i=1}^n \left(\frac{(x_i - m_i \mu)^2}{2m_i} \right)$$

$$\ell(\mu, \sigma^2) = -n \log \left(\sqrt{2\pi m_i} \right) - \frac{n}{2} \log (\sigma^2) - \frac{1}{\sigma^2} \sum_{i=1}^n \left(\frac{(x_i - m_i \mu)^2}{2m_i} \right)$$

\Rightarrow Procurando estimador de MV de σ^2

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = -\frac{n}{2\sigma^2} + \frac{1}{\sigma^4} \sum_{i=1}^n \left(\frac{(x_i - m_i \mu)^2}{2m_i} \right)$$

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = 0$$

$$-\frac{n}{2\hat{\sigma}^2} + \frac{1}{\hat{\sigma}^4} \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right) = 0$$

$$\frac{1}{\hat{\sigma}^4} \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right) = \frac{n}{2\hat{\sigma}^2}$$

$$\frac{n}{2\hat{\sigma}^2} = \frac{1}{\hat{\sigma}^4} \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right)$$

$$\frac{n\hat{\sigma}^4}{2\hat{\sigma}^2} = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right)$$

$$\frac{n\hat{\sigma}^2}{2} = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right)$$

$$\hat{\sigma}^2 = \frac{2}{n} \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right)$$

$$\hat{\sigma}^2 = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{n m_i} \right)$$

Observe que $\hat{\sigma}^2 = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{n m_i} \right)$ em posse de toda população não é viesado, mas para caso amostral é viesado, sendo necessário corrigir por $n-1$, análogo à variância amostral. Assim,

$$\hat{\sigma}_{MV}^2 = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right), \quad \text{porque } \frac{\partial^2}{\partial (\sigma^2)^2} \ell(\mu, \sigma^2) < 0$$

Note que $\hat{\sigma}_{MV}^2$ não depende de σ^2 , logo $\tau^*(\theta) = \sigma^2$ é estimável analiticamente e podemos usar (2) para encontrar o ENVVUM, aqui denotado por $g^*(x)$.

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = \frac{1}{Var[g^*(x)]} [g^*(x) - \tau^*(\theta)]$$

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = -\frac{(n-1)}{2\sigma^2} + \frac{1}{\sigma^4} \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{2m_i} \right)$$

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = \frac{\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{m_i} \right) - (n-1)\sigma^2}{2\sigma^4} \times \frac{\frac{1}{n-1}}{\frac{1}{n-1}}$$

$$\frac{\partial}{\partial \sigma^2} \ell(\mu, \sigma^2) = \frac{\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) - \sigma^2}{\frac{2\sigma^4}{n-1}} = \frac{1}{\frac{2\sigma^4}{n-1}} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) - \sigma^2 \right] = \frac{1}{Var[g^*(x)]} [g^*(x) - \tau^*(\theta)]$$

Logo, $g^*(x) = \sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right)$ é um ENVVUM de σ^2 , lembrando que $\hat{\mu}_{MV} = g(x) = \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i}$ e $Var[g^*(x)] = \frac{2\sigma^4}{n-1} = LICR$, porque $f(\cdot)$ para μ fixo, pertence à família exponencial uniparamétrica. Assim, $g^*(x) \sim \chi_{(n-1)}^2$.

\implies Verificando a não viesidade de $g^*(x)$

$$\begin{aligned} \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sum_{i=1}^n \frac{1}{(n-1)m_i} \mathbb{E}[(x_i - m_i \hat{\mu}_{MV})^2] = \sum_{i=1}^n \frac{1}{(n-1)m_i} \mathbb{E} \left[\left(x_i - m_i \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} \right)^2 \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sum_{i=1}^n \frac{1}{(n-1)m_i} \left[Var \left(x_i - m_i \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} \right) + \mathbb{E}^2 \left(x_i - m_i \frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} \right) \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sum_{i=1}^n \frac{1}{(n-1)m_i} \left[Var(x_i) - m_i^2 Var \left(\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} \right) + \left[\mathbb{E}(x_i) - m_i \mathbb{E} \left(\frac{\sum_{i=1}^n x_i}{\sum_{i=1}^n m_i} \right) \right]^2 \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sum_{i=1}^n \frac{1}{(n-1)m_i} \left[m_i \sigma^2 - m_i^2 \frac{\sigma^2}{\sum_{i=1}^n m_i} + \mathbb{E}[m_i \mu - m_i \mu]^2 \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sum_{i=1}^n \frac{1}{(n-1)} \left[\sigma^2 - m_i \frac{\sigma^2}{\sum_{i=1}^n m_i} \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \frac{1}{(n-1)} \left[\sum_{i=1}^n \sigma^2 - \sum_{i=1}^n m_i \frac{\sigma^2}{\sum_{i=1}^n m_i} \right] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \frac{1}{(n-1)} [n\sigma^2 - \sigma^2] \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \frac{1}{(n-1)} (n-1)\sigma^2 \\ \mathbb{E} \left[\sum_{i=1}^n \left(\frac{(x_i - m_i \hat{\mu}_{MV})^2}{(n-1)m_i} \right) \right] &= \sigma^2 \end{aligned}$$

$g^*(x)$ não é viesado, para σ^2 . Como $f(\cdot)$ fixando μ é da família exponencial uniparamétrica, e $g^*(x)$ é função de uma estatística suficiente completa $T(x) = x^2$, $g^*(x)$ é ENVVUM de σ^2 pelo teorema de Lehmann-Scheffé.

7) Seja X o conjunto dos números naturais, i.e. $X = \{0, 1, 2, 3, \dots\}$, e $A \subset X$, não vazio. Suponha que X tem distribuição de Poisson de parâmetro λ truncada em A , ou seja, a distribuição de X coincide com a distribuição de Y condicional a que $Y \in A$, sendo que $Y \sim \text{Poisson}(\lambda)$.

a) Suponha que $A = \{0, 1, 2, \dots, a\}$, em que a é um inteiro positivo. Mostre que λ não tem um estimador não viciado.

Resolução

$$\begin{aligned} f(Y = x | Y \in A; \lambda) &= \frac{\frac{\lambda^x e^{-\lambda}}{x!}}{P(y \leq a)} = \frac{\frac{\lambda^x e^{-\lambda}}{x!}}{\sum_{y=0}^a \frac{\lambda^y e^{-\lambda}}{y!}} = \frac{\lambda^x e^{-\lambda}}{x! e^{-\lambda} \sum_{y=0}^a \frac{\lambda^y}{y!}} = \frac{\lambda^x}{x! \sum_{y=0}^a \frac{\lambda^y}{y!}} \\ f(Y = x | Y \in A; \lambda) &= \begin{cases} \frac{\lambda^x}{x! \sum_{y=0}^a \frac{\lambda^y}{y!}}, & \text{se } x, y \in \{0, 1, 2, \dots, a\} \\ 0, & \text{caso contrário} \end{cases} \end{aligned}$$

O intervalo de valores onde a função $f(\cdot)$ é não negativa, depende de parâmetro, logo, $f(\cdot)$ não pertence à família exponencial e como consequência, não se pode usar o LICR, Rao-Blackwell e nem o teorema de Lehmann-Scheffé, podendo apenas provar pela definição $\mathbb{E}[g(x)] = \lambda$.

Obs. Na resolução que segue considera-se $\lambda > 0, a \geq 0$.

$$\begin{aligned}
\mathbb{E}[g(x)] &= \lambda \\
\sum_{x=0}^a \left\{ g(x) \left[\frac{\lambda^x}{x! \sum_{y=0}^a \frac{\lambda^y}{y!}} \right] \right\} &= \lambda \\
\sum_{k=0}^a \left\{ g(x) \cdot \frac{\lambda^x e^{-\lambda}}{x! \sum_{y=0}^a \frac{\lambda^y e^{-\lambda}}{y!}} \right\} &= \lambda \\
\frac{1}{\sum_{y=0}^a \frac{\lambda^y e^{-\lambda}}{y!}} \sum_{x=0}^a g(x) \cdot \frac{\lambda^x e^{-\lambda}}{x!} &= \lambda \\
\sum_{x=0}^a g(x) \cdot \frac{\lambda^x}{\lambda x!} &= \sum_{y=0}^a \frac{\lambda^y}{y!} \\
\sum_{x=0}^a g(x) \cdot \frac{\lambda^{x-1}}{x!} &= \left(\sum_{y=0}^{a-1} \frac{\lambda^y}{y!} \right) + \frac{\lambda^a}{a!} \\
\sum_{x=0}^a g(x) \cdot \frac{\lambda^{x-1}}{x!} &= \left(\sum_{y=0}^{a-1} \frac{\lambda^y}{y!} \right) + \frac{\lambda^a}{a!} \\
g(0) \cdot \frac{\lambda^{-1}}{0!} + g(1) \cdot \frac{\lambda^0}{1!} + g(2) \cdot \frac{\lambda^1}{2!} + \dots + g(a) \cdot \frac{\lambda^{a-1}}{a!} &= \frac{\lambda^0}{0!} + \frac{\lambda^1}{1!} + \dots + \frac{\lambda^{a-1}}{(a-1)!} + \frac{\lambda^a}{a!} \\
g(0) \cdot \lambda^{-1} + g(1) + g(2) \cdot \frac{\lambda}{2} + \dots + g(a) \cdot \frac{\lambda^{a-1}}{a!} &= 1 + \lambda + \dots + \frac{\lambda^{a-1}}{(a-1)!} + \frac{\lambda^a}{a!}
\end{aligned}$$

Tomando como referência o λ , todos termos com mesmo grau de λ são considerados semelhantes.

$$\begin{cases} g(0) \cdot \lambda^{-1} &= 0 \implies g(0) = 0 \\ g(1) &= 1 \\ g(2) \cdot \frac{\lambda}{2} &= \lambda \\ \dots &= \dots \\ g(a) \cdot \frac{\lambda^{a-1}}{a!} &= \frac{\lambda^{a-1}}{(a-1)!} \\ 0 &= \frac{\lambda^a}{a!} \iff 0 = 1 \quad \text{se } a = \min\{A\} = 0 \end{cases}$$

Como se sabe, é impossível um (1) ser igual a zero (0), pois, um (1) é sucessor de zero (0). Não só, considerando qualquer "a" maior que zero e finito ($0 < a < \infty$), como $\lambda > 0$, a expressão $\frac{\lambda^a}{a!} \neq 0$. Logo, com esta esplanção provamos que não existe um estimador $g(x)$ não viesado (viciado) para λ .

b) Suponha que $A = \{1, 2, 3, \dots\}$. Encontre o ENVVUM de λ .

Resolução

$$f(Y = x | Y \in A; \lambda) = \frac{\frac{\lambda^x e^{-\lambda}}{x!}}{1 - P(y = 0)} = \frac{\frac{\lambda^x e^{-\lambda}}{x!}}{1 - \frac{\lambda^0 e^{-\lambda}}{0!}} = \frac{\lambda^x e^{-\lambda}}{x! (1 - e^{-\lambda})} = \frac{\lambda^x}{x! e^{\lambda} (1 - e^{-\lambda})}$$

$$f(Y = x | Y \in A; \lambda) = \begin{cases} \frac{\lambda^x}{(e^{\lambda} - 1)x!}, & x \in \mathbb{N}^* \\ 0, & \text{caso contrário} \end{cases}$$

O intervalo de valores onde a função $f(\cdot)$ é não negativa, não depende de parâmetro, logo, $f(\cdot)$ pertence à família exponencial (FE) e como consequência, poder-se-ia usar o LICR, Rao-Blackwell e ou teorema de Lehmann-Scheffé. No entanto, não é possível encontrar analiticamente um estimador de MV que não dependa de λ (não será demonstrado aqui), logo, LICR e Rao-Blackwell não são as vias mais flexíveis (ou ideais), sendo ideal utilizar o teorema de Lehmann-Scheffé e usando a estatística suficiente completa (trivial se $f(\cdot)$ é da FE), encontrar $g(x)$ não viesado ($\mathbb{E}[g(x)] = \lambda$), que seja função da estatística suficiente completa ($T(x)$).

Obs. Na resolução deste exercício, considera-se $\lambda > 0$ e $x \in \mathbb{N}^*$

$$f(x, \lambda) = \frac{\lambda^x}{(e^{\lambda} - 1)x!}, \quad x \in \mathbb{N}^*$$

$$f(x, \lambda) = \frac{e^{\log(\lambda^x)}}{x! e^{\log(e^{\lambda} - 1)}}$$

$$f(x, \lambda) = \frac{\exp \{ \log(\lambda^x) - \log(e^{\lambda} - 1) \}}{x!}$$

$$f(x, \lambda) = \frac{1}{x!} \exp \left\{ \underbrace{x}_{T(x)} \underbrace{\log(\lambda)}_{\eta} - \underbrace{\log(e^{\lambda} - 1)}_{A(\eta)} \right\}$$

Como pode-se notar, $f(\cdot)$ pertence à família exponencial de posto completo, logo, $T(x) = x$ é uma estatística suficiente completa. Seja, $g(x) = a \cdot [T(x)] = a \cdot x$, uma função da estatística completa $T(x) = x$, se existir "a", função de x apenas, tal que $g(x) = a \cdot [T(x)]$, resulta num estimador não viesado de λ , então, $g(x)$ é um ENVVUM.

$$f(x, \lambda) = \frac{\lambda^x}{(e^{\lambda} - 1)x!}, \quad x \in \mathbb{N}^*$$

$$\mathbb{E}[g(x)] = \lambda$$

$$\sum_{x=1}^{\infty} g(x) f(x, \lambda) = \lambda, \quad x \text{ é variável aleatória discreta}$$

$$\sum_{x=1}^{\infty} g(x) \frac{\lambda^x}{(e^{\lambda} - 1)x!} = \lambda, \quad \text{condição para } g(x) \text{ não ser viesado}$$

$$\sum_{x=1}^{\infty} a \cdot x \frac{\lambda^x}{x!} = \lambda(e^{\lambda} - 1)$$

$$\sum_{x=1}^{\infty} a \cdot x \frac{\lambda^x}{x(x-1)! \lambda} = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} - 1, \quad e^{\lambda} = \sum_{n=0}^{\infty} \frac{\lambda^n}{n!}, \quad (\text{série de Maclaurin ou de Taylor com } c = 0)$$

$$\sum_{x=1}^{\infty} a \cdot \frac{\lambda^{x-1}}{(x-1)!} = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} - 1$$

$$\sum_{x=1}^{\infty} a \cdot \frac{\lambda^{x-1}}{(x-1)!} = \frac{\lambda^0}{0!} + \sum_{k=1}^{\infty} \frac{\lambda^k}{k!} - 1$$

$$\sum_{x=1}^{\infty} a \cdot \frac{\lambda^{x-1}}{(x-1)!} = 1 + \sum_{k=1}^{\infty} \frac{\lambda^k}{k!} - 1$$

$$\sum_{x=1}^{\infty} a \cdot \frac{\lambda^{x-1}}{(x-1)!} = \sum_{k=1}^{\infty} \frac{\lambda^k}{k!}$$

⇒ Continuação da resolução do exercício 7b)

$$\begin{aligned}
 \sum_{x=1}^{\infty} a \cdot \frac{\lambda^{x-1}}{(x-1)!} &= \sum_{k=1}^{\infty} \frac{\lambda^k}{k!} \\
 a \cdot \frac{\lambda^{1-1}}{(1-1)!} + a \cdot \frac{\lambda^{2-1}}{(2-1)!} + a \cdot \frac{\lambda^{3-1}}{(3-1)!} + a \cdot \frac{\lambda^{4-1}}{(4-1)!} + \dots &= \frac{\lambda^1}{1!} + \frac{\lambda^2}{2!} + \frac{\lambda^3}{3!} + \dots \\
 a + a\lambda + a \cdot \frac{\lambda^2}{2} + a \cdot \frac{\lambda^3}{6} + \dots &= \lambda + \frac{\lambda^2}{2} + \frac{\lambda^3}{6} + \dots
 \end{aligned}$$

$$\begin{cases} a = 0 & \text{para } x = 1 \\ a = 1 & \text{para } x = 2 \\ a = 1 & \text{para } x = 3 \\ a = 1 & \text{para } x = 4 \\ \dots & \\ a = 1 & \forall x \in A \setminus \{1\} \end{cases}$$

Assim, como encontrou-se "a", pode-se escrever a função $g(x)$, substituindo a pelo valor correspondente encontrando e observando todas condições em ele existe.

$$\begin{aligned}
 g(x) &= a \cdot [T(x)] = a \cdot x \\
 g(x) &= \begin{cases} 1 \cdot x & \text{se } x = 2, 3, 4, 5, 6, \dots \\ 0 \cdot x & \text{se } x = 1 \end{cases} \\
 g(x) &= \begin{cases} x & \text{se } x = 2, 3, 4, 5, 6, \dots \\ 0 & \text{se } x = 1 \end{cases}
 \end{aligned}$$

⇒ Verificando se $g(x)$ não é viesado

$$\begin{aligned}
 f(x, \lambda) &= \frac{\lambda^x}{(e^\lambda - 1)x!}, \quad x \in \mathbb{N}^* \\
 \mathbb{E}[g(x)] &= \sum_{x=2}^{\infty} x \frac{\lambda^x}{(e^\lambda - 1)x!} \\
 \mathbb{E}[g(x)] &= \frac{1}{e^\lambda - 1} \sum_{x=2}^{\infty} x \frac{\lambda^x}{x!} \\
 \mathbb{E}[g(x)] &= \frac{1}{\sum_{k=0}^{\infty} \frac{\lambda^k}{k!} - 1} \sum_{x=2}^{\infty} x \frac{\lambda^x}{x(x-1)!} \\
 \mathbb{E}[g(x)] &= \frac{1}{1 + \sum_{k=1}^{\infty} \frac{\lambda^k}{k!} - 1} \sum_{x=2}^{\infty} \frac{\lambda^x}{(x-1)!} \\
 \mathbb{E}[g(x)] &= \frac{1}{\sum_{k=1}^{\infty} \frac{\lambda^k}{k!}} \sum_{x=2}^{\infty} \frac{\lambda^x}{(x-1)!} \\
 \mathbb{E}[g(x)] &= \frac{1}{\sum_{k=1}^{\infty} \frac{\lambda^k}{k!}} \sum_{x=2}^{\infty} \frac{\lambda \cdot \lambda^{(x-1)}}{(x-1)!} \\
 \mathbb{E}[g(x)] &= \frac{\lambda}{\sum_{k=1}^{\infty} \frac{\lambda^k}{k!}} \sum_{x=2}^{\infty} \frac{\lambda^{(x-1)}}{(x-1)!}, \quad \text{observe que } k = x - 1, x \in \mathbb{N}^* \setminus \{1\} \\
 \mathbb{E}[g(x)] &= \lambda
 \end{aligned}$$

Como $g(x)$ é função da estatística suficiente completa $T(x) = x$, e é uma estatística não viesada, pelo teorema de Lehmann-Scheffé $g(x)$ é um ENVVUM de λ .

7 c) Suponha que $A = \{1, 2, 3, \dots\}$. Encontre o ENVVUM de $e^{-\lambda}$. Critique o estimador encontrado.

Resolução

Obs. Na resolução deste exercício, considera-se $\lambda > 0$, $x \in \mathbb{N}^*$ e $k \in \mathbb{N}$

Seja, $S(x) = b \cdot [T(x)] = b \cdot x$, uma função da estatística suficiente completa $T(x) = x$, se existir "b", função de x apenas, tal que $g(x) = b \cdot [T(x)]$, resulta num estimador não viesado de $e^{-\lambda}$, então, $S(x)$ é um ENVVUM.

$$\begin{aligned}
 f(x, \lambda) &= \frac{\lambda^x}{(e^\lambda - 1)x!}, \quad x \in \mathbb{N}^* \\
 \mathbb{E}[S(x)] &= e^{-\lambda} \\
 \sum_{x=1}^{\infty} s(x) \frac{\lambda^x}{(e^\lambda - 1)x!} &= e^{-\lambda} \\
 \sum_{x=1}^{\infty} b \cdot x \frac{\lambda^x}{(e^\lambda - 1)x!} &= e^{-\lambda} \\
 \sum_{x=1}^{\infty} b \cdot x \frac{\lambda^x}{x(x-1)!} &= e^{-\lambda}(e^\lambda - 1) \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= (1 - e^{-\lambda}) \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= 1 - \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!}, \quad e^{-\lambda} = \sum_{k=0}^{\infty} \frac{(-\lambda)^k}{k!}, \text{ (que é série de Maclaurin ou de Taylor com } c = 0) \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= 1 - \left(1 + \sum_{k=1}^{\infty} \frac{(-\lambda)^k}{k!} \right) \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= - \sum_{k=1}^{\infty} \frac{(-\lambda)^k}{k!} \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= \sum_{k=1}^{\infty} \frac{-1 \cdot (-1)^k \lambda^k}{k(k-1)!} \\
 \sum_{x=1}^{\infty} b \cdot \frac{\lambda^x}{(x-1)!} &= \sum_{k=1}^{\infty} \frac{(-1)^{k+1} \lambda^k}{k(k-1)!}, \text{ observe que } k = x \\
 b &= \frac{(-1)^{k+1}}{k} \\
 b &= \frac{(-1)^{x+1}}{x} \\
 &\implies \text{Substituindo } b \text{ em } S(x) \\
 S(x) &= b \cdot [T(x)] = b \cdot x \\
 S(x) &= \frac{(-1)^{x+1}}{x} \cdot x \\
 S(x) &= (-1)^{x+1}
 \end{aligned}$$

Como $S(x)$ é função da estatística suficiente completa $T(x) = x$, e é uma estatística não viesada, pelo teorema de Lehmann-Scheffé $S(x)$ é um ENVVUM de $e^{-\lambda}$.

Observe que $S(x)$ é uma série alternada, ou seja, assume valor positivo se x for ímpar e valor negativo se x for par. Tomando $\tau(\lambda) = e^{-\lambda}$, se $\lambda = 0$, $\tau(\lambda) = 1$ e $\lim_{\lambda \rightarrow \infty} e^{-\lambda} = 0$. Assim, se x for par sempre resultará em valores fora do espaço paramétrico da função $\tau(\lambda) = e^{-\lambda}$, que é $(0, 1)$, como consequência, $S(x)$ não é bom estimador.

16) Seja (X_1, \dots, X_n) uma amostra aleatória de uma distribuição discreta com função de probabilidade $f_{\theta,j}$, em que $\theta > 0$ e $j = 1, 2$; $f_{\theta,1}$ é a distribuição de Poisson de média θ e $f_{\theta,2}$ é a distribuição

geométrica de parâmetro $\theta/(1+\theta)$, isto é,

$$f_{\theta,2}(x) = \left[1 - \frac{\theta}{1+\theta}\right] \left[\frac{\theta}{1+\theta}\right]^x, \quad x = 0, 1, 2, \dots$$

Existe ENVVUM de θ ? Justifique.

Resolução

Para $j = 1$, temos:

(X_1, \dots, X_n) uma amostra aleatória de $X \sim \text{Poisson}(\theta)$, $\theta > 0$. Observe que X pertence a família exponencial,

$$f_{\theta,1}(x) = \frac{\theta^x e^{-\theta}}{x!} = \frac{1}{x!} \exp\{x \log \theta - \theta\} = h(x) \exp\{T(x)\eta(\theta) - B(\theta)\}, \quad x = 0, 1, 2, \dots$$

em que, $h(x) = \frac{1}{x!}$, $T(x) = x$, $\eta(\theta) = \log \theta$ e $B(\theta) = \theta$. O domínio de variação de $\eta(\theta) = (0, \infty)$ contém retângulos unidimensionais. Logo, $T(X) = \sum_{i=1}^n X_i$ é uma estatística suficiente minimal e completa.

Note que,

$$E_{\theta} \left[\frac{T}{n} \right] = E_{\theta} [\bar{X}] = \theta, \forall \theta$$

Logo, \bar{X} é o ENVUUM para θ , quando $j = 1$.

Para $j = 2$, temos:

(X_1, \dots, X_n) uma amostra aleatória de $X \sim \text{Geométrica}(1 - \frac{\theta}{1+\theta})$, $\theta > 0$. Observe que X pertence a família exponencial,

$$f_{\theta,2}(x) = \left[1 - \frac{\theta}{1+\theta}\right] \left[\frac{\theta}{1+\theta}\right]^x = \exp \left\{ x \log \left(\frac{\theta}{1+\theta} \right) + \log \left(1 - \frac{\theta}{1+\theta} \right) \right\} = h(x) \exp\{T(x)\eta(\theta) - B(\theta)\}$$

com $x = 0, 1, 2, \dots$, em que, $h(x) = 1$, $T(x) = x$, $\eta(\theta) = \log \left(\frac{\theta}{1+\theta} \right)$ e $B(\theta) = -\log \left(1 - \frac{\theta}{1+\theta} \right)$. O domínio de variação de $\eta(\theta) = (0, \infty)$ contém retângulos unidimensionais. Logo, $T(X) = \sum_{i=1}^n X_i$ é uma estatística suficiente minimal e completa.

Note que,

$$E_{\theta} \left[\frac{T}{n} \right] = E_{\theta} [\bar{X}] = \frac{1 - \left[1 - \frac{\theta}{1+\theta}\right]}{1 - \frac{\theta}{1+\theta}} = \frac{\frac{\theta}{1+\theta}}{\frac{1}{1+\theta}} = \theta, \forall \theta$$

Logo, \bar{X} é o ENVUUM para θ , quando $j = 2$.

- 17) Seja X_1, \dots, X_n variáveis aleatórias i.i.d. com função densidade de probabilidade $f_{\theta}(x) = \theta/x^2$, $x > \theta$; $\theta > 0$. Encontre um ENVVUM de $g(\theta)$ assumindo que $g(\theta)/\theta^n \rightarrow 0$ quando $\theta \rightarrow \infty$ e que g é diferenciável.

Resolução

A função de verossimilhança é dada por,

$$L(\theta; x_1, \dots, x_n) = \prod_{i=1}^n \frac{\theta}{x_i^2} I_{(\theta, \infty)}(x_i) = \frac{\theta^n}{\prod_{i=1}^n x_i^2} I_{(0, x_{(1)})}(\theta) = h(x) g_{\theta}(T(x)),$$

em que $h(x) = \prod_{i=1}^n \frac{1}{x_i^2}$ e $g_{\theta}(T(x)) = \theta^n I_{(0, x_{(1)})}(\theta)$. Pelo Critério da Fatoração, temos que $T = X_{(1)}$ é estatística suficiente para θ .

A distribuição de T é dada por,

$$\begin{aligned} F_T(t) &= P(T \leq t) = P(\min(X_1, \dots, X_n) \leq t) \\ &= 1 - P(\min(X_1, \dots, X_n) > t) \\ &= 1 - P(X_1 > t, \dots, X_n > t) \\ &\stackrel{ind}{=} 1 - \prod_{i=1}^n P(X_i > t) \\ &\stackrel{id.}{=} 1 - [P(X_i > t)]^n \\ &= 1 - [1 - P(X_1 < t)]^n \end{aligned}$$

Observe que,

$$F_X(t) = \int_{\theta}^t \frac{\theta}{x^2} dx = \theta \int_{\theta}^t x^{-2} dx = \theta [-x^{-1}]_{\theta}^t = \theta \left[-\frac{1}{t} + \frac{1}{\theta} \right] = 1 - \frac{\theta}{t}$$

Assim,

$$F_T(t) = 1 - [1 - F_X(t)]^n = 1 - \left[1 - \left[1 - \frac{\theta}{t} \right] \right]^n = 1 - \left[\frac{\theta}{t} \right]^n = 1 - \frac{\theta^n}{t^n}$$

Logo, a densidade de $T = X_{(1)}$ é,

$$f_T(t) = \frac{n\theta^n}{t^{n+1}} I_{(\theta, \infty)}(t)$$

Seja g uma função de T ,

$$\begin{aligned} E_{\theta}(g(t)) &= 0, \forall \theta > 0 \\ \Rightarrow \int_{\theta}^{\infty} \frac{g(t)n\theta^n}{t^{n+1}} dt &= 0, \forall \theta > 0 \\ \Rightarrow \int_{\theta}^{\infty} \frac{g(t)}{t^{n+1}} dt &= 0, \forall \theta > 0 \end{aligned}$$

Pelo Teorema Fundamental do Cálculo

$$\begin{aligned} \Rightarrow \left[\lim_{a \rightarrow \infty} H(a) - H(\theta) \right] &= 0, \forall \theta > 0 \\ \Rightarrow \frac{\partial}{\partial \theta} \left[\lim_{a \rightarrow \infty} H(a) - H(\theta) \right] &= \frac{\partial}{\partial \theta} 0, \forall \theta > 0 \\ \Rightarrow \frac{g(\theta)}{\theta^{n+1}} &= 0, \forall \theta > 0 \\ \Rightarrow g(\theta) &= 0, \forall \theta > 0 \\ \Rightarrow g(t) &= 0, \forall t > \theta \\ \Rightarrow P(g(t) = 0) &= 1 \end{aligned}$$

Logo, $T = X_{(1)}$ é uma estatística suficiente e completa. Note que,

$$E_{\theta}[\delta(t)] = \int_{\theta}^{\infty} \frac{\delta(t)n\theta^n}{t^{n+1}} dt = g(\theta), \forall \theta > 0$$

Como $g(\theta)/\theta^n \rightarrow 0$ quando $\theta \rightarrow \infty$

$$\begin{aligned} \Rightarrow \int_{\theta}^{\infty} \frac{\delta(t)}{t^{n+1}} dt &= \frac{g(\theta)}{n\theta^n}, \forall \theta > 0, \\ \Rightarrow \left[\lim_{a \rightarrow \infty} H(a) - H(\theta) \right] &= \frac{g(\theta)}{n\theta^n}, \forall \theta > 0 \end{aligned}$$

Como $g(\theta)$ é diferenciável

$$\begin{aligned} \Rightarrow \frac{\partial}{\partial \theta} \left[\lim_{a \rightarrow \infty} H(a) - H(\theta) \right] &= \frac{\partial}{\partial \theta} \frac{g(\theta)}{n\theta^n}, \forall \theta > 0 \\ \Rightarrow -\frac{\delta(\theta)}{\theta^{n+1}} &= \frac{g'(\theta)n\theta^n - g(\theta)n^2\theta^{n-1}}{n^2\theta^{2n}}, \forall \theta > 0 \\ \Rightarrow \delta(\theta) &= \frac{g(\theta)n^2\theta^{n-1}\theta^{n+1} - g'(\theta)n\theta^n\theta^{n+1}}{n^2\theta^{2n}}, \forall \theta > 0 \\ &= \frac{g(\theta)n^2\theta^{2n} - g'(\theta)n\theta^{2n+1}}{n^2\theta^{2n}}, \forall \theta > 0 \\ &= g(\theta) - \frac{g'(\theta)\theta}{n}, \forall \theta > 0 \\ \Rightarrow \delta(t) &= g(t) - \frac{g'(t)t}{n}, \forall t > 0 \end{aligned}$$

Assim, $\delta(T) = g(T) - \frac{g'(T)T}{n}$, em que $T = X_{(1)}$, é ENVVUM para $g(\theta)$.

- 29) Seja (X_1, \dots, X_n) uma amostra aleatória da distribuição de Pareto com função densidade de probabilidade $p_{\theta, \gamma}(x) = \theta \gamma^\theta x^{-(\theta+1)} I_{[\gamma, \infty)}(x)$, $\theta > 0, \gamma > 0$.

Seja $\mathcal{P} = \{P_{\theta, \gamma} : \theta > 0 \text{ e } \gamma > 0\}$ a família de possíveis distribuições da variável aleatória $X \sim \text{Pareto}(\theta, \gamma)$.

- a) Suponha que γ seja conhecido. Mostre que $\sum_{i=1}^n \log(X_i/\gamma)$ é uma estatística suficiente completa.

Resolução

Considerando ao parâmetro γ conhecido temos a densidade conjunta da distribuição Pareto iid como segue:

$$\begin{aligned} p_{\theta}(\mathbf{x}) &= \prod_{i=1}^n \theta \gamma^\theta x_i^{-(\theta+1)} I_{[\gamma, \infty)}(x_i), \theta > 0 \\ &= \theta^n \gamma^{n\theta} \prod_{i=1}^n x_i^{-(\theta+1)} I_{[\gamma, \infty)}(x_i), \theta > 0 \\ &= \theta^n \gamma^{n\theta} \prod_{i=1}^n x_i^{-\theta} x_i^{-1} I_{[\gamma, \infty)}(x_i), \theta > 0 \\ &= \exp \left\{ -\theta \sum_{i=1}^n \log x_i + n \log(\theta) + n\theta \log(\gamma) \right\} \prod_{i=1}^n x_i^{-1} I_{[\gamma, \infty)}(x_i), \theta > 0 \\ &= \exp \left\{ \underbrace{-\theta \sum_{i=1}^n \log \left(\frac{x_i}{\gamma} \right)}_{T(\mathbf{x})} + \underbrace{n \log(\theta)}_{-A(\eta)} \right\} \underbrace{\prod_{i=1}^n x_i^{-1} I_{[\gamma, \infty)}(x_i)}_{h(\mathbf{x})}, \theta > 0 \end{aligned}$$

seja

$$\eta = -\theta, T(\mathbf{x}) = \sum_{i=1}^n \log \left(\frac{x_i}{\gamma} \right), A(\eta) = -n \log(\theta) = -n \log(-\eta) \text{ e } h(\mathbf{x}) = \prod_{i=1}^n x_i^{-1} I_{[\gamma, \infty)}(x_i)$$

O parâmetro natural é $\eta = \eta(\theta) = -\theta \implies \eta(\theta) \in R^-$. Então, o espaço paramétrico $\eta(\theta) \in (-\infty, 0)$ contém retângulos unidimensionais abertos. Nem a T nem o η satisfazem restrições lineares, portanto dizemos que a família é de posto completo. Assim, a estatística $T = T(\mathbf{X}) = \sum_{i=1}^n \log \left(\frac{X_i}{\gamma} \right)$ é estatística suficiente completa para a família de distribuições de X com o parâmetro γ conhecido.

- b) Suponha que γ seja conhecido. Encontre o estimador não viciado de variância uniformemente mínima de θ .

Resolução

Considere a transformação $Y = \log \left(\frac{x}{\gamma} \right)$, então a distribuição acumulada de Y é dada por

$$\begin{aligned} P(Y \leq y) &= P \left[\log \left(\frac{X}{\gamma} \right) \leq y \right] = P \left(\frac{X}{\gamma} \leq e^y \right) = P(X \leq \gamma e^y) = \int_{\gamma}^{\gamma e^y} f(x, \theta, \gamma) dx, \forall x \geq \gamma, \theta > 0 \\ &= \int_{\gamma}^{\gamma e^y} \theta \gamma^\theta x^{-(\theta+1)} dx = \theta \gamma^\theta \int_{\gamma}^{\gamma e^y} x^{-(\theta+1)} dx = \theta \gamma^\theta \left(\frac{x^{-\theta}}{-\theta} \right) \Big|_{\gamma}^{\gamma e^y} = [-\gamma^\theta x^{-\theta}]_{\gamma}^{\gamma e^y} \\ &= -\gamma^\theta \frac{1}{(\gamma e^y)^\theta} + 1 = 1 - e^{-\theta y} I_{(0, \infty)}(y) \end{aligned}$$

Então, $Y \sim \text{Gama}(1, \theta)$.

Como X_1, \dots, X_n são variáveis aleatórias i.i.d., temos que $T = \sum_{i=1}^n \log \left(\frac{X_i}{\gamma} \right) \sim \text{Gama}(n, \theta)$, para todo $\theta > 0$.

Queremos encontrar $\delta(T)$ tal que $E_\theta(\delta(T)) = \theta, \forall \theta > 0$. Então, $\delta(T)$ será o ENVVUM para θ .

Pela propriedade da distribuição gama tem-se $E(T) = \frac{n}{\theta}$. Assim, tem-se trabalhar com o estimador $g(T) = \frac{n}{T}$

$$\begin{aligned} E_\theta[g(T)] &= E_\theta \left[\frac{n}{T} \right] = \int_0^\infty \frac{n}{t} \frac{\theta^n}{\Gamma(n)} t^{n-1} e^{-t\theta} dt = \frac{n\theta^n}{\Gamma(n)} \int_0^\infty t^{(n-1)-1} e^{-t\theta} dt \\ &\text{somente para } n \geq 2 \\ &= \frac{n\theta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\theta^{n-1}} \underbrace{\int_0^\infty \frac{\theta^{n-1}}{\Gamma(n-1)} t^{(n-1)-1} e^{-t\theta} dt}_{\text{Gama}(n-1, \theta)} \\ &= \frac{n\theta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\theta^{n-1}} = \theta n \frac{(n-2)!}{(n-1)!} = \frac{n\theta}{n-1}, \forall \theta > 0 \text{ e } \gamma \text{ conhecido.} \end{aligned}$$

Se $n = 1$,

$$\begin{aligned} E_\theta[\delta(T)] &= \theta, \forall \theta > 0 \\ \Leftrightarrow \int_0^\infty \delta(t) \frac{\theta}{\Gamma(1)} t^{1-1} e^{-t\theta} dt &= \theta, \forall \theta > 0 \\ \Leftrightarrow \theta \int_0^\infty \delta(t) e^{-t\theta} dt &= \theta, \forall \theta > 0 \\ \Leftrightarrow \int_0^\infty \delta(t) e^{-t\theta} dt &= 1, \forall \theta > 0 \\ \Leftrightarrow \int_0^\infty \delta(t) e^{-t\theta} dt &= \int_0^\infty \theta e^{-t\theta} dt, \forall \theta > 0 \\ \Leftrightarrow \delta(t) &= \theta, \forall \theta > 0 \end{aligned}$$

O estimador não pode depender do parâmetro. Mas como depende do parâmetro, então, não existe nenhum ENVVUM para θ

Se $n \geq 2$ e se tomarmos a estatística $T^* = \frac{n-1}{T}$, segue-se que

$$E_\theta [T^*] = E_\theta \left[\frac{n-1}{T} \right] = (n-1) E \left[\frac{1}{T} \right] = (n-1) \frac{\theta}{n-1} = \theta, \forall \theta > 0$$

Portanto, se $n \geq 2$ a estatística $T^* = \frac{n-1}{\sum_{i=1}^n \log\left(\frac{X_i}{\gamma}\right)}$ é ENVM para θ , pelo que é a função da estatística suficiente completa $T = \sum_{i=1}^n \log\left(\frac{X_i}{\gamma}\right)$ com média θ para todo $\theta > 0$.

- c) Suponha que θ seja conhecido. Mostre que $X_{(1)} = \min(X_1, \dots, X_n)$ é estatística suficiente completa e encontre o estimador não viciado de variância uniformemente mínima de γ .

Resolução

Considerando ao parâmetro θ conhecido temos a densidade conjunta da distribuição Pareto iid como segue:

$$\begin{aligned}
p_\gamma(\mathbf{x}) &= \prod_{i=1}^n \theta \gamma^\theta x_i^{-(\theta+1)} I_{[\gamma, \infty)}(x_i), \gamma > 0 \\
&= \gamma^{\theta n} \prod_{i=1}^n I_{[\gamma, \infty)}(x_i) \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \gamma > 0 \\
&= \gamma^{\theta n} I_{(X_1 \geq \gamma)} \dots I_{(X_n \geq \gamma)} \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \gamma > 0 \\
&= \gamma^{\theta n} I_{\{\min(X_1, \dots, X_n) \geq \gamma\}} \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \gamma > 0 \\
&= \underbrace{\gamma^{\theta n} I_{[\gamma, \infty)}(x_{(1)})}_{g_\gamma(T(\mathbf{x}))} \underbrace{\left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right]}_{h(\mathbf{x})}, \gamma > 0
\end{aligned}$$

Pelo Critério da Fatoração, como $g_\gamma(T(\mathbf{x})) = \gamma^{\theta n} I_{[\gamma, \infty)}(x_{(1)})$ e $h(\mathbf{x}) = \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right]$ são funções não negativas, a estatística $T = X_{(1)}$ é suficiente para a família de distribuições de X , com θ conhecido.

Temos mostrar que T é suficiente completa. Para tanto, considere $t = x_{(1)} \in [\gamma, \infty)$. Então, a distribuição de T é tal que

$$\begin{aligned}
F_{X_{(1)}}(t) &= P(T(x) \leq t) = P(X_{(1)} \leq t) \\
&= P(\min\{X_1, \dots, X_n\} \leq t) \\
&= 1 - P(\min\{X_1, \dots, X_n\} > t) \\
&= 1 - P(X_1 > t, \dots, X_n > t) \\
&= 1 - [P(X_1 > t)]^n \\
&= 1 - [1 - F(t)]^n \\
&= 1 - \left[1 - \int_\gamma^t \theta \gamma^\theta x_1^{-(\theta+1)} dx_1 \right]^n \\
&= 1 - \left[1 + \theta \gamma^\theta \frac{x^{-\theta}}{\theta} \Big|_\gamma^t \right]^n \\
&= 1 - \left[1 + \left(\frac{\gamma}{t} \right)^\theta - 1 \right]^n \\
&= 1 - \left(\frac{\gamma}{t} \right)^{n\theta} I_{[\gamma, \infty)}(t)
\end{aligned}$$

Assim, a função densidade de probabilidade (pdf) da distribuição é dada por:

$$f_T(t) = \frac{d}{dt} P(T(X) \leq t) = \frac{n\theta\gamma^{n\theta}}{t^{n\theta+1}} I_{([\gamma, \infty))}(t), \gamma > 0$$

Portanto, $T = X_{(1)}$ está distribuído como Pareto com parâmetros $n\theta$ e γ , ou seja, $T \sim \text{Pareto}(n\theta, \gamma)$.

A estatística T é completa se, para qualquer função $g(T)$, $E_\gamma[g(T)] = 0$, para todo $\gamma > 0$, implicar que $g(T) = 0$ quase certamente \mathcal{P} , com θ conhecido.

$$\begin{aligned}
&\Rightarrow E_\gamma[g(T)] = 0, \forall \gamma > 0 \\
&\Rightarrow \int_\gamma^\infty g(t) f_T(t) dt = 0, \forall \gamma > 0 \\
&\Rightarrow \int_\gamma^\infty g(t) \frac{n\theta\gamma^{n\theta}}{t^{n\theta+1}} dt = 0, \forall \gamma > 0 \\
&\Rightarrow \int_\gamma^\infty g(t) \frac{n}{t^{n\theta+1}} dt = 0, \forall \gamma > 0 \\
&\quad \text{Pelo teorema fundamental de calculo (TFC) tem-se} \\
&\Rightarrow \lim_{y \rightarrow \infty} G(y) - G(\gamma) = 0, \forall \gamma > 0, \text{ onde } G(t) \text{ é a antiderivada de } g(t) \frac{n}{t^{n\theta+1}} \\
&\Rightarrow \frac{\partial}{\partial \gamma} \left[\lim_{y \rightarrow \infty} G(y) \right] = \frac{\partial}{\partial \gamma} G(\gamma), \forall \gamma > 0 \\
&\Rightarrow 0 = g(\gamma) \frac{n}{\gamma^{n\theta+1}}, \forall \gamma > 0, \text{ vale resaltar que } \frac{n}{\gamma^{n\theta+1}} \neq 0 \\
&\Rightarrow g(\gamma) = 0, \forall \gamma > 0 \\
&\Rightarrow g(t) = 0, \forall t > 0
\end{aligned}$$

Portanto, $T = X_{(1)}$ é completa suficiente para \mathcal{P} , com θ conhecido na distribuição Pareto(θ, γ)

Por fim, queremos encontrar $\delta(T)$ tal que $E_\theta(\delta(T)) = \gamma$, $\forall \gamma > 0$. Então, $\delta(T)$ será o ENVVUM para θ , considerando θ conhecido.

$$\begin{aligned}
E_\gamma[\delta(T)] &= \int_\gamma^\infty \delta(t) \frac{n\theta\gamma^{n\theta}}{t^{n\theta+1}} dt = \gamma, \forall \gamma > 0 \\
&\Rightarrow \int_\gamma^\infty \delta(t) \frac{1}{t^{n\theta+1}} dt = \frac{\gamma^{1-n\theta}}{n\theta}, \forall \gamma > 0 \\
&\stackrel{TFC}{\Rightarrow} \lim_{y \rightarrow \infty} G(y) - G(\gamma) = \frac{\gamma^{1-n\theta}}{n\theta}, \forall \gamma > 0, \text{ onde } G(t) \text{ é a antiderivada de } g(t) = \frac{\delta(t)}{t^{n\theta+1}} \\
&\Rightarrow \frac{\partial}{\partial \gamma} \left[\lim_{y \rightarrow \infty} G(y) \right] = \frac{\partial}{\partial \gamma} G(\gamma) = \frac{\partial}{\partial \gamma} \left[\frac{\gamma^{1-n\theta}}{n\theta} \right], \forall \gamma > 0 \\
&\Rightarrow -g(\gamma) = \frac{(1-n\theta)\gamma^{1-n\theta-1}}{n\theta}, \forall \theta > 0 \\
&\Rightarrow -\delta(\gamma)\gamma^{-(n\theta+1)} = -\frac{(n\theta-1)}{n\theta}\gamma^{-n\theta}, \forall \theta > 0 \\
&\Rightarrow \delta(\gamma) = \frac{n\theta-1}{n\theta}\gamma^{n\theta+1-n\theta}, \forall \theta > 0 \\
&\Rightarrow \delta(t) = \frac{n\theta-1}{n\theta}t, \forall t > 0 \\
&\Rightarrow \delta(T) = \frac{n\theta-1}{n\theta}T \quad (q.c.\mathcal{P})
\end{aligned}$$

Portanto, $\delta(X_{(1)}) = \frac{n\theta-1}{n\theta}X_{(1)}$ é o ENVVUM para γ com θ conhecido para uma família Pareto ($n\theta, \gamma$), se $n\theta > 1$.

- d) Suponha que θ seja conhecido e que o espaço paramétrico para γ seja reduzido a $(0, 1]$. Mostre que $X(1) = \min(X_1, \dots, X_n)$ é uma estatística suficiente mas não é completa.

Resolução

Considere o espaço paramétrico $\Omega_0 = (0, 1]$ com θ fixo. Seja $\mathcal{P}_0 = \{P_\gamma, \gamma \in (0, 1]\}$, representando a família de distribuições do vetor aleatório $\mathbf{X} = X_1, \dots, X_n$, iid, tal que \mathcal{P}_0 é um subconjunto de \mathcal{P} , com a respectiva função de densidade conjunta.

$$\begin{aligned}
p_\gamma(\mathbf{x}) &= \prod_{i=1}^n \theta \gamma^\theta x_i^{-(\theta+1)} I_{[\gamma, \infty)}(x_i), \theta > 0, \gamma \in (0, 1] \\
&= \gamma^{\theta n} \prod_{i=1}^n I_{[\gamma, \infty)}(x_i) \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \theta > 0, \gamma \in (0, 1] \\
&= \gamma^{\theta n} I_{(X_1 \geq \gamma)} \dots I_{(X_n \geq \gamma)} \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \theta > 0, \gamma \in (0, 1] \\
&= \gamma^{\theta n} I_{\{\min(X_1, \dots, X_n) \geq \gamma\}} \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right], \theta > 0, \gamma \in (0, 1] \\
&= \underbrace{\gamma^{\theta n} I_{[\gamma, \infty)}(x_{(1)})}_{g_\gamma(T(\mathbf{x}))} \underbrace{\left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right]}_{h(\mathbf{x})}, \theta > 0, \gamma \in (0, 1]
\end{aligned}$$

Pelo Critério da Fatoração, como $g_\gamma(T(\mathbf{x})) = \gamma^{\theta n} I_{[\gamma, \infty)}(x_{(1)})$ e $h(\mathbf{x}) = \left[\theta^n \prod_{i=1}^n x_i^{-(\theta+1)} \right]$ são funções não negativas, a estatística $T = X_{(1)}$ é suficiente para a família de distribuições de X (\mathcal{P}_0), com θ conhecido.

Pelo item anterior a estatística $T = X_{(1)} \sim \text{Pareto}(n\theta, \gamma)$ é completa se, para qualquer função $g(T)$, $E_\gamma[g(T)] = 0, \forall \gamma \in (0, 1]$, implicar que $g(T) = 0$ quase certamente \mathcal{P}_0 , com θ conhecido.

$$\begin{aligned}
E_\gamma[g(T)] &= \int_\gamma^\infty g(t) f_T(t) dt = 0, \forall \gamma \in (0, 1] \\
&\Rightarrow \int_\gamma^\infty g(t) \frac{n\theta \gamma^{n\theta}}{t^{n\theta+1}} dt = 0, \forall \gamma \in (0, 1] \\
&\Rightarrow \int_\gamma^\infty g(t) \frac{1}{t^{n\theta+1}} dt = 0, \forall \gamma \in (0, 1] \\
&\Rightarrow H(\gamma) - H(0) = 0, \forall \gamma \in (0, 1], \text{ onde } H(t) \text{ representa a primitiva de } h(t) = g(t) \frac{1}{t^{n\theta+1}} dt \\
&\Rightarrow \frac{\partial}{\partial \gamma} [H(\gamma)] - \frac{\partial}{\partial \gamma} [H(0)] = \frac{\partial}{\partial \gamma} [0] \\
&\Rightarrow H'(\gamma) = H'(0), \forall \gamma \in (0, 1] \\
&\Rightarrow g(\gamma) \gamma^{-1-n\theta} = 0, \forall \gamma \in (0, 1], \text{ com } \gamma^{-1-n\theta} \neq 0 \\
&\Rightarrow g(\gamma) = 0, \forall \gamma \in (0, 1] \\
&\Rightarrow g(t) = 0, \forall t \in (0, 1]
\end{aligned}$$

No entanto, para algum $t > 0$, temos que $g(t) \neq 0$. Como exemplo, tem-se

$$g(t) = \begin{cases} 0, & \text{se } t \in (0, \gamma] \\ \frac{t^{n\theta-1}}{2} - t^{n\theta-2}, & \text{se } t \in (\gamma, \infty) \end{cases}.$$

como $\gamma \in (0, 1]$ e $n\theta > 2$, então $t \in (0, 1]$, e podemos reescrever g da seguinte forma

$$g(t) = \begin{cases} 0, & \text{se } t \in (0, 1] \\ \frac{t^{n\theta-1}}{2} - t^{n\theta-2}, & \text{se } t \in (1, \infty) \end{cases}.$$

Note que, $\forall \gamma \in (0, 1]$,

$$\begin{aligned}
E_\gamma[f(T)] &= \int_0^1 0 dt + \int_1^\infty \left(\frac{t^{n\theta-1}}{2} - t^{n\theta-2} \right) t^{-1-n\theta} dt \\
&= \int_1^\infty \frac{t^{-2}}{2} dt - \int_1^\infty t^{-3} dt = -\frac{1}{2} \frac{1}{t} \Big|_1^\infty + \frac{1}{2t^2} \Big|_1^\infty \\
&= 0
\end{aligned}$$

Portanto, $E_\gamma[f(T)] = 0, \forall \gamma \in (0, 1]$, mas $f(T)$ não é igual a zero com probabilidade 1, isto é, $P_\gamma(f(T) \neq 0) > 0$. Assim, $T = X_{(1)} = \min(X_1, \dots, X_n)$ não é estatística completa para $\gamma \in (0, 1]$, mas é suficiente.

- e) Suponha que θ seja conhecido e que o espaço paramétrico para γ seja reduzido a $(0, 1]$. Obtenha o estimador não viciado de variância uniformemente mínima de γ . Sugestão: Considere estimadores da forma $h(X_{(1)}) = aX_{(1)}\mathbb{I}_{(0,1]}(X_{(1)}) + b\mathbb{I}_{(1,+\infty)}(X_{(1)})$ e mostre que são não correlacionados com estimadores não viciados de zero.

Resolução

Seja $\gamma \in (0, 1]$ e θ fixo. Seja o estimador na forma

$$h(T) = aT\mathbb{I}_{(0,1]}(T) + b\mathbb{I}_{(1,+\infty)}(T)$$

com a e b constantes. Vamos encontrar os valores de a e b de forma que $h(T)$ seja estimador não viciado para γ , isto é,

$$\begin{aligned} E_\gamma[h(T)] &= \gamma, \quad \forall \gamma \in (0, 1]. \\ \Rightarrow \int_\gamma^\infty h(t)f_T(t)dt &= \gamma, \quad \forall \gamma \in (0, 1] \\ \Rightarrow \int_\gamma^\infty h(t)\frac{n\theta\gamma^{n\theta}}{t^{n\theta+1}}dt &= \gamma, \quad \forall \gamma \in (0, 1] \\ \Rightarrow \int_\gamma^\infty h(t)t^{-1-n\theta}dt &= \frac{\gamma^{1-n\theta}}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow \int_\gamma^\infty (at)t^{-1-n\theta}\mathbb{I}_{(0,1]}(t)dt + \int_\gamma^\infty bt^{-1-n\theta}\mathbb{I}_{(1,+\infty)}(t)dt &= \frac{\gamma^{1-n\theta}}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow \int_\gamma^1 at^{-n\theta}dt + \int_1^\infty bt^{-1-n\theta}dt &= \frac{\gamma^{1-n\theta}}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow a\frac{t^{1-n\theta}}{1-n\theta}\Big|_\gamma^1 - b\frac{t^{-n\theta}}{n\theta}\Big|_1^\infty &= \frac{\gamma^{1-n\theta}}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow a\frac{1}{1-n\theta} - a\frac{\gamma^{1-n\theta}}{1-n\theta} + b\frac{1}{n\theta} &= \frac{\gamma^{1-n\theta}}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow -a\frac{1}{1-n\theta} = \frac{1}{n\theta} \text{ e } a\frac{1}{1-n\theta} &= -b\frac{1}{n\theta}, \quad \forall \gamma \in (0, 1] \\ \Rightarrow a = \frac{n\theta-1}{n\theta} \text{ e } b = 1, \quad \forall \gamma \in (0, 1]. \end{aligned}$$

Logo,

$$h(T) = \frac{n\theta-1}{n\theta}T\mathbb{I}_{(0,1]}(T) + \mathbb{I}_{(1,+\infty)}(T)$$

é ENNVUM para γ tal que $\gamma \in (0, 1]$.

Considere \mathcal{U}_T como um subconjunto de $\mathcal{U} = \{U(\mathbf{X}) : E_\gamma[U(\mathbf{X})] = 0 \text{ e } E_\gamma[U^2(\mathbf{X})] < \infty, \forall \gamma \in (0, 1]\}$, formado por estimadores não viesados de zero que dependem apenas da estatística suficiente T para γ . Assim, dado que $U \in \mathcal{U}_T$,

$$E_\gamma[U(T)] = 0, \quad \forall \gamma \in (0, 1].$$

$$\begin{aligned} \Rightarrow E_\gamma[U(T)] &= \int_\gamma^\infty u(t)f_T(t)dt = 0, \quad \forall \gamma \in (0, 1] \\ \Rightarrow \int_\gamma^1 u(t)f_T(t)dt + \int_1^\infty u(t)f_T(t)dt &= 0, \quad \forall \gamma \in (0, 1] \end{aligned}$$

Logo, como $\gamma \in (0, 1]$ então de $\int_{\gamma}^1 u(t)f_T(t)dt$, para $t < 1$, temos que $u(t) = 0$. Assim, temos que:

$$u(t) = \begin{cases} 0, & \text{se } 0 < t \leq 1 \\ u^*(t), & \text{se } t > 1 \end{cases}$$

com $\int_1^{\infty} u^*(t)f_T(t)dt = 0$. Então,

$$\begin{aligned} E_{\gamma}[h(T)U(T)] &= E_{\gamma} [E_{\gamma}(h(T)U(T))\mathbb{I}_{(0,1]}(T)], \forall \gamma \in (0, 1] \\ &= E_{\gamma} \left[E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T\mathbb{I}_{(0,1]}(T) + \mathbb{I}_{(1,\infty)}(T) \right) U^*(T)\mathbb{I}_{(1,\infty)}(T) \right] \middle| \mathbb{I}_{(0,1]}(T) \right], \forall \gamma \in (0, 1] \\ &= E_{\gamma} \left[E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T\mathbb{I}_{(0,1]}(T) + (1 - \mathbb{I}_{(0,1]}(T)) \right) U^*(T) [1 - \mathbb{I}_{(0,1]}(T)] \right] \middle| \mathbb{I}_{(0,1]}(T) \right], \forall \gamma \in (0, 1] \\ &= E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T\mathbb{I}_{(0,1]}(T) + (1 - \mathbb{I}_{(0,1]}(T)) \right) U^*(T) [1 - \mathbb{I}_{(0,1]}(T)] \mathbb{I}_{(0,1]}(T) = 0 \right] P(T > 1) + \\ &\quad + E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T\mathbb{I}_{(0,1]}(T) + (1 - \mathbb{I}_{(0,1]}(T)) \right) U^*(T) [1 - \mathbb{I}_{(0,1]}(T)] \middle| \mathbb{I}_{(0,1]}(T) = 1 \right] P(T \leq 1) \\ &= E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T \cdot 0 + (1 - 0) \right) U^*(T)[1 - 0] \right] P(T > 1) + \\ &\quad + E_{\gamma} \left[\left(\frac{n\theta - 1}{n\theta} T \cdot 1 + (1 - 1) \right) U^*(T)[1 - 1] \right] P(T \leq 1), \forall \gamma \in (0, 1] \\ &= E_{\gamma} [U^*(T)] P(T > 1) + E_{\gamma} [0] P(T \leq 1), \forall \gamma \in (0, 1] \\ &= 0, \forall \gamma \in (0, 1] \quad \text{e} \quad U \in \mathcal{U}_T. \end{aligned}$$

Como $E_{\gamma}[U(T)] = 0$ e $E_{\gamma}[h(T)] = \gamma$ para todo $\gamma > 0$, a condição $E_{\gamma}[h(T)U(T)] = 0$ para $\gamma \in (0, 1]$ e $U \in \mathcal{U}_T$ é tanto necessária quanto suficiente para que $h(T) = \frac{n\theta - 1}{n\theta} T\mathbb{I}_{(0,1]}(T) + \mathbb{I}_{(1,\infty)}(T)$ seja o ENVVUM de γ . Além disso, essa condição também implica que $h(T)$ é não correlacionado com qualquer $U \in \mathcal{U}_T$.