



IME

INSTITUTO DE MATEMÁTICA
E ESTATÍSTICA
UNIVERSIDADE DE SÃO PAULO

Modelos Dinâmicos Bayesianos em Marketing: Uma Revisão

Baseado em Migon, Alves, Menezes e Pinheiro (2023)

Alex Monito Nhancololo¹

Seminários - [MAE5748](#)
01/12/2025

¹amnhancololo@ime.usp.br || amnhancololo@gmail.com



Lab250

CONTEXTUALIZAÇÃO

⇒ Modelos Lineares Dinâmicos (DLM)

- Criados por Harrison e Stevens em 1976
- Subutilizados no Marketing, mas extremamente poderosos



CONTEXTUALIZAÇÃO

⇒ Modelos Lineares Dinâmicos (DLM)

- Criados por Harrison e Stevens em 1976
- Subutilizados no Marketing, mas extremamente poderosos

⇒ Modelos L. Dinâmicos vs Modelos Lineares Generalizados (GLM)

- GLM os parâmetros $\theta_{p \times 1} = [\alpha, \beta]^\top$ são fixos $\forall t \in \mathbb{R}$
- DLM $\theta_{p \times 1}$ não são fixos $\forall t \in \mathbb{R}$
- GLM não se adapta aos "regime changes (RC)". **Ex. de RC:** Mudança repentina do comportamento do consumidor
- DLM se adapta rapidamente aos "regime changes"



CONTEXTUALIZAÇÃO

⇒ Modelos L. Dinâmicos vs Modelos Lineares Generalizados (GLM) em Big Data


- Múltiplos produtos, lojas e escalas temporais.
 - Em GLM, rodar modelos complexos (como VAR ou MCMC tradicional) é computacionalmente inviável e lento.
 - Em DLM flexível via Desacoplar/Reacoplar



Lab250

CONTEXTUALIZAÇÃO

⇒ DLM vs GLM em Big Data



CONTEXTUALIZAÇÃO

⇒ Regressão Linear

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2)$$
$$\Downarrow$$
$$(1)$$

$$y_i = [1 \ x_i] \begin{bmatrix} \alpha \\ \beta \end{bmatrix} + \varepsilon_i$$

$$y_i = \mathbf{x}_i^\top \boldsymbol{\theta} + \varepsilon_i, \quad \mathbf{x}_i^\top = [1 \ x_i], \quad \boldsymbol{\theta} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$$
$$(2)$$



CONTEXTUALIZAÇÃO

⇒ Regressão Linear

$$y_i = \alpha + \beta x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2)$$
$$\Downarrow$$
$$(1)$$

$$y_i = [1 \ x_i] \begin{bmatrix} \alpha \\ \beta \end{bmatrix} + \varepsilon_i$$

$$y_i = \mathbf{x}_i^\top \boldsymbol{\theta} + \varepsilon_i, \quad \mathbf{x}_i^\top = [1 \ x_i], \quad \boldsymbol{\theta} = \begin{bmatrix} \alpha \\ \beta \end{bmatrix}$$
$$(2)$$

⇒ Transição para Modelo Linear Dinâmico

$$y_t = \mathbf{x}_t^\top \boldsymbol{\theta}_t + \varepsilon_t$$
$$(3)$$

Problema: y_t é escalar a cada instante t e só podemos estimar um parâmetro $\boldsymbol{\theta}, \forall t \in \mathbb{R}$.



Modelos Lineares Dinâmicos

⇒ **Solução do problema:** Impor uma restrição para que os parâmetros de regressão no tempo t dependam do tempo $t - 1$ (Prop. Markov).

$$y_t = \mathbf{X}_t^\top \boldsymbol{\theta}_t + \varepsilon_t, \quad \varepsilon_t \sim N_m [0, V_t]$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \boldsymbol{\omega}_t, \quad \boldsymbol{\omega}_t \sim N_p (\mathbf{0}, \mathbf{W}_t)$$



Modelos Lineares Dinâmicos

⇒ **Solução do problema:** Impor uma restrição para que os parâmetros de regressão no tempo t dependam do tempo $t - 1$ (Prop. Markov).

$$y_t = \mathbf{X}_t^\top \boldsymbol{\theta}_t + \varepsilon_t, \quad \varepsilon_t \sim N_m [0, V_t]$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \omega_t, \quad \omega_t \sim N_p (\mathbf{0}, \mathbf{W}_t)$$

↓

$$\mathbf{y}_t = \mathbf{F}_t^\top \boldsymbol{\theta}_t + \varepsilon_t \quad \varepsilon_t \sim N_m [\mathbf{0}, \mathbf{V}_t] \quad (\text{Equação das observações})$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \omega_t, \quad \omega_t \sim N_p (\mathbf{0}, \mathbf{W}_t), \quad (\text{Equação dos estados})$$

DLM ⇒ $\{\mathbf{F}_t, \mathbf{G}_t, \mathbf{V}_t, \mathbf{W}_t\}(4)$

- $\{\mathbf{y}_t\}_{m \times 1}, \{\omega_t\}_{p \times 1}, \{\mathbf{F}_t\}_{m \times n}, \mathbf{G}_t = \mathbf{G}_{p \times p}, \{\mathbf{W}_t\}_{p \times 1}, \{\mathbf{V}_t\}_{m \times 1}, \boldsymbol{\theta}_{p \times 1}$
- $\varepsilon_t \perp \varepsilon_{t'}, \omega_t \perp \omega_{t'}, \varepsilon_t \perp \omega_t \perp D_t$
- $D_t = \{D_{t-1}, y_1, \dots, y_n, I_t\}$, informação disponível até tempo t
- I_t : informação extra aos dados, introduzida manualmente pelo analista para corrigir algo (Intervenção).



Exemplos de Modelos Lineares Dinâmicos ($\{F_t, G_t, V_t, W_t\}$)

- Modelo polinomial de 1^a ordem $\{1, 1, V_t, W_t\}$

$$\begin{aligned}y_t &= \theta_t + \varepsilon_t, \quad \varepsilon_t \sim N(0, V_t) \\ \theta_t &= \theta_{t-1} + \psi_t, \quad \psi_t \sim N(0, W_t)\end{aligned}\tag{5}$$

$\theta_t = \mu_t \implies$ Tendência do processo; $F_t = G_t = 1$

Obs: **Ruim** (a longo prazo) e **Bom** (a curto prazo)

Motivo: Seja $f_t(h) = \mathbb{E}[y_{t+h}|D_t] = m_t, \quad \forall h \geq 1$

Curto Prazo ($h = 1$)

- **Adaptação rápida:** se $\psi_t^* \uparrow \implies m_t \rightarrow y_t$

- **Ex:**

$$y_{t-1} = 80 \xrightarrow{\psi_t} y_t = 100 \implies f_t(1) \approx 100$$

- **Inferência:** $\hat{y}_{t+1} \approx y_t$

Se variância de ψ_t (que é W_t) \uparrow , o Ganho de Kalman (K_t) $\rightarrow 1$:

$$m_t = m_{t-1} + K_t(y_t - f_{t-1}) \approx y_t$$

Longo Prazo ($h \gg 1$)

- **Estacionaridade Projetada:** $\frac{\partial f_t(h)}{\partial h} = 0, \implies f_t(h) = m_t \quad (\forall h)$

- **Viés:** Se $\exists \beta \neq 0$ (Tendência): $\mathbb{E}[y_{t+h} - f_t(h)] \propto \beta \cdot h$

- **Consequência:** $\lim_{h \rightarrow \infty} \text{MSE}(h) \rightarrow \infty$



Exemplos de Modelos Lineares Dinâmicos ($\{F_t, G_t, V_t, W_t\}$)

- Modelo polinomial de 2^a ordem $\{F_t, G_t, 1, V_t, W_t\}$

$$y_t = \theta_{1,t} + \varepsilon_t, \quad \varepsilon_t \sim N(0, V_t) \implies \mathbf{y}_t = \underbrace{\begin{bmatrix} 1 & 0 \end{bmatrix}}_{\mathbf{F}_t^\top} \times \underbrace{\begin{bmatrix} \theta_{1,t} \\ \theta_{2,t} \end{bmatrix}}_{\boldsymbol{\theta}_t} + \varepsilon_t \sim N(0, V_t)$$
$$\vdots \qquad \qquad \qquad (6)$$

$$\begin{cases} \theta_{1,t} = \theta_{1,t-1} + \theta_{2,t-1} + \psi_{1,t} \\ \theta_{2,t} = \theta_{2,t-1} + \psi_{2,t} \end{cases} \implies \underbrace{\begin{bmatrix} \theta_{1,t} \\ \theta_{2,t} \end{bmatrix}}_{\boldsymbol{\theta}_t} = \underbrace{\begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}}_{\mathbf{G}_t = \mathbf{G}} \times \underbrace{\begin{bmatrix} \theta_{1,t-1} \\ \theta_{2,t-1} \end{bmatrix}}_{\boldsymbol{\theta}_t} + \underbrace{\begin{bmatrix} \psi_{1,t} \\ \psi_{2,t} \end{bmatrix}}_{\boldsymbol{\psi}_t}, \quad \boldsymbol{\psi}_t \sim N(0, \mathbf{W}_t)$$

Onde:

$\theta_{1,t}$ é por ex: nível de vendas na loja Atacadão, no dia t (ex: $\theta_{1,t=3} = 3000$);

$\theta_{1,t}$ é por ex: crescimento das vendas na loja Atacadão até o dia t (ex:

$\{\theta_{1,t_i}\}_{i=1}^3 = \{1000, 2000, 3000\}$, cres= 1000)



Modelo Sazonal (Fourier)

- Para a componente de frequência $k\omega$ (com $\omega = 2\pi/p$):

$$y_t = \mathbf{F}_t^\top \boldsymbol{\theta}_t + \nu_t \implies y_t = \underbrace{\begin{bmatrix} 1 & 0 \end{bmatrix}}_{\mathbf{F}_t} \times \underbrace{\begin{bmatrix} S_{1,t} \\ S_{2,t} \end{bmatrix}}_{\boldsymbol{\theta}_t} + \nu_t$$
$$\vdots \quad (7)$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \boldsymbol{\omega}_t \implies \underbrace{\begin{bmatrix} S_{1,t} \\ S_{2,t} \end{bmatrix}}_{\boldsymbol{\theta}_t} = \underbrace{\begin{bmatrix} \cos(k\omega) & \sin(k\omega) \\ -\sin(k\omega) & \cos(k\omega) \end{bmatrix}}_{\mathbf{G}_t(\text{Rotação})} \times \underbrace{\begin{bmatrix} S_{1,t-1} \\ S_{2,t-1} \end{bmatrix}}_{\boldsymbol{\theta}_{t-1}} + \boldsymbol{\omega}_t$$

Onde:

ω : Frequência angular. Se dados mensais ($p = 12$), $\omega = 2\pi/12$;

\mathbf{G}_t : Matriz de Rotação.



Modelo de Regressão Dinâmica

- Relação entre resposta y_t e covariável x_t com parâmetros variando no tempo.

$$y_t = \alpha_t + \beta_t x_t + \nu_t \implies y_t = \underbrace{\begin{bmatrix} 1 & x_t \end{bmatrix}}_{\mathbf{F}_t^\top} \times \underbrace{\begin{bmatrix} \alpha_t \\ \beta_t \end{bmatrix}}_{\boldsymbol{\theta}_t} + \nu_t$$

⋮

(8)

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \omega_t \implies \underbrace{\begin{bmatrix} \alpha_t \\ \beta_t \end{bmatrix}}_{\boldsymbol{\theta}_t} = \underbrace{\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}}_{\mathbf{G}_t = I} \times \underbrace{\begin{bmatrix} \alpha_{t-1} \\ \beta_{t-1} \end{bmatrix}}_{\boldsymbol{\theta}_{t-1}} + \omega_t$$

Onde:

x_t : Variável explicativa observada (ex: Preço do produto no dia t);

β_t : Elasticidade-preço.



Modelo de Função de Transferência (Efeito Memória)

- Modela o efeito defasado de uma intervenção x_t (ex: Propaganda) sobre y_t .
- Seja E_t o estado latente do "efeito acumulado":

$$y_t = \mu_t + E_t + \nu_t \implies y_t = \underbrace{\begin{bmatrix} 1 & 1 \end{bmatrix}}_{F_t^\top} \times \underbrace{\begin{bmatrix} \mu_t \\ E_t \end{bmatrix}}_{\theta_t} + \nu_t, \quad E_t = \underbrace{\lambda}_{\text{Decaimento}} E_{t-1} + \underbrace{\psi}_{\text{Impacto}} x_t \quad (9)$$

Onde:

ψx_t : Impacto imediato do investimento em mídia x_t ;

$\lambda \in (0, 1)$: Fator de retenção (memória).



μ_t : Vendas sem efeito da campanha.

Ex: Propaganda de TV. Você gasta x_t hoje. O efeito nas vendas (E_t) \uparrow instantaneamente (ψ) e \downarrow suavemente em x_{t+h} a uma taxa λ , mesmo se $x_{t+1} = 0$.



Exemplo: O Modelo de Função de Transferência

Figure: **(A)** Função de transferência de 1^a ordem: Ganho estocástico ($\psi \sim N$) define o salto inicial, e fator de decaimento ($0 < \lambda < 1$) define a memória. **(B)** Ajuste do Modelo: A linha azul ($h = 1$) segue os dados observados; a linha vermelha ($h = k$) projeta a curva teórica de esquecimento a longo prazo.



Fonte: Migon, Alves, Menezes e Pinheiro (2023)



Lab250

Modelo de Superposição de Blocos (Tend. + Saz. + Regressão)

■ $y_t = \text{Tendência}(\mu_t) + \text{Sazonal}(S_t) + \text{Regressão}(\beta_t x_t) + \nu_t$

$$y_t = \underbrace{\begin{bmatrix} \text{Tendência} & \text{Sazonal} & \text{Reg} \\ \overbrace{1 \quad 0}^{} & \overbrace{1 \quad 0}^{} & \overbrace{x_t}^{} \end{bmatrix}}_{\mathbf{F}_t^\top} \times \underbrace{\begin{bmatrix} \mu_t \\ \beta_t^{tend} \\ S_{1,t} \\ S_{2,t} \\ \beta_t^{reg} \end{bmatrix}}_{\theta_{global,t}} + \nu_t$$

⋮

(10)

$$\underbrace{\begin{bmatrix} \mu_t \\ \beta_t^{tend} \\ S_{1,t} \\ S_{2,t} \\ \beta_t^{reg} \end{bmatrix}}_{\theta_t} = \underbrace{\left[\begin{array}{cc|cc|c} 1 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ \hline 0 & 0 & \cos(\omega) & \sin(\omega) & 0 \\ 0 & 0 & -\sin(\omega) & \cos(\omega) & 0 \\ \hline 0 & 0 & 0 & 0 & 1 \end{array} \right]}_{\mathbf{G} = \text{diag}(\mathbf{G}_{tend}, \mathbf{G}_{saz}, \mathbf{G}_{reg})} \times \underbrace{\begin{bmatrix} \mu_{t-1} \\ \beta_{tend-1} \\ S_{1,t-1} \\ S_{2,t-1} \\ \beta_{reg-1} \end{bmatrix}}_{\theta_{t-1}} + \omega_t$$



Inferência Bayesiana em Modelos Lineares Dinâmicos

⇒ Modelos estáticos

$$p(\theta|y, \psi) \propto \ell(\theta|y)p(\theta|\psi), \quad \ell(\theta|y) = p(y|\theta), \quad \theta \in \Theta$$

$$p(y_f|y) = \int_{\Theta} p(y_f|\theta)p(\theta|y)d\theta = E_{\theta|y}[p(y_f|\theta)]$$



Lab250

⇒ Modelos estáticos

$$p(\theta|y, \psi) \propto \ell(\theta|y)p(\theta|\psi), \quad \ell(\theta|y) = p(y|\theta), \quad \theta \in \Theta$$

$$p(y_f|y) = \int_{\Theta} p(y_f|\theta)p(\theta|y)d\theta = E_{\theta|y}[p(y_f|\theta)]$$

onde:

- ψ é Hiperparâmetro, i.e., representa os parâmetros da distribuição dos parâmetros de cada modelo assumido.
- $p(\theta|\psi)$ é Priori, i.e., crença subjetiva sobre os parâmetros antes de ver os dados.
- $p(\theta|y)$ é Distribuição a Posteriori, i.e., crença atualizada (Priori + Dados) após a observação.
- $p(y_f|y)$ é Distribuição Preditiva, i.e., distr. dos dados futuros y_f .



Inferência Baysiana em Modelos Lineares Dinâmicos

⇒ Modelos Dinâmicos

Passo 1: Definir prior ($\theta_{t=0}$) dado todo conhecimento prévio (D_0)

$$(\boldsymbol{\theta}_0|D_0) \sim N[\mathbf{m}_0, \mathbf{C}_0], \quad \mathbf{m}_0 = \mathbb{E}[\boldsymbol{\theta}_0|D_0], \quad \mathbf{C}_0 = \text{Var}[\boldsymbol{\theta}_0|D_0]$$



$$\therefore, (\boldsymbol{\theta}_{t-1}|D_{t-1}) \sim N[\mathbf{m}_{t-1}, \mathbf{C}_{t-1}]$$



Inferência Baysiana em Modelos Lineares Dinâmicos

⇒ Modelos Dinâmicos

Passo 1: Definir prior ($\theta_{t=0}$) dado todo conhecimento prévio (D_0)

$$(\theta_0|D_0) \sim N[\mathbf{m}_0, \mathbf{C}_0], \quad \mathbf{m}_0 = \mathbb{E}[\theta_0|D_0], \quad \mathbf{C}_0 = \text{Var}[\theta_0|D_0]$$

↓

$$\therefore (\theta_{t-1}|D_{t-1}) \sim N[\mathbf{m}_{t-1}, \mathbf{C}_{t-1}]$$

Passo 2: Encontrar a dist. de θ_t , note que Posteriori $t - 1 \Rightarrow$ Priori t)

$$\theta_t = \mathbf{G}_t \theta_{t-1} + \omega_t, \quad \omega_t \sim N[\mathbf{0}, \mathbf{W}_t] \quad (\text{Eq. do sistema})$$

$$\mathbf{a}_t = \mathbb{E}[\theta_t|D_{t-1}] = \mathbb{E}[\mathbf{G}_t \theta_{t-1} + \omega_t|D_{t-1}] = \mathbf{G}_t \underbrace{\mathbb{E}[\theta_{t-1}|D_{t-1}]}_{\mathbf{m}_{t-1}} + \underbrace{\mathbb{E}[\omega_t]}_{\mathbf{0}} = \mathbf{G}_t \mathbf{m}_{t-1}$$

$$\begin{aligned}\mathbf{R}_t &= \text{Var}[\theta_t|D_{t-1}] = \text{Var}[\mathbf{G}_t \theta_{t-1} + \omega_t|D_{t-1}] = \mathbf{G}_t \underbrace{\text{Var}[\theta_{t-1}|D_{t-1}]}_{\mathbf{C}_{t-1}} \mathbf{G}_t^\top + \underbrace{\text{Var}[\omega_t]}_{\mathbf{W}_t} + \underbrace{2\text{Cov}(\dots)}_{\mathbf{0} \text{ (indep.)}} \\ &= \mathbf{G}_t \mathbf{C}_{t-1} \mathbf{G}_t^\top + \mathbf{W}_t\end{aligned}$$

$$\therefore (\theta_t|D_{t-1}) \sim N[\mathbf{a}_t, \mathbf{R}_t]$$



Inferência Baysiana em Modelos Lineares Dinâmicos

s Passo 3: Fazer a Predição de y_t (Priori $t \rightarrow$ Observável y_t)

$$y_t = \mathbf{F}_t^\top \boldsymbol{\theta}_t + \nu_t, \quad \nu_t \sim N[0, V_t]$$

⇒ Média Preditiva (f_t)

$$f_t = \mathbb{E}[y_t | D_{t-1}] = \mathbb{E}[\mathbf{F}_t^\top \boldsymbol{\theta}_t + \nu_t | D_{t-1}] = \mathbf{F}_t^\top \underbrace{\mathbb{E}[\boldsymbol{\theta}_t | D_{t-1}]}_{\mathbf{a}_t} + \underbrace{\mathbb{E}[\nu_t]}_0 = \mathbf{F}_t^\top \mathbf{a}_t$$

⇒ Variância Preditiva (Q_t)

$$Q_t = \text{Var}[y_t | D_{t-1}] = \text{Var}[\mathbf{F}_t^\top \boldsymbol{\theta}_t + \nu_t | D_{t-1}] = \mathbf{F}_t^\top \underbrace{\text{Var}[\boldsymbol{\theta}_t | D_{t-1}]}_{\mathbf{R}_t} \mathbf{F}_t + \underbrace{\text{Var}[\nu_t]}_{V_t} = \mathbf{F}_t^\top \mathbf{R}_t \mathbf{F}_t + V_t$$

$$\therefore (y_t | D_{t-1}) \sim N[f_t, Q_t]$$



Inferência Baysiana em Modelos Lineares Dinâmicos

Passo 4: Atualizar a distribuição θ_t , i.e, encontrar posteriori de $\theta_t | y_t, D_{t-1}$

⇒ Para obter $(\theta_t | y_t, D_{t-1})$, construímos a distribuição conjunta de θ_t e y_t .

1: Sabendo que $y_t = \mathbf{F}_t^\top \theta_t + \nu_t$ e que $\nu_t \perp \theta_t$:

$$\text{Cov}[\theta_t, y_t | D_{t-1}] = \text{Cov}[\theta_t, \mathbf{F}_t^\top \theta_t + \nu_t | D_{t-1}] = \underbrace{\text{Var}[\theta_t | D_{t-1}]}_{\mathbf{R}_t} \mathbf{F}_t + \underbrace{\text{Cov}[\theta_t, \nu_t]}_0 = \mathbf{R}_t \mathbf{F}_t \quad (11)$$

$$\Rightarrow \begin{pmatrix} \theta_t \\ y_t \end{pmatrix} \Big| D_{t-1} \sim N \left(\begin{pmatrix} \mathbf{a}_t \\ f_t \end{pmatrix}, \begin{bmatrix} \mathbf{R}_t & \mathbf{R}_t \mathbf{F}_t \\ \mathbf{F}_t^\top \mathbf{R}_t & Q_t \end{bmatrix} \right) \quad (12)$$



Inferência Baysiana em Modelos Lineares Dinâmicos

Passo 4: Atualizar a distribuição θ_t , i.e, encontrar posteriori de $\theta_t | y_t, D_{t-1}$

⇒ Para obter $(\theta_t | y_t, D_{t-1})$, construímos a distribuição conjunta de θ_t e y_t .

1: Sabendo que $y_t = \mathbf{F}_t^\top \theta_t + \nu_t$ e que $\nu_t \perp \theta_t$:

$$\text{Cov}[\theta_t, y_t | D_{t-1}] = \text{Cov}[\theta_t, \mathbf{F}_t^\top \theta_t + \nu_t | D_{t-1}] = \underbrace{\text{Var}[\theta_t | D_{t-1}]}_{\mathbf{R}_t} \mathbf{F}_t + \underbrace{\text{Cov}[\theta_t, \nu_t]}_0 = \mathbf{R}_t \mathbf{F}_t \quad (11)$$

$$\Rightarrow \begin{pmatrix} \theta_t \\ y_t \end{pmatrix} \Big| D_{t-1} \sim N \left(\begin{bmatrix} \mathbf{a}_t \\ f_t \end{bmatrix}, \begin{bmatrix} \mathbf{R}_t & \mathbf{R}_t \mathbf{F}_t \\ \mathbf{F}_t^\top \mathbf{R}_t & Q_t \end{bmatrix} \right) \quad (12)$$

2: Prop: Se $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} \right)$, então $(X | Y = y) \sim N(\mathbb{E}[X | Y], \text{Var}[X | Y])$:

$$\mathbb{E}[X | Y] = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y), \quad \text{Var}[X | Y] = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$



Inferência Baysiana em Modelos Lineares Dinâmicos

Passo 4: Atualizar a distribuição θ_t , i.e, encontrar posteriori de $\theta_t | y_t, D_{t-1}$

⇒ Para obter $(\theta_t | y_t, D_{t-1})$, construímos a distribuição conjunta de θ_t e y_t .

1: Sabendo que $y_t = \mathbf{F}_t^\top \theta_t + \nu_t$ e que $\nu_t \perp \theta_t$:

$$\text{Cov}[\theta_t, y_t | D_{t-1}] = \text{Cov}[\theta_t, \mathbf{F}_t^\top \theta_t + \nu_t | D_{t-1}] = \underbrace{\text{Var}[\theta_t | D_{t-1}]}_{\mathbf{R}_t} \mathbf{F}_t + \underbrace{\text{Cov}[\theta_t, \nu_t]}_0 = \mathbf{R}_t \mathbf{F}_t \quad (11)$$

$$\Rightarrow \begin{pmatrix} \theta_t \\ y_t \end{pmatrix} \Big| D_{t-1} \sim N \left(\begin{bmatrix} \mathbf{a}_t \\ f_t \end{bmatrix}, \begin{bmatrix} \mathbf{R}_t & \mathbf{R}_t \mathbf{F}_t \\ \mathbf{F}_t^\top \mathbf{R}_t & Q_t \end{bmatrix} \right) \quad (12)$$

2: Prop: Se $\begin{pmatrix} X \\ Y \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_x \\ \mu_y \end{pmatrix}, \begin{bmatrix} \Sigma_{xx} & \Sigma_{xy} \\ \Sigma_{yx} & \Sigma_{yy} \end{bmatrix} \right)$, então $(X | Y = y) \sim N(\mathbb{E}[X | Y], \text{Var}[X | Y])$:

$$\mathbb{E}[X | Y] = \mu_x + \Sigma_{xy} \Sigma_{yy}^{-1} (y - \mu_y), \quad \text{Var}[X | Y] = \Sigma_{xx} - \Sigma_{xy} \Sigma_{yy}^{-1} \Sigma_{yx}$$


3: Aplicação ao DLM, temos que $\Sigma_{xy} = \mathbf{R}_t \mathbf{F}_t$ e $\Sigma_{yy}^{-1} = Q_t^{-1}$:

$$\begin{aligned} \mathbf{m}_t &= \mathbf{a}_t + (\mathbf{R}_t \mathbf{F}_t) Q_t^{-1} (y_t - f_t) && \xrightarrow{\text{Def: } \mathbf{A}_t = \mathbf{R}_t \mathbf{F}_t Q_t^{-1}} \mathbf{m}_t &= \mathbf{a}_t + \mathbf{A}_t e_t \\ \mathbf{C}_t &= \mathbf{R}_t - (\mathbf{R}_t \mathbf{F}_t) Q_t^{-1} (\mathbf{F}_t^\top \mathbf{R}_t) && \xrightarrow{\text{Def: } \mathbf{A}_t = \mathbf{R}_t \mathbf{F}_t Q_t^{-1}} \mathbf{C}_t &= \mathbf{R}_t - \mathbf{A}_t Q_t \mathbf{A}_t^\top \end{aligned} \quad (13)$$

∴, $(\theta_t | y_t, D_t) \sim N[\mathbf{m}_t, \mathbf{C}_t]$ (Posteriori Atualizada).



Figure: Número mensal de passageiros transportados no Reino Unido de 1949 a 1960: **(A)** Série Observada (y_t); **(B)** Nível Local (μ_t) filtrado; **(C)** Fator de Crescimento/Inclinação (β_t); **(D)** Componente Sazonal (S_t) com amplitude variante. **Abaixo:** Ajuste final do modelo.




Fonte: Migon, Alves, Menezes e Pinheiro (2023)



Lab250

Figure: **(A)** Previsão de longo prazo feita em 1955 (linha azul). **(B)** Previsão atualizada em 1957 após observar novos dados (linha vermelha). Suavização/Smoothing ($E[\theta_t|D_T]$): **(A)** Ajuste global; **(B)** Nível; **(C)** Crescimento; **(D)** Sazonalidade.



Fonte: Migon, Alves, Menezes e Pinheiro (2023)



Lab250

Modelos Dinâmicos Generalizados (DGLM)

⇒ Os modelos discutidos até aqui, impunham dist. normal, o que nem sempre é possível.



Modelos Dinâmicos Generalizados (DGLM)

⇒ Os modelos discutidos até aqui, impunham dist. normal, o que nem sempre é possível.

⇒ **Solução:** Generalizar a distribuição de y_t (Família Exponencial) e conectar aos parâmetros de regressão θ_t via função de ligação $g(\cdot)$.

$$p(y_t|\eta_t, \phi_t) = b(y_t, \phi_t) \exp \left\{ \frac{y_t \eta_t - a(\eta_t)}{\phi_t} \right\} \quad (\text{Eq. das observações - EF})$$

$$\Downarrow \quad \mu_t = a'(\eta_t), \quad V_t = \phi_t a''(\eta_t), \quad g(\mu_t) = \lambda_t$$

$$\lambda_t = \mathbf{F}_t^\top \boldsymbol{\theta}_t \quad (\text{Preditor Linear})$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \boldsymbol{\omega}_t, \quad \boldsymbol{\omega}_t \sim [\mathbf{0}, \mathbf{W}_t], \quad (\text{Eq. dos estados})$$

$$\text{DGLM} \implies \{\text{EF}, g(\cdot), \mathbf{F}_t, \mathbf{G}_t, \mathbf{W}_t\}$$



Modelos Dinâmicos Generalizados (DGLM)

⇒ Os modelos discutidos até aqui, impunham dist. normal, o que nem sempre é possível.

⇒ **Solução:** Generalizar a distribuição de y_t (Família Exponencial) e conectar aos parâmetros de regressão θ_t via função de ligação $g(\cdot)$.

$$p(y_t|\eta_t, \phi_t) = b(y_t, \phi_t) \exp \left\{ \frac{y_t \eta_t - a(\eta_t)}{\phi_t} \right\} \quad (\text{Eq. das observações - EF})$$

$$\Downarrow \quad \mu_t = a'(\eta_t), \quad V_t = \phi_t a''(\eta_t), \quad g(\mu_t) = \lambda_t$$

$$\lambda_t = \mathbf{F}_t^\top \boldsymbol{\theta}_t \quad (\text{Preditor Linear})$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \boldsymbol{\omega}_t, \quad \boldsymbol{\omega}_t \sim [\mathbf{0}, \mathbf{W}_t], \quad (\text{Eq. dos estados})$$

DGLM ⇒ {EF, $g(\cdot)$, \mathbf{F}_t , \mathbf{G}_t , \mathbf{W}_t }

- η_t : Parâmetro natural (variante no tempo); ϕ_t : Parâmetro de escala/dispersão.
- $a(\cdot)$: Função que define os momentos (Média μ_t e Variância V_t).
- $g(\cdot)$: Função de ligação monótona e diferenciável (conecta μ_t ao preditor λ_t).
- $\boldsymbol{\omega}_t \sim [\mathbf{0}, \mathbf{W}_t]$: Indica especificação apenas de 1º e 2º momentos (não necessariamente Normal).



Avanços Recentes: Alta Dimensionalidade

1. Modelos Matriciais (Matrix-Variate DLM): Para modelar m séries temporais simultaneamente (ex: Vendas de m produtos).

$$\begin{aligned}\mathbf{Y}_t &= \mathbf{F}_t^\top \boldsymbol{\Theta}_t + \mathbf{E}_t, \quad \mathbf{E}_t \sim N(0, V_t \boldsymbol{\Sigma}) \\ \boldsymbol{\Theta}_t &= \mathbf{G} \boldsymbol{\Theta}_{t-1} + \boldsymbol{\Omega}_t\end{aligned}\tag{14}$$

- $\boldsymbol{\Theta}_t$: Matriz de estados ($q \times m$).
- Permite compartilhar estrutura (\mathbf{F}, \mathbf{G}) mas ter parâmetros distintos para cada série. Ex: Intensidade do vento e Direção do vento, ambas são afetadas pelas mesmas variáveis climáticas (F_t), mas de formas diferentes (os θ são diferentes para direção e intensidade).



Avanços Recentes: Alta Dimensionalidade

1. Modelos Matriciais (Matrix-Variate DLM): Para modelar m séries temporais simultaneamente (ex: Vendas de m produtos).

$$\begin{aligned}\mathbf{Y}_t &= \mathbf{F}_t^\top \boldsymbol{\Theta}_t + \mathbf{E}_t, \quad \mathbf{E}_t \sim N(0, V_t \boldsymbol{\Sigma}) \\ \boldsymbol{\Theta}_t &= \mathbf{G} \boldsymbol{\Theta}_{t-1} + \boldsymbol{\Omega}_t\end{aligned}\tag{14}$$

- $\boldsymbol{\Theta}_t$: Matriz de estados ($q \times m$).
- Permite compartilhar estrutura (\mathbf{F}, \mathbf{G}) mas ter parâmetros distintos para cada série.
Ex: Intensidade do vento e Direção do vento, ambas são afetadas pelas mesmas variáveis climáticas (F_t), mas de formas diferentes (os θ são diferentes para direção e intensidade).

2. Modelos Hierárquicos Dinâmicos: Estrutura multinível para capturar dependência entre grupos (são a versão dinâmica dos Modelos Lineares Mistos.).

$$y_t = \mathbf{F}_{1,t} \boldsymbol{\theta}_{1,t} + \epsilon_{1,t} \quad (\text{Nível Observacional})$$

$$\boldsymbol{\theta}_{1,t} = \mathbf{F}_{2,t} \boldsymbol{\theta}_t + \epsilon_{2,t} \quad (\text{Nível Estrutural/Grupos})$$

$$\boldsymbol{\theta}_t = \mathbf{G}_t \boldsymbol{\theta}_{t-1} + \omega_t \quad (\text{Evolução Latente})$$



Conclusão

- **Flexibilidade:** DLMs acomodam tendências, sazonalidade e regressores dinâmicos (como preço/mídia) naturalmente.
- **Adaptação:** Reagem rapidamente a mudanças estruturais (via Intervenção ou Fatores de Desconto), cruciais em ambientes voláteis (Marketing).
- **Interpretabilidade:** A decomposição em componentes latentes (nível, crescimento, sazonalidade) permite analisar separadamente cada efeito (Decouple/Recouple).
- **Generalização:** A extensão para DGLM e Modelos Hierárquicos permite aplicação em contagens (vendas discretas) e Big Data (múltiplas lojas).



Referência

- Migon, H. S., Alves, M. B., Menezes, A. F., & Pinheiro, E. G. (2023). **A review of Bayesian dynamic forecasting models: Applications in marketing.** Applied Stochastic Models in Business and Industry, 39(3), 471-493.

Obrigado!

Siga LAB250 clicando [Aqui](#)



Lab250