

UNIVERSIDADE DE SÃO PAULO

Programa de Pos-Graduação em Estatística

Alex Monito Nhancololo

1 Exercício 1: Seja (Z_1, \dots, Z_n) uma amostra aleatória de $Z \sim \text{Ber}(\theta)$, $\theta \in (0, 1)$

a) EMV para $g(\theta) = P_\theta(Z = 0)$ Como $Z \sim \text{Ber}(\theta)$, temos que:

$$P_\theta(Z = z) = f_\theta(z) = \theta^z(1 - \theta)^{1-z}$$

$$P_\theta(Z = 0) = \theta^0(1 - \theta)^{1-0} = 1 - \theta$$

$$L_{z_n}(\theta) = \prod_{i=1}^n P_\theta(Z = z_i) = \prod_{i=1}^n \theta^{z_i}(1 - \theta)^{1-z_i} = \theta^{\sum_{i=1}^n z_i} (1 - \theta)^{n - \sum_{i=1}^n z_i}$$

$$\ell(\theta) = \log \left(\theta^{\sum_{i=1}^n z_i} (1 - \theta)^{n - \sum_{i=1}^n z_i} \right) = \left(\sum_{i=1}^n z_i \right) \log \theta + \left(n - \sum_{i=1}^n z_i \right) \log(1 - \theta)$$

$$\frac{d\ell}{d\theta} = \frac{\sum_{i=1}^n z_i}{\theta} - \frac{n - \sum_{i=1}^n z_i}{1 - \theta} = U_n(\theta)$$

$$\frac{d\ell}{d\theta} = 0 \implies \frac{\sum_{i=1}^n z_i}{\hat{\theta}} - \frac{n - \sum_{i=1}^n z_i}{1 - \hat{\theta}} = 0 \iff \frac{\sum_{i=1}^n z_i}{\hat{\theta}} = \frac{n - \sum_{i=1}^n z_i}{1 - \hat{\theta}}$$

$$\left(\sum_{i=1}^n z_i \right) (1 - \hat{\theta}) = \hat{\theta} \left(n - \sum_{i=1}^n z_i \right)$$

$$\sum_{i=1}^n z_i - \cancel{\hat{\theta} \sum_{i=1}^n z_i} = \hat{\theta} n - \cancel{\hat{\theta} \sum_{i=1}^n z_i}$$

$$\sum_{i=1}^n z_i = \hat{\theta} n$$

$$\hat{\theta} = \frac{\sum_{i=1}^n z_i}{n}$$

$$\hat{\theta}_{MV}(z_n) = \bar{Z}, \text{ pois } \frac{dU_n(\theta)}{d(\theta)} = -\frac{\sum_{i=1}^n z_i}{\theta^2} - \frac{n - \sum_{i=1}^n z_i}{(1 - \theta)^2} < 0$$

Pelo princípio da invariância do EMV, o EMV para $g(\theta) = 1 - \theta$ é: $\widehat{g(\theta)}_{MV} = 1 - \hat{\theta}_{MV}(z_n) = 1 - \bar{Z}$.

b) EMV para $g(\theta) = \text{Var}_\theta(Z)$

Como $Z \sim \text{Ber}(\theta)$, e $\text{Var}_\theta(Z) = \theta(1 - \theta)$, e já calculou-se o EMV para θ , temos que pelo princípio da invariância, o EMV para $g(\theta) = \text{Var}_\theta(Z)$ é: $\widehat{g(\theta)}_{MV} = \hat{\theta}_{MV}(z_n)(1 - \hat{\theta}_{MV}(z_n)) = \bar{Z}(1 - \bar{Z})$.

c) Estimativas para os dados $(0, 0, 1, 0, 0, 1)$

\implies Para $g(\theta) = \theta$

$$\hat{\theta}_{MV}(z_n) = \frac{\sum_{i=1}^n z_i}{n} = \frac{0 + 0 + 1 + 0 + 0 + 1}{6} = \frac{2}{6} = \frac{1}{3}, n = 6.$$

\implies Para $g(\theta) = P_\theta(Z = 0) = 1 - \theta$:

$$\widehat{g(\theta)}_{MV} = 1 - \hat{\theta}_{MV}(z_n) = 1 - \bar{z} = 1 - \frac{1}{3} = \frac{2}{3}.$$

\implies Para $g(\theta) = \text{Var}_\theta(Z) = \theta(1 - \theta)$:

$$\widehat{g(\theta)} = \hat{\theta}_{MV}(z_n)(1 - \hat{\theta}_{MV}(z_n)) = \bar{z}(1 - \bar{z}) = \frac{1}{3} \cdot \left(1 - \frac{1}{3} \right) = \frac{1}{3} \cdot \frac{2}{3} = \frac{2}{9}.$$

d) Valor-p para $H_0 : \theta = 0.1$

Do exercício 1a), temos: $L_{z_n}(\theta) = \theta^{\sum_{i=1}^n z_i} (1 - \theta)^{n - \sum_{i=1}^n z_i}$. Pelo teorema da fatoração de Neyman, vemos que a verossimilhança depende dos dados apenas através da quantidade $\sum_{i=1}^n z_i$, portanto, $\sum_{i=1}^n z_i$ contém toda a informação da amostra relevante para inferência sobre o parâmetro θ . Isto é, a estatística suficiente é $T = \sum_{i=1}^n z_i$

Assim, sob H_0 , $T = \sum_{i=1}^n z_i \sim \text{Bin}(n = 6, \theta = 0.1)$. O valor observado é $T = \sum_{i=1}^6 z_i = 0 + 0 + 1 + 0 + 0 + 1 = 2$. O valor-p bilateral é definido como:

$$\text{Valor-p}(H_0, z_n) = 2 \cdot \min \left\{ \sup_{\theta \in \Theta_0} P_{\theta}^{(n)}(T_{H_0}(\mathbf{Z}_n) \geq T_{H_0}(z_n)), \sup_{\theta \in \Theta_0} P_{\theta}^{(n)}(T_{H_0}(\mathbf{Z}_n) \leq T_{H_0}(z_n)) \right\}.$$

Como $\Theta_0 = \{\theta = 0.1\}$ e $T = T_{H_0}(z_n) = \sum_{i=1}^n z_i = 2$, tem-se:

$$\sup_{\theta \in \Theta_0} P_{\theta}^{(n)}(T_{H_0}(\mathbf{Z}_n) \geq 2) = P_{0.1}(T \geq 2),$$

$$\sup_{\theta \in \Theta_0} P_{\theta}^{(n)}(T_{H_0}(\mathbf{Z}_n) \leq 2) = P_{0.1}(T \leq 2).$$

Sob H_0 a função de probabilidade é binomial (soma de Z experimentos Bernoulli), dada por:

$$P_{\theta}(T = k) = \binom{n}{k} \theta^k (1 - \theta)^{n-k} = P_{0.1}(T = k) = \binom{6}{k} (0.1)^k (0.9)^{6-k}, \quad k = 0, 1, \dots, 6.$$

$$P_{0.1}(T = 0) = \binom{6}{0} (0.1)^0 (0.9)^6 = 1 \cdot 1 \cdot 0.9^6 = 0.531441,$$

$$P_{0.1}(T = 1) = \binom{6}{1} (0.1)^1 (0.9)^5 = 6 \cdot 0.1 \cdot 0.9^5 = 0.354294,$$

$$P_{0.1}(T = 2) = \binom{6}{2} (0.1)^2 (0.9)^4 = 15 \cdot 0.01 \cdot 0.9^4 = 0.098415,$$

$$P_{0.1}(T = 3) = \binom{6}{3} (0.1)^3 (0.9)^3 = 20 \cdot 0.001 \cdot 0.9^3 = 0.01458,$$

$$P_{0.1}(T = 4) = \binom{6}{4} (0.1)^4 (0.9)^2 = 15 \cdot 0.0001 \cdot 0.9^2 = 0.001215,$$

$$P_{0.1}(T = 5) = \binom{6}{5} (0.1)^5 (0.9)^1 = 6 \cdot 0.00001 \cdot 0.9 = 0.000054,$$

$$P_{0.1}(T = 6) = \binom{6}{6} (0.1)^6 (0.9)^0 = 1 \cdot 0.000001 \cdot 1 = 0.000001.$$

Assim, temos:

$$\begin{aligned} P_{0.1}(T \geq 2) &= P(T = 2) + P(T = 3) + P(T = 4) + P(T = 5) + P(T = 6) \\ &= 0.098415 + 0.01458 + 0.001215 + 0.000054 + 0.000001 = 0.114265, \\ P_{0.1}(T \leq 2) &= P(T = 0) + P(T = 1) + P(T = 2) = 0.531441 + 0.354294 + 0.098415 = 0.98415. \end{aligned}$$

$$\text{Valor-p}(H_0, z_n) = 2 \cdot \min(P_{0.1}(T \geq 2), P_{0.1}(T \leq 2)) = 2 \cdot \min(0.114265, 0.98415) = 2 \cdot 0.114265 = 0.22853.$$

Nota: Não foi especificada a H_a , no caso de ser unilateral, bastaria apenas um Valor-p(H_0, z_n) = 0.114265, análogo à fórmula apresentada nas notas de aula.

2 Exercício: Seja (Z_1, \dots, Z_n) uma amostra aleatória de $Z \sim \exp(\theta), \theta \in (0, \infty)$

a) EMV para $g(\theta) = P_{\theta}(Z > 1)$

Como $Z \sim \exp(\theta)$, a função de densidade de Z é:

$$P_{\theta}(Z = z) = f_{\theta}(z) = \theta e^{-\theta z}, \quad z > 0$$

$$\begin{aligned} P_{\theta}(Z > 1) &= \int_1^{\infty} \theta e^{-\theta z} dz = \lim_{a \rightarrow \infty} \int_1^a \theta e^{-\theta z} dz = \lim_{a \rightarrow \infty} \int_1^a -d(e^{-\theta z}) = \lim_{a \rightarrow \infty} (-) \exp(-\theta z) \Big|_1^a \\ &= - \lim_{a \rightarrow \infty} [\exp(-\theta \times 1) - \exp(-\theta \times a)] = \exp(-\theta) - \cancel{\exp(-\theta \times \infty)} \xrightarrow{0} \\ &= \exp(-\theta) = g(\theta) \end{aligned}$$

A função de verossimilhança é:

$$\begin{aligned}
L_{z_n}(\theta) &= \prod_{i=1}^n P_\theta(Z = z_i) = \prod_{i=1}^n \theta e^{-\theta z_i} = \theta^n e^{-\theta \sum_{i=1}^n z_i}, \quad z_i > 0 \\
\ell(\theta) &= \log(L_{z_n}(\theta)) = \log\left(\theta^n e^{-\theta \sum_{i=1}^n z_i}\right) = n \log \theta - \theta \sum_{i=1}^n z_i = U_n(\theta) \\
\frac{d\ell}{d\theta} &= \frac{n}{\theta} - \sum_{i=1}^n z_i \\
\frac{d\ell}{d\theta} = 0 &\implies \frac{n}{\theta} - \sum_{i=1}^n z_i = 0 \iff \sum_{i=1}^n z_i = \frac{n}{\theta} \iff \hat{\theta} \sum_{i=1}^n z_i = n \\
\hat{\theta} &= \frac{n}{\sum_{i=1}^n z_i} \times \frac{\frac{1}{n}}{\frac{1}{n}} = \frac{1}{\bar{Z}} \\
\hat{\theta}_{MV}(z_n) &= \frac{1}{\bar{z}}, \quad \text{pois, } \frac{dU_n(\theta)}{d\theta} = \frac{d^2\ell}{d\theta^2} = -\frac{n}{\theta^2} < 0
\end{aligned}$$

Assim, pelo princípio da invariância do EMV, o EMV para $g(\theta) = \exp(-\theta)$ é:

$$\widehat{g(\theta)}_{MV} = g(\hat{\theta}_{MV}(z_n)) = \exp(-\hat{\theta}_{MV}(z_n)) = \exp(-1/\bar{Z})$$

b) EMV para $g(\theta) = P_\theta(0.1 < Z < 1)$

$$g(\theta) = P_\theta(0.1 < Z < 1) = \int_{0.1}^1 \theta \exp(-\theta \cdot z) dz = [-\exp(-\theta \cdot z)]_{0.1}^1 = \exp(-0.1 \cdot \theta) - \exp(-\theta)$$

Pelo princípio da invariância:

$$\widehat{g(\theta)}_{MV} = g(\hat{\theta}_{MV}(z_n)) = \exp(-0.1/\bar{Z}) - \exp(-1/\bar{Z}).$$

c) EMV para $g(\theta) = \text{Var}_\theta(Z)$

Como $Z \sim \text{Exp}(\theta)$, temos que $\text{Var}_\theta(Z) = \frac{1}{\theta^2}$. Pelo princípio da invariância:

$$\widehat{g(\theta)}_{MV} = \frac{1}{\hat{\theta}_{MV}^2(z_n)} = \frac{1}{(\frac{1}{\bar{z}})^2} = \bar{Z}^2.$$

d) IC aproximado de 95% para $g(\theta)$ com dados (0.2, 0.6, 0.3, 0.2, 0.8, 0.12)

Pela teoria assintótica do EMV, temos: $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N(0, V_\theta)$, onde V_θ (a variância assintótica). Se V_θ é contínua e com derivada contínua em relação a θ , temos: $\sqrt{n}V_\theta^{-\frac{1}{2}}(\hat{\theta}_n - \theta) \xrightarrow{D} N_p(0, I_p(\theta))$ e $Q_n(\mathbf{Z}_n) = n(\hat{\theta}_n - \theta)^\top V_\theta^{-1}(\hat{\theta}_n - \theta) \xrightarrow{D} \chi_p^2$. Assim, o IC aproximado de γ para θ é: $C_\gamma(\mathbf{Z}_n) = \{\theta \in \Theta : Q_n(\mathbf{Z}_n) \leq q_{\gamma,p}\}$, em que $q_{\gamma,p}$ é o quantil γ de uma χ_p^2 . Pelo exercício 2a), sabe-se que a função score é: $U_n(\theta) = \frac{d\ell}{d\theta} = \frac{n}{\theta} - \sum_{i=1}^n z_i$. Assim, a informação de Fisher é dada por:

$$I_n(\theta) = -E\left[\frac{d^2\ell}{d\theta^2}\right] = -E\left[\frac{dU_n(\theta)}{d\theta}\right] = -E\left[-\frac{n}{\theta^2}\right] = \frac{n}{\theta^2}.$$

Portanto, a variância assintótica do EMV $\hat{\theta}_n$ é: $\text{Var}_{\text{ass}}(\hat{\theta}_n) = I_n(\theta)^{-1} = \frac{\theta^2}{n}$.

Pelo que, $V_\theta = \text{Var}\left(\sqrt{n}(\hat{\theta}_n - \theta)\right) = n \cdot \text{Var}_{\text{ass}}(\hat{\theta}_n) = n \cdot \frac{\theta^2}{n} = \theta^2$. Assim, $V_\theta = \theta^2$, e $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{D} N(0, \theta^2)$.

Para uma função $g : \Theta \rightarrow \mathbb{R}$ diferenciável, pelo método delta, temos que: $\sqrt{n}(g(\hat{\theta}_n) - g(\theta)) \xrightarrow{D} N(0, [g'(\theta)]^2 V_\theta)$ e $\frac{\sqrt{n}(g(\hat{\theta}_n) - g(\theta))}{\sqrt{[g'(\theta)]^2 V_\theta}} = \frac{g(\hat{\theta}_n) - g(\theta)}{\sqrt{[g'(\theta)]^2 \frac{\theta^2}{n}}} = \frac{\sqrt{n}(g(\hat{\theta}_n) - g(\theta))}{\sqrt{[g'(\theta)]^2 \theta^2}} = \frac{\sqrt{n}(g(\hat{\theta}_n) - g(\theta))}{|g'(\theta)\theta|} \xrightarrow{D} N(0, 1)$

Um IC aproximado de γ para $g(\theta)$ é: $C_\gamma^{(g)}(\mathbf{Z}_n) = \left\{g(\theta) : \left|\frac{g(\hat{\theta}_n) - g(\theta)}{\frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}}}\right| \leq z_{(1+\gamma)/2}\right\}$, onde $z_{(1+\gamma)/2}$ é o quantil da normal padrão tal que $P(|Z| \leq z_{(1+\gamma)/2}) = \gamma$.

$$\begin{aligned}
C_\gamma^{(g)}(\mathbf{Z}_n) &= \left\{g(\theta) : \left|\frac{g(\hat{\theta}_n) - g(\theta)}{\frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}}}\right| \leq z_{(1+\gamma)/2}\right\} = \left\{g(\theta) : |g(\hat{\theta}_n) - g(\theta)| \leq \frac{z_{(1+\gamma)/2} \times |g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}}\right\} \\
&= \left\{g(\theta) : g(\hat{\theta}_n) \pm \frac{z_{(1+\gamma)/2} \times |g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}}\right\} \\
&= \left\{g(\theta) : g(\hat{\theta}_n) \pm 1.96 \cdot \frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}}\right\}
\end{aligned}$$

onde $z_{(1+\gamma)/2}$ é o quantil da normal padrão tal que $P(|Z| \leq z_{(1+\gamma)/2}) = \gamma$, com $Z \sim N(0, 1)$. Para $\gamma = 0.95$, $z_{(1+\gamma)/2} = z_{0.975} \approx 1.96$.

Nota: Aqui fiz considerando que $Z \sim N(0, 1)$, porém, sabe-se que $Z^2 \sim \chi_1^2$, então poderia usar teste Qui-quadrado.

\Rightarrow Dados: (0.2, 0.6, 0.3, 0.2, 0.8, 0.12), $n = 6$

$$\bar{z} = \frac{\sum_{i=1}^n}{n} = \frac{0.2 + 0.6 + 0.3 + 0.2 + 0.8 + 0.12}{6} = 0.37, \quad \hat{\theta}_n = \theta_{MV}(z_n) = \frac{1}{0.37} \approx 2.7027$$

a) Para $g(\theta) = \exp(-\theta) = P_\theta(Z > 1)$

$$\begin{aligned} \widehat{g(\theta)} &= \exp(-\hat{\theta}_{MV}(z_n)) = \exp(-1/\bar{z}) = e^{-2.7027} \approx 0.0671 \\ g'(\theta) &= -\exp(-\theta) \Rightarrow g'(\hat{\theta}_n) = -\widehat{g(\theta)} \approx -0.0671 \\ \frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}} &= \frac{0.0671 \times 2.7027}{\sqrt{6}} \approx 0.0740 \\ \text{IC}_{95\%} &= 0.0671 \pm 1.96 \times 0.0740 = (-0.0779, 0.2121) \end{aligned}$$

Nota: O IC inclui valores negativos, o que não é válido para uma probabilidade. Truncar o intervalo para $[0, 0.2121]$ pode ser ideal. No entanto, isso introduz um viés, pois a cobertura real do IC pode ser menor que o nível nominal. Uma abordagem mais rigorosa seria usar métodos de bootstrap ou transformações que garantam limites válidos.

Como $g(\theta) = P_\theta(Z > 1) = e^{-\theta} > 0$, usamos a transformação logarítmica.

Item (a): IC com transformação logarítmica para $g(\theta) = e^{-\theta}$

$$\begin{aligned} h(\theta) &= \log(g(\theta)) = -\theta \\ \widehat{h(\theta)} &= -\hat{\theta} = -2.7027 \\ h'(\theta) &= -1 \\ \text{Var}(\widehat{h(\theta)}) &\approx [h'(\theta)]^2 \cdot \frac{\hat{\theta}^2}{n} = (-1)^2 \cdot \frac{(2.7027)^2}{6} \approx \frac{7.3046}{6} \approx 1.2174 \\ \text{EP} &= \sqrt{\text{Var}(\widehat{h(\theta)})} \approx \sqrt{1.2174} \approx 1.1034 \\ \text{IC para } h(\theta) : \widehat{h(\theta)} \pm z_{0.975} \cdot \text{EP} &= -2.7027 \pm 1.96 \times 1.1034 = [-4.8654, -0.5400] \\ \text{IC para } g(\theta) : [e^{-4.8654}, e^{-0.5400}] &\approx [0.0077, 0.5828] \end{aligned}$$

Justificativa: A transformação logarítmica garante que o intervalo esteja contido em $(0, \infty)$, evitando valores negativos inadequados para uma probabilidade. O IC resultante $[0.0077, 0.5828]$ é assintoticamente válido e preserva a interpretação probabilística.

b) Para $g(\theta) = P_\theta(0.1 < Z < 1) = \exp(-0.1 \cdot \theta) - \exp(-\theta)$

$$\begin{aligned} \widehat{g(\theta)} &= \exp(-0.1/\bar{z}) - \exp(-1/\bar{z}) = e^{-0.27027} - e^{-2.7027} \approx 0.7632 - 0.0671 = 0.6961 \\ g'(\theta) &= -0.1 \exp(-0.1 \cdot \theta) + \exp(-\theta) \\ g'(\hat{\theta}_n) &= -0.1 \times \exp(-0.1/\bar{z}) + \exp(-1/\bar{z}) \approx -0.1 \times 0.7632 + 0.0671 = -0.00922 \\ \frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}} &= \frac{0.00922 \times 2.7027}{\sqrt{6}} \approx 0.01017 \\ \text{IC}_{95\%} &= 0.6961 \pm 1.96 \times 0.01017 = (0.6762, 0.7160) \end{aligned}$$

c) Para $g(\theta) = \text{Var}_\theta(Z) = \frac{1}{\theta^2}$

$$\begin{aligned} \widehat{g(\theta)} &= \frac{1}{\hat{\theta}_{MV}^2(z_n)} = \frac{1}{2.7027^2} \approx 0.1369 \\ g'(\theta) &= -\frac{2}{\theta^3} \Rightarrow g'(\hat{\theta}_n) \approx -\frac{2}{2.7027^3} \approx -0.1012 \\ \frac{|g'(\hat{\theta}_n)|\hat{\theta}_n}{\sqrt{n}} &= \frac{0.1012 \times 2.7027}{\sqrt{6}} \approx 0.1116 \\ \text{IC}_{95\%} &= 0.1369 \pm 1.96 \times 0.1116 = (-0.0818, 0.3556) \end{aligned}$$

Nota: O IC inclui valores negativos, o que não é válido para uma probabilidade. Truncar o intervalo para $[0, 0.3556]$ pode ser ideal. No entanto, isso introduz um viés, pois a cobertura real do IC pode ser menor que o nível nominal.

Uma abordagem mais rigorosa seria usar métodos de bootstrap ou transformações que garantam limites válidos.

Como $g(\theta) = g(\theta) = \text{Var}_\theta(Z) = 1/\theta^2 > 0$, usamos a transformação logarítmica.

Item (c): IC com Transformação Logarítmica para $g(\theta) = \frac{1}{\theta^2}$

$$h(\theta) = \ln(g(\theta)) = -2 \ln(\theta)$$

$$\widehat{h(\theta)} = -2 \ln(2.7027) \approx -2 \times 0.9943 = -1.9886$$

$$h'(\theta) = -\frac{2}{\theta}$$

$$\text{Var}(\widehat{h(\theta)}) \approx [h'(\theta)]^2 \cdot \frac{\hat{\theta}^2}{n} = \left(-\frac{2}{\theta}\right)^2 \cdot \frac{\hat{\theta}^2}{n} = \frac{4}{n} = \frac{4}{6} \approx 0.6667$$

$$\text{EP} = \sqrt{\text{Var}(\widehat{h(\theta)})} \approx \sqrt{0.6667} \approx 0.8165$$

$$\text{IC para } h(\theta) : \widehat{h(\theta)} \pm z_{0.975} \cdot \text{EP} = -1.9886 \pm 1.96 \times 0.8165 = [-3.5889, -0.3883]$$

$$\text{IC para } g(\theta) : [e^{-3.5889}, e^{-0.3883}] \approx [0.0276, 0.6783]$$

Justificativa: A transformação logarítmica assegura que a variância estimada seja positiva e que o IC para $g(\theta)$ esteja contido em $(0, \infty)$, corrigindo a limitação do método delta direto. O IC $[0.0276, 0.6783]$ é adequado para uma variância.

e) Com base na simulação de Monte Carlo, os intervalos de confiança (ICs) aproximados para o tamanho amostral original de $n=6$ não são confiáveis. A Figura 1 demonstra que para esta amostra pequena a cobertura empírica se desvia consideravelmente do nível nominal de 95%, os intervalos são, em média, muito longos e os estimadores apresentam um viés elevado. Para obter resultados mais confiáveis, a análise da Figura 2 é fundamental, pois mostra que tanto a cobertura quanto o comprimento dos ICs melhoram com o aumento do tamanho amostral. Observa-se que a cobertura converge para o valor esperado de 95% e os intervalos se tornam mais precisos à medida que n aumenta. Portanto, propõe-se um tamanho amostral de $n=50$, pois a partir desse ponto a simulação indica que a cobertura se estabiliza no nível desejado, produzindo ICs aproximados mais confiáveis para todos os casos.

Figura 1: Análise de cobertura dos intervalos de confiança

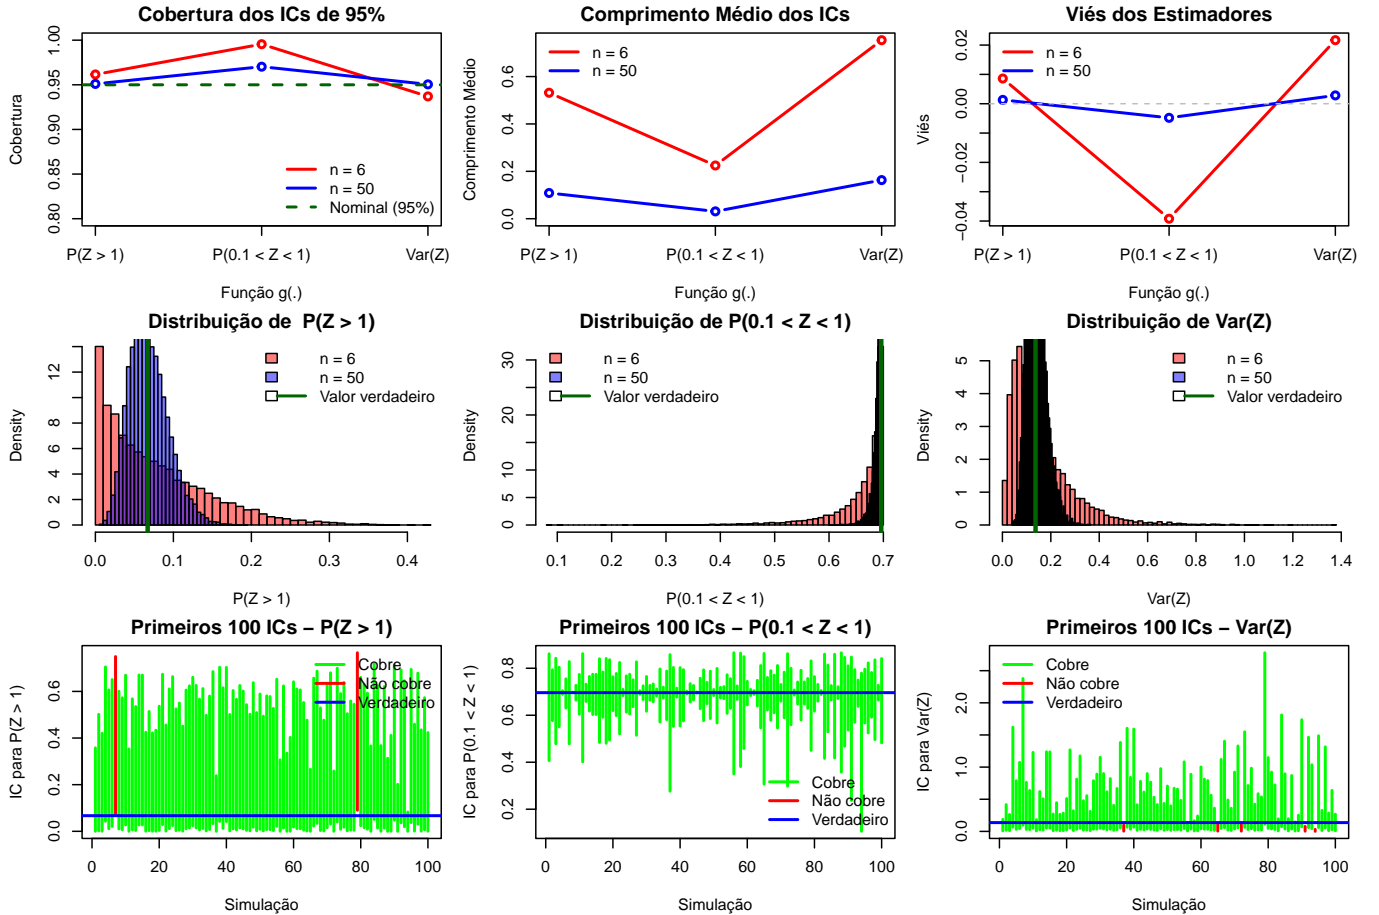
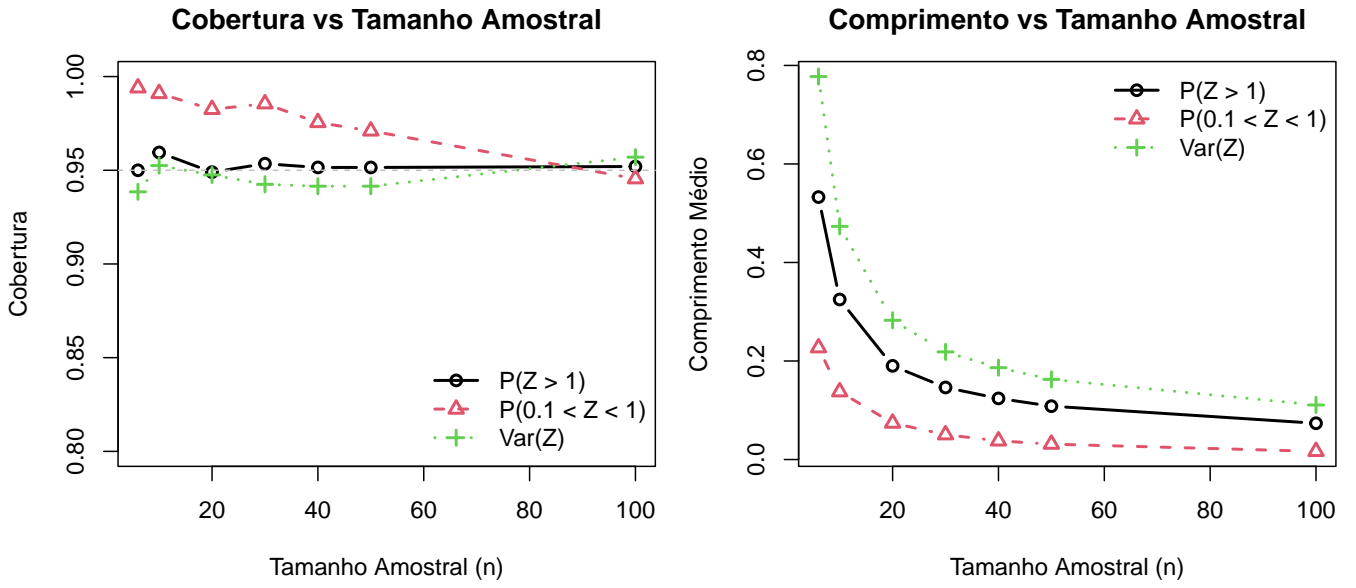


Figura 2: Análise de cobertura para diferentes tamanhos da amostra



3 Exercício: Seja (Z_1, \dots, Z_n) uma amostra aleatória de $Z \sim N(\mu, \sigma^2)$, com $\theta = (\mu, \sigma^2) \in (-\infty, \infty) \times (0, \infty)$

a) EMV para $g(\theta) = E_\theta(Z)$

$$g(\theta) = E_\theta(Z) = \mu$$

$$f(z|\mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z - \mu)^2}{2\sigma^2}\right)$$

$$L_{z_n}(\mu, \sigma^2) = \prod_{i=1}^n f(z_i|\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(z_i - \mu)^2}{2\sigma^2}\right) = (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{\sum_{i=1}^n (z_i - \mu)^2}{2\sigma^2}\right)$$

$$\ell(\mu, \sigma^2) = \log L_{z_n}(\mu, \sigma^2) = \log \left[\prod_{i=1}^n f(z_i|\mu, \sigma^2) \right] = \log \left[(2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{\sum_{i=1}^n (z_i - \mu)^2}{2\sigma^2}\right) \right]$$

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \mu)^2$$

$$\frac{d\ell(\mu, \sigma^2)}{d\mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (z_i - \mu) = U_n(\mu)$$

$$\frac{d\ell(\mu, \sigma^2)}{d\mu} = 0 \implies \sum_{i=1}^n (z_i - \hat{\mu}) = 0 \implies \hat{\mu}_{MV}(z_n) = \frac{1}{n} \sum_{i=1}^n z_i = \bar{Z}, \text{ pois } \frac{dU_n(\mu)}{d\mu} = -\frac{n}{\sigma^2} < 0$$

$$\widehat{g(\theta)} = \hat{\mu}_{MV}(z_n) = \bar{Z}$$

b) EMV para $g(\theta) = P_\theta(Z < 2)$

$$g(\theta) = P_\theta(Z < 2) = P_\theta\left(\underbrace{\frac{Z - \mu}{\sigma}}_{\tilde{Z} \sim N(0,1)} < \frac{2 - \mu}{\sigma}\right) = P_\theta(\tilde{Z} < \frac{2 - \mu}{\sigma}) = \Phi\left(\frac{2 - \mu}{\sigma}\right),$$

onde Φ é a função de distribuição acumulada da $\tilde{Z} \sim N(0, 1)$

$$\begin{aligned}\ell(\mu, \sigma^2) &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (z_i - \mu)^2 \\ \frac{d\ell(\mu, \sigma^2)}{d\sigma^2} &= -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (z_i - \mu)^2 = U_n(\sigma^2) \\ \frac{d\ell(\mu, \sigma^2)}{d\sigma^2} = 0 &\implies -\frac{n}{2\widehat{\sigma^2}} + \frac{1}{2(\widehat{\sigma^2})^2} \sum_{i=1}^n (z_i - \hat{\mu})^2 = 0 \iff \frac{n}{2\widehat{\sigma^2}} = \frac{1}{2(\widehat{\sigma^2})^2} \sum_{i=1}^n (z_i - \hat{\mu})^2 \\ n = \frac{1}{\widehat{\sigma^2}} \sum_{i=1}^n (z_i - \hat{\mu})^2 &\implies \widehat{\sigma^2}_{MV}(z_n) = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2, \\ \text{pois } \frac{dU_n(\sigma^2)}{d\sigma^2} &= \frac{n}{2(\sigma^2)^2} - \frac{\sum_{i=1}^n (z_i - \bar{Z})^2}{(\sigma^2)^3} < 0\end{aligned}$$

Assim, como EMV para $\mu : \hat{\mu}_{MV}(z_n) = \bar{Z}$ e EMV para $\sigma^2 : \widehat{\sigma^2}_{MV}(z_n) = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2$, pelo princípio da invariância

$$\widehat{g(\theta)} = \Phi\left(\frac{2 - \hat{\mu}_{MV}(z_n)}{\widehat{\sigma}_{MV}(z_n)}\right) = \Phi\left(\frac{2 - \bar{Z}}{\sqrt{\widehat{\sigma^2}_{MV}(z_n)}}\right)$$

c) EMV para $g(\theta) = P_\theta(2.6 < Z < 4)$

$$g(\theta) = P_\theta(2.6 < Z < 4) = P_\theta\left(\frac{2.6 - \mu}{\sigma} < \underbrace{\frac{Z - \mu}{\sigma}}_{\tilde{Z} \sim N(0,1)} < \frac{4 - \mu}{\sigma}\right) = \Phi\left(\frac{4 - \mu}{\sigma}\right) - \Phi\left(\frac{2.6 - \mu}{\sigma}\right)$$

Pelo princípio da invariância:

$$\widehat{g(\theta)} = \Phi\left(\frac{4 - \hat{\mu}}{\hat{\sigma}}\right) - \Phi\left(\frac{2.6 - \hat{\mu}_{MV}(z_n)}{\widehat{\sigma}_{MV}(z_n)}\right) = \Phi\left(\frac{4 - \bar{Z}}{\sqrt{\widehat{\sigma^2}_{MV}(z_n)}}\right) - \Phi\left(\frac{2.6 - \bar{Z}}{\sqrt{\widehat{\sigma^2}_{MV}(z_n)}}\right)$$

d) EMV para $g(\theta) = \text{Var}_\theta(Z)$

$g(\theta) = \text{Var}_\theta(Z) = \sigma^2$ e pelos cálculos acima, EMV para σ^2 é $\widehat{\sigma^2}_{MV}(z_n) = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2$. Assim, pelo princípio da invariância do EMV, temos

$$\widehat{g(\theta)} = \widehat{\sigma^2}_{MV}(z_n) = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2$$

e) Estimativas de MV com dados (2.4, 2.7, 2.3, 2, 2.5, 2.6)

$$n = 6$$

$$\bar{z} = \frac{2.4 + 2.7 + 2.3 + 2 + 2.5 + 2.6}{6} = \frac{14.5}{6} \approx 2.4167$$

$$\begin{aligned}\hat{\sigma}_{MV}^2(z_n) &= \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2 \\ &= \frac{1}{6} \sum_{i=1}^n (z_i - \bar{z})^2 \\ &= \frac{1}{6} [(2.4 - 2.4167)^2 + (2.7 - 2.4167)^2 + (2.3 - 2.4167)^2 + (2 - 2.4167)^2 + (2.5 - 2.4167)^2 + (2.6 - 2.4167)^2] \\ &= \frac{1}{6} [(-0.0167)^2 + (0.2833)^2 + (-0.1167)^2 + (-0.4167)^2 + (0.0833)^2 + (0.1833)^2] \\ &= \frac{1}{6} [0.00027889 + 0.08026889 + 0.01361889 + 0.17363889 + 0.00693889 + 0.03359889] \\ &= \frac{1}{6} \times 0.30834334 \approx 0.05139\end{aligned}$$

$$\hat{\sigma}_{MV}(z_n) = \sqrt{0.05139} \approx 0.2267$$

\Rightarrow Estimativas para cada item:

a) EMV para $g(\theta) = E_\theta(Z)$:

$$\widehat{g(\theta)} = \bar{z} = 2.4167$$

b) EMV para $g(\theta) = P_\theta(Z < 2)$:

$$\begin{aligned}\widehat{g(\theta)} &= \Phi\left(\frac{2 - \hat{\mu}_{MV}(z_n)}{\hat{\sigma}_{MV}(z_n)}\right) = \Phi\left(\frac{2 - 2.4167}{0.2267}\right) = \Phi\left(\frac{-0.4167}{0.2267}\right) \approx \Phi(-1.838) \\ &= 1 - \Phi(1.838) \\ \Phi(1.838) &\approx 0.9669 \quad (\text{da tabela da normal padrão}) \textbf{ ver aqui} \\ \Rightarrow \widehat{g(\theta)} &\approx 1 - 0.9669 = 0.0331\end{aligned}$$

c) EMV para $g(\theta) = P_\theta(2.6 < Z < 4)$:

$$\begin{aligned}\widehat{g(\theta)} &= \Phi\left(\frac{4 - \bar{Z}}{\sqrt{\hat{\sigma}_{MV}^2(z_n)}}\right) - \Phi\left(\frac{2.6 - \bar{Z}}{\sqrt{\hat{\sigma}_{MV}^2(z_n)}}\right) = \Phi\left(\frac{4 - 2.4167}{0.2267}\right) - \Phi\left(\frac{2.6 - 2.4167}{0.2267}\right) \\ &= \Phi\left(\frac{1.5833}{0.2267}\right) - \Phi\left(\frac{0.1833}{0.2267}\right) \\ &= \Phi(6.984) - \Phi(0.808) \\ \Phi(6.984) &\approx 1.0000 \\ \Phi(0.808) &\approx 0.7905 \quad (\text{da tabela da normal padrão}) \textbf{ ver aqui} \\ \Rightarrow \widehat{g(\theta)} &\approx 1.0000 - 0.7905 = 0.2095\end{aligned}$$

d) EMV para $g(\theta) = \text{Var}_\theta(Z)$:

$$\widehat{g(\theta)} = \hat{\sigma}_{MV}^2(z_n) = \frac{1}{n} \sum_{i=1}^n (z_i - \bar{Z})^2 = 0.05139, \text{ Cálculos no início da 3e)}$$

4 Exercício

Seja (Z_1, \dots, Z_n) uma amostra aleatória de $Z \sim f_\theta$, com $\theta \in (0, \infty)$, onde a função densidade de probabilidade é dada por: $f_\theta(x) = \theta x^{\theta-1}$, para $x \in (0, 1)$, e $f_\theta(x) = 0$ caso contrário.

a) EMV para $g(\theta) = E_\theta(Z)$

$$g(\theta) = E_\theta(Z) = \int_0^1 x \cdot \theta x^{\theta-1} dx = \theta \int_0^1 x^\theta dx = \theta \left[\frac{x^{\theta+1}}{\theta+1} \right]_0^1 = \frac{\theta}{\theta+1}.$$

$$L(\theta) = \prod_{i=1}^n f_\theta(z_i) = \prod_{i=1}^n \theta z_i^{\theta-1} = \theta^n \left(\prod_{i=1}^n z_i \right)^{\theta-1}.$$

$$\ell(\theta) = \log L(\theta) = n \log \theta + (\theta - 1) \sum_{i=1}^n \log z_i.$$

$$\frac{d\ell}{d\theta} = \frac{n}{\theta} + \sum_{i=1}^n \log z_i = U_n(\theta)$$

$$\frac{n}{\hat{\theta}} + \sum_{i=1}^n \log z_i = 0 \implies \hat{\theta}_{MV}(z_n) = -\frac{n}{\sum_{i=1}^n \log z_i}, \text{ pois } \frac{dU_n(\theta)}{d\theta} = -\frac{n}{\theta^2} < 0$$

Pelo princípio da invariância do EMV $\widehat{g(\theta)} = \frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n)+1}$.

b) EMV para $g(\theta) = P_\theta(Z > 0.3)$

$$g(\theta) = P_\theta(Z > 0.3) = \int_{0.3}^1 \theta x^{\theta-1} dx = [x^\theta]_{0.3}^1 = 1 - (0.3)^\theta.$$

Pelo princípio da invariância do EMV $\widehat{g(\theta)} = 1 - (0.3)^{\hat{\theta}_{MV}(z_n)}$.

c) EMV para $g(\theta) = P_\theta(0 < Z < 0.1)$

$$g(\theta) = P_\theta(0 < Z < 0.1) = \int_0^{0.1} \theta x^{\theta-1} dx = [x^\theta]_0^{0.1} = (0.1)^\theta.$$

Pelo princípio da invariância do EMV $\widehat{g(\theta)} = (0.1)^{\hat{\theta}_{MV}(z_n)}$.

d) EMV para $g(\theta) = \text{Var}_\theta(Z)$

$$E_\theta(Z) = \frac{\theta}{\theta+1},$$

$$E_\theta(Z^2) = \int_0^1 x^2 \cdot \theta x^{\theta-1} dx = \theta \int_0^1 x^{\theta+1} dx = \theta \left[\frac{x^{\theta+2}}{\theta+2} \right]_0^1 = \frac{\theta}{\theta+2},$$

$$\text{Var}_\theta(Z) = E_\theta(Z^2) - [E_\theta(Z)]^2 = \frac{\theta}{\theta+2} - \left(\frac{\theta}{\theta+1} \right)^2.$$

Pelo princípio da invariância do EMV $\widehat{g(\theta)} = \frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n)+2} - \left(\frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n)+1} \right)^2$.

e) Estimativas de MV com dados (0.12, 0.50, 0.20, 0.23, 0.30, 0.11)

$$n = 6,$$

$$\sum_{i=1}^n \log z_i = \log(0.12) + \log(0.50) + \log(0.20) + \log(0.23) + \log(0.30) + \log(0.11)$$

$$\approx -2.1203 - 0.6931 - 1.6094 - 1.4697 - 1.2040 - 2.2073 = -9.3038,$$

$$\hat{\theta}_{MV}(z_n) = -\frac{n}{\sum_{i=1}^n \log z_i} = -\frac{6}{-9.3038} \approx 0.6449.$$

a) Estimativa para $g(\theta) = E_\theta(Z)$:

$$\widehat{g(\theta)} = \frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n) + 1} = \frac{0.6449}{0.6449 + 1} \approx \frac{0.6449}{1.6449} \approx 0.3921.$$

b) Estimativa para $g(\theta) = P_\theta(Z > 0.3)$:

$$(0.3)^{\hat{\theta}_{MV}(z_n)} = \exp(0.6449 \cdot \log(0.3)) \approx \exp(0.6449 \cdot (-1.20397)) \approx \exp(-0.776) \approx 0.4603,$$

$$\widehat{g(\theta)} = 1 - (0.3)^{\hat{\theta}_{MV}(z_n)} = 1 - 0.4603 \approx 0.5397.$$

c) Estimativa para $g(\theta) = P_\theta(0 < Z < 0.1)$:

$$(0.1)^{\hat{\theta}_{MV}(z_n)} = \exp(0.6449 \cdot \log(0.1)) \approx \exp(0.6449 \cdot (-2.302585)) \approx \exp(-1.484) \approx 0.2269,$$
$$\widehat{g(\theta)} \approx 0.2269.$$

d) Estimativa para $g(\theta) = \text{Var}_\theta(Z)$:

$$\frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n) + 2} \approx \frac{0.6449}{2.6449} \approx 0.2438,$$
$$\left(\frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n) + 1} \right)^2 \approx \left(\frac{0.6449}{1.6449} \right)^2 \approx (0.3921)^2 \approx 0.1537,$$
$$\widehat{g(\theta)} = \frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n) + 2} - \left(\frac{\hat{\theta}_{MV}(z_n)}{\hat{\theta}_{MV}(z_n) + 1} \right)^2 = \widehat{g(\theta)} \approx 0.2438 - 0.1537 = 0.0901.$$