

UNIVERSIDADE DE SÃO PAULO
Programa de Post-Graduação em Estatística

Katerine Zuniga Lastra, Marília de Melo Sombra, Alex Monito Nhancololo

Lista 02 – Semestre de 2024-II – Prof. Silvia Ferrari

3) Suponha que $X \sim \text{Poisson}(\lambda)$, $\lambda > 0$, e que $Y|X = x \sim \text{Poisson}(x\lambda)$. Considere o problema de estimar λ com base em (X, Y) .

(a) Mostre que (X, Y) é uma estatística suficiente minimal para λ , mas não é completa.

$$f(x) = \begin{cases} \frac{\lambda^x e^{-\lambda}}{x!} & \text{se } x = 1, 2, \dots \\ e^{-\lambda} & \text{se } x = 0 \end{cases}, \text{ e } f(y|x) = \begin{cases} \frac{(x\lambda)^y e^{-x\lambda}}{y!} & \text{se } x = 1, 2, \dots \\ 0 & \text{se } x = 0 \end{cases}$$

$$\begin{aligned} f(x, y) &\stackrel{ind}{=} f(x) \times f(y|x) \\ &= \frac{\lambda^x e^{-\lambda}}{x!} \times \frac{(x\lambda)^y e^{-x\lambda}}{y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) + e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) \\ &= \frac{\lambda^{x+y} e^{-\lambda(1+x)} x^y}{x! y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) + e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) \\ &= \underbrace{e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)}}_{g_\lambda(T(x,y))} \underbrace{\frac{x^y}{x! y!} \mathbb{I}_{\{1,2,\dots\}}(x, y)}_{h(x,y)} \end{aligned}$$

$g_\lambda[T(x, y)]$ é função de λ e X, Y , apenas, logo, $T(X, Y) = (X, Y)$ é suficiente.

Sejam (x, y) e (x', y') pontos amostrais do espaço amostral χ .

$T(x, y) = T(x', y') \iff (x', y') \in D(x, y)$:

$$D(x, y) = \{(x', y') \in \chi : P(x', y') = P(x, y) \cdot h(x, y; x', y'), \forall \lambda \in \mathbb{R}_+, h(x, y; x', y') > 0\}$$

$$P(x', y') = e^{-\lambda} \mathbb{I}_{\{x'=0\}}(y') + \lambda^{x'+y'} e^{-\lambda(1+x')} \frac{(x')^{y'}}{x'! y'!} \mathbb{I}_{\{1,2,\dots\}}(x', y')$$

Caso 1) \implies

$$T(x, y) = T(x', y') \implies (x, y) = (x', y')$$

$$\begin{aligned} P(x', y') &= e^{-\lambda} \mathbb{I}_{\{x'=0\}}(y') + \lambda^{x'+y'} e^{-\lambda(1+x')} \frac{(x')^{y'}}{x'! y'!} \mathbb{I}_{\{1,2,\dots\}}(x', y') \\ &= e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x! y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \cdot h(x, y; x', y'), \forall \lambda \in \mathbb{R}_+ \\ &= e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x! y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \cdot 1, \forall \lambda \in \mathbb{R}_+, h(x, y; x', y') = 1 \\ &= e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x! y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \\ &(x', y') \in D(x, y) \end{aligned}$$

Caso 2) \iff

$$(x', y') \in D(x, y) \implies P(x', y') = P(x, y) \cdot h(x, y; x', y'), \forall \lambda \in \mathbb{R}_+, h(x, y; x', y') > 0$$

$$P(x', y') = P(x, y) \cdot 1, \forall \lambda \in \mathbb{R}_+$$

$$P(x', y') = P(x, y) \cdot 1, \forall \lambda \in \mathbb{R}_+$$

$$e^{-\lambda} \mathbb{I}_{\{x'=0\}}(y') + \lambda^{x'+y'} e^{-\lambda(1+x')} \frac{(x')^{y'}}{x'!y'} \mathbb{I}_{\{1,2,\dots\}}(x', y') = e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x!y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \cdot 1$$

$$e^{-\lambda} \mathbb{I}_{\{x'=0\}}(y') + \lambda^{x'+y'} e^{-\lambda(1+x')} \frac{(x')^{y'}}{x'!y'} \mathbb{I}_{\{1,2,\dots\}}(x', y') = e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x!y!} \mathbb{I}_{\{1,2,\dots\}}(x, y)$$

$(x', y') = (x, y)$, pelo princípio de semelhança de termos, e $x = x', y = y'$, por se tratar de par ordenado.

Se $(x, y) \neq (x', y')$, não se observa a proporcionalidade entre $P(x', y')$ e $P(x, y)$

$$\implies T(X, Y) = T(X', Y')$$

Portanto, pelo Teorema de Schervish, a estatística $T(X, Y) = (X, Y)$ é suficiente minimal para λ .

\implies Mostrando que $T(X, Y)$ não completa

Seja, $g(T)$ função da estatística suficiente minimal $T(X, Y)$

$$\mathbb{E}[g(T)] = 0, \forall \lambda > 0$$

$$P[g(T) = 0] \neq 1$$

$$\mathbb{E}[g(T)] = \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} g(T) \left[e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x!y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \right]$$

$$\mathbb{E}[g(T)] = \lim_{a \rightarrow \infty} \sum_{b=0}^a \sum_{y=0}^b g(T) \left[e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \frac{\lambda^x e^{-\lambda}}{x!} \times \frac{(x\lambda)^y e^{-x\lambda}}{y!} \mathbb{I}_{\{1,2,\dots\}}(x, y) \right]$$

$$\mathbb{E}[g(T)] = 0$$

O limite convirirá para zero pois os termos do denominador serão maiores que os do numerador quando $a \rightarrow \infty$ e $b \rightarrow \infty$. No entanto não necessariamente significa que $g(T) = 0$.

Contraexemplo

$$\begin{aligned} g(T) &= X^2 - X - Y \\ \mathbb{E}[g(T)] &= \mathbb{E}[X^2 - X - Y] \\ &= \mathbb{E}[X^2] - \mathbb{E}[X] - \mathbb{E}[Y] \\ &= \text{Var}_{\lambda}(X) + (\mathbb{E}[X])^2 - \mathbb{E}[X] - \mathbb{E}[\mathbb{E}[Y|X]] \end{aligned}$$

Na distribuição Poisson $\text{Var}(\cdot) = (\bar{\cdot})$

$$\begin{aligned} \mathbb{E}[g(T)] &= \lambda + \lambda^2 - \lambda - \mathbb{E}[X\lambda] \\ &= \lambda^2 - \lambda\mathbb{E}[X] \\ &= \lambda^2 - \lambda \cdot \lambda, \forall \lambda > 0 \\ &= 0, \text{ mas } g(T) \neq 0 \end{aligned}$$

$$\mathbb{E}[g(T)] = 0$$

$$P[g(T) = 0] \neq 1$$

(b) Obtenha o limite inferior de Cramér-Rao para a variância de estimadores não viciados de λ e compare com a variância de X , que é um estimador não viciado de λ .

$$\begin{aligned} \text{LICR} &= \frac{\left(\frac{d}{d\lambda}\lambda\right)^2}{I(\lambda)} = \frac{1}{I(\lambda)} \\ I(\lambda) &= -\mathbb{E}\left[\frac{d^2}{d\lambda^2} \log(P(X, Y))\right] \end{aligned}$$

Assumindo existência da segunda derivada do log da função e válidas todas condições de regularidade.

$$P(X, Y) = e^{-\lambda} \mathbb{I}_{\{x=0\}}(y) + \lambda^{x+y} e^{-\lambda(1+x)} \frac{(x)^y}{x!y!} \mathbb{I}_{\{1,2,\dots\}}(x, y)$$

$$\log(P(X, Y)) = -\lambda \mathbb{I}_{\{x=0\}} + [(x+y) \log(\lambda) - \lambda(1+x) + y \log(x) - \log(x!y!)] \mathbb{I}_{\{1,2,\dots\}}(x, y)$$

$$\frac{d}{d\lambda} \log(P(x, y)) = -1 \mathbb{I}_{\{x=0\}} + \left[\frac{x+y}{\lambda} - (1+x) \right] \mathbb{I}_{\{1,2,\dots\}}(x, y), \lambda > 0$$

$$\frac{d^2}{d\lambda^2} \log(P(x, y)) = -\frac{x+y}{\lambda^2} \mathbb{I}_{\{1,2,\dots\}}(x, y), \lambda > 0 (**)$$

$$I(\lambda) = -\mathbb{E} \left[-\frac{X+Y}{\lambda^2} \right]$$

$$I(\lambda) = \frac{1}{\lambda^2} (\mathbb{E}[X] + \mathbb{E}[Y])$$

$$I(\lambda) = \frac{1}{\lambda^2} (\lambda + \mathbb{E}[\mathbb{E}[Y|X]])$$

$$I(\lambda) = \frac{1}{\lambda^2} (\lambda + \mathbb{E}[X\lambda])$$

$$I(\lambda) = \frac{1}{\lambda^2} (\lambda + \lambda \mathbb{E}[X])$$

$$I(\lambda) = \frac{1}{\lambda^2} (\lambda + \lambda \cdot \lambda)$$

$$I(\lambda) = \frac{1+\lambda}{\lambda}, \lambda > 0$$

$$\text{LICR} = \frac{1}{I(\lambda)}$$

$$\text{LICR} = \frac{1}{\frac{\lambda}{1+\lambda}}$$

$$\begin{cases} \text{LICR} &= \frac{\lambda}{1+\lambda} \\ \text{Var}(X) &= \lambda \end{cases} \implies \text{LICR} \neq \text{Var}(X), \lambda > 0$$

(c) Encontre o estimador de máxima verossimilhança de λ e obtenha seu viés.

Resolução

$$\frac{d}{d\lambda} \log L(\lambda; x, y) = \left[\frac{x+y}{\lambda} - (1+x) \right] \mathbb{I}_{\{0,1,2,\dots\}}(x, y), \lambda > 0$$

$$\frac{d^2}{d\lambda^2} \log(P(x, y)) = -\frac{x+y}{\lambda^2} \mathbb{I}_{\{1,2,\dots\}}(x, y) < 0, \lambda > 0 (**)$$

$$\frac{d}{d\lambda} \log L(\lambda; x, y) = 0$$

$$\left[\frac{x+y}{\lambda} - (1+x) \right] \mathbb{I}_{\{0,1,2,\dots\}}(x, y) = 0, \lambda > 0$$

$$\frac{x+y}{\lambda} = (1+x) \mathbb{I}_{\{0,1,2,\dots\}}(x, y), \lambda > 0$$

$$x+y = (1+x)\lambda \mathbb{I}_{\{0,1,2,\dots\}}(x, y), \lambda > 0$$

$$\hat{\lambda} = \frac{x+y}{1+x} \mathbb{I}_{\{0,1,2,\dots\}}(x, y), \lambda > 0$$

$$\hat{\lambda}_{MV} = \frac{X+Y}{1+X}, \text{ pois, } \frac{d^2}{d\lambda^2} \log(P(x, y)) < 0$$

\implies Viés do estimador

$$\begin{aligned}
\mathbb{E}[\hat{\lambda}_{MV} - \lambda] &= \mathbb{E}[\hat{\lambda}_{MV}] - \lambda \\
&= \mathbb{E}\left[\frac{X+Y}{1+X}\right] - \lambda \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} \frac{x+y}{1+x} f(x, y|x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} \frac{x}{1+x} f(x, y|x) + \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} \frac{y}{1+x} f(x, y|x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} \frac{x}{1+x} f(x)f(y|x) + \sum_{x=0}^{\infty} \sum_{y=0}^{\infty} \frac{y}{1+x} f(x)f(y|x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \frac{x}{1+x} f(x) \sum_{y=0}^{\infty} f(y|x) + \sum_{x=0}^{\infty} \frac{1}{1+x} f(x) \sum_{y=0}^{\infty} y f(y|x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \frac{x}{1+x} f(x) \sum_{y=0}^{\infty} f(y|x) + \sum_{x=0}^{\infty} \frac{1}{1+x} f(x) \sum_{y=0}^{\infty} y f(y|x), \quad \text{f}(y|x) \text{ é função de prob.} \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \frac{x}{1+x} f(x) \sum_{y=0}^{\infty} f(y|x) + \sum_{x=0}^{\infty} \frac{1}{1+x} f(x) \sum_{y=0}^{\infty} y f(y|x), \quad \text{f}(y|x) \text{ é função de prob.} \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \frac{x}{1+x} f(x) + \sum_{x=0}^{\infty} \frac{\lambda x}{1+x} f(x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \sum_{x=0}^{\infty} \left[\frac{x}{1+x} f(x) + \frac{\lambda x}{1+x} f(x) \right] \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \sum_{x=0}^{\infty} \frac{x}{1+x} f(x) \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \sum_{x=0}^{\infty} \frac{x}{1+x} \frac{\lambda^x e^{-\lambda}}{x!} \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \sum_{x=0}^{\infty} \frac{x \lambda^x e^{-\lambda}}{(1+x)!}, \quad \text{seja } x+1=a, \text{ se } x=0, a=1 \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \sum_{a=1}^{\infty} \frac{(a-1) \lambda^{a-1} e^{-\lambda}}{a!} \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \left[\sum_{a=1}^{\infty} \frac{a \lambda^{a-1} e^{-\lambda}}{a!} - \sum_{a=1}^{\infty} \frac{\lambda^{a-1} e^{-\lambda}}{a!} \right] \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \left[\frac{1}{\lambda} \sum_{a=0}^{\infty} \frac{a \lambda^a e^{-\lambda}}{a!} - \frac{1}{\lambda} \sum_{a=1}^{\infty} \frac{\lambda^a e^{-\lambda}}{a!} \right] \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= (1+\lambda) \left[\frac{1}{\lambda} \mathbb{E}(a) - \frac{1}{\lambda} \left(1 - \frac{\lambda^0 e^{-\lambda}}{0!} \right) \right], \quad \sum_{a=0}^{\infty} \frac{\lambda^a e^{-\lambda}}{a!} = \frac{\lambda^0 e^{-\lambda}}{0!} + \sum_{a=1}^{\infty} \frac{\lambda^a e^{-\lambda}}{a!} = 1 \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \frac{1+\lambda}{\lambda} \left[\mathbb{E}(a) - \frac{1}{\lambda} \left(1 - e^{-\lambda} \right) \right] \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \frac{1+\lambda}{\lambda} \left[\lambda - \left(1 - e^{-\lambda} \right) \right] \\
\mathbb{E}\left[\frac{X+Y}{1+X}\right] &= \frac{1+\lambda}{\lambda} \left[\lambda - 1 + e^{-\lambda} \right]
\end{aligned}$$

$$\begin{aligned}\mathbb{E} \left[\frac{X+Y}{1+X} \right] &= \frac{1+\lambda}{\lambda} \left[\lambda - 1 + e^{-\lambda} \right] \\ \mathbb{E} \left[\hat{\lambda}_{MV} \right] - \lambda &= \mathbb{E} \left[\frac{X+Y}{1+X} \right] - \lambda \\ \mathbb{E} \left[\hat{\lambda}_{MV} \right] - \lambda &= \frac{1+\lambda}{\lambda} \left(\lambda - 1 + e^{-\lambda} \right) - \lambda\end{aligned}$$

Assim, o viés de do estimador $\mathbb{E} \left[\hat{\lambda}_{MV} \right]$ é $\frac{1+\lambda}{\lambda} (\lambda - 1 + e^{-\lambda}) - \lambda$.

Questão 4 Seja X uma variável aleatória com distribuição geométrica e função de probabilidade $P_\theta(X = x) = \theta(1-\theta)^x$, $x = 0, 1, \dots$. Qual é a menor variância possível para um estimador não viciado de θ (baseado em uma única observação)? Compare essa variância com o limite inferior de Cramér-Rao.

Um possível estimador não viciado de θ pode ser definido como $\delta(X) = X$, em que $E_\theta(\delta(X)) = \theta$, $\forall \theta \in (0, 1)$. Observe que a densidade de X pode ser escrita como

$$\begin{aligned}p_\theta(x) &= \theta(1-\theta)^x I_{\{0,\dots,\infty\}}(x) \\ &= \exp\{x \log(1-\theta) + \log(\theta)\} I_{\{0,\dots,\infty\}}(x) \\ &= \exp\{T(x)\eta(\theta) - B(\theta)\} h(x)\end{aligned}$$

em que $\eta(\theta) = \log(1-\theta)$, $T(X) = X$, $B(\theta) = -\log(\theta)$ e $h(x) = I_{\{0,\dots,\infty\}}(x)$. Como o espaço paramétrico de $\eta(\theta) \in (-\infty, 0)$ contém retângulos unidimensionais abertos, a família é de posto completo, logo, a estatística $T(X) = X$ é suficiente e completa. Assim, como $\delta(X) = X$ é não viciado e função de uma estatística suficiente e completa, então, $\delta(X)$ é ENVVUM para θ .

Para calcular a variância do estimador, temos que

$$Var_\theta(\delta(X)) = E_\theta[\delta(X)^2] - E_\theta^2[\delta(X)] = \theta(1-\theta)^0 + [\theta(1-\theta)^0]^2 = \theta - \theta^2 = \theta(1-\theta)$$

Para calcular o Limite Inferior de Cramér-Rao(LICR), temos

A função de verossimilhança é dada por:

$$L(\theta, x) = \theta(1-\theta)^x$$

A função de log-verossimilhança é dada por

$$l(\theta, x) = \log(\theta) + x \log(1-\theta)$$

A primeira derivada da função de log-verossimilhança é

$$\frac{\partial}{\partial \theta} l(\theta, x) = \frac{1}{\theta} - \frac{x}{1-\theta}$$

A derivada segunda da função de log-verossimilhança é

$$\frac{\partial^2}{\partial \theta^2} l(\theta, x) = -\frac{1}{\theta^2} - \frac{x}{(1-\theta)^2}$$

Assim, a informação de Fisher para θ é dada por

$$I(\theta) = -E_\theta \left[\frac{\partial^2}{\partial \theta^2} l(\theta, x) \right] = \frac{1}{\theta^2} + \frac{E_\theta[X]}{(1-\theta)^2} = \frac{1}{\theta^2} + \frac{(1-\theta)}{\theta(1-\theta)^2} = \frac{1}{\theta^2} + \frac{1}{\theta(1-\theta)} = \frac{(1-\theta)+\theta}{\theta^2(1-\theta)} = \frac{1}{\theta^2(1-\theta)}$$

Logo, o LICR é dado por

$$LICR = \frac{1}{I(\theta)} = \frac{1}{\frac{1}{\theta^2(1-\theta)}} = \theta^2(1-\theta)$$

Portanto, observamos que $Var_\theta = \theta(1-\theta) > \theta^2(1-\theta)$, $\forall \theta \in (0, 1)$.

14. Seja \mathcal{F} a classe das densidades de parâmetro $\theta(\theta > 0)$ com média $1/\theta$ e variância $1/\theta^2$ e que satisfazem as condições para a validade da desigualdade da informação.

(a) Mostre que uma densidade que minimiza a informação de Fisher para θ na classe \mathcal{F} é $f(x; \theta) = \theta \exp\{-\theta x\} I_{(0, \infty)}(x)$. Sugestão: use a desigualdade da informação.

Seja X uma variável aleatória tal que X tem distribuição P_θ , em que $P_\theta \in \mathcal{F}$ então, $E[X] = \frac{1}{\theta}$ e $\text{Var}(x) = \frac{1}{\theta^2}$.
Seja $\delta(x) = x$, então usando o teorema de desigualdade da informação;

$$\text{Var}(X) \geq \frac{\left(\frac{\partial}{\partial \theta} E[X]\right)^2}{I(\theta)},$$

onde $I(\theta)$ é a informação de Fisher.

$$\begin{aligned} \text{Var}(x) &\geq \frac{\left[\frac{\partial}{\partial \theta} E(x)\right]^2}{I(\theta)} \Leftrightarrow \frac{1}{\theta^2} \geq \frac{\left[-\frac{1}{\theta^2}\right]^2}{I(\theta)} = \frac{\frac{1}{\theta^4}}{I(\theta)} \\ &\Rightarrow I(\theta) \geq \frac{1}{\theta^2} \end{aligned}$$

Agora, devemos verificar se a densidade sugerida minimiza a informação de Fisher.

Assim, Desigualdade da Informação de Fisher é dada como

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(x; \theta) \right]$$

Assim temos que se a densidade é

$$\begin{aligned} f(x; \theta) &= \theta \exp\{-\theta x\} I_{(0, \infty)}(x) \\ \log f(x; \theta) &= \log \theta - \theta x. \\ \frac{\partial \log(x; \theta)}{\partial \theta} &= \frac{1}{\theta} - x. \\ \frac{\partial^2 \log f(x, \theta)}{\partial \theta^2} &= -\frac{1}{\theta^2} \end{aligned}$$

Logo

$$I(\theta) = -E \left[-\frac{1}{\theta^2} \right] = \frac{1}{\theta^2}$$

é miníma na classe \mathcal{F}

(b) Considere a distribuição $N(1/\theta, 1/\theta^2)$ e encontre o LICR (limite inferior de Cramer-Rao para variâncias de estimadores não viciados de $g(\theta)$). Compare-o com o correspondente LICR para a distribuição exponencial.

Considere a distribuição $N(1/\theta, 1/\theta^2)$, $\theta > 0$. A densidade de probabilidade é dada por:

$$\begin{aligned} p_\theta(x) &= \frac{1}{\sqrt{2\pi \frac{1}{\theta^2}}} \exp \left\{ -\frac{\theta^2}{2} \left(x - \frac{1}{\theta} \right)^2 \right\}. \\ \log p_\theta(x) &= -\frac{\theta^2}{2} \left(x^2 - 2\frac{x}{\theta} + \frac{1}{\theta^2} \right) - \frac{1}{2} \log(2\pi) + \log \theta \\ \log p_\theta(x) &= -\frac{\theta^2 x^2}{2} + \theta x - \frac{1}{2} - \log(2\pi) + \log \theta \\ \frac{\partial}{\partial \theta} \log p_\theta(x) &= -\theta x^2 + x + \frac{1}{\theta}. \\ \frac{\partial^2}{\partial \theta^2} \log p_\theta(x) &= -x^2 - \frac{1}{\theta^2}. \end{aligned}$$

A informação de Fisher é dada por:

$$I(\theta) = -E \left[\frac{\partial^2}{\partial \theta^2} \log p_\theta(x) \right].$$

Então;

$$\begin{aligned} I(\theta) &= -E \left[-x^2 - \frac{1}{\theta^2} \right] = E[x^2] + \frac{1}{\theta^2} \\ I(\theta) &= -E \left[-x^2 - \frac{1}{\theta^2} \right] = E[x^2] + \frac{1}{\theta^2} \\ &= \text{Var}[x] + (E[x])^2 + \frac{1}{\theta^2} \\ &= \frac{1}{\theta^2} + \frac{1}{\theta^2} + \frac{1}{\theta^2} = \frac{3}{\theta^2} \end{aligned}$$

A fórmula do Limite Inferior de Cramer-Rao (LICR) para variâncias de estimadores não-viesados é dada por:

$$LICR = \frac{\left[\frac{\partial}{\partial \theta} E(x) \right]^2}{I(\theta)}$$

Então

$$LICR = \frac{\frac{1}{\theta^4}}{\frac{3}{\theta^2}} = \frac{1}{3\theta^2}$$

Por outro lado, para o caso da distribuição exponencial no item (a), o LICR foi dado por:

$$LICR_a = \frac{\frac{1}{\theta^4}}{\frac{1}{\theta^2}} = \frac{1}{\theta}$$

Portanto, comparando os dois resultados, o LICR para a distribuição normal $N\left(\frac{1}{\theta}, \frac{1}{\theta^2}\right)$ é $\frac{1}{3\theta^2}$, enquanto o LICR para a distribuição exponencial é $\frac{1}{\theta^2}$. Logo, o LICR da distribuição exponencial é maior do que o da distribuição normal.

Como $I(\theta)$ da distribuição exponencial minimiza a informação de Fisher dentro da classe \mathcal{F} , o LICR correspondente será o máximo dentro dessa classe.

22. Sejam X_1, \dots, X_n observações independentes de X , que tem distribuição seminormal com função densidade de probabilidade

$$f(x; \xi) = \left(\frac{2}{\pi} \right)^{1/2} \exp \left\{ -\frac{(x - \xi)^2}{2} \right\} \mathbb{I}_{[\xi, +\infty)}(x), \quad \xi \in \mathbb{R}.$$

(a) Obtenha uma estatística suficiente minimal para ξ .

Resolução

$$\begin{aligned}
f(x; \xi) &= \left(\frac{2}{\pi}\right)^{1/2} \exp\left\{-\frac{(x - \xi)^2}{2}\right\} \mathbb{I}_{[\xi, +\infty)}(x), \quad \xi \in \mathbb{R} \\
f(x; \xi) &\stackrel{\text{ind}}{=} \prod_{i=1}^n \left(\frac{2}{\pi}\right)^{1/2} \exp\left\{-\frac{(x_i - \xi)^2}{2}\right\} \mathbb{I}_{\{\xi \leq x_i < \infty\}}(x), \quad \xi \in \mathbb{R} \\
f(x; \xi) &= \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\sum_{i=1}^n \frac{(x_i - \xi)^2}{2}\right\} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x) \\
f(x; \xi) &= \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\sum_{i=1}^n \frac{x_i^2 - 2x_i\xi + \xi^2}{2}\right\} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x) \\
f(x; \xi) &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n \xi^2}{2}} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x) \\
f(x; \xi) &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x), \quad (*) \\
f(x; \xi) &= \underbrace{e^{\xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x)}_{g_\xi[T(x)]} \underbrace{\left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} \mathbb{I}_{\{X_{(n)} < \infty\}}(x)}_{h(x)}
\end{aligned}$$

$g_\xi[T(x)]$ é função de ξ e X , apenas, pela estatística, $T(X)$ e $h(x) \geq 0$, logo,

$T(X) = (\sum_{i=1}^n x_i, X_{(1)}) = (\sum_{i=1}^n x_i, X_{(1)})$ é estatística suficiente para ξ .

⇒ Verificando a suficiência minimal

Sejam x, y pontos amostrais do espaço amostral χ .

$T(x) = T(y) \iff y \in D(x)$:

$$D(x) = \{y \in \chi : P(y) = P(x) \cdot h(x, y), \forall \xi \in \mathbb{R}, h(x, y) > 0\}$$

Caso 1) ⇒

$$\begin{aligned}
T(x) = T(y) &\implies \left(x_{(1)}, \sum_{i=1}^n x_i\right) = \left(y_{(1)}, \sum_{i=1}^n y_i\right) \\
P(y) &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n y_i^2}{2}} e^{\xi \sum_{i=1}^n y_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \\
P(y) &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n y_i^2}{2}} e^{\xi \sum_{i=1}^n y_i} e^{-\frac{n\xi^2}{2}} \frac{e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n x_i^2}{2}}}{e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n x_i^2}{2}}} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \times \\
&\quad \times \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{x_{(n)} < \infty\}}(x) \\
P(y) &= \left(\frac{2}{\pi}\right)^{\frac{n}{2}} e^{-\frac{\sum_{i=1}^n y_i^2}{2} - \frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n y_i - \xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} \times \\
&\quad \times \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{x_{(n)} < \infty\}}(x) \\
P(y) &= \left(\frac{2}{\pi}\right)^{\frac{n}{2}} e^{-\frac{\sum_{i=1}^n y_i^2}{2} - \frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi (\sum_{i=1}^n y_i - \sum_{i=1}^n x_i)} e^{-\frac{n\xi^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} \times \\
&\quad \times \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{x_{(n)} < \infty\}}(x) \\
P(y) &= \underbrace{\left(\frac{2}{\pi}\right)^{\frac{n}{2}} e^{-\frac{n\xi^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{x_{(n)} < \infty\}}(x)}_{P(x)} h(x, y) \\
h(x, y) &= e^{-\frac{\sum_{i=1}^n y_i^2}{2} - \frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi (\sum_{i=1}^n y_i - \sum_{i=1}^n x_i)} \times \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \\
P(y) &= P(x) h(x, y) \\
y &\in D(x)
\end{aligned}$$

Caso 2) \Leftarrow

$$y \in D(x)$$

$$P(y) = P(x) \cdot h(x, y), \forall \xi \in \mathbb{R}, h(x, y) > 0$$

$$\begin{aligned} P(y) &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n y_i^2}{2}} e^{\xi \sum_{i=1}^n y_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) \mathbb{I}_{\{y_{(n)} < \infty\}}(y) \\ &= \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{x_{(n)} < \infty\}}(x) h(x, y), h(x, y) > 0, \forall \xi \in \mathbb{R} \end{aligned}$$

$$\implies e^{\xi \sum_{i=1}^n y_i} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) = e^{\xi \sum_{i=1}^n x_i} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R}$$

Caso a) Supondo que $\sum_{i=1}^n y_i = \sum_{i=1}^n x_i$ e $y_{(1)} \neq x_{(1)}$, $\forall \xi \in \mathbb{R}$

$$e^{\xi \sum_{i=1}^n y_i} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) = e^{\xi \sum_{i=1}^n x_i} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R} \implies \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) = \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R}$$

Assim, se $y_{(1)} < x_{(1)}$ $\implies \exists \xi \in \mathbb{R} : y_{(1)} < \xi < x_{(1)}$ logo, $\mathbb{I}_{\{y_{(1)} \geq \xi\}} = 0$ e $\mathbb{I}_{\{x_{(1)} \geq \xi\}} = 1$ (Absurdo!)

Por outro lado, se $x_{(1)} < y_{(1)}$ $\implies \exists \xi \in \mathbb{R} : x_{(1)} < \xi < y_{(1)}$ logo, $\mathbb{I}_{\{y_{(1)} \geq \xi\}} = 1$ e $\mathbb{I}_{\{x_{(1)} \geq \xi\}} = 0$ (Absurdo!)

A indicadora só assume dois valores 0 ou 1. Assim, sob condição $y_{(1)} < \xi < x_{(1)}$, ξ não teria um valor correspondente. Idem para $x_{(1)} < \xi < y_{(1)}$.

Logo, para que $e^{\xi \sum_{i=1}^n y_i} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) = e^{\xi \sum_{i=1}^n x_i} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R}$,

$$y_{(1)} = x_{(1)}$$

Caso b): Supondo que $\sum_{i=1}^n y_i \neq \sum_{i=1}^n x_i$ e $y_{(1)} = x_{(1)}$, $\forall \xi \in \mathbb{R}$

$$\begin{aligned} e^{\xi \sum_{i=1}^n y_i} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) &= e^{\xi \sum_{i=1}^n x_i} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R} \implies e^{\xi \sum_{i=1}^n y_i} = e^{\xi \sum_{i=1}^n x_i}, \forall \xi \in \mathbb{R} \\ &\implies \frac{e^{\xi \sum_{i=1}^n y_i}}{e^{\xi \sum_{i=1}^n x_i}} = 1, \forall \xi \in \mathbb{R} \\ &\implies e^{\xi \sum_{i=1}^n y_i - \xi \sum_{i=1}^n x_i} = 1, \forall \xi \in \mathbb{R} \\ &\implies e^{\xi (\sum_{i=1}^n y_i - \sum_{i=1}^n x_i)} = 1, \forall \xi \in \mathbb{R} \end{aligned}$$

$$\text{O que só é possível se } \sum_{i=1}^n y_i = \sum_{i=1}^n x_i$$

Caso c) Supondo que $\sum_{i=1}^n y_i \neq \sum_{i=1}^n x_i$ e $y_{(1)} \neq x_{(1)}$, $\forall \xi \in \mathbb{R}$

$e^{\xi \sum_{i=1}^n y_i} \mathbb{I}_{\{y_{(1)} \geq \xi\}}(y) = e^{\xi \sum_{i=1}^n x_i} \mathbb{I}_{\{x_{(1)} \geq \xi\}}(x), \forall \xi \in \mathbb{R}$. Esta igualdade não se é satisfeita, pelas justificativas vistas em a) e b)

Logo, $(x_{(1)}, \sum_{i=1}^n x_i) = (y_{(1)}, \sum_{i=1}^n y_i)$ e

$$T(X) = \left(\sum_{i=1}^n x_i, X_{(1)} \right),$$

é estatística suficiente minimal.

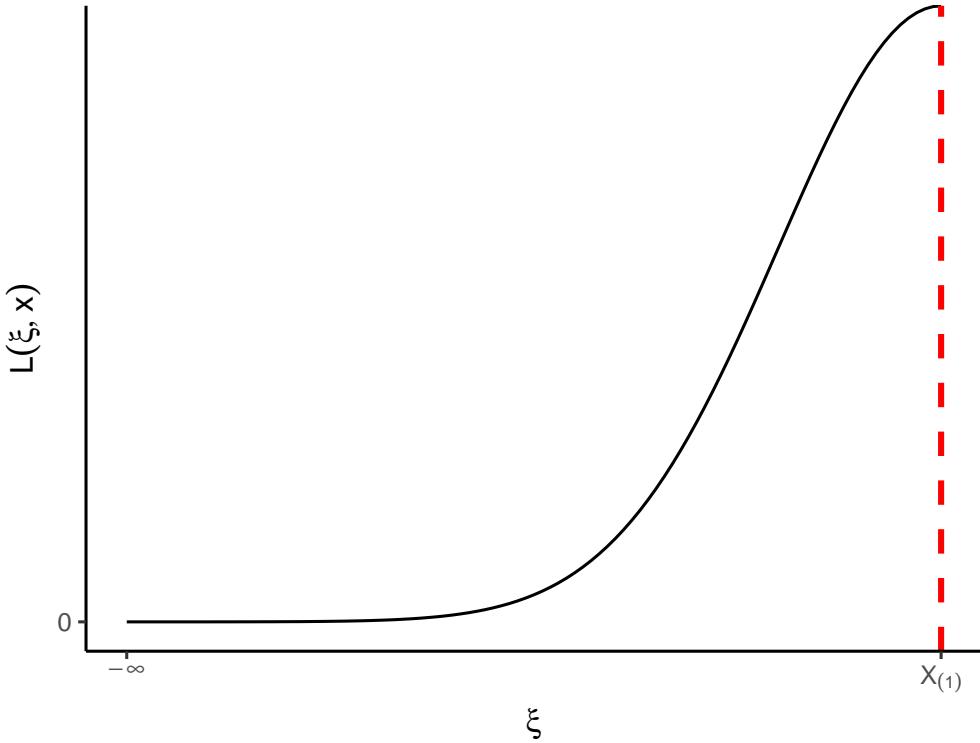
(b) Esboce a função de verossimilhança. Encontre o estimador de máxima verossimilhança de ξ .

Resolução

$$f(x; \xi) = \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{X_{(1)} \geq \xi\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x), \quad \text{visto no (*)}$$

$$f(x; \xi) = \left(\frac{2}{\pi}\right)^{n/2} e^{-\frac{\sum_{i=1}^n x_i^2}{2}} e^{\xi \sum_{i=1}^n x_i} e^{-\frac{n\xi^2}{2}} \mathbb{I}_{\{\xi \leq X_{(1)}\}}(x) \mathbb{I}_{\{X_{(n)} < \infty\}}(x)$$

$$\xi \leq X_{(1)} \implies \hat{\xi}_{MV} = X_{(1)}$$



(c) Encontre o estimador ERM (equivariante por localização de risco mínimo) de ξ sob perda quadrática.

Resolução

$$\begin{aligned}
 f(x_i; \xi) &= \left(\frac{2}{\pi}\right)^{1/2} \exp\left\{-\frac{(x_i - \xi)^2}{2}\right\} \mathbb{I}_{\{\xi \leq x_i < \infty\}}(x), \quad \xi \in \mathbb{R} \\
 f(x_i - u) &= \left(\frac{2}{\pi}\right)^{1/2} \exp\left\{-\frac{(x_i - u)^2}{2}\right\} \mathbb{I}_{\{u \leq x_i < \infty\}}(x), \quad u \in \mathbb{R} \\
 f(x_1 - u, x_2 - u, \dots) &\stackrel{ind}{=} \prod_{i=1}^n \left(\frac{2}{\pi}\right)^{1/2} \exp\left\{-\frac{(x_i - u)^2}{2}\right\} \mathbb{I}_{\{u \leq x_i < \infty\}}(x) \\
 f(x_1 - u, x_2 - u, \dots) &= \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\frac{\sum_{i=1}^n (x_i - u)^2}{2}\right\} \mathbb{I}_{\{u \leq x_i < \infty\}}(x), \quad u \in \mathbb{R} \\
 f(x_1 - u, x_2 - u, \dots) &= \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - u)^2}{2}\right\} \mathbb{I}_{\{u \leq x_i < \infty\}}(x), \quad u \in \mathbb{R} \\
 f(x_1 - u, x_2 - u, \dots) &= \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2}\right\} \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\} \mathbb{I}_{\{u \leq x_i < \infty\}}(x), \quad u \in \mathbb{R} \\
 T(x) &= \frac{\int_{s(u)}^{s(u)} u f(x_1 - u, x_2 - u, \dots) du}{\int_{s(u)}^{s(u)} f(x_1 - u, x_2 - u, \dots) du} \\
 T(x) &= \frac{\int_{-\infty}^{X(1)} u \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2}\right\} \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\} du}{\int_{-\infty}^{X(1)} \left(\frac{2}{\pi}\right)^{n/2} \exp\left\{-\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{2}\right\} \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\} du} \\
 T(x) &= \frac{\int_{-\infty}^{X(1)} u \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\} du}{\int_{-\infty}^{X(1)} \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\} du} \\
 \text{Seja } y &= \exp\left\{-\frac{n(\bar{x} - u)^2}{2}\right\}
 \end{aligned}$$

Seja $y = \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\}$ (*)

$$\frac{dy}{du} = n(\bar{x} - \mu) \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\}$$

$$\frac{dy}{du} = n\bar{x} \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} - n\mu \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\}$$

$$dy = \left[n\bar{x} \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} - n\mu \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} \right] du$$

$$dy = n\bar{x} \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} du - n\mu \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} du$$

$$dy - n\bar{x} \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} du = -n\mu \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} du$$

$$-\frac{1}{n} dy + \bar{x} \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} = \mu \exp \left\{ -\frac{n(\bar{x} - u)^2}{2} \right\} du$$

$$T(x) = \frac{\int_{-\infty}^{X(1)} u \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}$$

$$T(x) = \frac{\int_{-\infty}^{X(1)} -\frac{1}{n} dy + \bar{x} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}$$

$$T(x) = \frac{\int_{-\infty}^{X(1)} -\frac{1}{n} dy}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du} + \frac{\bar{x} \int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}$$

$$T(x) = \frac{\int_{-\infty}^{X(1)} -\frac{1}{n} dy}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du} + \bar{x}$$

$$T(x) = \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X(1)} dy}{\int_{-\infty}^{X(1)} \exp \left\{ -\frac{n(\bar{x}-u)^2}{2} \right\} du}$$

$$T(x) = \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X(1)} dy}{\int_{-\infty}^{X(1)} \frac{\sqrt{2\pi}}{\sqrt{2\pi}} \exp \left\{ -\frac{[-\sqrt{n}(\bar{x}-u)]^2}{2} \right\} du}$$

$$T(x) = \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X(1)} dy}{\int_{-\infty}^{X(1)} \frac{\sqrt{2\pi}}{\sqrt{2\pi}} \exp \left\{ -\frac{[\sqrt{n}(-\bar{x}+u)]^2}{2} \right\} du}$$

$$T(x) = \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X(1)} dy}{\int_{-\infty}^{X(1)} \frac{\sqrt{2\pi}}{\sqrt{2\pi}} \exp \left\{ -\frac{[\sqrt{n}(u-\bar{x})]^2}{2} \right\} du}$$

$$T(x) = \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X(1)} dy}{\sqrt{2\pi} \int_{-\infty}^{X(1)} \frac{1}{\sqrt{2\pi}} \left(\frac{1}{\sqrt{n}} \right) \exp \left\{ -\frac{[\sqrt{n}(u-\bar{x})]^2}{2} \right\} d[\sqrt{n}(u-\bar{x})]}$$

$$d[\sqrt{n}(u-\bar{x})] = \sqrt{n} du \implies du = \frac{d[\sqrt{n}(u-\bar{x})]}{\sqrt{n}}$$

$$\begin{aligned}
T(x) &= \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X_{(1)}} dy}{\sqrt{2\pi} \int_{-\infty}^{X_{(1)}} \frac{1}{\sqrt{2\pi}} \left(\frac{1}{\sqrt{n}}\right) \exp\left\{-\frac{[\sqrt{n}(u-\bar{x})]^2}{2}\right\} d[\sqrt{n}(u-\bar{x})]} \\
d[\sqrt{n}(u-\bar{x})] &= \sqrt{n}du \implies du = \frac{d[\sqrt{n}(u-\bar{x})]}{\sqrt{n}} \\
T(x) &= \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X_{(1)}} dy}{\underbrace{\frac{\sqrt{2\pi}}{\sqrt{n}} \int_{-\infty}^{X_{(1)}} \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{[\sqrt{n}(u-\bar{x})]^2}{2}\right\} d[\sqrt{n}(u-\bar{x})]}_{\text{fdp normal padrão para } \sqrt{n}(u-\bar{x})}} \\
T(x) &= \bar{x} - \frac{\frac{1}{n} \int_{-\infty}^{X_{(1)}} dy}{\frac{\sqrt{2\pi}}{\sqrt{n}} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\lim_{a \rightarrow -\infty} \int_a^{X_{(1)}} dy}{\frac{n\sqrt{2\pi}}{\sqrt{n}} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\lim_{a \rightarrow -\infty} y|_a^{X_{(1)}}}{\frac{n\sqrt{n}\sqrt{2\pi}}{n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\lim_{a \rightarrow -\infty} \exp\left\{-\frac{n(\bar{x}-u)^2}{2}\right\}|_a^{X_{(1)}}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\lim_{a \rightarrow -\infty} \exp\left\{-\frac{n(\bar{x}-X_{(1)})^2}{2}\right\} - \exp\left\{-\frac{n(\bar{x}-a)^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n(\bar{x}-X_{(1)})^2}{2}\right\} - \lim_{a \rightarrow -\infty} \exp\left\{-\frac{n(\bar{x}-a)^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n(\bar{x}-X_{(1)})^2}{2}\right\} - 0}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n(\bar{x}-X_{(1)})^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n[-(\bar{x}-X_{(1)})]^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n[-\bar{x}+X_{(1)}]^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]} \\
T(x) &= \bar{x} - \frac{\exp\left\{-\frac{n(X_{(1)}-\bar{x})^2}{2}\right\}}{\sqrt{2\pi n} \Phi[\sqrt{n}(X_{(1)} - \bar{x})]}, \text{ que é estimador ERM de } \xi \text{ sob perda quadrática.}
\end{aligned}$$

Este estimador pode ser expresso de várias maneiras, trocando as posições dos termos $X_{(1)}$ e \bar{x} , devido ao grau (dois) que é par. No entanto a troca não altera as suas estimativas.

25. Seja $X = (X_1, \dots, X_n)$ uma amostra aleatória de uma distribuição exponencial truncada e função densidade de probabilidade

$$p(x; \xi) = \frac{e^{-(x-\xi)/b}}{b(1 - e^{-1/b})}, x \in [\xi, \xi + 1]; -\infty < \xi < +\infty,$$

em que $b > 0$ é conhecido.

Seja $\mathcal{P} = \{P_\xi, \xi \in R\}$ a família de possíveis distribuições do vetor aleatório $X = (X_1, \dots, X_n)$ com densidade conjunta

$$\begin{aligned} p_\epsilon(\mathbf{x}) &= p_\epsilon(x_1, \dots, x_n), \text{ onde } \mathbf{x} = (x_1, \dots, x_n) \\ &\stackrel{\text{ind.}}{=} \prod_{i=1}^n \frac{1}{b(1 - e^{-1/b})} \exp \left\{ -\frac{1}{b}(x_i - \epsilon) \right\} I_{[\epsilon, \epsilon+1]}(x_i) \\ &= \left(\frac{1}{b(1 - e^{-1/b})} \right)^n \exp \left\{ -\frac{1}{b} \sum_{i=1}^n (x_i - \epsilon) \right\} \prod_{i=1}^n I_{[\epsilon, \epsilon+1]}(x_i) \\ &= \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} \prod_{i=1}^n I_{[\epsilon, \epsilon+1]}(x_i) \\ &= \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} I(x_{(n)} \leq \epsilon + 1) I(x_{(1)} \geq \epsilon) \end{aligned}$$

em que $b > 0$ conhecido.

Note que a última igualdade decorre do fato que,

$$\begin{aligned} I_{[\epsilon, \epsilon+1]}(x_i) &= 1 \iff \epsilon \leq x_i \leq \epsilon + 1, \quad i = 1, \dots, n \\ &\quad \epsilon \leq x_1, x_2, \dots, x_n \leq \epsilon + 1 \\ &\quad \epsilon \leq x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)} \leq \epsilon + 1 \\ &\quad \text{é suficiente que} \\ &\quad x_{(1)} \geq \epsilon \text{ e } x_{(n)} \leq \epsilon + 1, \text{ onde } x_{(1)} = \min(x_1, \dots, x_n) \text{ e } x_{(n)} = \max(x_1, \dots, x_n) \end{aligned}$$

Logo

$$\prod_{i=1}^n I_{[\epsilon, \epsilon+1]}(x_i) = I(x_n \leq \epsilon + 1) I(x_{(1)} \geq \epsilon) = \begin{cases} 1, & x_{(1)} \geq \epsilon \text{ e } x_{(n)} \leq \epsilon + 1 \\ 0, & \text{caso contrário} \end{cases}$$

(a) Encontre o estimador de máxima verossimilhança $\delta(X)$ de ξ e verifique que é equivariante por localização.

A densidade conjunta $p_\epsilon(\mathbf{x})$, quando vista como uma função de ϵ , é denominada função de verossimilhança de \mathbf{x} e representada por $\mathcal{L}(\epsilon; \mathbf{x})$, sendo expressa da seguinte maneira.

$$\mathcal{L}(\epsilon; \mathbf{x}) = \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} I(x_n \leq \epsilon + 1) I(x_{(1)} \geq \epsilon)$$

Então,

$$I(x_{(n)} \leq \epsilon + 1) I(x_{(1)} \geq \epsilon) = I_{[x_{(n)}-1, x_{(1)}]}(\epsilon) = \begin{cases} 1, & \text{se } x_{(1)} \geq \epsilon \text{ e } x_{(n)} \leq \epsilon + 1 \\ 0, & \text{caso contrário} \end{cases}$$

O estimador $\hat{\epsilon} \in \mathbb{R}$ que satisfaz

$$\mathcal{L}(\hat{\epsilon}; \mathbf{x}) = \sup_{\epsilon \in \mathbb{R}} \mathcal{L}(\epsilon; \mathbf{x})$$

Este é o estimador de máxima verossimilhança (EMV) de ϵ . Primeiramente, observe que, para todo $b > 0$, temos que $b^n (1 - e^{-1/b})^n > 0$, uma vez que

$$b > 0 \implies -\frac{1}{b} < 0 \iff e^{-1/b} < e^0 \iff 1 - e^{-1/b} > 0 \Rightarrow b^n (1 - e^{-1/b})^n > 0$$

Assim sendo,

$$\mathcal{L}(\hat{\epsilon}; \mathbf{x}) = \sup_{\epsilon \in \mathbb{R}} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} I_{[x_{(n)}-1, x_{(1)}]}(\epsilon)$$

Assim, podemos notar que, para $\epsilon \in [x_{(n)} - 1, x_{(1)}]$, verifica-se que

$$\frac{\partial}{\partial \epsilon} \left[\exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} \right] = \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\} \frac{n}{b} > 0$$

Consequentemente, $\mathcal{L}(\epsilon; \mathbf{x})$ é uma função estritamente crescente em relação a ϵ no intervalo $[x_{(n)} - 1, x_{(1)}]$. Assim, o EMV de ϵ satisfaz que

$$\delta(\mathbf{X}) = \hat{\epsilon} = X_{(1)}$$

pois

$$\sup_{\epsilon \in \mathbb{R}} \mathcal{L}(\epsilon; \mathbf{x}) = \sup_{\epsilon \in [x_{(n)}-1, x_{(1)}]} \mathcal{L}(\epsilon; \mathbf{x}) = \mathcal{L}(x_{(1)}; \mathbf{x})$$

A seguir, demonstraremos que este estimador é equivariante por localização. Para isso, considere $a \in \mathbb{R}$, e observe que

$$\begin{aligned} \delta(\mathbf{X} + a) &= \min(X_1 + a, X_2 + a, \dots, X_n + a) \\ &= X_{(1)} + a \\ &= \delta(\mathbf{X}) + a \end{aligned}$$

(b) Obtenha o estimador de Pitman de ξ (estimador equivariante por localização de risco mínimo sob perda quadrática). Verifique que, de fato, o estimador que encontrou é equivariante por localização.

Observe que $\mathbf{X} = (X_1, \dots, X_n)$ é um vetor de variáveis aleatórias que pertence a uma família de distribuições de localização com densidade conjunta

$$p_\epsilon(\mathbf{x}) = f(x_1 - \epsilon, \dots, x_n - \epsilon), \text{ com } \mathbf{x} = (x_1, \dots, x_n) \in [\epsilon, \epsilon + 1]^n, \epsilon \in \mathbb{R} \text{ e}$$

$$f(x_1 - \epsilon, \dots, x_n - \epsilon) = \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - n\epsilon \right) \right\}$$

Considere a função de perda quadrática $L(\epsilon, \delta(\mathbf{X})) = (\delta(\mathbf{X}) - \epsilon)^2$. Assim, o estimador equivariante por localização que minimiza o risco é o estimador de Pitman $\delta^*(\mathbf{X})$, tal que

$$\delta^*(\mathbf{x}) = \frac{\int_{x_{(n)}-1}^{x_{(1)}} u f(x_1 - u, \dots, x_n - u) du}{\int_{x_{(n)}-1}^{x_{(1)}} f(x_1 - u, \dots, x_n - u) du} \quad (1)$$

e $f(x_1 - u, \dots, x_n - u)$ assume a forma a seguir

$$\begin{aligned} f(x_1 - u, \dots, x_n - u) &= \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \left(\sum_{i=1}^n x_i - nu \right) \right\} I_{[x_{(n)}-1, x_{(1)}]}(u) \\ &= \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \sum_{i=1}^n x_i + \frac{n}{b} u \right\} I_{[x_{(n)}-1, x_{(1)}]}(u) \\ &= \frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \sum_{i=1}^n x_i \right\} \exp \left\{ \frac{n}{b} u \right\} I_{[x_{(n)}-1, x_{(1)}]}(u) \\ &= \exp \left\{ \frac{n}{b} u \right\} I_{[x_{(n)}-1, x_{(1)}]}(u) \underbrace{\frac{1}{b^n (1 - e^{-1/b})^n} \exp \left\{ -\frac{1}{b} \sum_{i=1}^n x_i \right\}}_{h(\mathbf{x}, b)} \end{aligned}$$

Assim, a partir da equação 1, obtém-se o estimador de Pitman como;

$$\begin{aligned} \delta^*(\mathbf{x}) &= \frac{\int_{x_{(n)}-1}^{x_{(1)}} u \exp \left\{ \frac{n}{b} u \right\} h(\mathbf{x}, b) du}{\int_{x_{(n)}-1}^{x_{(1)}} \exp \left\{ \frac{n}{b} u \right\} h(\mathbf{x}, b) du} \\ &= \frac{\int_{x_{(n)}-1}^{x_{(1)}} u \exp \left\{ \frac{n}{b} u \right\} du}{\int_{x_{(n)}-1}^{x_{(1)}} \exp \left\{ \frac{n}{b} u \right\} du} \end{aligned}$$

A integral do numerador será resolvida utilizando o método de integração por partes.

$$\begin{aligned} w &= u \text{ e } dv = \exp \left\{ \frac{n}{b} u \right\} \Rightarrow dw = du \text{ e } v = \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \\ \int_{x_{(n)}-1}^{x_{(1)}} u \exp \left\{ \frac{n}{b} u \right\} du &= wv \Big|_{x_{(n)}-1}^{x_{(1)}} - \int_{x_{(n)}-1}^{x_{(1)}} v du \\ \int_{x_{(n)}-1}^{x_{(1)}} u \exp \left\{ \frac{n}{b} u \right\} du &= u \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} - \frac{b}{n} \int_{x_{(n)}-1}^{x_{(1)}} \exp \left\{ \frac{n}{b} u \right\} du \\ &= u \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} - \frac{b}{n} \left(\frac{b}{n} \right) \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} \\ &= u \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} - \left(\frac{b}{n} \right)^2 \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} \\ &= \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \left(u - \frac{b}{n} \right) \Big|_{x_{(n)}-1}^{x_{(1)}} \\ &= \frac{b}{n} \left[\exp \left\{ \frac{n}{b} x_{(1)} \right\} \left(x_{(1)} - \frac{b}{n} \right) - \exp \left\{ \frac{n}{b} (x_{(n)} - 1) \right\} \left(x_{(n)} - 1 - \frac{b}{n} \right) \right] \end{aligned}$$

Por outro lado, a integral do denominador é calculada da seguinte maneira

$$\begin{aligned} \int_{x_{(n)}-1}^{x_{(1)}} \exp \left\{ \frac{n}{b} u \right\} du &= \frac{b}{n} \exp \left\{ \frac{n}{b} u \right\} \Big|_{x_{(n)}-1}^{x_{(1)}} \\ &= \frac{b}{n} \exp \left\{ \frac{n}{b} x_{(1)} \right\} - \frac{b}{n} \exp \left\{ \frac{n}{b} (x_{(n)} - 1) \right\} \\ &= \frac{b}{n} \left(\exp \left\{ \frac{n}{b} x_{(1)} \right\} - \exp \left\{ \frac{n}{b} (x_{(n)} - 1) \right\} \right) \end{aligned}$$

Então, temos que

$$\delta^*(\mathbf{X}) = \frac{\frac{b}{n}[\exp\left\{\frac{n}{b}X_{(1)}\right\}(X_{(1)} - \frac{b}{n}) - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}(X_{(n)} - 1 - \frac{b}{n})]}{\frac{b}{n}[\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}]}$$

$$\delta^*(\mathbf{X}) = \frac{\exp\left\{\frac{n}{b}X_{(1)}\right\}(X_{(1)} - \frac{b}{n}) - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}(X_{(n)} - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}}$$

Seja $a \in \mathbb{R}$ e note o seguinte

$$\begin{aligned}\delta^*(\mathbf{X} + a) &= \frac{\exp\left\{\frac{n}{b}(X + a)_{(1)}\right\}((X + a)_{(1)} - \frac{b}{n}) - \exp\left\{\frac{n}{b}((X + a)_{(n)} - 1)\right\}((X + a)_{(n)} - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}(X + a)_{(1)}\right\} - \exp\left\{\frac{n}{b}((X + a)_{(n)} - 1)\right\}} \\ &= \frac{\exp\left\{\frac{n}{b}(X_{(1)} + a)\right\}(X_{(1)} + a - \frac{b}{n}) - \exp\left\{\frac{n}{b}(X_{(n)} + a - 1)\right\}(X_{(n)} + a - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}(X_{(1)} + a)\right\} - \exp\left\{\frac{n}{b}(X_{(n)} + a - 1)\right\}} \\ &= \frac{\exp\left\{\frac{n}{b}X_{(1)} + a\frac{n}{b}\right\}(X_{(1)} + a - \frac{b}{n}) - \exp\left\{\frac{n}{b}X_{(n)} + a\frac{n}{b} - \frac{n}{b}\right\}(X_{(n)} + a - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}X_{(1)} + a\frac{n}{b}\right\} - \exp\left\{\frac{n}{b}X_{(n)} + a\frac{n}{b} - \frac{n}{b}\right\}} \\ &= \frac{\exp\left\{\frac{n}{b}a\right\}\exp\left\{\frac{n}{b}X_{(1)}\right\}(X_{(1)} + a - \frac{b}{n}) - \{\exp\frac{n}{b}a\}\exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}(X_{(n)} + a - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}a\right\}\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}a\right\}\exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}} \\ &= \frac{\cancel{\exp\left\{\frac{n}{b}a\right\}} [\exp\left\{\frac{n}{b}X_{(1)}\right\}(X_{(1)} + a - \frac{b}{n}) - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}(X_{(n)} + a - 1 - \frac{b}{n})]}{\cancel{\exp\left\{\frac{n}{b}a\right\}} [\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}]} \\ &= \frac{\exp\left\{\frac{n}{b}X_{(1)}\right\}(X_{(1)} - \frac{b}{n}) - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}(X_{(n)} - 1 - \frac{b}{n})}{\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}} + \\ &\quad + \frac{a\exp\left\{\frac{n}{b}X_{(1)}\right\} - a\exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}}{\exp\left\{\frac{n}{b}X_{(1)}\right\} - \exp\left\{\frac{n}{b}(X_{(n)} - 1)\right\}} \\ &= \delta^*(\mathbf{X}) + a, \forall a \in \mathbb{R}.\end{aligned}$$

Onde $\min(X_1 + a, \dots, X_n + a) = (X + a)_{(1)} = X_{(1)} + a$. Assim, o estimador $\delta^*(\mathbf{X})$ é equivariante por localização.

Questão 26 Seja $X = (X_1, \dots, X_n)$ com função densidade de probabilidade

$$f_X(x; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad x = (x_1, \dots, x_n) \in R^n; \tau > 0$$

,em que f é conhecida e τ é um parâmetro de escala desconhecido. Considere o problema de estimar τ^r , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(X)$, tal que $\delta(x) > 0$ para todo $x \in R^n$, é equivariante por escala se $\delta(bx) = b^r \delta(x)$, para todo $b > 0$ e todo $x \in R^n$. Considere a função de perda $L(\tau, d) = [(d - \tau^r)/\tau^r]^2$.

(a) Mostre que o risco $R(\tau, \delta(X))$ de qualquer estimador equivariante por escala $\delta(X)$ é constante.

Seja $U = (U_1, \dots, U_n)$ v.a. independentes, tal que $X \stackrel{d}{=} \tau U$, $\tau > 0$. Então o risco $R(\tau, \delta(X))$ é dado por,

$$\begin{aligned} R(\tau, \delta(X)) &= E_\tau[L(\tau, \delta(X))] \\ &= E_\tau \left[\left(\frac{\delta(X) - \tau^r}{\tau^r} \right)^2 \right] \\ &= E_\tau \left[\left(\frac{\delta(\tau U) - \tau^r}{\tau^r} \right)^2 \right] \\ &= E_\tau \left[\left(\frac{\tau^r \delta(U) - \tau^r}{\tau^r} \right)^2 \right], \text{ usando o fato que } \delta(\cdot) \text{ é equivariante por escala} \\ &= E_1 \left[(\delta(U) - 1)^2 \right] \end{aligned}$$

Como podemos observar, o risco $R(\tau, \delta(X))$ é constante.

(b) Seja $\delta_0(X)$ um estimador equivariante por escala. Mostre que um estimador $\delta(X)$ é equivariante por escala se e somente se $\delta(x) = \delta_0(x)/v(x)$, em que $v(x)$ é tal que

$$v(cx) = v(x) > 0, \text{ para todo } c > 0 \text{ e todo } x \in R^n. \quad (2)$$

Mostre ainda que, se $x_n \neq 0$ e $n > 1$, uma condição necessária e suficiente para que $v(x)$ satisfaça (1) é que exista uma função $w(y)$ tal que $v(x) = w(y)$ em que $y = (x_1/|x_n|, \dots, x_n/|x_n|)$.

Para a primeira parte da questão temos:

Provando (\Rightarrow): Supondo que $\delta(X)$ é equivariante por escala, então

$$\delta(cx) = c^r \delta(x), \forall c > 0, \forall x \in R \text{ e } r \geq 1$$

Pelo que foi definido no enunciado, seja $\delta_0(X)$ um estimador equivariante por escala, $v(cx) = \delta_0(x)/\delta(x)$ e $v(cx) = v(x) > 0$, para todo $c > 0$ e todo $x \in R^n$, então

$$v(cx) = \frac{\delta_0(cx)}{\delta(cx)} = \frac{c^r \delta_0(x)}{c^r \delta(x)} = \frac{\delta_0(x)}{\delta(x)} = v(x), \text{ para todo } c > 0 \text{ e todo } x \in R^n$$

Assim, $\delta(X) = \delta_0(X)/v(x)$.

Provando (\Leftarrow): Se o estimador $\delta(X)$ pode ser escrito como $\delta(X) = \delta_0(X)/v(x)$, sendo $\delta_0(x)$ equivariante por escala e $v(cx) = v(x) > 0$, para todo $c > 0$ e todo $x \in R^n$, então,

$$\delta(cx) = \frac{\delta_0(cx)}{v(cx)} = \frac{c^r \delta_0(x)}{v(x)} = c^r \delta(x), \text{ para todo } c > 0 \text{ e todo } x \in R^n$$

Logo, $\delta(X)$ é equivariante por escala.

Para a segunda parte do item, temos:

Provando (\Rightarrow): Se $v(cx) = v(x) > 0$, para todo $c > 0$ e todo $x \in R^n$, então se utilizarmos c tal que $c = 1/|x_n|$, $n > 1$ e $x_n \neq 0$, então

$$v(x) = v(cx) = v\left(\frac{1}{|x_n|}x\right) = v\left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|}\right) = v\left(\frac{x_n}{|x_n|}\right) = w(y)$$

em que $y = (x_1/|x_n|, \dots, x_n/|x_n|)$.

Provando (\Leftarrow): Se existe uma função $w(y)$ tal que $v(x) = w(y)$ em que $y = (x_1/|x_n|, \dots, x_n/|x_n|)$, então, para $\forall c > 0$ e $x \in R$

$$v(cx) = w(cy) = w\left(\frac{cx_1}{|cx_n|}, \dots, \frac{cx_n}{|cx_n|}\right) = w\left(\frac{x_1}{|x_n|}, \dots, \frac{x_n}{|x_n|}\right) = w(y) = v(y)$$

- (c) Seja $\delta_0(X)$ um estimador equivariante de risco finito. Mostre que o estimador equivariante de risco mínimo de τ^r é dado por

$$\delta^* = \delta_0 \frac{E_1[\delta_0(X)|Y]}{E_1[\delta_0^2(X)|Y]},$$

em que $Y = (X_1/|X_n|, \dots, X_n/|X_n|)$.

Como visto anteriormente, $R(1, \delta(X)) = E_1[(\delta(X) - 1)^2]$, $\tau > 0$. Assim,

$$\begin{aligned} R(1, \delta(X)) &= E_1[E_1[(\delta(X) - 1)^2 | Y = y]] \\ &= E_1 \left[E_1 \left[\left(\frac{\delta_0(X)}{w(Y)} - 1 \right)^2 | Y = y \right] \right] \\ &= E_1 \left[E_1 \left[\left(\frac{\delta_0(X) - w(Y)}{w(Y)} \right)^2 | Y = y \right] \right] \\ &= \int E_1 \left[\left(\frac{\delta_0(X) - w(Y)}{w(Y)} \right)^2 | Y = y \right] dP_1(y) \\ &= \int \rho(\delta_0(X), w(Y)) dP_1(y) \end{aligned}$$

Assim, encontrar $w^*(y)$ que minimize a função de risco $R(1, \delta(X))$ é equivalente a minimizar o integrando para cada y . Dado que, como enunciado, $\delta_0(X)$ tem risco finito,

$$\begin{aligned} \rho(\delta_0(X), w(Y)) &= E_1 \left[\left(\frac{\delta_0(X) - w(Y)}{w(Y)} \right)^2 | Y = y \right] \\ &= \frac{1}{w(Y)^2} E_1 \left[(\delta_0(X) - w(Y))^2 | Y = y \right] \\ &= \frac{1}{w(Y)^2} \left(E_1 \left[(\delta_0(X))^2 | Y = y \right] - 2E_1 [(\delta_0(X)w(Y)) | Y = y] + E_1 \left[(w(Y))^2 | Y = y \right] \right) \\ &= \frac{1}{w(Y)^2} E_1 \left[(\delta_0(X))^2 | Y = y \right] - \frac{2}{w(Y)} E_1 [\delta_0(X) | Y = y] + 1 \end{aligned}$$

Assim,

$$\begin{aligned} \frac{\partial \rho(\delta_0(X), w(y))}{\partial w(y)} &= 0 \\ \Leftrightarrow -\frac{2}{(w^*(y))^3} E_1 \left[(\delta_0(X))^2 | Y = y \right] + \frac{2}{(w^*(y))^2} E_1 [\delta_0(X) | Y = y] &= 0 \\ \Leftrightarrow \frac{2}{(w^*(y))^3} E_1 \left[(\delta_0(X))^2 | Y = y \right] &= \frac{2}{(w^*(y))^2} E_1 [\delta_0(X) | Y = y] \\ \Leftrightarrow w^*(y) &= \frac{E_1 \left[(\delta_0(X))^2 | Y = y \right]}{E_1 [\delta_0(X) | Y = y]} \end{aligned}$$

Logo, $w^*(Y) = \frac{E_1[(\delta_0(X))^2|Y]}{E_1[\delta_0(X)|Y]}$. Desse modo, o estimador equivariante de risco mínimo de τ^r é dado por

$$\delta^*(X) = \frac{\delta_0(X)}{w^*(Y)} = \delta_0(X) \frac{E_1[\delta_0(X)|Y]}{E_1[\delta_0^2(X)|Y]},$$

em que $Y = (X_1/|X_n|, \dots, X_n/|X_n|)$.

- (d) Considere a situação em que (X_1, \dots, X_n) é uma amostra aleatória da distribuição $N(0, \tau^2)$, $\tau > 0$. Encontre o estimador equivariante de risco mínimo de τ^2 . Sugestão: usar o Teorema de Basu. Seja a distribuição conjunta de $X = (X_1, \dots, X_n)$ dada por

$$\begin{aligned} p_\tau(x) &\stackrel{ind}{=} \prod_{i=1}^n p_\tau(x_i) I_{(-\infty, \infty)}(x_i) \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\tau^2}} \exp\left\{-\frac{x_i^2}{2\tau^2}\right\} I_{(-\infty, \infty)}(x_i) \\ &= \frac{1}{\tau^n} \frac{1}{(2\pi)^{n/2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i}{\tau}\right)^2\right\} I_{(-\infty, \infty)}(x_i) \\ &= \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), x \in R^n, \tau > 0 \end{aligned}$$

com $f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right) = \frac{1}{(2\pi)^{n/2}} \exp\left\{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i}{\tau}\right)^2\right\}$. Assim, como podemos observar, a distribuição $p_\tau(x)$ pertence a família de escala. Além disso, a distribuição $p_\tau(x)$ pode ser escrita como

$$\begin{aligned} p_\tau(x) &= \exp\left\{-\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i}{\tau}\right)^2 - \frac{n}{2} \log(\tau^2)\right\} \frac{1}{(2\pi)^{n/2}} \prod_{i=1}^n I_{(-\infty, \infty)}(x_i) \\ &= \exp\{\eta T(x) - A(\eta)\} h(x) \end{aligned}$$

em que $\eta = -\frac{1}{2\tau^2}$, $T(X) = \sum_{i=1}^n X_i^2$, $A(\eta) = \frac{n}{2} \log(\tau^2) = \frac{n}{2} \log\left(-\frac{1}{2\eta}\right)$ e $h(x) = \frac{1}{(2\pi)^{n/2}} \prod_{i=1}^n I_{(-\infty, \infty)}(x_i)$.

Como o espaço paramétrico de $\eta \in (-\infty, 0)$ contém retângulos unidimensionais abertos, a família é de posto completo, logo, a estatística $T(X) = \sum_{i=1}^n X_i^2$ é suficiente e completa.

Considerando o estimado $\delta_0(X) = T(X) = \sum_{i=1}^n X_i^2$, temos

$$\delta_0(bx) = \sum_{i=1}^n (bx_i)^2 = b^2 \sum_{i=1}^n x_i^2 = b^2 \delta_0(x), \quad b > 0$$

Como $\delta_0(x) > 0, \forall x \in R^n$, por definição o estimador $\delta_0(x)$ é equivariante por escala.

Com base no item anterior, podemos obter o estimador equivariante de risco mínimo de τ^2 com

$$\delta^*(X) = \delta_0(X) \frac{E_1[\delta_0(X)|Y]}{E_1[\delta_0^2(X)|Y]},$$

em que $Y = \psi(X) = \left(\frac{X_1}{|X_n|}, \dots, \frac{X_n}{|X_n|}\right)$ tal que $x \neq 0$ e $n > 1$. Observe que, sendo $b > 0$,

$$\begin{aligned} Y &= \psi(bX) \\ &= \left(\frac{bX_1}{|bX_n|}, \dots, \frac{bX_n}{|bX_n|}\right) \\ &= \left(\frac{X_1}{|X_n|}, \dots, \frac{X_n}{|X_n|}\right) \\ &= \psi(X) \end{aligned}$$

logo, $Y = \psi(X)$ é invariante por escala, sendo função do vetor aleatório X que tem distribuição em uma família de escala, portanto, $Y = (Y_1, \dots, Y_n)$ é uma estatística anciliar. Como $\delta_0(X)$ é uma estatística suficiente e completa e Y é anciliar, pelo Teorema de Basu, $\delta_0(X)$ é independente de Y .

Para $r = 1$, as v.a. X_i são independentes e distribuídas segundo $N(0, 1)$, $i = 1, \dots, n$, então $Z =$

$\sum_{i=1}^n X_i^2 \sim \chi_n^2$. Assim, o estimador equivariante de risco mínimo de τ^2 é dado por

$$\begin{aligned}
\delta^*(X) &= \delta_0(X) \frac{E_1[\delta_0(X)]}{E_1[\delta_0^2(X)]} \\
&= \sum_{i=1}^n X_i^2 \frac{E_1[\sum_{i=1}^n X_i^2]}{E_1[Z^2]} \\
&= \sum_{i=1}^n X_i^2 \frac{\sum_{i=1}^n E_1[X_i^2]}{E_1[Z^2]} \\
&= \sum_{i=1}^n X_i^2 \frac{\sum_{i=1}^n (Var_1(X_i) + E_1^2[X_i])}{(Var_1(Z) + E_1^2[Z])} \\
&= \sum_{i=1}^n X_i^2 \frac{\sum_{i=1}^n (1 + 0)}{(2n + n^2)} \\
&= \sum_{i=1}^n X_i^2 \frac{n}{2n + n^2} \\
&= \frac{1}{2+n} \sum_{i=1}^n X_i^2
\end{aligned}$$

27. Seja $\mathbf{X} = (X_1, \dots, X_n)$ com função densidade de probabilidade conjunta

$$f_\tau(\mathbf{X}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n, \tau > 0$$

em que f é conhecida e τ é parâmetro de escala desconhecido. Considere o problema de estimar τ , $r \geq 1$, inteiro. Dizemos que um estimador $\delta(\mathbf{X})$ é equivariante por escala se $\delta(b\mathbf{X}) = b^r \delta(\mathbf{X})$, para todo $b > 0$. Pode-se mostrar que o estimador de Pitman de τ^r , dado por $\delta^*(\mathbf{X})$ sendo

$$\delta^*(\mathbf{X}) = \frac{\int_0^\infty v^{n+r-1} f(vx_1, \dots, vx_n) dv}{\int_0^\infty v^{n+2r-1} f(vx_1, \dots, vx_n) dv}$$

é um estimador equivariante por escala de risco mínimo sob perda $[(d - \tau^r)/\tau^r]^2$.

(a) Mostre que, de fato, o estimador $\delta^*(\mathbf{X})$ é equivariante por escala.

Resolução

$$\begin{aligned} \delta^*(b\mathbf{X}) &= \frac{\int_0^\infty v^{n+r-1} f(bvx_1, \dots, bvx_n) dv}{\int_0^\infty v^{n+2r-1} f(bvx_1, \dots, bvx_n) dv} \\ \text{Seja } bv = k \iff v = \frac{k}{b}, bdv = dk \implies v = \frac{dk}{b}, b > 0 \\ &= \frac{\int_0^\infty \left(\frac{k}{b}\right)^{n+r-1} f(kx_1, kx_2, \dots, kx_n) \frac{dk}{b}}{\int_0^\infty \left(\frac{k}{b}\right)^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) \frac{dk}{b}} \\ &= \frac{\frac{1}{b^{n+r-1} \cdot b} \int_0^\infty k^{n+r-1} f(kx_1, kx_2, \dots, kx_n) dk}{\frac{1}{b^{n+2r-1} \cdot b} \int_0^\infty k^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) dk} \\ &= \frac{\frac{1}{b^{n+r}} \int_0^\infty k^{n+r-1} f(kx_1, kx_2, \dots, kx_n) dk}{\frac{1}{b^{n+2r}} \int_0^\infty k^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) dk} \\ &= \frac{b^{n+2r}}{b^{n+r}} \frac{\int_0^\infty k^{n+r-1} f(kx_1, kx_2, \dots, kx_n) dk}{\int_0^\infty k^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) dk} \\ &= (b^{n+2r-n-r}) \frac{\int_0^\infty k^{n+r-1} f(kx_1, kx_2, \dots, kx_n) dk}{\int_0^\infty k^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) dk} \\ &= b^r \frac{\int_0^\infty k^{n+r-1} f(kx_1, kx_2, \dots, kx_n) dk}{\int_0^\infty k^{n+2r-1} f(kx_1, kx_2, \dots, kx_n) dk} \\ &= b^r \delta^*(\mathbf{X}), b > 0, \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n \end{aligned}$$

Logo, o estimador $\delta^*(\mathbf{X})$ é equivariante por escala.

(b) Obtenha o estimador $\delta^*(\mathbf{X})$ de τ^r para a situação em que \mathbf{X} é uma amostra aleatória da distribuição exponencial de média $\tau > 0$.

Resolução

Seja $\mathbf{X} = (X_1, \dots, X_n)$ com função densidade de probabilidade conjunta

$$f_\tau(\mathbf{X}; \tau) = \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n, \tau > 0$$

em que f é conhecida e τ é parâmetro de escala desconhecido.

Considerando $f_\tau(x; \tau)$ uma distribuição exponencial de média $\tau > 0$, tem-se:

$$\begin{aligned}
f_\tau(x; \tau) &= \frac{1}{\tau} \exp \left\{ -\frac{1}{\tau} \right\} \mathbb{I}_{(0, \infty)}(x_i), \quad \tau > 0 \\
f(\mathbf{X}; \tau) &\stackrel{\text{ind}}{=} \prod_{i=1}^n f_\tau(x_i; \tau) \mathbb{I}_{(0, \infty)}(x_i) \\
&= \prod_{i=1}^n \frac{1}{\tau} \exp \left\{ -\frac{1}{\tau} x_i \right\} \mathbb{I}_{(0, \infty)}(x_i) \\
&= \frac{1}{\tau^n} \exp \left\{ -\frac{1}{\tau} \sum_{i=1}^n x_i \right\} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \infty\}} \\
&= \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \tau > 0 \\
\text{Se } f_\tau(\mathbf{X}; \tau) &= \frac{1}{\tau^n} f\left(\frac{x_1}{\tau}, \dots, \frac{x_n}{\tau}\right), \quad \mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n, \tau > 0, \\
\delta^*(\mathbf{X}) &= \frac{\int_0^\infty v^{n+r-1} f(vx_1, \dots, vx_n) dv}{\int_0^\infty v^{n+2r-1} f(vx_1, \dots, vx_n) dv}
\end{aligned}$$

Então, para a nossa fistribuição tem-se:

$$\begin{aligned}
\delta^*(\mathbf{X}) &= \frac{\int_0^\infty v^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} dv}{\int_0^\infty v^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} dv} \\
\delta^*(\mathbf{X}) &= \frac{\int_0^\infty \left(\frac{\sum_{i=1}^n x_i v}{\sum_{i=1}^n x_i}\right)^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} dv}{\int_0^\infty \left(\frac{\sum_{i=1}^n x_i v}{\sum_{i=1}^n x_i}\right)^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} dv} \\
\delta^*(\mathbf{X}) &= \frac{\left(\frac{1}{\sum_{i=1}^n x_i}\right)^{n+r-1} \int_0^\infty (\sum_{i=1}^n x_i v)^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} \frac{1}{\sum_{i=1}^n x_i} d(v \sum_{i=1}^n x_i)}{\left(\frac{1}{\sum_{i=1}^n x_i}\right)^{n+2r-1} \int_0^\infty (\sum_{i=1}^n x_i v)^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} \frac{1}{\sum_{i=1}^n x_i} d(v \sum_{i=1}^n x_i)} \\
\delta^*(\mathbf{X}) &= \left(\frac{1}{\sum_{i=1}^n x_i}\right)^{n+r-1-n-2r+1} \times \frac{\frac{1}{\sum_{i=1}^n x_i}}{\frac{1}{\sum_{i=1}^n x_i}} \times \frac{\int_0^\infty (\sum_{i=1}^n x_i v)^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)}{\int_0^\infty (\sum_{i=1}^n x_i v)^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)} \\
\delta^*(\mathbf{X}) &= \left(\frac{1}{\sum_{i=1}^n x_i}\right)^{-r} \frac{\int_0^\infty (v \sum_{i=1}^n x_i)^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)}{\int_0^\infty (v \sum_{i=1}^n x_i)^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)} \\
\delta^*(\mathbf{X}) &= \left(\sum_{i=1}^n x_i\right)^r \frac{\int_0^\infty (v \sum_{i=1}^n x_i)^{n+r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)}{\int_0^\infty (v \sum_{i=1}^n x_i)^{n+2r-1} \exp\{-v \sum_{i=1}^n x_i\} d(v \sum_{i=1}^n x_i)} \\
\delta^*(\mathbf{X}) &= \left(\sum_{i=1}^n x_i\right)^r \frac{\Gamma(n+r)}{\Gamma(n+2r)}, \quad \Gamma(a) = \int_0^\infty t^{a-1} e^{-t} dt, \text{ aqui, } t = v \sum_{i=1}^n x_i
\end{aligned}$$

Assim, o estimador $\delta^*(\mathbf{X})$ de τ^r para a distribuição exponencial é:

$$\delta^*(\mathbf{X}) = \left(\sum_{i=1}^n x_i\right)^r \frac{\Gamma(n+r)}{\Gamma(n+2r)}, \quad r \geq 1$$

(c) No contexto do item (b), encontre o estimador não viesado de risco mínimo de τ^r considerando a perda dada acima.

$$\begin{aligned}
f_\tau(\mathbf{X}; \tau) &= \frac{1}{\tau^n} \exp \left\{ -\frac{1}{\tau} \sum_{i=1}^n x_i \right\} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \infty\}} \\
f_\tau(\mathbf{X}; \tau) &= \exp \left\{ \log \left(\frac{1}{\tau^n} \right) \right\} \exp \left\{ -\frac{1}{\tau} \sum_{i=1}^n x_i \right\} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \infty\}} \\
&= \exp \left\{ -\frac{1}{\tau} \sum_{i=1}^n x_i - n \log(\tau) \right\} \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \infty\}} \\
&= \exp\{\eta T(\mathbf{x}) - A(\eta)\} h(\mathbf{x})
\end{aligned}$$

onde,

$$\begin{cases} T(\mathbf{X}) &= \sum_{i=1}^n X_i, \eta = -\frac{1}{\tau} \\ A(\eta) &= n \log(\tau) = n \left(-\frac{1}{\eta} \right) \\ h(\mathbf{x}) &= \mathbb{I}_{\{X_{(1)} > 0\}} \mathbb{I}_{\{X_{(n)} < \infty\}} \end{cases}$$

$\eta \in \mathbb{R}^-$. Este espaço paramétrico contém retângulos unidimensionais abertos e tanto o parâmetro canônico η e a estatística suficiente $T(\mathbf{X})$, não satisfazem as restrições lineares. Como consequência, $f(\cdot)$ pertence à família exponencial de posto completo.

Pela justificativa acima, $T(\mathbf{X})$ é estatística suficiente completa para τ .

\implies Função de perda

Seja $L(\tau, d) = \left(\frac{d - \tau^r}{\tau^r} \right)^2$, $r \geq 1$ e $d = \delta(\mathbf{X})$, a função de perda quadrática e estimador de τ respectivamente. Esta função é quadrática e tomando d como o estimador de τ que minimiza a função de perda, como seu coeficiente é positivo, quando representada graficamente a $L(\tau, d)$, será uma parábola voltada para cima, em que d vértice representará o valor do estimador de τ que minimiza a função de perda, ou seja, esta função será estritamente convexa.

$$\frac{dL(\tau, d)}{d(d)} = \frac{2}{\tau^r} \left(\frac{d - \tau^r}{\tau^r} \right), \quad \frac{d^2L(\tau, d)}{dd^2} = \frac{2}{\tau^{2r}} > 0$$

, esta função tem um estimador d que a minimiza.

\implies Estimador não viesado de risco mínimo sob perda quadrática

Como $X_i \sim e^{\frac{1}{\tau}}, \tau > 0, i = 1, \dots, n \iff X_i \sim \text{Gama}(1, 1/\tau), \tau > 0, i = 1, \dots, n$.

$$T(\mathbf{X}) = \sum_{i=1}^n X_i \sim \text{Gama}(n, 1/\tau), \quad X_i \text{ são iid}$$

$$\begin{aligned}
\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)}{\Gamma(n+2r)} \mathbb{E}[T^r] \\
\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)}{\Gamma(n+2r)} \int_0^\infty t^r \frac{1}{\tau^n \Gamma(n)} t^{n-1} \exp \left\{ -\frac{1}{\tau} t \right\} dt \\
\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)}{\tau^n \Gamma(n) \Gamma(n+2r)} \int_0^\infty t^{r+n-1} \exp \left\{ -\frac{1}{\tau} t \right\} dt \\
\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)}{\tau^n \Gamma(n) \Gamma(n+2r)} \int_0^\infty \left(\frac{\tau t}{\tau} \right)^{r+n-1} \exp \left\{ -\frac{1}{\tau} t \right\} \tau d \left(\frac{t}{\tau} \right) \\
\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r) \tau^{r+n-1}}{\tau^n \Gamma(n) \Gamma(n+2r)} \int_0^\infty \left(\frac{t}{\tau} \right)^{r+n-1} \exp \left\{ -\frac{1}{\tau} t \right\} \tau d \left(\frac{t}{\tau} \right)
\end{aligned}$$

$$\begin{aligned}\mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)\tau^{r+n-1}}{\tau^n\Gamma(n)\Gamma(n+2r)} \int_0^\infty \left(\frac{t}{\tau}\right)^{r+n-1} \exp\left\{-\frac{1}{\tau}t\right\} \tau d\left(\frac{t}{\tau}\right) \\ \mathbb{E}[\delta(\mathbf{T})] &= \underbrace{\frac{\Gamma(n+r)\tau^{r-1}\tau}{\Gamma(n)\Gamma(n+2r)} \int_0^\infty \left(\frac{t}{\tau}\right)^{r+n-1} \exp\left\{-\frac{1}{\tau}t\right\} d\left(\frac{t}{\tau}\right)}_{\text{função gama}} \\ \mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma(n+r)\tau^r}{\Gamma(n)\Gamma(n+2r)} \Gamma(r+n) \\ \mathbb{E}[\delta(\mathbf{T})] &= \frac{\Gamma^2(n+r)\tau^r}{\Gamma(n)\Gamma(n+2r)}\end{aligned}$$

Assim,

$$\begin{aligned}\delta(\mathbf{T}) &= \frac{\Gamma(n+2r)\Gamma(n)}{\Gamma^2(n+r)} \delta^*(\mathbf{T}) \\ &= \frac{\Gamma(n+2r)\Gamma(n)}{\Gamma^2(n+r)} \left(\sum_{i=1}^n x_i \right)^r \frac{\Gamma(n+r)}{\Gamma(n+2r)}, r \geq 1 \\ &= \frac{\Gamma(n)}{\Gamma(n+r)} \left(\sum_{i=1}^n x_i \right)^r, r \geq 1 \\ &= \frac{\Gamma(n)}{\Gamma(n+r)} T^r, r \geq 1\end{aligned}$$

Observa-se que $\mathbb{E}[\delta(\mathbf{X})] = \tau^r, \forall \tau > 0$ e $r \geq 1$ e como descrito acima, a função de perda é estritamente convexa em relação a d . Assim, $\delta(\mathbf{T}) = \frac{\Gamma(n)}{\Gamma(n+r)} (\sum_{i=1}^n x_i)^r, r \geq 1$, é estimador não viesado de risco mínimo, pois, sob perda quadrática o estimador de Pitman é admissível.