

UNIVERSIDADE DE SÃO PAULO
Programa de Post-Graduação em Estatística

Katerine Zuniga Lastra, Marília de Melo Sombra, Alex Monito Nhancololo

Lista 04 – Semestre de 2024-II – Prof. Silvia Ferrari

Questão 2 Seja (X_1, \dots, X_n) uma amostra aleatória de X , que tem distribuição geométrica com função de probabilidade

$$f(x|\theta) = \theta^x(1 - \theta), \quad x = 0, 1, \dots; \quad \theta \in [0, 1).$$

Considere o problema de estimar θ . Obtenha (i) o estimador de máxima verossimilhança; (ii) o estimador do método dos momentos e (iii) o estimador de Bayes com respeito à perda quadrática tomando uma distribuição a priori uniforme no intervalo unitário.

Para (i), a função de densidade conjunta é dada por

$$\begin{aligned} L(\theta, x) &= \prod_{i=1}^n \theta^{x_i} (1 - \theta) I_{\{0,1,\dots\}}(x_i) \\ &= \theta^{\sum_{i=1}^n x_i} (1 - \theta)^n \prod_{i=1}^n I_{\{0,1,\dots\}}(x_i) \\ &\propto \theta^{\sum_{i=1}^n x_i} (1 - \theta)^n \end{aligned}$$

O logaritmo da função de verossimilhança é

$$l(\theta, x) = \sum_{i=1}^n x_i \log(\theta) + n \log(1 - \theta)$$

Assim, obtemos o EMV de θ , fazendo

$$\begin{aligned} \frac{dl(\theta, x)}{d\theta} &= 0 \\ \Leftrightarrow \sum_{i=1}^n x_i \frac{1}{\hat{\theta}} - n \frac{1}{1 - \hat{\theta}} &= 0 \\ \Leftrightarrow \bar{x} \frac{1}{\hat{\theta}} &= \frac{1}{1 - \hat{\theta}} \\ \Leftrightarrow \frac{1 - \hat{\theta}}{\hat{\theta}} &= \frac{1}{\bar{x}} \\ \Leftrightarrow \frac{1}{\hat{\theta}} - 1 &= \frac{1}{\bar{x}} \\ \Leftrightarrow \frac{1}{\hat{\theta}} &= \frac{1}{\bar{x}} + 1 \\ \Leftrightarrow \frac{1}{\hat{\theta}} &= \frac{1 + \bar{x}}{\bar{x}} \\ \Leftrightarrow \hat{\theta} &= \frac{\bar{x}}{1 + \bar{x}} \end{aligned}$$

Observe ainda que

$$\frac{d^2 l(\theta, x)}{d\theta^2} = - \sum_{i=1}^n x_i \frac{1}{\theta^2} - n \frac{1}{(1 - \theta)^2} < 0$$

Para (ii), temos que $\mu = \frac{\theta}{1-\theta}$ e $m_1 = \frac{\sum_{i=1}^n x_i}{n}$, logo, obtemos o estimador pelo metodo dos momentos fazendo,

$$\begin{aligned}\frac{\hat{\theta}}{1-\hat{\theta}} &= \frac{\sum_{i=1}^n x_i}{n} \\ \Leftrightarrow \frac{\hat{\theta}}{1-\hat{\theta}} &= \bar{x} \\ \Leftrightarrow \frac{1-\hat{\theta}}{\hat{\theta}} &= \frac{1}{\bar{x}} \\ \Leftrightarrow \frac{1}{\hat{\theta}} - 1 &= \frac{1}{\bar{x}} \\ \Leftrightarrow \frac{1}{\hat{\theta}} &= \frac{1}{\bar{x}} + 1 \\ \Leftrightarrow \frac{1}{\hat{\theta}} &= \frac{1+\bar{x}}{\bar{x}} \\ \Leftrightarrow \hat{\theta} &= \frac{\bar{x}}{1+\bar{x}}\end{aligned}$$

Para (iii), temos a distribuição a priori é dado por $\Theta \sim U(0, 1)$

$$\pi(\theta) = 1I_{(0,1)}(\theta)$$

a função de perda é $L_R(\theta, d) = (\theta - d)^2$, e

$$f(x|\theta) = \theta^{\sum_{i=1}^n x_i} (1-\theta)^n \prod_{i=1}^n I_{\{0,1,\dots\}}(x_i)$$

Assim, a distribuição a posteriori de θ é

$$\pi(\theta|x) = \pi(\theta) \times f(x|\theta) \propto \theta^{\sum_{i=1}^n x_i} (1-\theta)^n I_{(0,1)}(\theta)$$

Assim, $\Theta|X = x \sim \text{Beta}(\sum_{i=1}^n x_i + 1, n + 1)$ Logo, obtemos o estimador de Bayes, fazendo

$$\delta = \frac{\sum_{i=1}^n X_i + 1}{(\sum_{i=1}^n X_i + 1) + (n + 1)} = \frac{\sum_{i=1}^n X_i + 1}{\sum_{i=1}^n X_i + n + 2} \quad (1)$$

1) Suponha que, dado θ , X_1, \dots, X_n sejam variáveis aleatórias independentes e identicamente distribuídas tal que $X_i|\theta \sim U(0, \theta)$. Considere a seguinte distribuição a priori para θ : $\frac{1}{\theta} \sim \text{Gama}(a, b)$, com $a, b > 0$ conhecidos.

(a) O estimador de Bayes de θ sob perda quadrática é dado por $\hat{\theta}(X_{(n)})$, onde $X_{(n)} = \max(X_1, \dots, X_n)$, e

$$\hat{\theta}(y) = \frac{\int_y^\infty \theta \cdot \frac{1}{\theta^{n+a+1}} \exp\left(-\frac{1}{\theta b}\right) d\theta}{\int_y^\infty \frac{1}{\theta^{n+a+1}} \exp\left(-\frac{1}{\theta b}\right) d\theta}.$$

Solução:

O estimador de bayes sob perda quadrática é dado por

$$\hat{\theta}(\hat{X}_{(n)}) = \mathbb{E}[\theta|X = x] = \int_{S(\theta)} \theta \lambda(\theta|x) d\theta = \int_{S(\theta)} \theta \frac{p(\theta, \mathbf{x}|\theta)}{q(\mathbf{x})} d\theta$$

onde $\lambda(\theta|X)$ é distribuição posterior de θ .

$$\lambda(\theta) = \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \text{ e } p(X = x|\theta) = \frac{1}{\theta} \mathbb{I}_{(0,\theta)}(x), \quad \theta \in (0, \infty)$$

$$p(\mathbf{x}|\theta) \stackrel{iid}{=} \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}_{(0,\theta)}(x_i) = \frac{1}{\theta^n} \mathbb{I}_{\{x_{(n)} < \theta\}}(x) = \frac{1}{\theta^n} \mathbb{I}_{\{\theta > x_{(n)}\}}(x)$$

$$\begin{aligned}
p(\theta, \mathbf{x}|\theta) &= p(\mathbf{x}|\theta) \times \lambda(\theta) = \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \mathbb{I}_{\{\theta > x_{(n)}\}}(x), \quad \theta \in (x_{(n)}, \infty) \\
&= \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \mathbb{I}_{\{\theta > x_{(n)}\}}(x), \quad \theta \in (x_{(n)}, \infty) \\
&= \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \mathbb{I}_{\{\theta > x_{(n)}\}}(x), \quad \theta \in (x_{(n)}, \infty) \\
&= \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \mathbb{I}_{\{\theta > x_{(n)}\}}(x), \quad \theta \in (x_{(n)}, \infty) \\
q(\mathbf{x}) &= \int_{s(\theta)} p(\theta, \mathbf{x}|\theta) d\theta = \int_{s(\theta)} \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) \mathbb{I}_{\{\theta > x_{(n)}\}}(x) d\theta, \quad \theta \in (x_{(n)}, \infty) \\
&= \int_{x_{(n)}}^{\infty} \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) d\theta \\
&= \int_{x_{(n)}}^{\infty} \frac{1}{\theta^{n+a+1}} \times \frac{1}{\Gamma(a)b^a} \exp\left(-\frac{1}{b\theta}\right) d\theta
\end{aligned}$$

Assim,

$$\begin{aligned}
\hat{\theta}(\hat{X}_{(n)}) &= \mathbb{E}[\theta|X = x] = \int_{S(\theta)} \theta \lambda(\theta|\mathbf{x}) d\theta = \int_{S(\theta)} \theta \frac{p(\theta, \mathbf{x}|\theta)}{q(\mathbf{x})} d\theta, \quad \theta \in (x_{(n)}, \infty) \\
&= \frac{\int_{S(\theta)} \theta p(\theta, \mathbf{x}|\theta) d\theta}{q(\mathbf{x})}, \quad \theta \in (x_{(n)}, \infty) \\
&= \frac{\int_{x_{(n)}}^{\infty} \theta p(\theta, \mathbf{x}|\theta) d\theta}{q(\mathbf{x})} \\
&= \frac{\int_{x_{(n)}}^{\infty} \theta \frac{1}{\theta^n} \times \frac{1}{\Gamma(a)b^a} \theta^{-a-1} \exp\left(-\frac{1}{b\theta}\right) d\theta}{\int_{x_{(n)}}^{\infty} \frac{1}{\theta^{n+a+1}} \times \frac{1}{\Gamma(a)b^a} \exp\left(-\frac{1}{b\theta}\right) d\theta} \\
&= \frac{\int_{x_{(n)}}^{\infty} \theta \frac{1}{\theta^{n+a+1}} \exp\left(-\frac{1}{b\theta}\right) d\theta}{\int_{x_{(n)}}^{\infty} \frac{1}{\theta^{n+a+1}} \times \exp\left(-\frac{1}{b\theta}\right) d\theta}
\end{aligned}$$

Assim, considerando $\hat{X}_{(n)} = y$, tem-se:

$$\hat{\theta}(y) = \frac{\int_y^{\infty} \theta \frac{1}{\theta^{n+a+1}} \exp\left(-\frac{1}{b\theta}\right) d\theta}{\int_y^{\infty} \frac{1}{\theta^{n+a+1}} \times \exp\left(-\frac{1}{b\theta}\right) d\theta}$$

(b) Mostre que $\hat{\theta}(y)$ pode ser expresso como

$$\hat{\theta}(y) = \frac{1}{b(n+a-1)} \cdot \frac{P\left[\chi_{2(n+a-1)}^2 < \frac{2}{by}\right]}{P\left[\chi_{2(n+a)}^2 < \frac{2}{by}\right]}.$$

Solução: Seja,

$$\theta = \frac{2}{bx}, \quad d\theta = -\frac{2}{bx^2} dx$$

Sabe-se que $\theta \in (y, \infty)$. Se $\theta = y$ se tem: $\theta = \frac{2}{bx} \implies y = \frac{2}{bx} \iff x = \frac{2}{by} \iff \theta \in \left(\frac{2}{by}, \infty\right)$.

Assim,

$$\begin{aligned}
\hat{\theta}(y) &= \frac{\int_y^\infty \theta^{\frac{1}{\theta^{n+a+1}}} \exp\left(-\frac{1}{b\theta}\right) d\theta}{\int_y^\infty \frac{1}{\theta^{n+a+1}} \times \exp\left(-\frac{1}{b\theta}\right) d\theta} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{2}{bx} \left(\frac{2}{bx}\right)^{\frac{1}{n+a+1}} \left[\exp\left(-\frac{1}{b\left(\frac{2}{bx}\right)}\right)\right] \left(-\frac{2}{bx^2}\right) dx}{\int_{\frac{2}{by}}^\infty \left(\frac{2}{bx}\right)^{\frac{1}{n+a+1}} \times \left[\exp\left(-\frac{1}{b\left(\frac{2}{bx}\right)}\right)\right] \left(-\frac{2}{bx^2}\right) dx} \\
&= \frac{\int_{\frac{2}{by}}^\infty \left(\frac{2}{bx}\right)^{1-n-a-1} \left[\exp\left(-\frac{x}{2}\right)\right] \left(\frac{1}{bx^2}\right) dx}{\int_{\frac{2}{by}}^\infty \frac{1}{\frac{2^{n+a+1}}{b^{n+a+1} x^{n+a+1}}} \times \left[\exp\left(-\frac{x}{2}\right)\right] \left(\frac{1}{bx^2}\right) dx} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{b^{n+a-1} x^{n+a-2}}{2^{n+a}} \exp\left(-\frac{x}{2}\right) dx}{\int_{\frac{2}{by}}^\infty \frac{b^{n+a+1-1} x^{n+a+1-2}}{2^{n+a} \times 2} \times \exp\left(-\frac{x}{2}\right) dx} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{b^{n+a} x^{n+a-2}}{b \times 2^{n+a}} \exp\left(-\frac{x}{2}\right) dx}{\int_{\frac{2}{by}}^\infty \frac{b^{n+a} x^{n+a-1}}{2^{n+a} \times 2} \times \exp\left(-\frac{x}{2}\right) dx} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{x^{n+a-2}}{b} \exp\left(-\frac{x}{2}\right) dx}{\int_{\frac{2}{by}}^\infty \frac{x^{n+a-1}}{2} \times \exp\left(-\frac{x}{2}\right) dx} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{\left(\frac{2x}{2}\right)^{n+a-2}}{b} \exp\left(-\frac{x}{2}\right) 2d\left(\frac{x}{2}\right)}{\int_{\frac{2}{by}}^\infty \frac{\left(\frac{2x}{2}\right)^{n+a-1}}{2} \times \exp\left(-\frac{x}{2}\right) 2d\left(\frac{x}{2}\right)} \\
&= \frac{\int_{\frac{2}{by}}^\infty \frac{2^{n+a-1} \left(\frac{x}{2}\right)^{n+a-2}}{b} \exp\left(-\frac{x}{2}\right) d\left(\frac{x}{2}\right)}{\int_{\frac{2}{by}}^\infty 2^{n+a-1} \left(\frac{x}{2}\right)^{n+a-1} \times \exp\left(-\frac{x}{2}\right) d\left(\frac{x}{2}\right)} \\
&= \frac{\int_{\frac{2}{by}}^\infty \left(\frac{x}{2}\right)^{n+a-2} \exp\left(-\frac{x}{2}\right) d\left(\frac{x}{2}\right)}{b \int_{\frac{2}{by}}^\infty \left(\frac{x}{2}\right)^{n+a-1} \times \exp\left(-\frac{x}{2}\right) d\left(\frac{x}{2}\right)} \\
&= \frac{-\Gamma(n+a-1) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a-1)} \frac{x^{(n+a-1)-1}}{2^{(n+a-1)-1}} \frac{1}{2} \exp\left(-\frac{x}{2}\right) dx}{-b\Gamma(n+a) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a)} \frac{x^{(n+a)-1}}{2^{(n+a)-1}} \times \frac{1}{2} \exp\left(-\frac{x}{2}\right) dx} \\
&= \frac{-\Gamma(n+a-1) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a-1)} \frac{x^{(n+a-1)-1}}{2^{(n+a-1)-1}} \exp\left(-(2^{-1})x\right) dx}{-b\Gamma(n+a) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a)} \frac{x^{(n+a)-1}}{2^{(n+a)-1}} \times \exp\left(-(2^{-1})x\right) dx} \\
&= \frac{\Gamma(n+a-1) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a-1)} (2^{-1})^{(n+a-1)} x^{(n+a-1)-1} \exp\left(-(2^{-1})x\right) dx}{\underbrace{\Gamma(n+a-1) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a-1)} (2^{-1})^{(n+a-1)} x^{(n+a-1)-1} \exp\left(-(2^{-1})x\right) dx}_{Gama(n+a-1,2)}} \\
&= \frac{1}{b\Gamma(n+a) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a)} (2^{-1})^{n+a} x^{(n+a)-1} \times \exp\left(-(2^{-1})x\right) dx} \underbrace{\Gamma(n+a) \int_{-\infty}^{\frac{2}{by}} \frac{1}{\Gamma(n+a)} (2^{-1})^{n+a} x^{(n+a)-1} \times \exp\left(-(2^{-1})x\right) dx}_{Gama(n+a,2)}
\end{aligned}$$

Sabe-se $Gama\left(\frac{x}{2}, 2\right) \stackrel{d}{=} \chi_{(x)}^2$, $Gama(a, r) = \frac{r^a x^{a-1} e^{-r \cdot x}}{\Gamma(a)}$ e $Gama(n) = (n-1)!$.

$$\begin{aligned}
\hat{\theta}(y) &= \frac{(n+a-2)! \int_{-\infty}^{\frac{2}{by}} Gama\left(\frac{2(n+a-1)}{2}, 2\right) dx}{b(n+a-1)! \int_{-\infty}^{\frac{2}{by}} Gama\left(\frac{2(n+a)}{2}, 2\right) dx} = \frac{(n+a-2)! \int_{-\infty}^{\frac{2}{by}} \chi_{2(n+a-1)}^2 dx}{b(n+a-1) \cdot (n+a-2)! \int_{-\infty}^{\frac{2}{by}} \chi_{2(n+a)}^2 dx} \\
\hat{\theta}(y) &= \frac{1}{b(n+a-1)} \cdot \frac{P\left[\chi_{2(n+a-1)}^2 < \frac{2}{by}\right]}{P\left[\chi_{2(n+a)}^2 < \frac{2}{by}\right]}
\end{aligned}$$

3. Prove ou dê contra-exemplo.

(a) Se um estimador minimax é único, então ele é admissível.

Resposta: Verdadeira.

Demonstração:

Considere $\delta^*(\mathbf{X})$ como um estimador minimax único. Vamos supor, por contradição, que δ^* não seja admissível. Dessa forma, deve existir um estimador alternativo δ' que domine δ^* , ou seja, $R(\theta, \delta') \leq R(\theta, \delta^*)$ para todo θ , com desigualdade estrita para pelo menos um valor de θ . Assim, podemos afirmar que:

$$\sup_{\theta \in \Omega} R(\theta, \delta') \leq \sup_{\theta \in \Omega} R(\theta, \delta^*).$$

Por outro lado, como $\delta^*(\mathbf{X})$ é minimax, ele atinge a menor cota superior para $\sup_{\theta \in \Omega} R(\theta, \delta(\mathbf{X}))$, resultando em:

$$\begin{aligned} \sup_{\theta \in \Omega} R(\theta, \delta'(\mathbf{X})) &\leq \sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})), \\ \sup_{\theta \in \Omega} R(\theta, \delta'(\mathbf{X})) &\geq \sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})) = \inf_{\delta} \sup_{\theta \in \Omega} R(\theta, \delta(\mathbf{X})). \end{aligned}$$

Combinando as expressões anteriores, concluímos que:

$$\sup_{\theta \in \Omega} R(\theta, \delta'(\mathbf{X})) = \sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})).$$

Nesse caso, δ' também seria um estimador minimax, o que contradiz a hipótese de que δ^* é único. Portanto, se um estimador minimax δ^* é único, não pode haver outro estimador que o domine, o que implica que δ^* é admissível.

(b) Um estimador minimax não pode ser não viciado.

Resposta: Falsa.

Vamos apresentar um contra-exemplo, definindo um estimador δ que seja minimax e não viciado.

Considere X_1, \dots, X_n como uma amostra aleatória de uma distribuição de Poisson com média $\lambda > 0$. Se assumirmos uma função de perda da forma $\frac{1}{\lambda}(d - \lambda)^2$ e uma distribuição a priori Gama(a,b) para λ , com $a = 1$, o estimador \bar{X} é minimax para λ (conforme demonstrado no exercício 10 da Lista 4). No entanto, este estimador é não viciado, pois

$$E_{\lambda}[\bar{X}] = \frac{1}{n} \sum_{i=1}^n E_{\lambda}[X_i] = \frac{1}{n} n\lambda = \lambda, \quad \forall \lambda > 0.$$

(c) Se um estimador tem risco constante e é admissível, ele é minimax.

Resposta: Verdadeira.

Demonstração:

Seja $\delta^*(\mathbf{X})$ um estimador com risco constante para θ , ou seja,

$$\sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})) = R(\theta, \delta^*(\mathbf{X})) \quad (*)$$

Além disso, suponha que $\delta^*(\mathbf{X})$ seja admissível para θ . Assim, para qualquer outro estimador δ' , temos:

$$R(\theta, \delta^*(\mathbf{X})) \leq R(\theta, \delta'(\mathbf{X})), \quad \forall \theta \in \Omega,$$

com desigualdade estrita para algum valor de θ . Com base na igualdade de acima (*), podemos reescrever isso da seguinte maneira:

$$\sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})) \leq \sup_{\theta \in \Omega} R(\theta, \delta'(\mathbf{X}))$$

Portanto, temos que:

$$\sup_{\theta \in \Omega} R(\theta, \delta^*(\mathbf{X})) = \inf_{\delta} \sup_{\theta \in \Omega} R(\theta, \delta(\mathbf{X}))$$

ou seja, $\delta^*(\mathbf{X})$ é um estimador minimax.

(d) Se um estimador equivariante por localização de risco mínimo é admissível, ele é minimax.

Resposta: Verdadeira.

Demonstração:

Seja $\mathbf{X} = (X_1, \dots, X_n)$ uma amostra aleatória cuja função de densidade é dada por:

$$f(\mathbf{x} - \theta) = f(x_1 - \theta, \dots, x_n - \theta), \quad \theta \in \mathbb{R},$$

onde f é conhecida, θ é um parâmetro de localização não especificado, e $\mathbf{x} = (x_1, \dots, x_n)$. Considere um estimador $\delta(\mathbf{X})$ que seja admissível e equivariante em relação ao parâmetro de localização θ . Em outras palavras, $\delta(\mathbf{x} + \theta) = \delta(\mathbf{x}) + \theta$ para todo $\theta \in \mathbb{R}$ e $\mathbf{x} \in \mathbb{R}^n$. Além disso, assuma que a função de perda seja invariante sob translações: $L(\theta, \delta(\mathbf{X})) = L(\theta + a, \delta(\mathbf{X}) + a)$, $\forall a \in \mathbb{R}$.

Definimos $\mathbf{U} = (U_1, \dots, U_n)'$, onde U_i , $i = 1, \dots, n$, são variáveis aleatórias independentes com distribuição fixa F . Podemos então expressar \mathbf{X} como:

$$\mathbf{X} \stackrel{d}{=} \mathbf{U} + \theta, \quad \theta \in \mathbb{R}$$

Vamos denotar a função de risco associada ao estimador $\delta(\mathbf{X})$ como $R(\theta, \delta(\mathbf{X}))$, que pode ser escrita da seguinte maneira:

$$\begin{aligned} R(\theta, \delta(\mathbf{X})) &= E_\theta[L(\theta, \delta(\mathbf{X}))] \\ &= E_\theta[L(\theta, \delta(\mathbf{U} + \theta))] \\ &= E_\theta[L(\theta, \delta(\mathbf{U}) + \theta)] \\ &= E_0[L(0, \delta(\mathbf{U}))] \end{aligned}$$

Na segunda igualdade, usamos a propriedade da família de distribuições invariante por localização; na terceira, usamos a definição de equivariância do estimador; e na quarta, usamos a invariância da função de perda. Assim, a função de risco não depende de θ , ou seja, o risco do estimador δ é constante em relação a θ . Portanto, pelo resultado do item (c), concluímos que δ é um estimador minimax, já que possui risco constante e é admissível (por hipótese).

5. Suponha que, dado θ , X_1, \dots, X_n (com $n \geq 1$) sejam variáveis aleatórias independentes e identicamente distribuídas com densidade

$$f(x|\theta) = \exp(\theta - x), \quad x > \theta.$$

Considere que a distribuição a priori para θ seja exponencial padrão, ou seja, $\pi(\theta) = \exp(-\theta)$.

Encontre a densidade a posteriori de θ e o estimador de Bayes de θ sob perda quadrática.

Solução

$$\begin{aligned} f(x|\theta) &= \exp\{\theta - x\} \mathbb{I}_{(\theta, \infty)}(x) \\ f(\mathbf{x}|\theta) &\stackrel{ind}{=} \prod_{i=1}^n \exp\{\theta - x_i\} \mathbb{I}_{(\theta, \infty)}(x_i) = \exp\left\{\sum_{i=1}^n (\theta - x_i)\right\} \mathbb{I}_{\{x_{(1)} > \theta\}} \mathbb{I}_{\{x_{(n)} < \infty\}}(x) \\ \lambda(\theta) &= \exp\{-\theta\}, \quad \theta > 0 \\ p(\theta, \mathbf{x}|\theta) &\stackrel{ind}{=} \lambda(\theta) \times f(\mathbf{x}|\theta) = \exp\{-\theta\} \times \exp\left\{\sum_{i=1}^n (\theta - x_i)\right\} \mathbb{I}_{\{x_{(1)} > \theta\}} \mathbb{I}_{\{x_{(n)} < \infty\}}(x) \\ \lambda(\theta|\mathbf{x}) &= \frac{p(\theta, \mathbf{x}|\theta)}{q(\mathbf{x})} = \frac{f(\mathbf{x}|\theta) \times \lambda(\theta)}{q(\mathbf{x})} \\ q(\mathbf{x}) &= \int_{s(\theta)} p(\theta, \mathbf{x}|\theta) d\theta \\ q(\mathbf{x}) &= \int_{s(\theta)} \exp\{-\theta\} \times \exp\left\{\sum_{i=1}^n (\theta - x_i)\right\} \mathbb{I}_{\{x_{(1)} > \theta\}} \mathbb{I}_{\{x_{(n)} < \infty\}}(x) d\theta, \quad \theta > 0 \end{aligned}$$

$$\begin{aligned}
q(x) &= \int_{s(\theta)} \exp\{-\theta\} \times \exp\left\{\sum_{i=1}^n (\theta - x_i)\right\} \mathbb{I}_{\{\theta < x_{(1)}\}} \mathbb{I}_{\{x_{(n)} < \infty\}}(x) d\theta, \quad \theta > 0 \\
&= \int_0^{x_{(1)}} \exp\{-\theta\} \times \exp\{n\theta - n\bar{x}\} d\theta \\
&= \int_0^{x_{(1)}} \exp\{-\theta\} \times \exp\{n\theta\} \frac{1}{e^{n\bar{x}}} d\theta \\
&= \frac{1}{e^{n\bar{x}}} \int_0^{x_{(1)}} \exp\{-\theta + n\theta\} d\theta \\
&= \frac{1}{e^{n\bar{x}}} \int_0^{x_{(1)}} \exp\{(-1 + n)\theta\} d\theta \\
&= \frac{1}{e^{n\bar{x}}} \int_0^{x_{(1)}} \frac{1}{(n-1)} \exp\{(-1 + n)\theta\} d((-1 + n)\theta) \\
&= \frac{1}{e^{n\bar{x}}(n-1)} \exp\{(-1 + n)\theta\} \Big|_0^{x_{(1)}} \\
&= \frac{1}{e^{n\bar{x}}(n-1)} \exp\{(n-1)x_{(1)}\} - \frac{1}{e^{n\bar{x}}(n-1)} \\
&= \frac{1}{e^{n\bar{x}}(n-1)} [\exp\{(n-1)x_{(1)}\} - 1] \\
\lambda(\theta|\mathbf{x}) &= \frac{p(\theta, \mathbf{x}|\theta)}{q(x)} = \frac{f(\mathbf{x}|\theta) \times \lambda(\theta)}{q(x)} \\
\lambda(\theta|\mathbf{x}) &= \frac{\exp\{-\theta\} \times \exp\left\{\sum_{i=1}^n (\theta - x_i)\right\} \mathbb{I}_{\{x_{(1)} > \theta\}} \mathbb{I}_{\{x_{(n)} < \infty\}}(x)}{\frac{1}{e^{n\bar{x}}(n-1)} [\exp\{(n-1)x_{(1)}\} - 1]} \\
&= \frac{\exp\{-\theta\} \times \exp\{n\theta\} \frac{1}{e^{n\bar{x}}}}{\frac{1}{e^{n\bar{x}}(n-1)} [\exp\{(n-1)x_{(1)}\} - 1]} \\
&= \frac{(n-1) \exp\{n\theta - \theta\}}{\exp\{(n-1)x_{(1)}\} - 1} \\
&= \frac{(n-1) \exp\{(n-1)\theta\}}{\exp\{(n-1)x_{(1)}\} - 1}
\end{aligned}$$

\implies Estimador de bayes sob perda quadrática

$$\begin{aligned}
\delta(x) &= \mathbb{E}[\Theta|X] = \int_{s(\theta)} \theta \lambda(\theta|\mathbf{x}) d\theta \\
\delta(x) &= \int_0^{x_{(1)}} \theta \frac{(n-1) \exp\{(n-1)\theta\}}{\exp\{(n-1)x_{(1)}\} - 1} d\theta \\
\delta(x) &= \frac{1}{\exp\{(n-1)x_{(1)}\} - 1} \int_0^{x_{(1)}} \theta (n-1) \exp\{(n-1)\theta\} d\theta \\
\text{Seja } u &= \theta, \quad du = d\theta \text{ e } dv = (n-1) \exp\{(n-1)\theta\} d\theta \\
v &= \int dv = \int (n-1) \exp\{(n-1)\theta\} d\theta = \frac{(n-1)}{(n-1)} \int \exp\{(n-1)\theta\} d((n-1)\theta) = \exp\{(n-1)\theta\} \\
\delta(x) &= \frac{1}{\exp\{(n-1)x_{(1)}\} - 1} \left[\theta \exp\{(n-1)\theta\} \Big|_0^{x_{(1)}} - \int_0^{x_{(1)}} \exp\{(n-1)\theta\} d\theta \right] \\
&= \frac{1}{\exp\{(n-1)x_{(1)}\} - 1} \left[\theta \exp\{(n-1)\theta\} \Big|_0^{x_{(1)}} - \frac{1}{(n-1)} \exp\{(n-1)\theta\} \Big|_0^{x_{(1)}} \right] \\
&= \frac{1}{\exp\{(n-1)x_{(1)}\} - 1} \left[x_{(1)} \exp\{(n-1)x_{(1)}\} - \frac{1}{(n-1)} \exp\{(n-1)x_{(1)}\} - \left(-\frac{1}{(n-1)} \right) \right] \\
&= \frac{1}{\exp\{(n-1)x_{(1)}\} - 1} \left[x_{(1)} \exp\{(n-1)x_{(1)}\} - \frac{1}{(n-1)} (\exp\{(n-1)x_{(1)}\} - 1) \right] \\
&= \frac{x_{(1)} \exp\{(n-1)x_{(1)}\}}{\exp\{(n-1)x_{(1)}\} - 1} - \frac{\exp\{(n-1)x_{(1)}\} - 1}{(n-1)(\exp\{(n-1)x_{(1)}\} - 1)} \\
&= \frac{x_{(1)} \exp\{(n-1)x_{(1)}\}}{\exp\{(n-1)x_{(1)}\} - 1} - \frac{1}{(n-1)}
\end{aligned}$$

Assim, o estimador de Bayes fica:

$$\delta(X) = \frac{X_{(1)} \exp \{(n-1)X_{(1)}\}}{\exp \{(n-1)X_{(1)}\} - 1} - \frac{1}{(n-1)}$$

8. Seja $\mathbf{X} = (X_1, \dots, X_n)$ um vetor de n variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição $N(0, \sigma^2)$. Considere o problema de estimar σ^2 com a função de perda $L(\sigma^2, d) = \left(\frac{d}{\sigma^2} - 1\right)^2 = \frac{(d - \sigma^2)^2}{\sigma^4}$. Considere uma distribuição a priori Gama(a, b) para $\theta = 1/(2\sigma^2)$ com densidade

$$\pi(\theta) = \frac{1}{\Gamma(a)b^a} \theta^{a-1} \exp \left\{ -\frac{\theta}{b} \right\}, \quad a > 0, \quad b > 0.$$

Considere $X|\theta \sim N(0, \sigma^2)$. A função de densidade condicional é dada por:

$$f(x|\theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{1}{2\sigma^2}(x)^2 \right) I_{(-\infty, \infty)}(x)$$

Assumindo $\theta = \frac{1}{2\sigma^2}$, a densidade conjunta da amostra \mathbf{x} , condicionada a θ , pode ser expressa por:

$$f(\mathbf{x} | \theta) = (\pi)^{-n/2} \theta^{n/2} \exp \left(-\theta \sum_{i=1}^n x_i^2 \right) \prod_{i=1}^n I_{(-\infty, \infty)}(x_i)$$

Considere uma distribuição a priori para θ pertencente à família Gama, Gama(a, b), onde $a > 0$ e $b > 0$, cuja densidade é dada por:

$$\pi(\theta) \propto \theta^{a-1} \exp \left(-\frac{\theta}{b} \right) I_{(0, \infty)}(\theta)$$

Assim, a distribuição a posteriori de θ , denotada por $\pi(\theta | \mathbf{x})$, é proporcional ao produto da verossimilhança pela priori:

$$\begin{aligned} \pi(\theta | \mathbf{x}) &\propto f(\mathbf{x} | \theta) \pi(\theta) \propto \theta^{n/2} \exp \left(-\theta \sum_{i=1}^n x_i^2 \right) \cdot \theta^{a-1} \exp \left(-\frac{\theta}{b} \right) I_{(0, \infty)}(\theta) \\ &\propto \theta^{(n/2+a)-1} \exp \left(-\theta \left(\sum_{i=1}^n x_i^2 + \frac{1}{b} \right) \right) I_{(0, \infty)}(\theta) \end{aligned}$$

Portanto, θ condicionado a $\mathbf{X} = \mathbf{x}$ segue uma distribuição Gama, ou seja:

$$\theta | \mathbf{X} = \mathbf{x} \sim \text{Gama} \left(\frac{n}{2} + a, \left(\sum_{i=1}^n x_i^2 + \frac{1}{b} \right)^{-1} \right).$$

(a) Encontre o estimador de Bayes de σ^2 .

Considere a função de perda

$$L(\sigma^2, d) = \left(\frac{d - \sigma^2}{\sigma^2} \right)^2 = \frac{1}{(\sigma^2)^2} (d - \sigma^2)^2 = w(\sigma^2) (d - g(\sigma^2))^2, \quad \forall \sigma^2 > 0$$

onde $g(\sigma^2) = \sigma^2$ e $w(\sigma^2) = \left(\frac{1}{\sigma^2}\right)^2$. Dessa forma, o estimador de Bayes $\delta_\Delta(\mathbf{X})$ é dado por:

$$\begin{aligned}
\delta_{\Delta}(\mathbf{x}) &= \frac{E[w(\sigma^2)g(\sigma^2) \mid \mathbf{X} = \mathbf{x}]}{E[w(\sigma^2) \mid \mathbf{X} = \mathbf{x}]} \\
&= \frac{E\left[\left(\frac{1}{\sigma^2}\right)^2 \sigma^2 \mid \mathbf{X} = \mathbf{x}\right]}{E\left[\left(\frac{1}{\sigma^2}\right)^2 \mid \mathbf{X} = \mathbf{x}\right]} \\
&= \frac{E\left[\frac{1}{\sigma^2} \mid \mathbf{X} = \mathbf{x}\right]}{\text{Var}\left[\frac{1}{\sigma^2} \mid \mathbf{X}\right] + E^2\left[\frac{1}{\sigma^2} \mid \mathbf{X} = \mathbf{x}\right]}
\end{aligned}$$

Como $\theta = \frac{1}{2\sigma^2}$, temos que $\frac{1}{\sigma^2} \mid \mathbf{X} = \mathbf{x} \sim \text{Gama}\left(\frac{n}{2} + a, 2\left(\sum_{i=1}^n x_i^2 + \frac{1}{b}\right)^{-1}\right)$. Assim, segue que:

$$\delta_{\Delta}(\mathbf{x}) = \frac{\frac{2\left(\frac{n}{2} + a\right)}{\sum_{i=1}^n x_i^2 + \frac{1}{b}}}{\frac{4\left(\frac{n}{2} + a\right)}{\left(\sum_{i=1}^n x_i^2 + \frac{1}{b}\right)^2} + \frac{4\left(\frac{n}{2} + a\right)^2}{\left(\sum_{i=1}^n x_i^2 + \frac{1}{b}\right)^2}} = \frac{2\left(\frac{n}{2} + a\right)}{\frac{4\left(\frac{n}{2} + a\right)\left(1 + \frac{n}{2} + a\right)}{\sum_{i=1}^n x_i^2 + \frac{1}{b}}} = \frac{\sum_{i=1}^n x_i^2 + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a\right)}$$

(b) Mostre que o estimador minimax de σ^2 é $\frac{\sum_{i=1}^n X_i^2}{n+2}$.

Considere uma sequência de distribuições a priori $\text{Gama}(a_k, b)$ para θ , com $k \geq 1$ e $a_k \xrightarrow{k \rightarrow \infty} 0$. Sendo que $a > 0$ e $b > 0$ são valores arbitrários, pelo resultado do item anterior, o estimador de Bayes utilizando essa sequência de estimadores é dado por:

$$\delta_k(\mathbf{X}) = \frac{\sum_{i=1}^n X_i^2 + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a_k\right)}$$

e o risco associado a esse estimador é:

$$\begin{aligned}
R(\sigma^2, \delta_k(\mathbf{X})) &= E_{\sigma^2} \left[\frac{1}{(\sigma^2)^2} (\delta_k(\mathbf{X}) - \sigma^2)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\text{Var}(\delta_k(\mathbf{X})) + (E[\delta_k(\mathbf{X}) - \sigma^2])^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\text{Var}\left(\frac{\sum_{i=1}^n X_i^2 + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a_k\right)}\right) + \left(E\left[\frac{\sum_{i=1}^n X_i^2 + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a_k\right)}\right] - \sigma^2\right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\frac{n(E[X_1^4] - E^2[X_1^2])}{4\left(1 + \frac{n}{2} + a_k\right)^2} + \left(\frac{nE[X_1^2] + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a_k\right)} - \sigma^2\right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\frac{2n\sigma^4}{4\left(1 + \frac{n}{2} + a_k\right)^2} + \left(\frac{n\sigma^2 + \frac{1}{b}}{2\left(1 + \frac{n}{2} + a_k\right)} - \sigma^2\right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{4\left(1 + \frac{n}{2} + a_k\right)^2} \left[2n\sigma^4 + \left(\frac{1}{b} - 2\sigma^2 - 2a_k\sigma^2\right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{4\left(1 + \frac{n}{2} + a_k\right)^2} \left[2n\sigma^4 + \left(\frac{1}{b} - 2\sigma^2(1 + a_k)\right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{4\left(1 + \frac{n}{2} + a_k\right)^2} \left[2n\sigma^4 + \frac{1}{b^2} - \frac{4}{b}\sigma^2(1 + a_k) + 4(\sigma^2)^2(1 + a_k)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{4\left(1 + \frac{n}{2} + a_k\right)^2} \left[\frac{1}{b^2} - \frac{4}{b}\sigma^2(1 + a_k) + (\sigma^2)^2(2n + 4(1 + a_k)^2) \right] \\
&= \frac{1}{4\left(1 + \frac{n}{2} + a_k\right)^2} \left[\frac{1}{(b\sigma^2)^2} - \frac{4}{b}(1 + a_k) \cdot \frac{1}{\sigma^2} + 2n + 4(1 + a_k)^2 \right]
\end{aligned}$$

O risco de Bayes do estimador $\delta_k(\mathbf{X})$ é dado por:

$$\begin{aligned}
r_k &= E [R(\sigma^2, \delta_k(\mathbf{X}))] \\
&= \frac{1}{4(1 + \frac{n}{2} + a_k)^2} \left[\frac{1}{b^2} E \left[\frac{1}{(\sigma^2)^2} \right] - E \left[\frac{1}{\sigma^2} \right] \cdot \frac{4}{b} (1 + a_k) + (2n + 4(1 + a_k)^2) \right] \\
&= \frac{1}{4(1 + \frac{n}{2} + a_k)^2} \left[\frac{1}{b^2} (4a_k b^2 + 4a_k^2 b^2) - 2a_k b \cdot \frac{4}{b} (1 + a_k) + (2n + 4(1 + a_k)^2) \right] \\
&= \frac{1}{(1 + \frac{n}{2} + a_k)^2} \left[a_k(1 + a_k) - 2a_k(1 + a_k) + \frac{n}{2} + (1 + a_k)^2 \right]
\end{aligned}$$

Assim:

$$r_k \xrightarrow{k \rightarrow \infty} \frac{1 + \frac{n}{2}}{(1 + \frac{n}{2})^2} = \frac{1}{1 + \frac{n}{2}} = \frac{2}{n + 2} = r.$$

Por outro lado, considere o estimador $\delta^M(\mathbf{X}) = \frac{1}{n+2} \sum_{i=1}^n X_i^2$, cujo risco é:

$$\begin{aligned}
R(\sigma^2, \delta^M(\mathbf{X})) &= \frac{1}{(\sigma^2)^2} \left[\text{Var} \left(\frac{1}{n+2} \sum_{i=1}^n X_i^2 \right) + \left(E \left[\frac{1}{n+2} \sum_{i=1}^n X_i^2 \right] - \sigma^2 \right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\frac{n(E[X_1^4] - E^2[X_1^2])}{(n+2)^2} + \left(\frac{n}{n+2} E[X_1^2] - \sigma^2 \right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \left[\frac{2n\sigma^4}{(n+2)^2} + \left(\frac{n\sigma^2}{n+2} - \sigma^2 \right)^2 \right] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{(n+2)^2} [2n\sigma^4 + (-2\sigma^2)^2] \\
&= \frac{1}{(\sigma^2)^2} \cdot \frac{1}{(n+2)^2} \cdot 2\sigma^4(n+2) = \frac{2}{n+2}
\end{aligned}$$

Portanto:

$$r = R(\sigma^2, \delta^M(\mathbf{X})) = \sup_{\sigma^2} R(\sigma^2, \delta^M(\mathbf{X}))$$

Assim, $\delta^M(\mathbf{X}) = \frac{1}{n+2} \sum_{i=1}^n X_i^2$ é um estimador minimax de σ^2 .

22. Sejam X_1, \dots, X_m e Y_1, \dots, Y_n amostras aleatórias independentes das distribuições $N(\mu_x, \sigma_x^2)$ e $N(\mu_y, \sigma_y^2)$, respectivamente; onde $\mu_x \in \mathbb{R}, \mu_y \in \mathbb{R}, \sigma_x^2 > 0$ e $\sigma_y^2 > 0$. Considere o problema de estimar $\Delta = \mu_y - \mu_x$ sob perda quadrática.

(a) Mostre que $\hat{\Delta} = \bar{Y} - \bar{X}$ é um estimador minimax de Δ quando σ_x e σ_y são conhecidos; com

$$\bar{X} = \frac{1}{m} \sum_{i=1}^m X_i \quad \text{e} \quad \bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i.$$

Solução

Seja, $\theta = (\mu_x, \mu_y)$. o risco do estimador de Bayes $\hat{\Delta}$, pode ser descrito por:

$$\begin{aligned}
R(\Delta, \hat{\Delta}) &= \mathbb{E} [(\hat{\Delta} - \Delta)^2] \\
&= Var [(\hat{\Delta} - \Delta)] + \left(\mathbb{E} [(\hat{\Delta} - \Delta)^2] \right)^2 \\
&= Var [\bar{Y} - \bar{X}] \\
&\stackrel{ind}{=} Var [\bar{Y}] + Var [\bar{X}] \\
&= \frac{\sigma_Y^2}{m} - \frac{\sigma_X^2}{n}, \quad m, n > 0
\end{aligned}$$

$$\lambda(\mu_x, \mu_y) \stackrel{ind}{=} \lambda(\mu_x) \lambda(\mu_y), \quad \text{em que } \lambda(\mu_y) \text{ e } \lambda(\mu_y) \text{ são priores (marginais) normais}$$

$$\propto \exp \left\{ -\frac{1}{2b_x} (\mu_x - a_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2b_y} (\mu_y - a_y)^2 \right\}$$

$$p(x, y | \mu_x, \mu_y) \propto \exp \left\{ -\frac{1}{2\sigma_x^2} (x - \mu_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_y^2} (y - \mu_y)^2 \right\}$$

$$p(\mathbf{x}, \mathbf{y} | \mu_x, \mu_y) \propto \exp \left\{ -\frac{1}{2\sigma_x^2} \sum_{i=1}^m (x_i - \mu_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_y^2} \sum_{i=1}^n (y_i - \mu_y)^2 \right\}$$

$$p(\mathbf{x}, \mathbf{y} | \mu_x, \mu_y) \propto \exp \left\{ -\frac{1}{2\sigma_x^2} \sum_{i=1}^m (x_i - \mu_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_y^2} \sum_{i=1}^n (y_i - \mu_y)^2 \right\}$$

$$\lambda(\mu_x, \mu_y | \mathbf{x}, \mathbf{y}) \propto p(\mathbf{x}, \mathbf{y} | \mu_x, \mu_y) \times \lambda(\mu_x, \mu_y)$$

$$\propto \exp \left\{ -\frac{1}{2\sigma_x^2} \sum_{i=1}^m (x_i - \mu_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2\sigma_y^2} \sum_{i=1}^n (y_i - \mu_y)^2 \right\} \times \exp \left\{ -\frac{1}{2b_x} (\mu_x - a_x)^2 \right\} \cdot \exp \left\{ -\frac{1}{2b_y} (\mu_y - a_y)^2 \right\}$$

$$\propto \exp \left\{ -\frac{1}{2\sigma_x^2} \sum_{i=1}^m (x_i^2 - 2x_i\mu_x + \mu_x^2) \right\} \times \exp \left\{ -\frac{1}{2\sigma_y^2} \sum_{i=1}^n (y_i^2 - 2y_i\mu_y + \mu_y^2) \right\} \times \exp \left\{ -\frac{1}{2b_x} (\mu_x^2 - 2\mu_x a_x + a_x^2) \right\} \times$$

$$\times \exp \left\{ -\frac{1}{2b_y} (\mu_y^2 - 2\mu_y a_y + a_y^2) \right\}$$

$$\propto \exp \left\{ -\frac{1}{2} \left(\frac{\mu_x^2}{b_x} - \frac{2\mu_x a_x}{b_x} + \frac{m\mu_x^2}{\sigma_x^2} - \frac{2m\bar{x}\mu_x}{\sigma_x^2} \right) \right\} \times \exp \left\{ -\frac{1}{2} \left(\frac{\mu_y^2}{b_y} - \frac{2\mu_y a_y}{b_y} + \frac{n\mu_y^2}{\sigma_y^2} - \frac{2n\bar{y}\mu_y}{\sigma_y^2} \right) \right\}$$

$$\propto \exp \left(-\frac{1}{2} \left[\left(\frac{1}{b_x} + \frac{m}{\sigma_x^2} \right) \left(\mu_x^2 - \frac{2\mu_x \left(\frac{a_x}{b_x} + \frac{m\bar{x}}{\sigma_x^2} \right)}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \right) \right] \right) \times \exp \left(-\frac{1}{2} \left[\left(\frac{1}{b_y} + \frac{n}{\sigma_y^2} \right) \left(\mu_y^2 - \frac{2\mu_y \left(\frac{a_y}{b_y} + \frac{n\bar{y}}{\sigma_y^2} \right)}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} \right) \right] \right)$$

$$\sim N \left(\frac{\frac{a_x}{b_x} + \frac{m\bar{x}}{\sigma_x^2}}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}}, \frac{1}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \right)$$

$$\sim N \left(\frac{\frac{a_y}{b_y} + \frac{n\bar{y}}{\sigma_y^2}}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}}, \frac{1}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} \right)$$

Portanto,

$$\begin{aligned}
\hat{\Delta}(\mathbf{x}, \mathbf{y}) &= \mathbb{E} [\Delta | \mathbf{x}, \mathbf{y}] = \bar{Y} - \bar{X} \\
&= \frac{\frac{a_y}{b_y} + \frac{n\bar{y}}{\sigma_y^2}}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} - \frac{\frac{a_x}{b_x} + \frac{m\bar{x}}{\sigma_x^2}}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \\
R(\Delta, \hat{\Delta}) &= \text{Var} [\bar{Y}] + \text{Var} [\bar{X}] \\
&= \frac{1}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} + \frac{1}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \\
\lim_{\substack{b_y \rightarrow \infty \\ b_x \rightarrow \infty}} R(\Delta, \hat{\Delta}) &= \lim_{b_y \rightarrow \infty} \left[\lim_{b_x \rightarrow \infty} R(\Delta, \hat{\Delta}) \right] \\
&= \lim_{b_y \rightarrow \infty} \left[\lim_{b_x \rightarrow \infty} \frac{1}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} + \frac{1}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \right] \\
&= \lim_{b_y \rightarrow \infty} \frac{1}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} + \frac{1}{\frac{m}{\sigma_x^2}} \\
&= \frac{1}{\frac{n}{\sigma_y^2}} + \frac{1}{\frac{m}{\sigma_x^2}} \\
&= \frac{\sigma_y^2}{n} + \frac{\sigma_x^2}{m} = \sup_{\theta}(\theta, \bar{Y} - \bar{X}), \quad \text{Que é uma constante}
\end{aligned}$$

Sabe-se que se $\sup_{\theta}(\theta, \hat{\Delta})$ é uma constante, então $\hat{\Delta}$ é minimax. Logo,

$$\hat{\Delta} = \bar{Y} - \bar{X}$$

é minimax.

- (b) Mostre que $\hat{\Delta} = Y - X$ é um estimador minimax de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

Sugestão: Use o seguinte resultado:

Se, dado ξ , Z_1, \dots, Z_n são independentes e têm distribuição $N(\xi, \sigma^2)$, e se a distribuição a priori para ξ é $N(\zeta, b^2)$, então a distribuição a posteriori de ξ , dado $Z_1 = z_1, \dots, Z_n = z_n$, é normal com média

$$\frac{nz/\sigma^2 + \zeta/b^2}{n/\sigma^2 + 1/b^2}$$

e variância

$$\left(\frac{n}{\sigma^2} + \frac{1}{b^2} \right)^{-1},$$

onde $z = \frac{1}{n} \sum_{i=1}^n z_i$.

Solução

$$\begin{aligned}
R(\Delta, \hat{\Delta}) &= \frac{1}{\frac{1}{b_y} + \frac{n}{\sigma_y^2}} + \frac{1}{\frac{1}{b_x} + \frac{m}{\sigma_x^2}} \\
&= \frac{1}{\frac{1}{b_y} + \frac{n}{M_y}} + \frac{1}{\frac{1}{b_x} + \frac{m}{M_x}}, \quad M_x > 0 \text{ e } M_y > 0 \\
\lim_{\substack{b_y \rightarrow \infty \\ b_x \rightarrow \infty}} R(\Delta, \hat{\Delta}) &= \lim_{b_y \rightarrow \infty} \left[\lim_{b_x \rightarrow \infty} R(\Delta, \hat{\Delta}) \right] \\
&= \lim_{b_y \rightarrow \infty} \left[\lim_{b_x \rightarrow \infty} \frac{1}{\frac{1}{b_y} + \frac{n}{M_y}} + \frac{1}{\frac{1}{b_x} + \frac{m}{M_x}} \right] \\
&= \lim_{b_y \rightarrow \infty} \frac{1}{\frac{1}{b_y} + \frac{n}{M_y}} + \frac{1}{\frac{m}{M_x}} \\
&= \frac{1}{\frac{n}{M_x}} + \frac{1}{\frac{m}{M_x}} \\
&= \frac{M_y}{n} + \frac{M_x}{m} \\
&= \sup_{\theta}^*(\theta, \bar{Y} - \bar{X}), \quad \text{Que é uma constante}
\end{aligned}$$

- Se $M_y > \sigma_y^2$ e $M_x \leq \sigma_x^2$ ou vice-versa, observa-se que:

$$\sup_{\theta}^*(\theta, \bar{Y} - \bar{X}) > \sup_{\theta}(\theta, \bar{Y} - \bar{X})$$

, tornando $\bar{Y} - \bar{X}$ não minimax de Δ , pois existe outro estimador com menor supremo (menor risco máximo).

- Se $M_y = \sigma_y^2$ e $M_x = \sigma_x^2$, observa-se que:

$$\sup_{\theta}^*(\theta, \bar{Y} - \bar{X}) = \sup_{\theta}(\theta, \bar{Y} - \bar{X})$$

, logo $\bar{Y} - \bar{X}$ é estimador minimax de Δ .

- Se $M_y < \sigma_y^2$ e $M_x \leq \sigma_x^2$, ou vice-versa, ou ambos (M_x, M_y) estritamente menores, observa-se que:

$$\sup_{\theta}^*(\theta, \bar{Y} - \bar{X}) < \sup_{\theta}(\theta, \bar{Y} - \bar{X})$$

, logo $\bar{Y} - \bar{X}$ é estimador minimax de Δ .

Logo, $\hat{\Delta} = Y - X$ é um estimador minimax de Δ quando $\sigma_x^2 \leq M_x$ e $\sigma_y^2 \leq M_y$, sendo $M_x > 0$ e $M_y > 0$ constantes conhecidas.

Questão 15 Seja $\hat{\theta}$ um estimador não viciado de um parâmetro $\theta \in R$. Seja $R(\theta, \tilde{\theta})$ o risco do estimador $\tilde{\theta}$ de θ .

- (a) Sob perda quadrática, mostre que o estimador $\hat{\theta} + c$, em que $c \neq 0$ é uma constante conhecida, não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ .

Sob perda quadrática, o risco do estimador $\hat{\theta} + c$ é dado por

$$\begin{aligned}
R(\theta, \hat{\theta} + c) &= E[(\hat{\theta} + c - \theta)^2] \\
&= E[(\hat{\theta} - \theta + c)^2] \\
&= E[(\hat{\theta} - \theta)^2] + 2cE[\hat{\theta} - \theta] + c^2
\end{aligned}$$

Como $\hat{\theta}$ é um estimador não viciado para θ , $E[\hat{\theta} - \theta] = 0$, logo

$$\begin{aligned}
R(\theta, \hat{\theta} + c) &= E[(\hat{\theta} - \theta)^2] + c^2 \\
&= R(\theta, \hat{\theta}) + c^2
\end{aligned}$$

Como $c \neq 0$, $c^2 > 0$, então, $R(\theta, \hat{\theta} + c) > R(\theta, \hat{\theta})$. Assim, o estimador $\hat{\theta} + c$, em que $c \neq 0$ é uma constante conhecida, não é estimador minimax de θ , pois, o risco do estimador $\hat{\theta} + c$ é sempre maior do que o risco de $\hat{\theta}$. Não obstante, se $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ , a comparação seria irrelevante, tendo em vista que $\sup_{\theta} R(\theta, \hat{\theta}) = \infty = \sup_{\theta} R(\theta, \hat{\theta} + c)$.

- (b) Sob perda quadrática, mostre que o estimador $c\hat{\theta}$, em que $c \in (0, 1)$ é uma constante conhecida, não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ .

Sob perda quadrática, o risco do estimador $c\hat{\theta}$ é dado por

$$\begin{aligned} R(\theta, c\hat{\theta}) &= E[(c\hat{\theta} - \theta)^2] \\ &= c^2 E[(\hat{\theta} - \theta)^2 + (1 - c)^2 \theta^2] \end{aligned}$$

Observe que como $c \in (0, 1)$, $c^2 R(\theta, \hat{\theta}) < R(\theta, \hat{\theta})$. Além disso, vale salientar que o termo dado por $(1 - c)^2 \theta^2$ é um erro adicional que cresce quadraticamente em função de θ . Assim,

$$\sup_{\theta} R(\theta, c\hat{\theta}) = \sup_{\theta} (c^2 R(\theta, \hat{\theta}) + (1 - c)^2 \theta^2)$$

Nesse caso o supremo do risco de $c\hat{\theta}$ pode ser grande devido a expressão $(1 - c)^2 \theta^2$, implicando que o estimador $c\hat{\theta}$ não minimiza o supremo do risco, ou seja, não pode ser minimax. A menos que todos os estimadores fossem infinitos, pois nesse caso o aumento indefinido no risco de $c\hat{\theta}$ não faria diferença.

- (c) Considere a função de perda $L(\theta, d) = (d - \theta)^2 / \theta^2$, assumindo que $\theta \neq 0$. Mostre que o estimador $\hat{\theta}$ não é estimador minimax de θ , a menos que $\sup_{\theta} R(\theta, \tilde{\theta}) = \infty$ para todo estimador $\tilde{\theta}$ de θ . Sugestão: Obtenha o risco de $c\hat{\theta}$ com $c = 1/(1 + \zeta)$, em que $\zeta = \sup_{\theta} R(\theta, \hat{\theta})$, e compare com o risco de $\hat{\theta}$.

Sob a função de perda $L(\theta, d) = (d - \theta)^2 / \theta^2$, o risco do estimador $\hat{\theta}$ é dado por

$$R(\theta, \hat{\theta}) = E \left[\frac{(\hat{\theta} - \theta)^2}{\theta^2} \right]$$

Como $\hat{\theta}$ é um estimador não viciado para θ , $E[\hat{\theta} - \theta] = 0$, logo

$$R(\theta, \hat{\theta}) = \frac{Var(\hat{\theta})}{\theta^2}$$

que decresce com aumento em θ . Já se considerarmos o estimador $c\hat{\theta}$ o seu risco é dado por

$$R(\theta, c\hat{\theta}) = E \left[\frac{(c\hat{\theta} - \theta)^2}{\theta^2} \right] = \frac{c^2 Var(\hat{\theta})}{\theta^2} + \frac{(1 - c)^2 \theta^2}{\theta^2}$$

Seja $\zeta = \sup_{\theta} \frac{Var(\hat{\theta})}{\theta^2} = \sup_{\theta} R(\theta, \hat{\theta})$. Assim, se $\zeta = \infty$, então $\sup_{\theta} R(\theta, c\hat{\theta}) = \infty$ e não será minimax. Mas, se $0 < \zeta < \infty$ então $\sup_{\theta} R(\theta, c\hat{\theta}) = c^2 \zeta + (1 - c)^2 = (1 + \zeta)c^2 - 2c + 1$, que atinge o ponto de mínimo global em $c^* = \frac{1}{1 + \zeta}$, desde que $\zeta > 0$, $c^* < 1$ e, portanto, $\sup_{\theta} R(\theta, c^* \hat{\theta}) < \sup_{\theta} R(\theta, \hat{\theta})$.

Questão 23 Prove: Seja δ um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $g(\theta)$ sob perda quadrática. Então, $a\delta + b$ é um estimador de Bayes (respectivamente NVVUM, minimax, admissível) de $ag(\theta) + b$. Aqui, a e b são números reais.

Se δ é um estimador de Bayes de $g(\theta)$ sob perda quadrática, e $\delta' = a\delta + b$ é um estimador de $g'(\theta) = ag(\theta) + b$. O estimador de Bayes de $g'(\theta)$ é dado por

$$\delta' = E[ag(\theta) + b | X = x] = aE[g(\theta) | X = x] + b = a\delta + b$$

Sob perda quadrática, o risco de δ' é dado por

$$R(g'(\theta), \delta') = E_{\theta}[(a\delta + b - ag(\theta) - b)^2] = E_{\theta}[(a(\delta - g(\theta)))^2] = a^2 E_{\theta}[(\delta - g(\theta))^2] = a^2 R(g(\theta), \delta)$$

Observe que, se δ é ENVVUM de $g(\theta)$, e sendo U o conjunto de todos os estimadores não viciados de 0, uma condição necessária e suficiente para que δ seja ENVVUM de $g(\theta)$ é que

$$E_{\theta}[\delta U] = 0, \forall u \in U, \forall \theta \in \Omega$$

Observe que δ' é não viciado para $g'(\theta)$

$$E_{\theta}[\delta'] = E_{\theta}[a\delta + b] = aE_{\theta}[\delta] + b = ag(\theta) + b = g'(\theta), \forall \theta \in \Omega$$

Além disso, como $E_{\theta}^2[\delta] < \infty, \forall \theta \in \Omega$, então $Var_{\theta}(\delta) < \infty$ e $E_{\theta}[\delta] < \infty, \forall \theta \in \Omega$, logo

$$E_{\theta}[\delta'^2] = Var_{\theta}(\delta') + E_{\theta}^2[\delta'] = a^2 Var_{\theta}(\delta) + (aE_{\theta}[\delta] + b)^2 < \infty$$

Como δ' é não viciado e tem segundo momento finito, uma condição necessária e suficiente para ser ENVVUM de $g'(\theta)$ é ser não correlacionado com todo estimador não viciado de zero, observe que

$$E_{\theta}[\delta' U] = E_{\theta}[(a\delta + b)U] = aE_{\theta}[\delta U] + bE_{\theta}[U] = 0, \forall u \in U, \forall \theta \in \Omega$$

Se δ é estimador minimax de $g(\theta)$, então

$$\sup_{\theta} R(ag(\theta) + b, a\delta + b) = \inf_{\delta^*} \sup_{\theta} R(ag(\theta) + b, a\delta^* + b)$$

Observe que

$$R(g'(\theta), \delta') = R(ag(\theta) + b, a\delta + b) = a^2 R(g(\theta), \delta)$$

Assim,

$$\begin{aligned} \sup_{\theta} R(g'(\theta), \delta') &= \sup_{\theta} a^2 R(g(\theta), \delta) = a^2 \inf_{\delta^*} \sup_{\theta} R(g(\theta), \delta^*) \\ &= \inf_{\delta^*} \sup_{\theta} a^2 R(g(\theta), \delta^*) = \inf_{\delta^*} \sup_{\theta} R(ag(\theta) + b, a\delta^* + b) \end{aligned}$$

Logo, δ' é estimador minimax de $g'(\theta)$.

Por fim, se δ é admissível para $g(\theta)$, então não existe outro estimador risco menor para todo θ pertencente ao espaço paramétrico. Sob perda quadrática,

$$R(g'(\theta), \delta') = a^2 R(g(\theta), \delta) < a^2 R(g(\theta), \delta^*) = R(ag(\theta) + b, a\delta^* + b), \forall \theta \in \Omega$$

Logo, $\delta' = a\delta + b$, com $a, b \in R$ e $a \neq 0$ é admissível para $g'(\theta)$.