

UNIVERSIDADE DE SÃO PAULO
Programa de Post-Graduação em Estatística

Katerine Zuniga Lastra, Marília de Melo Sombra, Alex Monito Nhancololo

Lista 04 – Semestre de 2024-II – Prof. Silvia Ferrari

3. Seja (X_1, \dots, X_n) uma amostra aleatória de variável aleatória com função densidade de probabilidade

$$f(x; \theta) = \frac{1}{2\theta} \exp(-|x|/\theta), x \in \mathcal{R}; \theta > 0.$$

(a) Sem usar propriedades de famílias com razão de verossimilhanças monótonas, obtenha o teste uniformemente mais poderoso de $H: \theta \leq \theta_0$ contra $K: \theta > \theta_0$ de nível α .

Observe inicialmente que, a densidade conjunta é dada por

$$\begin{aligned} p_\theta(\mathbf{x}) &\stackrel{\text{ind.}}{=} \prod_{i=1}^n \frac{1}{2\theta} \exp\left\{-\frac{|x_i|}{\theta}\right\} \mathbb{I}_{(-\infty, \infty)}(x_i) \\ &= \left(\frac{1}{2\theta}\right)^n \exp\left\{-\frac{1}{\theta} \sum_{i=1}^n |x_i|\right\} \prod_{i=1}^n \mathbb{I}_{(-\infty, \infty)}(x_i) \\ &= \frac{1}{(2\theta)^n} \exp\left\{-\frac{1}{\theta} \sum_{i=1}^n |x_i|\right\} \prod_{i=1}^n \mathbb{I}_{(-\infty, \infty)}(x_i) \end{aligned}$$

Sabemos que, pelo Lema de Neyman-Pearson, um teste ϕ é mais poderoso de nível α para testar $H^*: \theta = \theta_0$ contra $K^*: \theta = \theta_1 (\theta_1 > \theta_0)$ se satisfaz

$$\phi(\mathbf{x}) = \begin{cases} 1, & p_{\theta_1}(\mathbf{x}) > kp_{\theta_0}(\mathbf{x}) \\ 0, & p_{\theta_1}(\mathbf{x}) < kp_{\theta_0}(\mathbf{x}). \end{cases} \quad \text{e} \quad E_{\theta_0}[\phi(\mathbf{X})] = \alpha$$

Observe que,

$$\begin{aligned} \phi(\mathbf{x}) = 1 &\Leftrightarrow \frac{1}{(2\theta_1)^n} \exp\left\{-\frac{1}{\theta_1} \sum_{i=1}^n |x_i|\right\} > k \frac{1}{(2\theta_0)^n} \exp\left\{-\frac{1}{\theta_0} \sum_{i=1}^n |x_i|\right\} \\ &\Leftrightarrow \exp\left\{-\frac{1}{\theta_1} \sum_{i=1}^n |x_i| + \frac{1}{\theta_0} \sum_{i=1}^n |x_i|\right\} > k \left(\frac{2\theta_1}{2\theta_0}\right)^n \\ &\Leftrightarrow \exp\left\{\left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right) \sum_{i=1}^n |x_i|\right\} > k \left(\frac{\theta_1}{\theta_0}\right)^n \\ &\Leftrightarrow \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right) \sum_{i=1}^n |x_i| > \log\left(k \left(\frac{\theta_1}{\theta_0}\right)^n\right) \\ &\Leftrightarrow \sum_{i=1}^n |x_i| > \left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right)^{-1} \log\left(k \left(\frac{\theta_0}{\theta_1}\right)^n\right) \\ &\Leftrightarrow \sum_{i=1}^n |x_i| > k' \end{aligned}$$

e

$$\begin{aligned}
\phi(\mathbf{x}) = 0 &\Leftrightarrow \frac{1}{(2\theta_1)^n} \exp \left\{ -\frac{1}{\theta_1} \sum_{i=1}^n |x_i| \right\} < k \frac{1}{(2\theta_0)^n} \exp \left\{ -\frac{1}{\theta_0} \sum_{i=1}^n |x_i| \right\} \\
&\Leftrightarrow \exp \left\{ -\frac{1}{\theta_1} \sum_{i=1}^n |x_i| + \frac{1}{\theta_0} \sum_{i=1}^n |x_i| \right\} < k \left(\frac{2\theta_1}{2\theta_0} \right)^n \\
&\Leftrightarrow \exp \left\{ \left(\frac{1}{\theta_0} - \frac{1}{\theta_1} \right) \sum_{i=1}^n |x_i| \right\} < k \left(\frac{\theta_1}{\theta_0} \right)^n \\
&\Leftrightarrow \left(\frac{1}{\theta_0} - \frac{1}{\theta_1} \right) \sum_{i=1}^n |x_i| < \log \left(k \left(\frac{\theta_1}{\theta_0} \right)^n \right) \\
&\Leftrightarrow \sum_{i=1}^n |x_i| < \left(\frac{1}{\theta_0} - \frac{1}{\theta_1} \right)^{-1} \log \left(k \left(\frac{\theta_0}{\theta_1} \right)^n \right) \\
&\Leftrightarrow \sum_{i=1}^n |x_i| < k'
\end{aligned}$$

Portanto, um teste mais poderoso de nível α é dado como segue

$$\phi^*(\mathbf{x}) = \begin{cases} 1, \sum_{i=1}^n |x_i| > k' \\ 0, \sum_{i=1}^n |x_i| \leq k' \end{cases},$$

em que k' é tal que $E_{\theta_0}[\phi^*(\mathbf{X})] = \alpha$.

Assim, usando o fato que se $X_i \sim \text{Laplace}(0, \theta)$, então $|X_i| \sim \text{Exp}(0, \theta)$, e $\sum_{i=1}^n |X_i| \sim \text{Gama}(n, \frac{1}{\theta})$, logo $\frac{2}{\theta} \sum_{i=1}^n |X_i| \sim \mathcal{X}_{2n}^2$

Portanto,

$$\begin{aligned}
\alpha = E_{\theta_0}[\phi^*(\mathbf{X})] &\Leftrightarrow P_{\theta_0} \left(\sum_{i=1}^n |X_i| > k' \right) = \alpha \\
&\Leftrightarrow P_{\theta_0} \left(\frac{2}{\theta_0} \sum_{i=1}^n |X_i| > \frac{2}{\theta_0} k' \right) = \alpha \\
&\Leftrightarrow P \left(\mathcal{X}_{2n}^2 > \frac{2}{\theta_0} k' \right) = \alpha
\end{aligned}$$

Sendo $q_{1-\alpha}$ o quantil $1 - \alpha$ de uma distribuição qui-quadrado com $2n$ graus de liberdade, então

$$\frac{2k'}{\theta_0} = q_{1-\alpha} \Leftrightarrow k' = \frac{\theta_0 q_{1-\alpha}}{2}$$

Sendo assim, pelo LNP, o teste dado por

$$\phi^*(\mathbf{x}) = \begin{cases} 1, \sum_{i=1}^n |x_i| > \frac{\theta_0 q_{1-\alpha}}{2} \\ 0, \sum_{i=1}^n |x_i| \leq \frac{\theta_0 q_{1-\alpha}}{2} \end{cases},$$

é mais poderoso de nível α para testar $H^* : \theta = \theta_0$ contra $K^* : \theta = \theta_1 (\theta_1 > \theta_0)$. Como isso vale para todo $\theta_1 > \theta_0$ e o teste não depende de θ_1 , então ele é UMP de nível α para testar $H^* : \theta = \theta_0$ contra $K : \theta > \theta_0$. Além disso,

$$\begin{aligned}
E_\theta[\phi^*(\mathbf{X})] &= P_\theta \left(\sum_{i=1}^n |X_i| > \frac{\theta_0 q_{1-\alpha}}{2} \right) \\
&= P_\theta \left(\frac{2}{\theta} \sum_{i=1}^n |X_i| > \frac{2}{\theta} \frac{\theta_0 q_{1-\alpha}}{2} \right) \\
&= P \left(\mathcal{X}_{2n}^2 > \frac{\theta_0}{\theta} q_{1-\alpha} \right), \forall \theta > 0.
\end{aligned}$$

Como $\theta \leq \theta_0$ então $\frac{\theta_0}{\theta} \geq 1$, logo

$$E_\theta[\phi^*(\mathbf{X})] = P\left(\mathcal{X}_{2n}^2 > \frac{\theta_0}{\theta} q_{1-\alpha}\right) \leq P_\theta(\mathcal{X}_{2n}^2 > q_{1-\alpha}) = \alpha, \forall \theta \leq \theta_0$$

Assim, concluimos que o teste $\phi^*(x)$ é UMP para as hipóteses $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$

(b) Obtenha o teste da razão de verossimilhanças de $H : \theta = \theta_0$ contra $K' : \theta \neq \theta_0$ de nível α .

Seja $L(\theta; \mathbf{x})$ a verossimilhança de \mathbf{X} com densidade $p_\theta(\mathbf{x})$. Definimos $\Omega = \theta > 0$ e $\Omega_H = \theta = \theta_0$, onde $\theta_0 > 0$. A razão de verossimilhanças generalizada é λ .

$$\lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Omega_H} L(\theta; \mathbf{x})}{\sup_{\theta \in \Omega} L(\theta; \mathbf{x})} = \frac{L(\theta_0, \mathbf{x})}{L(\hat{\theta}, \mathbf{x})},$$

em que $\hat{\theta}$ é EMV de θ .

A função de log-verossimilhança para θ é dada como;

$$l(\theta, \mathbf{x}) = \log(L(\theta; \mathbf{x})) = -n \log(2\theta) - \frac{1}{\theta} \sum_{i=1}^n |x_i|$$

Portanto, valem as seguintes 2 equações:

$$\begin{aligned} \frac{\partial l(\theta, \mathbf{x})}{\partial \theta} = 0 &\iff -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n |x_i| = 0 \\ &\iff \frac{1}{\theta^2} \sum_{i=1}^n |x_i| = \frac{n}{\theta} \\ &\iff \frac{1}{\theta} \sum_{i=1}^n |x_i| = n \\ &\iff \theta = \frac{\sum_{i=1}^n |x_i|}{n} \\ \frac{\partial^2 l(\theta, \mathbf{x})}{\partial \theta^2} < 0 &\Rightarrow \frac{\partial^2 l(\theta, \mathbf{x})}{\partial \theta^2} = \frac{\partial}{\partial \theta} \left(-\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^n |x_i| \right) \\ &= \frac{n}{\theta^2} - \frac{2}{\theta^3} \sum_{i=1}^n |x_i| \\ &= \frac{1}{\theta^2} \left(n - \frac{2}{\theta} \sum_{i=1}^n |x_i| \right) \end{aligned}$$

Dado que $\frac{\partial^2 l(\theta, \mathbf{x})}{\partial \theta^2} \Big|_{\theta=\frac{1}{n} \sum_{i=1}^n |x_i|} < 0$, conclui-se que $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n |X_i|$ é o estimador de máxima verossimilhança para θ . Assim:

$$\begin{aligned}
\lambda(\mathbf{x}) &= \frac{\frac{1}{(2\theta_0)^n} \exp \left\{ -\frac{1}{\theta_0} \sum_{i=1}^n |x_i| \right\}}{\frac{1}{(2\hat{\theta})^n} \exp \left\{ -\frac{1}{\hat{\theta}} \sum_{i=1}^n |x_i| \right\}} \\
&= \left(\frac{\hat{\theta}}{\theta_0} \right)^n \exp \left\{ -\frac{1}{\theta_0} \sum_{i=1}^n |x_i| + \frac{1}{\hat{\theta}} \sum_{i=1}^n |x_i| \right\} \\
&= \left(\frac{\hat{\theta}}{\theta_0} \right)^n \exp \left\{ \left(\frac{1}{\hat{\theta}} - \frac{1}{\theta_0} \right) \sum_{i=1}^n |x_i| \right\} \\
&= \left(\frac{1}{n\theta_0} \sum_{i=1}^n |x_i| \right)^n \exp \left\{ \left(\frac{n}{\sum_{i=1}^n |x_i|} - \frac{1}{\theta_0} \right) \sum_{i=1}^n |x_i| \right\} \\
&= \exp \left\{ \left(n - \frac{\sum_{i=1}^n |x_i|}{\theta_0} \right) + n \log \left(\frac{1}{n\theta_0} \sum_{i=1}^n |x_i| \right) \right\} \\
&= \exp \left\{ -n \left(\frac{1}{n\theta_0} \sum_{i=1}^n |x_i| - \log \left(\frac{1}{n\theta_0} \sum_{i=1}^n |x_i| \right) - 1 \right) \right\}
\end{aligned}$$

O teste de razão de verossimilhanças rejeita H se

$$\lambda(\mathbf{X}) < k, k \in [0, 1].$$

sabemos que a função exponencial é uma função estritamente crescente, então, rejeitamos H de modo que;

$$\begin{aligned}
-n \left(\frac{1}{n\theta_0} \sum_{i=1}^n |X_i| - \log \left(\frac{1}{n\theta_0} \sum_{i=1}^n |X_i| \right) - 1 \right) &< k \\
\frac{1}{n\theta_0} \sum_{i=1}^n |X_i| - \log \left(\frac{1}{n\theta_0} \sum_{i=1}^n |X_i| \right) - 1 &> k^*
\end{aligned}$$

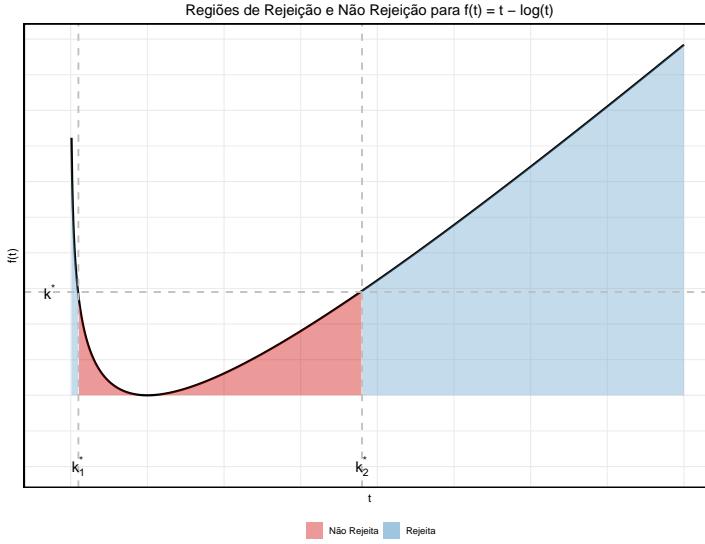
Seja $T = \frac{1}{n\theta_0} \sum_{i=1}^n |X_i|$, podemos escrever a razão de verossimilhança como uma função de T .

$$f(t) = t - \log(t) - 1 > k^*$$

Analisamos o comportamento de $f(t)$;

- Se $T \rightarrow 0 \Rightarrow f(t) \rightarrow \infty$, isto é, $t = 0$ é assíntota vertical.
- Se $t \rightarrow \infty \Rightarrow f(w) \rightarrow \infty$
- $f'(t) = 1 + \frac{1}{t} = 0 \Rightarrow w = 1$, isto é, $w = 1$ é ponto crítico de $f(t)$.
- $f''(t) = -\frac{1}{t^2} < 0$, logo $f(t)$ é função convexa.

A figura abaixo mostra a função $f(t)$, e o teste rejeita H se $T < k_1^*$ ou $T > k_2^*$, ou seja, se $\lambda(\mathbf{X}) < k$, e $E_{\theta_0}[\phi(\mathbf{X})] = \alpha$. Assim



$$\begin{aligned}
\alpha &= E_{\theta_0}[\phi(\mathbf{X})] = P_{\theta_0}\left(\sum_{i=1}^n |X_i| < k_1^*\right) + P_{\theta_0}\left(\sum_{i=1}^n |X_i| > k_2^*\right) \\
&= P_{\theta_0}\left(\frac{2}{\theta} \sum_{i=1}^n |X_i| < \frac{2k_1^*}{\theta}\right) + P_{\theta_0}\left(\frac{2}{\theta} \sum_{i=1}^n |X_i| > \frac{2k_2^*}{\theta}\right) \\
&= P_{\theta_0}\left(\mathcal{X}_{2n}^2 < \frac{2k_1^*}{\theta_0}\right) + P_{\theta_0}\left(\mathcal{X}_{2n}^2 > \frac{2k_2^*}{\theta_0}\right) \\
&\Rightarrow \frac{2k_1^*}{\theta_0} = q_{\alpha_1} \text{ e } \frac{2k_2^*}{\theta_0} = q_{1-\alpha_2} \\
&\Rightarrow k_1^* = \frac{\theta_0 q_{\alpha_1}}{2} \text{ e } k_2^* = \frac{\theta_0 q_{1-\alpha_2}}{2}.
\end{aligned}$$

Portanto, concluímos que o teste da razão de verossimilhança de nível α é:

$$\lambda(\mathbf{x}) = \begin{cases} 1, & \text{se } \sum_{i=1}^n |x_i| < \frac{\theta_0 q_{\alpha_1}}{2} \text{ ou } \sum_{i=1}^n |x_i| > \frac{\theta_0 q_{1-\alpha_2}}{2} \\ 0, & \text{c.c.} \end{cases}$$

Especificamente, considere $\alpha_1 = \alpha_2 = \frac{\alpha}{2}$.

(c) Obtenha uma quantidade pivotal que depende dos dados apenas através de uma estatística suficiente minimal e determine um intervalo de confiança para θ com coeficiente de confiança $1-\alpha$; $\alpha \in (0, 1)$.

Verificamos que $\sum_{i=1}^n |X_i|$ é uma estatística suficiente minimal, pela família exponencial;

$$\begin{aligned}
p_\theta(\mathbf{x}) &= \frac{1}{(2\theta)^n} \exp\left\{-\frac{1}{\theta} \sum_{i=1}^n |x_i|\right\} \prod_{i=1}^n \mathbb{I}_{(-\infty, \infty)}(x_i) \\
&= \exp\left\{-\frac{1}{\theta} \sum_{i=1}^n |x_i| + n \log(2\theta)\right\} \prod_{i=1}^n \mathbb{I}_{(-\infty, \infty)}(x_i) \\
&= \exp\{\eta T(\mathbf{x}) - A(\eta)\} h(\mathbf{x})
\end{aligned}$$

Isto é, a família de possíveis distribuições de \mathcal{P} pertence a família exponencial unidimensional na forma canônica

$$\eta = -\frac{1}{\theta} \rightarrow A(\eta) = -n \log(2\theta) = -n \log\left(-\frac{2}{\eta}\right),$$

$$T(\mathbf{x}) = \sum_{i=1}^n |x_i|, \text{ e } h(\mathbf{x}) = \prod_{i=1}^n \mathbb{I}_{(-\infty, \infty)}(x_i)$$

O espaço paramétrico canônico é definido como $\Delta = \eta : \eta \in \mathbb{R}^-$ e inclui intervalos abertos unidimensionais. Em outras palavras, existe um subconjunto $B \subset \Delta$, onde $B = a < \eta < b$, com $-\infty < a < b < 0$. Neste contexto, o parâmetro canônico η e a estatística suficiente T não estão sujeitos a restrições lineares. Assim, a família de distribuições possíveis para o vetor aleatório \mathbf{X} forma uma família exponencial de posto completo. Isso implica que a estatística $T = T(\mathbf{X}) = \sum_{i=1}^n |X_i|$ é completa e suficiente para \mathcal{P} , o que significa que $T(\mathbf{X})$ é também minimalmente suficiente. Portanto, a função $Q(\mathbf{X}, \theta)$ depende de \mathbf{X} apenas através de uma estatística suficiente minimal.

Então, seja $Q(\mathbf{X}, \theta) = \frac{2}{\theta} \sum_{i=1}^n |X_i|$, com $Q \sim \mathcal{X}_{2n}^2$ do item (a), uma quantidade pivotal(Q). Assim, um intervalo de confiança para θ com nível $1 - \alpha$ é dado por;

$$\begin{aligned} P_\theta(q_{\alpha_1} < Q < q_{1-\alpha_2}) &= 1 - \alpha \\ \Rightarrow P_\theta\left(q_{\alpha_1} < \frac{2}{\theta} \sum_{i=1}^n |X_i| < q_{1-\alpha_2}\right) &= 1 - \alpha \\ \Rightarrow P_\theta\left(\frac{q_{\alpha_1}}{2 \sum_{i=1}^n |X_i|} < \frac{1}{\theta} < \frac{q_{1-\alpha_2}}{2 \sum_{i=1}^n |X_i|}\right) &= 1 - \alpha \\ \Rightarrow P_\theta\left(\frac{2 \sum_{i=1}^n |X_i|}{q_{1-\alpha_2}} < \theta < \frac{2 \sum_{i=1}^n |X_i|}{q_{\alpha_1}}\right) &= 1 - \alpha \end{aligned}$$

em que q_α é o quantil α da distribuição \mathcal{X}_{2n}^2 . Assim, se definirmos $\alpha_1 = \alpha_2 = \frac{\alpha}{2}$, temos que,

$$IC_{100(1-\alpha)\%}(\theta) = \left[\frac{2 \sum_{i=1}^n |X_i|}{q_{1-\frac{\alpha}{2}}}, \frac{2 \sum_{i=1}^n |X_i|}{q_{\frac{\alpha}{2}}} \right].$$

(d) Obtenha um limite superior de confiança uniformemente mais acurado para θ com coeficiente de confiança $1 - \alpha$.

Seja $0 < \theta_0 < \theta_1$ e considere a razão de verossimilhanças a seguir:

$$\begin{aligned} \frac{p_{\theta_1}}{p_{\theta_0}} &= \frac{\frac{1}{(2\theta_1)^n} \exp\left\{-\frac{1}{\theta_1} \sum_{i=1}^n |x_i|\right\}}{\frac{1}{(2\theta_0)^n} \exp\left\{-\frac{1}{\theta_0} \sum_{i=1}^n |x_i|\right\}} \\ &= \left(\frac{\theta_0}{\theta_1}\right)^n \exp\left\{\left(\frac{1}{\theta_0} - \frac{1}{\theta_1}\right) \sum_{i=1}^n |x_i|\right\} \end{aligned}$$

A função $p_\theta(x)$ possui uma razão de verossimilhança monótona em $t = \sum_{i=1}^n |x_i|$. Como $F_\theta(t)$ é contínua em t e θ , existe um limite superior de confiança, $\bar{\theta}$, para θ , com nível de confiança $1 - \alpha$, que é uniformemente mais acurado pode ser encontrado resolvendo

$$\begin{aligned} F_\theta(t) = \alpha &\Rightarrow P_\theta(T \leq t) = \alpha \\ &\Rightarrow P_\theta\left(\sum_{i=1}^n |X_i| \leq t\right) = \alpha \\ &\Rightarrow P_\theta\left(\frac{2}{\theta} \sum_{i=1}^n |X_i| \leq \frac{2}{\theta} t\right) = \alpha \\ &\Rightarrow P_\gamma\left(\mathcal{X}_{2n}^2 \leq \frac{2}{\theta} t\right) = \alpha. \end{aligned}$$

Se q_α é o quantil α da distribuição \mathcal{X}_{2n}^2 , então

$$\bar{\theta}(T) = \frac{2T}{q_\alpha}$$

Questão 5.

Sejam X_1, \dots, X_n uma amostra aleatória de uma distribuição $U(0, \theta)$.

- (a) Mostre que, para testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$, qualquer teste para o qual $E_{\theta_0}(\phi(X)) = \alpha$, $E_\theta(\phi(X)) \leq \alpha$, para $\theta \leq \theta_0$, e $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$, é UMP de nível α . Sugestão: Use o Lema de Neyman Pearson, com $k = \left(\frac{\theta_0}{\theta_1}\right)^n$.

Observe inicialmente que

$$p_\theta(x) = \frac{1}{\theta^n} \prod_{j=1}^n I_{(0,\theta)}(x_i) = \frac{1}{\theta^n} I_{(x_{(n)}, \infty)}(\theta), \quad x = (x_1, \dots, x_n), \quad x_{(n)} = \max(x_1, \dots, x_n)$$

Pelo Lema de Neyman-Pearson, um teste que satisfaz

$$\phi(x) = \begin{cases} 1, & p_1(x) > kp_0(x) \\ 0, & p_1(x) < kp_0(x) \end{cases} \quad \text{e} \quad E_{\theta_0}(\phi(X)) = \alpha \quad (1)$$

é MP para testar $H^* : \theta = \theta_0$ contra $K^* : \theta = \theta_1 (\theta_1 > \theta_0)$.

Assim, note que

$$\begin{aligned} \phi(x) = 1 &\Leftrightarrow \frac{1}{\theta_1^n} I_{(x_{(n)}, \infty)}(\theta_1) > k \frac{1}{\theta_0^n} I_{(x_{(n)}, \infty)}(\theta_0) \\ &\Leftrightarrow \frac{\theta_0^n}{\theta_1^n} I_{(x_{(n)}, \infty)}(\theta_1) > k I_{(x_{(n)}, \infty)}(\theta_0) \end{aligned}$$

usando $k = \left(\frac{\theta_0}{\theta_1}\right)^n$, temos que

$$\begin{aligned} \phi(x) = 1 &\Leftrightarrow I_{(x_{(n)}, \infty)}(\theta_1) > I_{(x_{(n)}, \infty)}(\theta_0) \\ &\Leftrightarrow I_{(x_{(n)}, \infty)}(\theta_1) = 1 \quad \text{e} \quad I_{(x_{(n)}, \infty)}(\theta_0) = 0 \\ &\Leftrightarrow x_{(n)} < \theta_1 \quad \text{e} \quad x_{(n)} > \theta_0, \quad \text{com } \theta_1 > \theta_0 \\ &\Leftrightarrow x_{(n)} > \theta_0 \end{aligned}$$

e

$$\begin{aligned} \phi(x) = 0 &\Leftrightarrow \frac{1}{\theta_1^n} I_{(x_{(n)}, \infty)}(\theta_1) < k \frac{1}{\theta_0^n} I_{(x_{(n)}, \infty)}(\theta_0) \\ &\Leftrightarrow \frac{\theta_0^n}{\theta_1^n} I_{(x_{(n)}, \infty)}(\theta_1) < k I_{(x_{(n)}, \infty)}(\theta_0) \end{aligned}$$

usando $k = \left(\frac{\theta_0}{\theta_1}\right)^n$, temos que

$$\begin{aligned} \phi(x) = 1 &\Leftrightarrow I_{(x_{(n)}, \infty)}(\theta_1) < I_{(x_{(n)}, \infty)}(\theta_0) \\ &\Leftrightarrow I_{(x_{(n)}, \infty)}(\theta_1) = 0 \quad \text{e} \quad I_{(x_{(n)}, \infty)}(\theta_0) = 1 \\ &\Leftrightarrow x_{(n)} > \theta_1 \quad \text{e} \quad x_{(n)} < \theta_0, \quad \text{com } \theta_1 > \theta_0 \quad (\text{impossível}) \end{aligned}$$

logo, um teste que satisfaz $\phi(x) = 1$ quando $x_{(n)} < \theta_0$ e $E_{\theta_0}(\phi(X)) = \alpha$ é MP para testar $H^* : \theta = \theta_0$ contra $K^* : \theta = \theta_1 (\theta_1 > \theta_0)$.

Considere o teste

$$\phi(x) = \begin{cases} 1, & \text{se } x_{(n)} > c\theta_0, \\ 0, & \text{cc} \end{cases} \quad c \in (0, 1)$$

em que c é tal que $E_{\theta_0}(\phi(X)) = \alpha$, logo,

$$\begin{aligned} P_{\theta_0}(X_{(n)} > c\theta_0) &= \alpha \\ \Leftrightarrow 1 - P_{\theta_0}(X_{(n)} \leq c\theta_0) &= \alpha \\ \Leftrightarrow \left(\frac{c\theta_0}{\theta_0}\right)^n &= 1 - \alpha \\ \Leftrightarrow c &= (1 - \alpha)^{1/n} \end{aligned}$$

Assim, o teste

$$\phi(x) = \begin{cases} 1, & \text{se } x_{(n)} > (1 - \alpha)^{1/n}\theta_0 \\ 0, & \text{cc} \end{cases}$$

é MP de nível α para testar $H^* : \theta = \theta_0$ contra $K^* : \theta = \theta_1 (\theta_1 > \theta_0)$. Como isso vale para todo $\theta_1 > \theta_0$ e o teste não depende de θ_1 , então ele é UMP para testar $H^* : \theta = \theta_0$ contra $K : \theta_1 > \theta_0$. Além disso, para $\theta \leq \theta_0$,

$$E_\theta(\phi(X)) = P_\theta(X_{(n)} > (1 - \alpha)^{1/n}\theta_0) = 1 - P_\theta(X_{(n)} \leq (1 - \alpha)^{1/n}\theta_0)$$

Se $(1 - \alpha)^{1/n}\theta_0 < \theta$

$$E_\theta(\phi(X)) = 1 - \left(\frac{(1 - \alpha)^{1/n}\theta_0}{\theta}\right)^n = 1 - (1 - \alpha)\left(\frac{\theta_0}{\theta}\right)^n \leq 1 - (1 - \alpha) = \alpha$$

pois $\frac{\theta_0}{\theta} \geq 1$.

Se $(1 - \alpha)^{1/n}\theta_0 > \theta$

$$E_\theta(\phi(X)) = 0 \leq \alpha$$

Logo, como $E_\theta(\phi(X)) \leq \alpha$, o teste $\phi(x)$ é UMP de nível α para testar $H : \theta \leq \theta_0$ contra $K : \theta > \theta_0$.

(b) Mostre que, para testar $H : \theta = \theta_0$ contra $K : \theta \neq \theta_0$, o teste $\phi(x) = 1$ quando $\max(x_1, \dots, x_n) > \theta_0$ ou $\max(x_1, \dots, x_n) \leq \theta_0\alpha^{1/n}$ e $\phi(x) = 0$, caso contrário, é UMP de nível α . Sugestão: Considere separadamente 3 situações: (i) $H : \theta = \theta_0$ contra $K_1 : \theta = \theta_1 > \theta_0$; (ii) $H : \theta = \theta_0$ contra $K_2 : \theta = \theta_1, \theta_0\alpha^{1/n} < \theta_1 < \theta_0$; (iii) $H : \theta = \theta_0$ contra $K_3 : \theta = \theta_1 \leq \theta_0\alpha^{1/n}$.

Considere testar $H : \theta = \theta_0$ contra $K^{**} : \theta \neq \theta_0$ com o seguinte teste

$$\phi^*(x) = \begin{cases} 1, & \text{quando } x_{(n)} > \theta_0 \text{ ou } x_{(n)} \leq \theta_0\alpha^{\frac{1}{n}} \\ 0, & \text{quando } \theta_0\alpha^{\frac{1}{n}} < x_{(n)} \leq \theta_0 \end{cases} \quad (2)$$

Para testar H contra K^{**} consideramos separadamente 3 situações:

- i. H contra $K_1 : \theta = \theta_1 (\theta_1 > \theta_0)$.
- ii. H contra $K_2 : \theta = \theta_1 \left(\theta_0\alpha^{\frac{1}{n}} < \theta_1 < \theta_0\right)$.
- iii. H contra $K_3 : \theta = \theta_1 \left(\theta_1 \leq \theta_0\alpha^{\frac{1}{n}}\right)$

Caso (i): H contra $K_1 : \theta = \theta_1 (\theta_1 > \theta_0)$:

Pelo lema de Neyman-Pearson no item (a), qualquer teste que satisfaça as condições 1 é um teste MP de nível α para testar H contra K_1 . Verificamos que a primeira condição da equação 1 é satisfeita por (2), restando verificar so a segunda condição de 1 usando a função poder a seguir:

$$\begin{aligned} B(\theta) &= E_\theta[\phi^*(\mathbf{X})] \\ &= P_\theta(X_{(n)} > \theta_0) + P_\theta(X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}) \\ &= 1 - P_\theta(X_{(n)} \leq \theta_0) + P_\theta(X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}) \\ &= 1 - [P_\theta(X_1 \leq \theta_0)]^n + \left[P_\theta(X_1 \leq \theta_0 \alpha^{\frac{1}{n}}) \right]^n \\ &= 1 - \left(\frac{\theta_0}{\theta} \right)^n + \left(\frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta} \right)^n \\ &= 1 - \left(\frac{\theta_0}{\theta} \right)^n (1 - \alpha). \end{aligned}$$

Sabe-se que $E_{\theta_0}[\phi^*(\mathbf{X})] = \alpha$, pois $E_\theta[\phi^*(\mathbf{X})] = \alpha$ para todo $\theta \in \Omega_H$. Concluímos, então, que o teste na equação 2 é MP de nível α para testar H contra K_1 . Portanto, é UMP para testar H contra $K_1 : \theta > \theta_0$.

Caso (ii): H contra $K_2 : \theta = \theta_1 \left(\theta_0 \alpha^{\frac{1}{n}} < \theta_1 < \theta_0 \right)$.

Pelo lema de NP, de forma análoga ao item (a), tem-se o seguinte;

$$p_{\theta_1}(\mathbf{x}) > kp_{\theta_0}(\mathbf{x}) \implies \theta_0 \leq x_{(n)} < \theta_1.$$

Assumindo $k = \left(\frac{\theta_0}{\theta_1} \right)^n$, a condição $\theta_0 < x_{(n)} \leq \theta_1$ é impossível, pois, por hipótese, $\theta_1 < \theta_0$ e $\theta_1 < \theta_0 < x_{(n)}$ também não ocorre. Pelo lema de Neyman-Pearson, o teste de nível α mais poderoso para H contra K_2 satisfaz essas condições.

$$\begin{aligned} \phi^*(\mathbf{x}) &= 0, \text{ quando } x_{(n)} > \theta_1 \text{ e,} \\ E_{\theta_0}[\phi^*(\mathbf{X})] &= \alpha. \end{aligned}$$

Observamos que a equação 2 satisfaz $\phi^*(\mathbf{x}) = 0$ quando $x_{(n)} > \theta_1 > \theta_0 \alpha^{\frac{1}{n}}$, com $\theta_1 < \theta_0$. Similarmente ao caso (i), o teste em 2 para H contra K_2 possui nível α , ou seja, $E_{\theta_0}[\phi^*(\mathbf{x})] = \alpha$. Concluímos, então, que o teste em 2 é MP de nível α para H contra K_2 , sendo UMP para H contra $K_2 : \theta_0 \alpha^{\frac{1}{n}} < \theta < \theta_0$.

Caso (iii): H contra $K_3 : \theta = \theta_1 \left(\theta_1 \leq \theta_0 \alpha^{\frac{1}{n}} \right)$.

Pelo lema de NP, de forma análoga ao item (a), tem-se o seguinte;

$$\begin{aligned} p_{\theta_1}(\mathbf{x}) > kp_{\theta_0}(\mathbf{x}) &\implies \theta_0 \leq x_{(n)} < \theta_1 \\ p_{\theta_1}(\mathbf{x}) < kp_{\theta_0}(\mathbf{x}) &\implies \theta_1 \leq x_{(n)} < \theta_0. \end{aligned}$$

Assumindo $k = \left(\frac{\theta_0}{\theta_1} \right)^n$, a condição $\theta_0 < x_{(n)} \leq \theta_1$ é impossível, pois consideramos que $\theta_1 \leq \theta_0 \alpha^{\frac{1}{n}} < \theta_0$. Além disso, a condição $\theta_1 \leq \theta_0 \leq x_{(n)}$ também não ocorre. Pelo lema de Neyman-Pearson, qualquer teste que satisfaça essas condições é MP de nível α para H contra K_3 .

$$\phi(\mathbf{x}) = 0, \text{ quando } x_{(n)} > \theta_1 \text{ e,}$$

$$E_{\theta_0}[\phi(\mathbf{X})] = \alpha.$$

Considere assim, o teste

$$\phi'(\mathbf{x}) = \begin{cases} \gamma, & \text{se } x_{(n)} \leq \theta_1 \\ 0, & x_{(n)} > \theta_1. \end{cases}$$

O poder do teste $\phi'(\mathbf{x})$ é dado por:

$$\begin{aligned} B_{\phi'}(\theta) &= E_{\theta}[\phi'(\mathbf{X})], \forall \theta = \theta_1 \left(\theta_1 \leq \theta_0 \alpha^{\frac{1}{n}} \right) \\ &= \alpha \left(\frac{\theta_0}{\theta_1} \right)^n P_{\theta} (X_{(n)} \leq \theta_1) \\ &= \alpha \left(\frac{\theta_0}{\theta_1} \right)^n [P_{\theta_1}(X_1 \leq \theta_1)]^n \\ &= \alpha \left(\frac{\theta_0}{\theta_1} \right)^n \left(\frac{\theta_1}{\theta_1} \right)^n \\ &= \alpha \left(\frac{\theta_0}{\theta_1} \right)^n \end{aligned}$$

Por outro lado, temos que o poder do teste $\phi^*(\mathbf{x})$ é dado por:

$$\begin{aligned} B_{\phi}^*(\theta) &= E_{\theta}[\phi^*(\mathbf{X})], \forall \theta = \theta_1 \left(\theta_1 \leq \theta_0 \alpha^{\frac{1}{n}} \right) \\ &= P_{\theta_1}(X_{(n)} > \theta_0) + P_{\theta_1}(X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}) \\ &= P_{\theta_1}(X_{(n)} \leq \theta_0 \alpha^{\frac{1}{n}}) \\ &= \left[P_{\theta_1}(X_1 \leq \theta_0 \alpha^{\frac{1}{n}}) \right]^n \\ &= \left(\frac{\theta_0 \alpha^{\frac{1}{n}}}{\theta_1} \right)^n \\ &= \alpha \left(\frac{\theta_0}{\theta_1} \right)^n \end{aligned}$$

Na terceira igualdade sob K_3 , temos $P_{\theta_1}(X_{(n)} > \theta_0) = 0$ com $\theta_1 \leq \theta_0 \alpha^{\frac{1}{n}} \leq \theta_0$, o teste ϕ tem o mesmo poder que um teste MP de nível α , ou seja, $B_{\phi}^*(\theta) = B_{\phi'}(\theta)$. Assim, ϕ é também um teste MP de nível α para H contra K_3 . Como vimos no caso (i), $E_{\theta_0}[B_{\phi}^*(\theta)] = \alpha$. Concluímos então que o teste em 2 é MP de nível α para H contra K_3 e, portanto é UMP para H contra $K_3 : \theta_1 \leq \theta_0 \alpha^{\frac{1}{n}}$, já que a decisão de rejeitar H independe do valor específico de θ_1 para rejeitar H quando $\theta_0 > \theta_1$.

Por fim, 2 é um teste UMP de nível α para testar $H : \theta = \theta_0$ contra $K_1 : \theta > \theta_0$, $K_2 : \theta_0 \alpha^{\frac{1}{n}} < \theta < \theta_0$, e $K_3 : \theta_1 \leq \theta_0 \alpha^{\frac{1}{n}}$. Logo, é também um teste UMP de nível α para testar $H : \theta = \theta_0$ contra $K^{**} : \theta \neq \theta_0$.

7. Sejam X_1, \dots, X_n variáveis aleatórias independentes tais que X_i tem distribuição exponencial de média $(\lambda \beta^i)^{-1}$; $\lambda > 0$, $\beta > 0$. Suponha que β é conhecido.

- (a) Encontre um limite inferior de confiança uniformemente mais acurado para λ com coeficiente de confiança $1 - \alpha$.

Observe inicialmente que

$$p_\lambda(x) = \prod_{i=1}^n \lambda \beta^i \exp\{-x_i \lambda \beta^i\} = \lambda^n \exp\{-\lambda \sum_{i=1}^n x_i \beta^i\} \prod_{i=1}^n \beta^i, \quad x = (x_1, \dots, x_n), \quad \lambda, \beta > 0, \beta \text{ conhecido}$$

Assim, a razão de verossimilhanças é dada por

$$\frac{p_{\lambda_1}}{p_{\lambda_0}} = \frac{\lambda_1^n \exp\{-\lambda_1 \sum_{i=1}^n x_i \beta^i\} \prod_{i=1}^n \beta^i}{\lambda_0^n \exp\{-\lambda_0 \sum_{i=1}^n x_i \beta^i\} \prod_{i=1}^n \beta^i} = \left(\frac{\lambda_1}{\lambda_0}\right)^n \exp\left\{-\left(\lambda_1 - \lambda_0\right) \prod_{i=1}^n \beta^i\right\}$$

Assim, $p_{\lambda_1}/p_{\lambda_0}$ tem razão de verossimilhança monótona em $T(x) = -\sum_{i=1}^n x_i \beta^i$. Além disso, como $F_\lambda(t)$ é função contínua em cada variável t e θ quando a outra está fixa, então existe um limite inferior de confiança uniformemente mais acurado $\underline{\lambda}$ para λ com nível de confiança $1 - \alpha$ como solução de $F_\lambda(t) = 1 - \alpha$.

Observe inicialmente que, como $X_i \sim \text{Exp}((\lambda \beta^i)^{-1})$, fazendo $Y_i = X_i \beta^i$, temos que

$$P(X_i \beta^i \leq y) = P(X_i \leq y/\beta^i) = F_{X_i}(y/\beta^i)$$

assim

$$P(Y_i = y) = \lambda \beta^i \exp\left\{-\frac{y}{\beta^i} \lambda \beta^i\right\} \frac{1}{\beta^i} = \lambda \exp\{-y \lambda\}$$

logo, $Y_i \sim \text{Exp}(\lambda)$, então $\sum_{i=1}^n Y_i = \sum_{i=1}^n X_i \beta^i \sim \text{Gama}(n, \lambda)$, e $2\lambda \sum_{i=1}^n X_i \beta^i \sim \chi_{2n}^2$. Desse modo

$$\begin{aligned} F_\lambda(t) = 1 - \alpha &\Leftrightarrow P_\lambda(T \leq t) = 1 - \alpha \\ &\Leftrightarrow P_\lambda\left(-\sum_{i=1}^n X_i \beta^i \leq t\right) = 1 - \alpha \\ &\Leftrightarrow P_\lambda\left(\sum_{i=1}^n X_i \beta^i > -t\right) = 1 - \alpha \\ &\Leftrightarrow 1 - P_\lambda\left(\sum_{i=1}^n X_i \beta^i \leq -t\right) = 1 - \alpha \\ &\Leftrightarrow P_\lambda\left(2\lambda \sum_{i=1}^n X_i \beta^i \leq -2\lambda t\right) = \alpha \\ &\Leftrightarrow P(\chi_{2n}^2 \leq -2\lambda t) = \alpha \end{aligned}$$

Sendo $\chi_{2n,\alpha}^2$ o quantil α de uma distribuição qui-quadrado com $2n$ graus de liberdade, temos que

$$-2\lambda t = \chi_{2n,\alpha}^2 \Leftrightarrow \lambda = -\frac{\chi_{2n,\alpha}^2}{2t} = \frac{\chi_{2n,\alpha}^2}{2 \sum_{i=1}^n X_i \beta^i}$$

(b) Mostre que $\lambda \sum X_i \beta^i$ é uma quantidade pivotal.

Observe que, como $X_i \sim \text{Exp}((\lambda \beta^i)^{-1})$, então para $Y_i = X_i \beta^i$, temos que

$$P(X_i \beta^i \leq y) = P(X_i \leq y/\beta^i) = F_{X_i}(y/\beta^i)$$

assim

$$P(Y_i = y) = \lambda \beta^i \exp\left\{-\frac{y}{\beta^i} \lambda \beta^i\right\} \frac{1}{\beta^i} = \lambda \exp\{-y \lambda\}$$

logo, $Y_i \sim \text{Exp}(\lambda)$, assim $\sum_{i=1}^n Y_i = \sum_{i=1}^n X_i \beta^i \sim \text{Gama}(n, \lambda)$, então $\lambda \sum_{i=1}^n X_i \beta^i \sim \text{Gama}(n, 1)$.

Portanto, com $\lambda \sum_{i=1}^n X_i \beta^i$ é função da amostra e do parâmetro λ , mas sua distribuição não depende de λ , concluimos que $\lambda \sum_{i=1}^n X_i \beta^i$ é uma quantidade pivotal.

- (c) Construa um intervalo de confiança para λ com coeficiente de confiança γ baseado na quantidade pivotal dada em (b).

Usando o fato que $2\lambda \sum_{i=1}^n X_i \beta^i \sim \chi_{2n}^2$, podemos construir um intervalo de confiança para λ com coeficiente de confiança $1 - \alpha$ dado por:

$$\begin{aligned} P_\lambda \left(\chi_{2n,\alpha_1}^2 \leq 2\lambda \sum_{i=1}^n X_i \beta^i \leq \chi_{2n,\alpha_2}^2 \right) &= 1 - \alpha \\ \Leftrightarrow P_\lambda \left(\frac{\chi_{2n,\alpha_1}^2}{2 \sum_{i=1}^n X_i \beta^i} \leq \lambda \leq \frac{\chi_{2n,\alpha_2}^2}{2 \sum_{i=1}^n X_i \beta^i} \right) &= 1 - \alpha \end{aligned}$$

Assim,

$$IC(\lambda, 1 - \alpha) = \left[\frac{\chi_{2n,\alpha_1}^2}{2 \sum_{i=1}^n X_i \beta^i}, \frac{\chi_{2n,\alpha_2}^2}{2 \sum_{i=1}^n X_i \beta^i} \right]$$

Para $\alpha_1 = \alpha_2 = \alpha/2$, temos

$$IC(\lambda, 1 - \alpha) = \left[\frac{\chi_{2n,\alpha/2}^2}{2 \sum_{i=1}^n X_i \beta^i}, \frac{\chi_{2n,1-\alpha/2}^2}{2 \sum_{i=1}^n X_i \beta^i} \right]$$

- (d) Suponha que, a priori, λ tem distribuição gama de parâmetros $a > 0$ e $b > 0$, e função densidade de probabilidade

$$\pi(\lambda) = \frac{1}{b^a \Gamma(a)} \lambda^{a-1} \exp \left\{ -\frac{\lambda}{b} \right\}, \quad \lambda > 0.$$

Encontre o estimador de Bayes de λ sob perda quadrática.

Primeiramente vamos obter a distribuição a posteriori, dada por

$$\begin{aligned} \pi(\lambda|x) &= f(x|\lambda)\pi(\lambda) \\ &= \lambda^n \exp \left\{ -\lambda \sum_{i=1}^n x_i \beta^i \right\} \prod_{i=1}^n \beta^i \frac{1}{b^a \Gamma(a)} \lambda^{a-1} \exp \left\{ -\frac{\lambda}{b} \right\} \\ &\propto \lambda^{n+a-1} \exp \left\{ -\lambda \left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b} \right) \right\}, \quad \lambda, a, b, \beta > 0 \end{aligned}$$

Observe que $\lambda|x \sim Gama(n+a, \sum_{i=1}^n x_i \beta^i + \frac{1}{b})$

Assim, sob perda quadrática, $l(\lambda, d) = (d - \lambda)^2$, o estimador de Bayes é dado por

$$\delta(x) = E[\lambda|x] = \frac{n+a}{\sum_{i=1}^n x_i \beta^i + \frac{1}{b}}$$

- (e) No contexto do item (d), suponha que a é inteiro ($a \geq 1$) e obtenha um intervalo de credibilidade para λ da forma $(\tilde{\lambda}, +\infty)$ com probabilidade $1 - \alpha$.

Usando o fato que $\lambda|x \sim Gama(n+a, \sum_{i=1}^n x_i \beta^i + \frac{1}{b})$, então $2(\sum_{i=1}^n x_i \beta^i + \frac{1}{b}) \times \lambda|x \sim Gama(n+a, 1/2) \stackrel{d}{=} \chi_{2(n+a)}^2$, assim, temos que

$$\begin{aligned} P(\lambda|x \geq \tilde{\lambda}) &= 1 - \alpha \\ \Leftrightarrow 1 - P(\lambda|x < \tilde{\lambda}) &= 1 - \alpha \\ \Leftrightarrow P(\lambda|x < \tilde{\lambda}) &= \alpha \\ \Leftrightarrow P\left(2\left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b}\right) \lambda|x < 2\left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b}\right) \tilde{\lambda}\right) &= \alpha \\ \Leftrightarrow P\left(\chi_{2(n+a)}^2 < 2\left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b}\right) \tilde{\lambda}\right) &= \alpha \end{aligned}$$

Assim,

$$2 \left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b} \right) \tilde{\lambda} = \chi^2_{2(n+a), \alpha}$$

em que $\chi^2_{2(n+a), \alpha}$ representa o quantil α de uma distribuição qui-quadrado com $2(n+a)$ graus de liberdade.

$$\tilde{\lambda} = \frac{\chi^2_{2(n+a), \alpha}}{2 \left(\sum_{i=1}^n x_i \beta^i + \frac{1}{b} \right)}.$$

Questão 9. Considere uma única observação de uma variável aleatória X .

- (a) Use o Lema de Neyman-Pearson para encontrar o teste mais poderoso de nível α de $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b)$, sendo $b > 1$ fixado. Se $\alpha = 0.05$ e foi observado $x = 0.1$, qual é sua decisão? Qual é o nível descritivo (p-valor) do teste?

Resolução

Pelo lema de Neyman Pearson podemos definir o seguinte teste.

$$\phi(x) = \begin{cases} 1 & \text{se } f_K(x) > kf_H(x) \quad (\text{região de rejeição de } H) \\ 0 & \text{se } f_K(x) < kf_H(x) \quad (\text{região de não rejeição de } H), \end{cases}$$

que para

$$\mathbf{E}_H[\phi(x)] = \alpha,$$

é um teste mais poderoso de nível α para testar H contra K .

$$f_K(x) = \frac{1}{B(1, b)} x^{1-1} (1-x)^{b-1} \mathbf{I}_{(0,1)}(x), \quad b > 0 \quad \text{e} \quad f_H(x) = \mathbf{I}_{(0,1)}(x)$$

$$\begin{aligned} & f_K(x) > kf_H(x) \\ & \frac{1}{B(1, b)} x^{1-1} (1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & \frac{1}{\frac{\Gamma(1)\Gamma(b)}{\Gamma(1+b)}} x^{1-1} (1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & \frac{\Gamma(1+b)}{\Gamma(1)\Gamma(b)} x^{1-1} (1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & \frac{b!}{0!(b-1)!} x^{1-1} (1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & \frac{b(b-1)!}{(b-1)!} x^0 (1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & b(1-x)^{b-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b > 0 \\ & b(1-x)^{b-1} > k, \quad b > 0 \\ & (1-x)^{b-1} > \frac{k}{b}, \quad b > 0 \\ & (1-x) > \left(\frac{k}{b}\right)^{\frac{1}{b-1}} \\ & -x > \left(\frac{k}{b}\right)^{\frac{1}{b-1}} - 1 \\ & x < 1 - \underbrace{\left(\frac{k}{b}\right)^{\frac{1}{b-1}}}_{k'} \\ & x < k' \end{aligned}$$

$$\phi(x) = \begin{cases} 1 & \text{se } x < k' \\ 0 & \text{se } x > k', \end{cases}$$

$$\mathbf{E}_H[\phi(x)] = \alpha$$

$$P_H(x < k') = \alpha$$

$$\int_0^{k'} dx = \alpha, \quad \text{H: } X \sim U(0, 1)$$

$$\begin{aligned} X|_0^{k'} &= \alpha \\ k' &= \alpha \end{aligned}$$

Assim,

$$\phi(x) = \begin{cases} 1 & \text{se } x < \alpha \\ 0 & \text{se } x \geq \alpha, \end{cases}$$

é um teste mais poderoso de nível α para testar $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b)$, sendo $b > 1$ fixado.

Se $x = 0,1$ e $\alpha = 0,05$ tem-se:

$$\phi(x) = \begin{cases} 1 & \text{se } 0,1 < 0,05 \text{ (absurdo!)} \\ 0 & \text{se } 0,1 \geq 0,05 \text{ (região de não rejeição de H)} \end{cases}$$

logo, não há evidência para rejeição de H, pois 0,1 está na região de não rejeição de H.

valor-p $\hat{p}(x) = \inf\{\alpha : x \in S_\alpha\}$, onde $S_\alpha = \{x : x < \alpha\}$ é região de rejeição.

$$\hat{p}(x) = \inf \alpha : x \in S_\alpha$$

$$\hat{p}(x) = \inf\{\alpha : 0 < x < \alpha\}$$

$$\hat{p}(x) = \inf\{\alpha : 0 < 0,1 < \alpha\}$$

$$\hat{p}(x) = 0,1$$

Como $\hat{p}(x) = 0,1 > 0,05$, ao nível de significância de 5%, não há evidência para rejeitar a hipótese H.

- (b) O teste obtido em (a) é uniformemente mais poderoso de $H : X \sim U(0, 1)$ contra $K' : X \sim \text{Beta}(1, b)$, $b > 1$? Justifique.

Resolução

Sim, pois conforme descrito em a) o teste $\phi(x)$ era mais poderoso, de nível α , para testar H contra K. Ademais, $\phi(x)$ não depende do valor de $b > 0$. Assim, o teste $\phi(x)$ é uniformemente mais poderoso para testar $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b)$, $\forall b > 0$, ao nível de significância de α , como mostrou-se em a) $E_H[\phi(x)] \leq a$.

- (c) Existe teste uniformemente mais poderoso de $H : X \sim U(0, 1)$, contra $K'' : X \sim \text{Beta}(1, b)$, $b \neq 1$? Justifique.

Resolução

Sejam as hipóteses:

- i) $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b_1)$, $b_1 > b > 1$. Podemos definir o seguinte teste.

$$\phi(x) = \begin{cases} 1 & \text{se } f_K(x) > kf_H(x) \\ 0 & \text{se } f_K(x) < kf_H(x), \end{cases}$$

$$f_K(x) = \frac{1}{B(1, b_1)} x^{1-1} (1-x)^{b_1-1} \mathbf{I}_{(0,1)}(x), \quad b_1 > b > 1 \quad \text{e} \quad f_H(x) = \mathbf{I}_{(0,1)}(x)$$

$$f_K(x) > kf_H(x)$$

$$\frac{1}{B(1, b_1)} x^{1-1} (1-x)^{b_1-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b_1 > 1$$

$$\frac{1}{\Gamma(1)\Gamma(b_1)} \frac{1}{\Gamma(1+b_1)} x^{1-1} (1-x)^{b_1-1} \mathbf{I}_{(0,1)}(x) > k \mathbf{I}_{(0,1)}(x), \quad b_1 > b > 1$$

... análogo ao que foi feito em a)

$$x < \underbrace{\left(\frac{k}{b_1}\right)^{\frac{1}{b_1-1}}}_{k'}$$

$$x < k'$$

$$\phi(x) = \begin{cases} 1 & \text{se } x < k' \\ 0 & \text{se } x > k', \end{cases}$$

$$\begin{aligned}
\mathbf{E}_H[\phi(x)] &= \alpha \\
P_H(x < k') &= \alpha \\
\int_0^{k'} dx &= \alpha, \quad H: X \sim U(0, 1) \\
X|_0^{k'} &= \alpha \\
k' &= \alpha
\end{aligned}$$

Assim,

$$\phi(x) = \begin{cases} 1 & \text{se } x < \alpha \\ 0 & \text{se } x > \alpha, \end{cases}$$

é um teste mais poderoso de nível α para testar $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b_1)$, sendo $b_1 > b > 1$ fixado. Como $\phi(x)$ não depende do valor de b_1 , o teste $\phi(x)$ é uniformemente mais poderoso para testar $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b), \forall b > 1$, ao nível de significância de α .

ii) $H : X \sim U(0, 1)$ contra $K : X \sim \text{Beta}(1, b_1), 0 < b_1 < b < 1$.

$$\phi^*(x) = \begin{cases} 1 & \text{se } x < k/b \\ 0 & \text{se } x > k/b, \end{cases}$$

$$\begin{aligned}
\mathbf{E}_{b_1}[\phi(x)] &= P_H(x < k/b) \\
&= (b_1/b)k = \alpha \\
k &= (b/b_1)\alpha
\end{aligned}$$

$$\phi^*(x) = \begin{cases} 1 & \text{se } x < \frac{b\alpha}{b_1 b} \\ 0 & \text{se } x > \frac{b\alpha}{b_1 b}, \end{cases}$$

$$\phi^*(x) = \begin{cases} 1 & \text{se } x < \frac{\alpha}{b_1} \\ 0 & \text{se } x > \frac{\alpha}{b_1}, \end{cases}$$

Como pode-se observar, o nosso teste $\phi^*(x)$ depende de b_1 . Assim, tem-se os seguintes casos:

a) $0 < b_1 < 1$:

O teste $\phi^*(x) = 1$ rejeita para maiores valores de x , pois menor valor de b_1 , maiores valores para $\frac{\alpha}{b_1}$.

b) $b_1 > 1$:

O teste $\phi^*(x)$ rejeita para menores valores de x , pois maior valor de b_1 , menores valores para $\frac{\alpha}{b_1}$.

Estes dois casos mostram que o comportamento da função de teste $\phi^*(x)$ está diretamente relacionado ao valor de b_1 , e não há um único ponto de corte que funcione uniformemente para todas as alternativas b_1 .

Portanto, não existe um teste uniformemente mais poderoso (UMP) para para testar $H : X \sim U(0, 1)$, contra $K' : X \sim \text{Beta}(1, b), b \neq 1$, já que a função de teste $\phi^*(x)$ depende do valor específico de b .

11.) Sejam X_{i1}, \dots, X_{in_i} observações independentes de distribuições normais de média μ_i e variância σ_i^2 para $i = 1, 2; \mu_1, \mu_2 \in \mathbb{R}, \sigma_1^2, \sigma_2^2 > 0$.

(a) Obtenha o teste da razão de verossimilhanças de $H : \mu_1 = \mu_2$ versus $K : \mu_1 \neq \mu_2$ de nível α (com $0 < \alpha < 1$), supondo que σ_1^2 e σ_2^2 são conhecidos.

Resolução

$$\begin{aligned}
f_1(x, \mu_1, \sigma_1^2) &= \frac{1}{\sqrt{2\pi\sigma_1^2}} \exp\left\{-\frac{1}{2\sigma_1^2}(x - \mu_1)^2\right\} \\
f_1(\mathbf{x}, \mu_1, \sigma_1^2) &\stackrel{\text{ind}}{=} (2\pi\sigma_1^2)^{-\frac{n_1}{2}} \exp\left\{-\frac{1}{2\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu_1)^2\right\} \\
f_2(x, \mu_2, \sigma_2^2) &= \frac{1}{\sqrt{2\pi\sigma_2^2}} \exp\left\{-\frac{1}{2\sigma_2^2}(x - \mu_2)^2\right\} \\
f_2(\mathbf{x}, \mu_2, \sigma_2^2) &\stackrel{\text{ind}}{=} (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu_2)^2\right\} \\
f(\mathbf{x}_{1i}, \mu_1, \mu_2, \sigma_1^2, \sigma_2^2) &\stackrel{\text{ind}}{=} (2\pi\sigma_1^2)^{-\frac{n_1}{2}} \exp\left\{-\frac{1}{2\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu_1)^2\right\} \times (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu_2)^2\right\} \\
L(\mathbf{x}_{1i}, \mu_1, \mu_2) &\stackrel{\text{ind}}{=} (2\pi\sigma_1^2)^{-\frac{n_1}{2}} \times (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu_1)^2 - \frac{1}{2\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu_2)^2\right\} \\
\ell(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2) &= -\frac{n_1}{2} \log(2\pi\sigma_1^2) - \frac{n_2}{2} \log(2\pi\sigma_2^2) - \frac{1}{2\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu_1)^2 - \frac{1}{2\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu_2)^2
\end{aligned}$$

Sob $H_0 \mu_1 = \mu_2$

$$\begin{aligned}
\ell(\mu, \sigma_1^2, \sigma_2^2) &= -\frac{n_1}{2}(2\pi\sigma_1^2) - \frac{n_2}{2}(2\pi\sigma_2^2) - \frac{1}{2\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu)^2 - \frac{1}{2\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu)^2 \\
\frac{d\ell(\mu, \sigma_1^2, \sigma_2^2)}{d\mu} &= -\frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu)(-1) - \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu)(-1) \\
\frac{d\ell(\mu, \sigma_1^2, \sigma_2^2)}{d\mu} &= \frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \mu) + \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \mu) \\
\frac{d^2\ell(\mu, \sigma_1^2, \sigma_2^2)}{d\mu^2} &= -\frac{n_1}{\sigma_1^2} - \frac{n_2}{\sigma_2^2} < 0, \text{ logo existe estimador de máxima verossimilhança (MV) para } \mu \\
\frac{d\ell(\mu, \sigma_1^2, \sigma_2^2)}{d\mu} &= 0 \\
\frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}(x_{i1} - \hat{\mu}) + \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}(x_{i2} - \hat{\mu}) &= 0 \\
\frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}x_{i1} - \frac{n_1\hat{\mu}}{\sigma_1^2} + \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}x_{i2} - \frac{n_2\hat{\mu}}{\sigma_2^2} &= 0 \\
-\frac{n_1\hat{\mu}}{\sigma_1^2} - \frac{n_2\hat{\mu}}{\sigma_2^2} &= -\frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}x_{i1} - \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}x_{i2} \\
\left(\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}\right)\hat{\mu} &= \frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}x_{i1} + \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}x_{i2} \\
\hat{\mu} &= \frac{\frac{1}{\sigma_1^2}\sum_{i=1}^{n_1}x_{i1} + \frac{1}{\sigma_2^2}\sum_{i=1}^{n_2}x_{i2}}{\left(\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}\right)} \\
\hat{\mu} &= \frac{\frac{n_1\bar{x}_1}{\sigma_1^2} + \frac{n_2\bar{x}_2}{\sigma_2^2}}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}}
\end{aligned}$$

Sem restrição de H

$\hat{\mu}_1 = \bar{X}_1$ e $\hat{\mu}_2 = \bar{X}_2$, pois sabe-se que a média é estimador MV para μ

$$\begin{aligned}
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{\sup_{\mu \in \Theta_0} L(\mu | x_1, x_2)}{\sup_{\mu \in \Theta} L(\mu | x_1, x_2)} \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{(2\pi\sigma_1^2)^{-\frac{n_1}{2}} \times (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 \right\}}{(2\pi\sigma_1^2)^{-\frac{n_1}{2}} \times (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2 \right\}} \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{\exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 \right\}}{\exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2 \right\}} \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \exp \left\{ -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 + \frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 + \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2 \right\} \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \exp \{ A + B \} \\
A &= -\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 + \frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 \text{ e } B = -\frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 + \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2 \\
A &= -\frac{1}{2\sigma_1^2} \left(\sum_{i=1}^{n_1} x_{i1}^2 - 2\hat{\mu} \sum_{i=1}^{n_1} x_{i1} + \sum_{i=1}^{n_1} \hat{\mu}^2 \right) + \frac{1}{2\sigma_1^2} \left(\sum_{i=1}^{n_1} x_{i1}^2 - 2\hat{\mu}_1 \sum_{i=1}^{n_1} x_{i1} + \sum_{i=1}^{n_1} \hat{\mu}_1^2 \right) \\
A &= \frac{1}{2\sigma_1^2} \left(-\sum_{i=1}^{n_1} x_{i1}^2 + 2\hat{\mu} \sum_{i=1}^{n_1} x_{i1} - \sum_{i=1}^{n_1} \hat{\mu}^2 + \sum_{i=1}^{n_1} x_{i1}^2 - 2\hat{\mu}_1 \sum_{i=1}^{n_1} x_{i1} + \sum_{i=1}^{n_1} \hat{\mu}_1^2 \right) \\
A &= \frac{1}{2\sigma_1^2} (2\hat{\mu} n_1 \bar{x}_1 - n_1 \hat{\mu}^2 - 2\hat{\mu}_1 n_1 \bar{x}_1 + n_1 \hat{\mu}_1^2) \\
A &= \frac{n_1}{2\sigma_1^2} (2\hat{\mu} \bar{x}_1 - \hat{\mu}^2 - 2\bar{x}_1^2 + \bar{x}_1^2), \quad \hat{\mu}_1 = \bar{x}_1 \\
A &= \frac{n_1}{2\sigma_1^2} (2\hat{\mu} \bar{x}_1 - \hat{\mu}^2 - \bar{x}_1^2) \\
A &= -\frac{n_1}{2\sigma_1^2} (-2\hat{\mu} \bar{x}_1 + \hat{\mu}^2 + \bar{x}_1^2) \\
A &= -\frac{n_1}{2\sigma_1^2} (\bar{x}_1 - \hat{\mu})^2 \\
A &= -\frac{n_1}{2\sigma_1^2} \left(\bar{x}_1 - \frac{\frac{n_1 \bar{x}_1}{\sigma_1^2} + \frac{n_2 \bar{x}_2}{\sigma_2^2}}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 \\
A &= -\frac{n_1}{2\sigma_1^2} \left(\frac{\frac{n_1 \bar{x}_1}{\sigma_1^2} + \frac{n_2 \bar{x}_1}{\sigma_2^2} - \frac{n_1 \bar{x}_1}{\sigma_1^2} - \frac{n_2 \bar{x}_2}{\sigma_2^2}}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 \\
A &= -\frac{n_1}{2\sigma_1^2} \left(\frac{\frac{\bar{x}_1}{\sigma_2^2} - \frac{n_2 \bar{x}_2}{\sigma_2^2}}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 \\
A &= -\frac{n_1 n_2^2}{2\sigma_1^2 \sigma_2^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 \\
\text{De forma análoga, } B &= -\frac{n_2}{2\sigma_2^2} (\bar{x}_2 - \hat{\mu})^2 = -\frac{n_2 n_1^2}{2\sigma_2^2 \sigma_1^4} \left(\frac{\bar{x}_2 - \bar{x}_1}{\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2}} \right)^2 \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \exp \left\{ -\frac{n_1 n_2^2}{2\sigma_1^2 \sigma_2^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 - \frac{n_2 n_1^2}{2\sigma_2^2 \sigma_1^4} \left(\frac{\bar{x}_2 - \bar{x}_1}{\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2}} \right)^2 \right\} \\
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \exp \left\{ -\frac{n_1 n_2^2}{2\sigma_1^2 \sigma_2^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 - \frac{n_2 n_1^2}{2\sigma_2^2 \sigma_1^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2}} \right)^2 \right\}
\end{aligned}$$

Rejeita-se H, se: $\lambda(\mathbf{x}_1, \mathbf{x}_2) < c$, $c \in (0, 1)$

$$\begin{aligned}
& \exp \left\{ -\frac{n_1 n_2^2}{2 \sigma_1^2 \sigma_2^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_1}{\sigma_1^2} + \frac{n_2}{\sigma_2^2}} \right)^2 - \frac{n_2 n_1^2}{2 \sigma_2^2 \sigma_1^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2}} \right)^2 \right\} < c \\
& \exp \left\{ - \left[\frac{n_1 n_2^2}{2 \sigma_1^2 \sigma_2^4} + \frac{n_2 n_1^2}{2 \sigma_2^2 \sigma_1^4} \right] \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2}} \right)^2 \right\} < c \\
& - \left[\frac{n_1 n_2^2}{2 \sigma_1^2 \sigma_2^4} + \frac{n_2 n_1^2}{2 \sigma_2^2 \sigma_1^4} \right] \frac{(\bar{x}_1 - \bar{x}_2)^2}{\left(\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2} \right)^2} < c' \\
& - \left(\frac{n_1 n_2}{2 \sigma_1^2 \sigma_2^2} \right) \left[\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2} \right] \frac{(\bar{x}_1 - \bar{x}_2)^2}{\left(\frac{n_2}{\sigma_2^2} + \frac{n_1}{\sigma_1^2} \right)^2} < c' \\
& - \left(\frac{n_1 n_2}{2 \sigma_1^2 \sigma_2^2} \right) \frac{(\bar{x}_1 - \bar{x}_2)^2}{\left(\frac{n_2 \sigma_1^2}{\sigma_1^2 \sigma_2^2} + \frac{n_1 \sigma_2^2}{\sigma_1^2 \sigma_2^2} \right)} < c' \\
& - \frac{n_1 n_2}{2} \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{n_2 \sigma_1^2 + n_1 \sigma_2^2} \right] \frac{1}{\frac{1}{n_1 n_2}} < c' \\
& - \frac{1}{2} \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right] < c' \\
& \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right] > c' \\
& \left[\frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \right]^2 > c' \\
& [Z]^2 > c', Z \text{ é normal padrão} \\
& [Z]^2 \sim \chi_1^2 \\
& \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \sim \chi_1^2 \\
& \phi(x, y) = \begin{cases} 1 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \sim \chi_1^2 > c'' \\ 0 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \sim \chi_1^2 < c'' \end{cases} \\
& \mathbf{E}_H[\phi(x, y)] = \alpha \\
& P_H \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} > c'' \right] = \alpha \\
& 1 - P_H \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq c'' \right] = \alpha
\end{aligned}$$

$$P_H \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \leq c'' \right] = 1 - \alpha$$

$$P_H [\chi_1^2 \leq c''] = 1 - \alpha$$

$$c'' = \chi_{1, 1-\alpha}^2$$

$$\phi(x, y) = \begin{cases} 1 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} > \chi_{1, 1-\alpha}^2 \quad (\text{Aqui o teste rejeita H}) \\ 0 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} < \chi_{1, 1-\alpha}^2 \quad (\text{Aqui o teste não rejeita H}) \end{cases}$$

(b) Obtenha o teste da razão de verossimilhanças de $H : \sigma_1^2 = \sigma_2^2$ versus $K : \sigma_1^2 \neq \sigma_2^2$ de nível α .

Resolução

$$f_1(\mathbf{x}, \mu_1, \sigma_1^2) \stackrel{ind}{=} (2\pi\sigma_1^2)^{-\frac{n_1}{2}} \exp\left\{-\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2\right\}$$

$$f_2(\mathbf{x}, \mu_2, \sigma_2^2) \stackrel{ind}{=} (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2\right\}$$

$$L(\mathbf{x}_{1i}, \mu_1, \mu_2) \stackrel{ind}{=} (2\pi\sigma_1^2)^{-\frac{n_1}{2}} \times (2\pi\sigma_2^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2\right\}$$

$$\ell(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2) = -\frac{n_1}{2} \log(\sigma_1^2) - \frac{n_2}{2} \log(\sigma_2^2) - \frac{1}{2\sigma_1^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{2\sigma_2^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2$$

Sob $H_0 \sigma_1^2 = \sigma_2^2$

$$\ell(\mu_1, \mu_2, \sigma^2) = -\frac{n_1}{2} \log(\sigma^2) - \frac{n_2}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2$$

$$\frac{d\ell(\mu_1, \mu_2, \sigma^2)}{d\sigma^2} = -\frac{n_1}{2\sigma^2} - \frac{n_2}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 + \frac{1}{2\sigma^4} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2$$

$$\frac{d^2\ell(\mu_1, \mu_2, \sigma^2)}{d(\sigma^2)^2} = \frac{n_1}{2\sigma^4} + \frac{n_2}{2\sigma^4} - \frac{1}{\sigma^3} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{\sigma^3} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2 < 0 \text{ logo existe estimador MV}$$

$$\frac{d\ell(\mu_1, \mu_2, \sigma^2)}{d\sigma^2} = 0$$

$$-\frac{n_1}{2\hat{\sigma}^2} - \frac{n_2}{2\hat{\sigma}^2} + \frac{1}{2\hat{\sigma}^4} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 + \frac{1}{2\hat{\sigma}^4} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2 = 0$$

$$-\frac{n_1}{2\hat{\sigma}^2} - \frac{n_2}{2\hat{\sigma}^2} = -\frac{1}{2\hat{\sigma}^4} \left[\sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2 \right]$$

$$-\frac{1}{2\hat{\sigma}^2} (n_1 + n_2) = -\frac{1}{2\hat{\sigma}^4} \left[\sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2 \right]$$

$$(n_1 + n_2) \hat{\sigma}^2 = \left[\sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2 \right]$$

$$\hat{\sigma}^2 = \frac{[\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2]}{n_1 + n_2} \text{ estimativa viesada}$$

$$\hat{\sigma}^2 = S^2 = \frac{[\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2]}{n_1 + n_2 - 2} \text{ estimativa não viesada}$$

$$\hat{\sigma}^2 = S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

Sem restrição de H

$$\hat{\sigma}_1^2 = \frac{\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2}{n_1} \text{ e } \hat{\sigma}_2^2 = \frac{\sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2}{n_2}, \text{ já é de conhecimento}$$

No entanto estas estimativas são viesadas para a variância

$$\begin{aligned} \hat{\sigma}_{*1}^2 &= S_1^2 = \frac{\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2}{n_1 - 1} \text{ e } \hat{\sigma}_{*2}^2 = S_2^2 = \frac{\sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2}{n_2 - 1}, \text{ estimativas não viesadas} \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{\sup_{\sigma \in \Theta_0} L(\sigma | x_1, x_2)}{\sup_{\sigma \in \Theta} L(\sigma | x_1, x_2)} \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{\left(2\pi\hat{\sigma}_{*1}^2\right)^{-\frac{n_1}{2}} \times \left(2\pi\hat{\sigma}_{*2}^2\right)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\hat{\sigma}_{*2}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2\right\}}{\left(2\pi\hat{\sigma}_{*1}^2\right)^{-\frac{n_1}{2}} \times \left(2\pi\hat{\sigma}_{*2}^2\right)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\hat{\sigma}_{*2}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2\right\}} \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \frac{\left(\hat{\sigma}_{*1}^2\right)^{-\frac{n_1}{2}} \times \left(\hat{\sigma}_{*2}^2\right)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2}(n_1 - 1)S_1^2 - \frac{1}{2\hat{\sigma}_{*2}^2}(n_2 - 1)S_2^2\right\}}{\left(\hat{\sigma}_{*1}^2\right)^{-\frac{n_1}{2}} \left(\hat{\sigma}_{*2}^2\right)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2}(n_1 - 1)S_1^2 - \frac{1}{2\hat{\sigma}_{*2}^2}(n_2 - 1)S_2^2\right\}} \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \left(\frac{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}{S_1^2}\right)^{-\frac{n_1}{2}} \left(\frac{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}{S_2^2}\right)^{-\frac{n_2}{2}} \frac{\exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2}(n_1 - 1)S_1^2 - \frac{1}{2\hat{\sigma}_{*2}^2}(n_2 - 1)S_2^2\right\}}{\exp\left\{-\frac{1}{2S_1^2}(n_1 - 1)S_1^2 - \frac{1}{2S_2^2}(n_2 - 1)S_2^2\right\}} \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \left(\frac{S_1^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_1}{2}} \left(\frac{S_2^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_2}{2}} \times A \\ A &= \frac{\exp\left\{-\frac{1}{2\hat{\sigma}_{*1}^2}(n_1 - 1)S_1^2 - \frac{1}{2\hat{\sigma}_{*2}^2}(n_2 - 1)S_2^2\right\}}{\exp\left\{-\frac{1}{2S_1^2}(n_1 - 1)S_1^2 - \frac{1}{2S_2^2}(n_2 - 1)S_2^2\right\}} \\ A &= \frac{\exp\left\{-\frac{(n_1-1)S_1^2}{2\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}\right)} - \frac{(n_2-1)S_2^2}{2\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}\right)}\right\}}{\exp\left\{-\frac{1}{2}(n_1 - 1) - \frac{1}{2}(n_2 - 1)\right\}} \\ A &= \frac{\exp\left\{-\frac{(n_1-1)(n_1+n_2-2)S_1^2}{2((n_1-1)S_1^2+(n_2-1)S_2^2)} - \frac{(n_2-1)(n_1+n_2-2)S_2^2}{2((n_1-1)S_1^2+(n_2-1)S_2^2)}\right\}}{\exp\left\{-\frac{1}{2}(n_1 - 1) - \frac{1}{2}(n_2 - 1)\right\}} \\ A &= \frac{\exp\left\{-\frac{[(n_1-1)S_1^2+(n_2-1)S_2^2](n_1+n_2-2)}{2[(n_1-1)S_1^2+(n_2-1)S_2^2]}\right\}}{\exp\left\{-\frac{1}{2}(n_1 - 1) - \frac{1}{2}(n_2 - 1)\right\}} \\ A &= \frac{\exp\left\{-\frac{(n_1+n_2-2)}{2}\right\}}{\exp\left\{-\frac{1}{2}[n_1 + n_2 - 2]\right\}} \\ A &= 1 \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \left(\frac{S_1^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_1}{2}} \left(\frac{S_2^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_2}{2}} \times 1 \\ \lambda(\mathbf{x}_1, \mathbf{x}_2) &= \left(\frac{S_1^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_1}{2}} \left(\frac{S_2^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}}\right)^{\frac{n_2}{2}} \end{aligned}$$

Rejeita se $\lambda(\mathbf{x}_1, \mathbf{x}_2) < c, c \in (0, 1)$

$$\begin{aligned}
& \left(\frac{S_1^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \right)^{\frac{n_1}{2}} \left(\frac{S_2^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \right)^{\frac{n_2}{2}} < c \\
& \left(\frac{S_1^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \right) \left(\frac{S_2^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \right) < c' \\
& \frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} < c' \\
& \frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} \sim F_{(n_2-1, n_1-1)} \\
& \phi(x) = \begin{cases} 1 & \text{se } \frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} < c' \text{ ou } > c'' \\ 0 & \text{c.c} \end{cases}
\end{aligned}$$

$$\begin{aligned}
& \mathbf{E}[\phi(x)] = \alpha \\
& P_H \left[\frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} < c' \right] = \alpha \\
& 1 - P_H \left[\frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} \geq c' \right] = \alpha \\
& P_H \left[\frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} \geq c' \right] = 1 - \alpha \\
& c' = F_{(n_1-1, n_2-1, 1-\alpha)}
\end{aligned}$$

$$\phi(x) = \begin{cases} 1 & \text{se } \frac{\left(\frac{(n_1-1)S_1^2}{n_1-1} \right) \left(\frac{(n_2-1)S_2^2}{n_2-1} \right)}{\left(\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \right)^2} < F_{(n_1-1, n_2-1, 1-\alpha_1)} \text{ ou } > F_{(n_1-1, n_2-1, 1-\alpha_2)} \quad \alpha_1 + \alpha_2 = \alpha \\ 0 & \text{c.c} \end{cases}$$

- (c) Suponha agora que as variâncias são desconhecidas, mas iguais (isto é, $\sigma_1^2 = \sigma_2^2 = \sigma^2$), e refaça a parte (a).

Resolução

$$\begin{aligned}
f_1(\mathbf{x}, \mu_1, \sigma^2) & \stackrel{ind}{=} (2\pi\sigma^2)^{-\frac{n_1}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2\right\} \\
f_2(\mathbf{x}, \mu_2, \sigma^2) & \stackrel{ind}{=} (2\pi\sigma^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2\right\} \\
f(\mathbf{x}_{1i}, \mu_1, \mu_2, \sigma^2) & \stackrel{ind}{=} (2\pi\sigma^2)^{-\frac{n_1}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2\right\} \times (2\pi\sigma^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2\right\} \\
L(\mathbf{x}_{1i}, \mu_1, \mu_2) & \stackrel{ind}{=} (2\pi\sigma^2)^{-\frac{n_1}{2}} \times (2\pi\sigma^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2\right\}
\end{aligned}$$

$$\ell(\mu_1, \mu_2, \sigma^2, \sigma^2) = -\frac{n_1}{2} \log(2\pi\sigma^2) - \frac{n_2}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu_1)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu_2)^2$$

Sob $H_0 \mu_1 = \mu_2$

$$\ell(\mu, \sigma^2) = -\frac{n_1}{2} \log(2\pi\sigma^2) - \frac{n_2}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu)^2 - \frac{1}{2\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu)^2$$

$$\frac{d\ell(\mu, \sigma^2)}{d\mu} = -\frac{1}{\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu)(-1) - \frac{1}{\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu)(-1)$$

$$\frac{d\ell(\mu, \sigma^2)}{d\mu} = \frac{1}{\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \mu) + \frac{1}{\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \mu)$$

$$\frac{d^2\ell(\mu, \sigma^2)}{d\mu^2} = -\frac{n_1}{\sigma^2} - \frac{n_2}{\sigma^2} < 0, \text{ logo existe estimador de máxima verossimilhança (MV) para } \mu$$

$$\frac{d\ell(\mu, \sigma^2)}{d\mu} = 0$$

$$\frac{1}{\sigma^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}) + \frac{1}{\sigma^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}) = 0$$

$$\frac{1}{\sigma^2} \sum_{i=1}^{n_1} x_{i1} - \frac{n_1 \hat{\mu}}{\sigma^2} + \frac{1}{\sigma^2} \sum_{i=1}^{n_2} x_{i2} - \frac{n_2 \hat{\mu}}{\sigma^2} = 0$$

$$\sum_{i=1}^{n_1} x_{i1} - n_1 \hat{\mu} + \sum_{i=1}^{n_2} x_{i2} - n_2 \hat{\mu} = 0$$

$$(n_1 + n_2) \hat{\mu} = \sum_{i=1}^{n_2} x_{i2} + \sum_{i=1}^{n_1} x_{i1}$$

$$\hat{\mu} = \frac{\sum_{i=1}^{n_1} x_{i1} + \sum_{i=1}^{n_2} x_{i2}}{n_1 + n_2} = \frac{n_1 \bar{x}_1 + n_2 \bar{x}_2}{n_1 + n_2}$$

Sem restrição de \mathbf{H}

$\hat{\mu}_1 = \bar{X}_1$ e $\hat{\mu}_2 = \bar{X}_2$, pois sabe-se que a média é estimador MV para μ

$$\hat{\sigma}^2 = \frac{[\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2]}{n_1 + n_2} \text{ estimativa viesada}$$

$$\hat{\sigma}^{*2} = S^2 = \frac{[\sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 + \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2]}{n_1 + n_2 - 2} \text{ estimativa não viesada}$$

$$\hat{\sigma}^{*2} = S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \frac{\sup_{\mu \in \Theta_0} L(\mu | x_1, x_2)}{\sup_{\mu \in \Theta} L(\mu | x_1, x_2)}$$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \frac{(2\pi\hat{\sigma}^2)^{-\frac{n_1}{2}} \times (2\pi\hat{\sigma}^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2\right\}}{(2\pi\hat{\sigma}^2)^{-\frac{n_1}{2}} \times (2\pi\hat{\sigma}^2)^{-\frac{n_2}{2}} \exp\left\{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2\right\}}$$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \frac{\exp\left\{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2\right\}}{\exp\left\{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2\right\}}$$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \exp\left\{-\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 + \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 - \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 + \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2\right\}$$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \exp\{A + B\}$$

$$\begin{aligned}
A &= -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu})^2 + \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_1} (x_{i1} - \hat{\mu}_1)^2 \\
A &= -\frac{n_1 n_2^2}{2\hat{\sigma}^2 \hat{\sigma}^4} \left(\frac{\bar{x}_1 - \bar{x}_2}{\frac{n_1}{\hat{\sigma}^2} + \frac{n_2}{\hat{\sigma}^2}} \right)^2 \quad \text{demonstrado em a) para } \sigma_i^2 \text{ conhecidos} \\
A &= -\frac{n_1 n_2^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 \\
B &= -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu})^2 + \frac{1}{2\hat{\sigma}^2} \sum_{i=1}^{n_2} (x_{i2} - \hat{\mu}_2)^2
\end{aligned}$$

De forma análoga, $B = -\frac{n_2 n_1^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2$

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) = \exp \left\{ -\frac{n_1 n_2^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 - \frac{n_2 n_1^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 \right\}$$

Rejeita-se H, se:

$$\lambda(\mathbf{x}_1, \mathbf{x}_2) < c, \quad c \in (0, 1)$$

$$\begin{aligned}
\lambda(\mathbf{x}_1, \mathbf{x}_2) &= \exp \left\{ -\frac{n_1 n_2^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 - \frac{n_2 n_1^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 \right\} \\
&\exp \left\{ -\frac{n_1 n_2^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 - \frac{n_2 n_1^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 \right\} < c \\
&-\frac{n_1 n_2^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 - \frac{n_2 n_1^2}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 < c' \\
&\frac{1}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 + \frac{1}{2\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 > c' \\
&\frac{1}{\hat{\sigma}^2} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 > c'
\end{aligned}$$

$$\begin{aligned}
&\frac{1}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \left(\frac{\bar{x}_1 - \bar{x}_2}{n_1 + n_2} \right)^2 > c' \\
&\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1 + n_2)^2} > c'
\end{aligned}$$

Sabe-se que $\frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \cdot \left(\frac{1}{n_1} + \frac{1}{n_2} \right)}} \sim t_{n_1+n_2-2}$

$$\begin{aligned}
(t_{n_1+n_2-2})^2 &\equiv \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2} \cdot \left(\frac{1}{n_1} + \frac{1}{n_2} \right)} \sim F_{1, n_1+n_2-2, \alpha} \\
&\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2+(n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1 + n_2)^2} \sim F_{n_1+n_2-1, n_1+n_2-2, \alpha}
\end{aligned}$$

$$\phi(x, y) = \begin{cases} 1 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1+n_2)^2} > c' \\ 0 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1+n_2)^2} < c' \end{cases}$$

$$\mathbf{E}_H[\phi(x, y)] = \alpha$$

$$P_H \left[\frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1+n_2)^2} > c'' \right] = \alpha$$

$$c' = F_{n_1+n_2-1, n_1+n_2-2, \alpha}$$

$$\phi(x, y) = \begin{cases} 1 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1+n_2)^2} > F_{n_1+n_2-1, n_1+n_2-2, \alpha} \\ 0 & \text{se } \frac{(\bar{x}_1 - \bar{x}_2)^2}{\frac{(n_1-1)S_1^2 + (n_2-1)S_2^2}{n_1+n_2-2}} \frac{1}{(n_1+n_2)^2} < F_{n_1+n_2-1, n_1+n_2-2, \alpha} \end{cases}$$