

UNIVERSIDADE DE SÃO PAULO

Programa de Pos-Graduação em Estatística

Alex Monito Nhancololo, Stefan Zurman Gonçalves

Lista 01 – Semestre de 2024-II – Prof. Gilberto

1. Considere a função densidade de probabilidade da distribuição hiperbólica:

$f(y; \theta, \phi) = a(y; \phi) \exp[\phi\{y\theta + (1 - \theta^2)^{\frac{1}{2}}\}]$, em que $0 < \theta < 1$, $-\infty < y < \infty$, $\phi^{-1} > 0$ é o parâmetro de dispersão, $a(y; \phi) = \frac{\phi K_1(\phi\sqrt{1+y^2})}{\pi\sqrt{1+y^2}}$ é uma função normalizadora e $K_1(\cdot)$ é a função de Bessel de ordem 1. Mostre que essa distribuição pertence à família exponencial. Encontre a função de variância $V(\mu)$. Obtenha os componentes do desvio $d^{*2}(y_i; \hat{\mu}_i)$ supondo uma amostra de n variáveis aleatórias independentes de médias μ_i e parâmetro de dispersão ϕ^{-1} , para $i = 1, \dots, n$. Expressse também a medida R^2 .

Resolução

- (i) Mostrando que a distribuição pertence à família exponencial:

$$\begin{aligned}
 f(y; \theta, \phi) &= a(y; \phi) \exp[\phi\{y\theta + (1 - \theta^2)^{\frac{1}{2}}\}] \\
 f(y; \theta, \phi) &= \frac{\phi K_1(\phi\sqrt{1+y^2})}{\pi\sqrt{1+y^2}} \exp[\phi\{y\theta + (1 - \theta^2)^{\frac{1}{2}}\}] \\
 f(y; \theta, \phi) &= \exp \left\{ \log \left[\frac{\phi K_1(\phi\sqrt{1+y^2})}{\pi\sqrt{1+y^2}} \right] \right\} \exp[\phi\{y\theta + (1 - \theta^2)^{\frac{1}{2}}\}] \\
 f(y; \theta, \phi) &= \exp \left\{ \log \left[\frac{\phi K_1(\phi\sqrt{1+y^2})}{\pi\sqrt{1+y^2}} \right] + \phi \left[y\theta + (1 - \theta^2)^{\frac{1}{2}} \right] \right\} \\
 f(y; \theta, \phi) &= \exp \left\{ \phi \left[y\theta - \underbrace{\left\{ -(1 - \theta^2)^{\frac{1}{2}} \right\}}_{b(\theta)} \right] + \underbrace{\left[\log \left(\frac{\phi K_1(\phi\sqrt{1+y^2})}{\pi\sqrt{1+y^2}} \right) \right]}_{c(y; \phi)} \right\}.
 \end{aligned}$$

Como a função densidade de probabilidade tem forma $f(y; \theta, \phi) = \exp \{ \phi [y\theta - b(\theta)] + c(y; \phi) \}$, esta distribuição pertence à família exponencial (linear).

- (ii) Obtendo a média:

Para a família exponencial, vale que

$$\mu = \mathbb{E}(Y) = b'(\theta) = \frac{d}{d\theta} b(\theta).$$

Como $b(\theta) = -(1 - \theta^2)^{\frac{1}{2}}$, segue que

$$\begin{aligned}
 \mu &= \frac{d}{d\theta} \left[-(1 - \theta^2)^{\frac{1}{2}} \right] \\
 \mu &= -\frac{1}{2}(1 - \theta^2)^{-\frac{1}{2}}(-2\theta)
 \end{aligned}$$

$$\begin{aligned}\mu &= \frac{\gamma}{2}(1-\theta^2)^{-\frac{1}{2}}(\cancel{2}\theta) \\ \mu &= \theta(1-\theta^2)^{-\frac{1}{2}} = \frac{\theta}{\sqrt{1-\theta^2}}, \quad (0 < \theta < 1).\end{aligned}$$

A partir disso, segue que

$$\begin{aligned}\mu &= \theta(1-\theta^2)^{-\frac{1}{2}} \Rightarrow \mu^2 = \theta^2(1-\theta^2)^{-1} \\ &\Rightarrow \frac{1}{\mu^2} = \frac{1-\theta^2}{\theta^2} \Rightarrow \frac{1}{\mu^2} = \frac{1}{\theta^2} - 1 \\ &\Rightarrow \frac{1}{\mu^2} + 1 = \frac{1}{\theta^2} \Rightarrow \frac{1+\mu^2}{\mu^2} = \frac{1}{\theta^2} \\ &\Rightarrow \theta^2 = \frac{\mu^2}{1+\mu^2} \Rightarrow \theta = \left(\frac{\mu^2}{1+\mu^2}\right)^{\frac{1}{2}} \quad (*).\end{aligned}$$

A última expressão vale uma vez que θ assume valores positivos, ou seja, $0 < \theta < 1$.

(iii) Obtendo a função de variância:

Para a família exponencial, vale que

$$V(\mu) = \frac{d^2 b(\theta)}{d\theta^2} = \frac{d}{d\theta} \left[\frac{db(\theta)}{d\theta} \right] = \frac{d\mu}{d\theta}.$$

Então, segue que

$$\begin{aligned}V(\mu) &= \frac{d}{d\theta} \left(\theta(1-\theta^2)^{-\frac{1}{2}} \right) \\ V(\mu) &= (1-\theta^2)^{-\frac{1}{2}} + \left[\cancel{\frac{\gamma}{2}}(1-\theta^2)^{-\frac{3}{2}}(\cancel{2}\cdot\theta)\theta \right] \\ V(\mu) &= (1-\theta^2)^{-\frac{1}{2}} + \theta^2(1-\theta^2)^{-\frac{3}{2}}.\end{aligned}$$

Utilizando o resultado em (*),

$$\begin{aligned}V(\mu) &= \left(1 - \frac{\mu^2}{1+\mu^2}\right)^{-\frac{1}{2}} + \frac{\mu^2}{1+\mu^2} \left(1 - \frac{\mu^2}{1+\mu^2}\right)^{-\frac{3}{2}} \\ V(\mu) &= \left(\frac{1+\mu^2-\mu^2}{1+\mu^2}\right)^{-\frac{1}{2}} + \frac{\mu^2}{1+\mu^2} \left(\frac{1+\mu^2-\mu^2}{1+\mu^2}\right)^{-\frac{3}{2}} \\ V(\mu) &= \left(\frac{1}{1+\mu^2}\right)^{-\frac{1}{2}} + \frac{\mu^2}{1+\mu^2} \left(\frac{1}{1+\mu^2}\right)^{-\frac{3}{2}} \\ V(\mu) &= (1+\mu^2)^{\frac{1}{2}} + \frac{\mu^2}{1+\mu^2} (1+\mu^2)^{\frac{3}{2}} \\ V(\mu) &= (1+\mu^2)^{\frac{1}{2}} + \frac{\mu^2}{1+\mu^2} (1+\mu^2)^{\frac{1}{2}} (1+\mu^2) \\ V(\mu) &= (1+\mu^2)^{\frac{1}{2}} + \mu^2 (1+\mu^2)^{\frac{1}{2}} \\ V(\mu) &= (1+\mu^2)^{\frac{1}{2}} (1+\mu^2) \\ V(\mu) &= (1+\mu^2)^{\frac{3}{2}}.\end{aligned}$$

(iv) Obtendo os componentes do desvio $d^{*2}(y_i; \hat{\mu}_i)$:

Os componentes do desvio são dados por

$$d^{*2}(y_i; \hat{\mu}_i) = \phi d^2(y_i; \hat{\mu}_i)$$

$$d^{*2}(y_i; \hat{\mu}_i) = 2\phi \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + (b(\hat{\theta}_i) - b(\tilde{\theta}_i)) \right\}, i = 1, 2, \dots, n.$$

Segue que

$$b(\theta) = - (1 - \theta^2)^{\frac{1}{2}} = - \left(1 - \frac{\mu^2}{1 + \mu^2} \right)^{\frac{1}{2}} = - \left(\frac{1 + \mu^2 - \mu^2}{1 + \mu^2} \right)^{\frac{1}{2}} = - \left(\frac{1}{1 + \mu^2} \right)^{\frac{1}{2}} = - \frac{1}{\sqrt{1 + \mu^2}}.$$

Assim, obtém-se:

$$\text{Para o modelo saturado: } \tilde{\theta}_i = \sqrt{\frac{y_i^2}{1 + y_i^2}}, \quad b(\tilde{\theta}_i) = -\frac{1}{\sqrt{1 + y_i^2}}.$$

$$\text{Para o modelo sob investigação: } \hat{\theta}_i = \sqrt{\frac{\hat{\mu}_i^2}{1 + \hat{\mu}_i^2}}, \quad b(\hat{\theta}_i) = -\frac{1}{\sqrt{1 + \hat{\mu}_i^2}}.$$

Então,

$$d^{*2}(y_i, \hat{\mu}_i) = \phi d^2(y_i, \hat{\mu}_i)$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ y_i(\tilde{\theta}_i - \hat{\theta}_i) + (b(\hat{\theta}_i) - b(\tilde{\theta}_i)) \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ y_i \left(\sqrt{\frac{y_i^2}{1 + y_i^2}} - \sqrt{\frac{\hat{\mu}_i^2}{1 + \hat{\mu}_i^2}} \right) + \left[-\frac{1}{\sqrt{1 + \hat{\mu}_i^2}} - \left(-\frac{1}{\sqrt{1 + y_i^2}} \right) \right] \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ y_i \left(\frac{y_i}{\sqrt{1 + y_i^2}} - \frac{\hat{\mu}_i}{\sqrt{1 + \hat{\mu}_i^2}} \right) + \left(-\frac{1}{\sqrt{1 + \hat{\mu}_i^2}} + \frac{1}{\sqrt{1 + y_i^2}} \right) \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ y_i \left[\frac{y_i \sqrt{1 + y_i^2}}{\left(\sqrt{1 + y_i^2} \right)^2} - \frac{\hat{\mu}_i \sqrt{1 + \hat{\mu}_i^2}}{\left(\sqrt{1 + \hat{\mu}_i^2} \right)^2} \right] + \left[-\frac{\sqrt{1 + \hat{\mu}_i^2}}{\left(\sqrt{1 + \hat{\mu}_i^2} \right)^2} + \frac{\sqrt{1 + y_i^2}}{\left(\sqrt{1 + y_i^2} \right)^2} \right] \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ y_i \left(\frac{y_i \sqrt{1 + y_i^2}}{1 + y_i^2} - \frac{\hat{\mu}_i \sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} \right) + \left(-\frac{\sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} + \frac{\sqrt{1 + y_i^2}}{1 + y_i^2} \right) \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ \frac{y_i^2 \sqrt{1 + y_i^2}}{1 + y_i^2} - \frac{\hat{\mu}_i y_i \sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} + \frac{\sqrt{1 + y_i^2}}{1 + y_i^2} - \frac{\sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ \frac{y_i^2 \sqrt{1 + y_i^2}}{1 + y_i^2} + \frac{\sqrt{1 + y_i^2}}{1 + y_i^2} - \frac{\hat{\mu}_i y_i \sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} - \frac{\sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ \frac{(y_i^2 + 1) \sqrt{1 + y_i^2}}{1 + y_i^2} - \frac{\hat{\mu}_i y_i \sqrt{1 + \hat{\mu}_i^2} + \sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ \sqrt{1 + y_i^2} - \frac{(\hat{\mu}_i y_i + 1) \sqrt{1 + \hat{\mu}_i^2}}{1 + \hat{\mu}_i^2} \right\}$$

$$d^{*2}(y_i, \hat{\mu}_i) = 2\phi \left\{ \sqrt{1 + y_i^2} - \frac{\hat{\mu}_i y_i + 1}{\sqrt{1 + \hat{\mu}_i^2}} \right\}, i = 1, 2, \dots, n.$$

(v) Expressão de \mathbf{R}^2 :

Inicialmente, encontra-se o desvio do modelo, dado por

$$D^*(y; \hat{\mu}) = \sum_{i=1}^n d^{*2}(y_i, \hat{\mu}_i)$$

$$D^*(y; \hat{\mu}) = 2\phi \sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\hat{\mu}_i y_i + 1}{\sqrt{1+\hat{\mu}_i^2}} \right\}.$$

Em seguida, encontra-se o desvio do modelo apenas com o intercepto, dado por

$$D^*(y; \bar{y}) = \sum_{i=1}^n d^{*2}(y_i, \bar{y})$$

$$D^*(y; \bar{y}) = 2\phi \sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\bar{y} y_i + 1}{\sqrt{1+\bar{y}^2}} \right\}.$$

Então, vale que

$$R^2 = 1 - \frac{D^*(y; \hat{\mu})}{D^*(y; \bar{y})}$$

$$R^2 = 1 - \frac{2\phi \sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\hat{\mu}_i y_i + 1}{\sqrt{1+\hat{\mu}_i^2}} \right\}}{2\phi \sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\bar{y} y_i + 1}{\sqrt{1+\bar{y}^2}} \right\}}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\hat{\mu}_i y_i + 1}{\sqrt{1+\hat{\mu}_i^2}} \right\}}{\sum_{i=1}^n \left\{ \sqrt{1+y_i^2} \right\} - \frac{n\bar{y}^2 + n}{\sqrt{1+\bar{y}^2}}}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n \left\{ \sqrt{1+y_i^2} - \frac{\hat{\mu}_i y_i + 1}{\sqrt{1+\hat{\mu}_i^2}} \right\}}{\sum_{i=1}^n \left\{ \sqrt{1+y_i^2} \right\} - n\sqrt{1+\bar{y}^2}}.$$

2. Supor que Y_1, \dots, Y_k sejam variáveis aleatórias independentes tais que Y_i tenha função de probabilidade expressa na forma

$$f(y_i; \psi) = \binom{m}{y_i} \left(\frac{\psi}{1+\psi} \right)^{y_i} \left(\frac{1}{1+\psi} \right)^{m-y_i},$$

com $\psi > 0$ e $y_i = 0, 1, \dots, m$ e $i = 1, \dots, k$. Como fica a estatística do teste da razão de verossimilhanças para testar $H_0 : \psi = 1$ contra $H_1 : \psi \neq 1$? Qual a distribuição nula assintótica da estatística do teste?

Resolução

$$f(y_i; \psi) = \binom{m}{y_i} \left(\frac{\psi}{1+\psi} \right)^{y_i} \left(\frac{1}{1+\psi} \right)^{m-y_i}, i = 1, \dots, k,$$

Como as variáveis aleatórias são independentes e identicamente distribuídas, a função de verossimilhança é dada por

$$L(\psi; y_1, \dots, y_k) \stackrel{iid}{=} \prod_{i=1}^k \binom{m}{y_i} \left(\frac{\psi}{1+\psi} \right)^{y_i} \left(\frac{1}{1+\psi} \right)^{m-y_i}$$

A log-verossimilhança é então dada por

$$\begin{aligned}
\ell(\psi) &= \log \left[\prod_{i=1}^k \binom{m}{y_i} \left(\frac{\psi}{1+\psi} \right)^{y_i} \left(\frac{1}{1+\psi} \right)^{m-y_i} \right] \\
\ell(\psi) &= \sum_{i=1}^k \left[\log \left(\binom{m}{y_i} \left(\frac{\psi}{1+\psi} \right)^{y_i} \left(\frac{1}{1+\psi} \right)^{m-y_i} \right) \right] \\
\ell(\psi) &= \sum_{i=1}^k \left[\log \binom{m}{y_i} + y_i \log \left(\frac{\psi}{1+\psi} \right) + (m-y_i) \log \left(\frac{1}{1+\psi} \right) \right] \\
\ell(\psi) &= \sum_{i=1}^k \left[\log \binom{m}{y_i} + y_i \log(\psi) - y_i \log(1+\psi) - (m-y_i) \log(1+\psi) \right] \\
\ell(\psi) &= \sum_{i=1}^k \left[\log \binom{m}{y_i} + y_i \log(\psi) - y_i \log(1+\psi) - m \log(1+\psi) + y_i \log(1+\psi) \right] \\
\ell(\psi) &= \sum_{i=1}^k \left[\log \binom{m}{y_i} + y_i \log(\psi) - m \log(1+\psi) \right] \\
&\Rightarrow \boxed{\ell(\psi) = \sum_{i=1}^k \log \binom{m}{y_i} + \log(\psi) \sum_{i=1}^k y_i - mk \log(1+\psi)}.
\end{aligned}$$

Segue então que

$$\frac{d\ell(\psi)}{d\psi} = \frac{1}{\psi} \sum_{i=1}^k y_i - \frac{mk}{1+\psi} \quad \text{e} \quad \frac{d^2\ell(\psi)}{d\psi^2} = -\frac{1}{\psi^2} \sum_{i=1}^k y_i + \frac{mk}{(1+\psi)^2}.$$

Quando $\frac{d\ell(\psi)}{d\psi} = 0$,

$$\begin{aligned}
\frac{1}{\hat{\psi}} \sum_{i=1}^k y_i - \frac{mk}{1+\hat{\psi}} &= 0 \iff \frac{1}{\hat{\psi}} \sum_{i=1}^k y_i = \frac{mk}{1+\hat{\psi}} \iff \frac{1}{\hat{\psi}}(1+\hat{\psi}) = \frac{mk}{\sum_{i=1}^k y_i} \iff \frac{1}{\hat{\psi}} + 1 = \frac{mk}{\sum_{i=1}^k y_i} \\
&\iff \frac{1}{\hat{\psi}} = \frac{mk}{\sum_{i=1}^k y_i} - 1 \iff \frac{1}{\hat{\psi}} = \frac{mk - \sum_{i=1}^k y_i}{\sum_{i=1}^k y_i} \iff \hat{\psi} = \frac{\sum_{i=1}^k y_i}{mk - \sum_{i=1}^k y_i} \\
&\hat{\psi} = \frac{\sum_{i=1}^k y_i}{mk - \sum_{i=1}^k y_i} \times \frac{\frac{1}{k}}{\frac{1}{k}} \\
&\hat{\psi} = \frac{\bar{y}}{m-\bar{y}}, \quad \bar{y} \neq m.
\end{aligned}$$

Em $\hat{\psi} = \frac{\bar{y}}{m-\bar{y}}$,

$$\begin{aligned}
\frac{d^2\ell(\hat{\psi})}{d\psi^2} &= -\frac{1}{(\frac{\bar{y}}{m-\bar{y}})^2} \sum_{i=1}^k y_i + \frac{mk}{(1+\frac{\bar{y}}{m-\bar{y}})^2} \\
\frac{d^2\ell(\hat{\psi})}{d\psi^2} &= -\frac{(m-\bar{y})^2}{\bar{y}^2} k \bar{y} + \frac{mk}{(\frac{m}{m-\bar{y}})^2} \\
\frac{d^2\ell(\hat{\psi})}{d\psi^2} &= -\frac{k(m-\bar{y})^2}{\bar{y}} + \frac{mk(m-\bar{y})^2}{m^2} \\
\frac{d^2\ell(\hat{\psi})}{d\psi^2} &= -\frac{k(m-\bar{y})^2}{\bar{y}} + \frac{k(m-\bar{y})^2}{m} < 0,
\end{aligned}$$

uma vez que $m > \bar{y}$. Logo, $\hat{\psi} = \frac{\bar{y}}{m-\bar{y}}$ maximiza a função de verossimilhança para $\bar{y} \neq m$.

A estatística do teste da razão de verossimilhanças é dada por

$$\xi_{RV} = 2 \left(\ell(\hat{\psi}) - \ell(\psi_0) \right),$$

onde $\psi_0 = 1$ sob a hipótese nula $H_0 : \psi = 1$.

Substituindo $\psi_0 = 1$ na log-verossimilhança:

$$\ell(\psi_0 = 1) = \sum_{i=1}^k \log \binom{m}{y_i} + \log(1) \sum_{i=1}^k y_i - mk \log(1+1) = \boxed{\sum_{i=1}^k \log \binom{m}{y_i} - mk \log(2)}, \quad \log(1) = 0.$$

Para $\hat{\psi}$:

$$\begin{aligned} \ell(\hat{\psi}) &= \sum_{i=1}^k \log \binom{m}{y_i} + \log(\hat{\psi}) \sum_{i=1}^k y_i - mk \log(1 + \hat{\psi}) \\ \ell(\hat{\psi}) &= \sum_{i=1}^k \log \binom{m}{y_i} + \log \left(\frac{\bar{y}}{m-\bar{y}} \right) \sum_{i=1}^k y_i - mk \log \left(1 + \frac{\bar{y}}{m-\bar{y}} \right) \\ \Rightarrow \ell(\hat{\psi}) &= \boxed{\sum_{i=1}^k \log \binom{m}{y_i} + \log \left(\frac{\bar{y}}{m-\bar{y}} \right) \sum_{i=1}^k y_i - mk \log \left(\frac{m}{m-\bar{y}} \right)}. \end{aligned}$$

Logo, a estatística do teste é:

$$\begin{aligned} \xi_{RV} &= 2 \left(\ell(\hat{\psi}) - \ell(\psi_0) \right) \\ \xi_{RV} &= 2 \left[\sum_{i=1}^k \log \binom{m}{y_i} + \log \left(\frac{\bar{y}}{m-\bar{y}} \right) \sum_{i=1}^k y_i - mk \log \left(\frac{m}{m-\bar{y}} \right) - \left(\sum_{i=1}^k \log \binom{m}{y_i} - mk \log(2) \right) \right] \\ \xi_{RV} &= 2 \left[\sum_{i=1}^k \log \binom{m}{y_i} + \log \left(\frac{\bar{y}}{m-\bar{y}} \right) \sum_{i=1}^k y_i - mk \log \left(\frac{m}{m-\bar{y}} \right) - \sum_{i=1}^k \log \binom{m}{y_i} + mk \log(2) \right] \\ \xi_{RV} &= 2 \left[\log \left(\frac{\bar{y}}{m-\bar{y}} \right) \sum_{i=1}^k y_i + mk \left[\log(2) - \log \left(\frac{m}{m-\bar{y}} \right) \right] \right] \\ \xi_{RV} &= 2 \left[k\bar{y} \log \left(\frac{\bar{y}}{m-\bar{y}} \right) + mk \log \left(\frac{2(m-\bar{y})}{m} \right) \right] \\ \xi_{RV} &\xrightarrow[k \rightarrow \infty]{H_0} \chi_{(1)}^2 \end{aligned}$$

Sob a hipótese nula $H_0 : \psi = 1$, quando o tamanho da amostra tende ao infinito ($k \rightarrow \infty$), a estatística do teste da razão de verossimilhanças segue, assintoticamente, uma distribuição qui-quadrado com 1 grau de liberdade ($\chi_{(1)}^2$), pois estamos testando um único parâmetro (ψ).

3. Supor que $Z_i \stackrel{iid}{\sim} ZAP(\mu, \pi)$, para $i = 1, \dots, n$, em que a função de probabilidades de Z_i é dada por

$$f_Z(z_i; \mu, \pi) = \begin{cases} \pi & \text{se } z_i = 0, \\ (1-\pi) \frac{f_Y(z_i; \mu)}{1-f_Y(0; \mu)} & \text{se } z_i = 1, 2, \dots, \end{cases}$$

em que $f_Y(y_i; \mu)$ denota a função de probabilidades de uma $P(\mu)$. Obter a estatística do teste da razão de verossimilhanças para testar $H : \mu = 1$ contra $A : \mu \neq 1$. Qual é a distribuição nula assintótica da estatística do teste?

Resolução

$$f_Z(z_i; \mu, \pi) = \pi I_{\{0\}}(z_i) + (1 - \pi) \frac{f_Y(z_i; \mu)}{1 - f_Y(0; \mu)} I_{\{\mathbb{N}^*\}}(z_i)$$

Como as variáveis aleatórias são independentes e identicamente distribuídas, a função de verossimilhança é dada por

$$L(\mu, \pi; z_1, \dots, z_k) \stackrel{iid}{=} \prod_{i=1}^n \left[\pi I_{\{0\}}(z_i) + (1 - \pi) \frac{f_Y(z_i; \mu)}{1 - f_Y(0; \mu)} I_{\{\mathbb{N}^*\}}(z_i) \right].$$

Suponha que as r primeiras observações são zero

$$\begin{aligned} L(\mu, \pi) &= \prod_{i=1}^r \pi \prod_{i=r+1}^n \left[(1 - \pi) \frac{f_Y(z_i; \mu)}{1 - f_Y(0; \mu)} \right] \\ \ell(\mu, \pi) &= \log \left(\prod_{i=1}^r \pi \right) + \log \left(\prod_{i=r+1}^n \left[(1 - \pi) \frac{f_Y(z_i; \mu)}{1 - f_Y(0; \mu)} \right] \right) \\ \ell(\mu, \pi) &= \log(\pi^r) + \sum_{i=r+1}^n \log \left[(1 - \pi) \frac{f_Y(z_i; \mu)}{1 - f_Y(0; \mu)} \right], \quad \text{observe que, } \sum_{i=r+1}^n = \sum_{i=1}^{n-r} \\ \ell(\mu, \pi) &= r \log(\pi) + \sum_{i=1}^{n-r} (\log(1 - \pi) + \log[f_Y(z_i; \mu)] - \log[1 - f_Y(0; \mu)]) \\ \ell(\mu, \pi) &= r \log(\pi) + \sum_{i=1}^{n-r} \log(1 - \pi) + \sum_{i=1}^{n-r} \log[f_Y(z_i; \mu)] - \sum_{i=1}^{n-r} \log[1 - f_Y(0; \mu)] \end{aligned}$$

Observe que $Y \sim Pois(\mu)$: $f_Y(z_i; \mu) = \frac{\mu^{z_i} e^{-\mu}}{z_i!}$ e se $z_i = 0$ tem-se $f_Y(0; \mu) = e^{-\mu}$

$$\begin{aligned} \ell(\mu, \pi) &= r \log(\pi) + (n - r) \log(1 - \pi) + \sum_{i=1}^{n-r} \log \left(\frac{\mu^{z_i} e^{-\mu}}{z_i!} \right) - \sum_{i=1}^{n-r} \log(1 - e^{-\mu}) \\ \ell(\mu, \pi) &= r \log(\pi) + (n - r) \log(1 - \pi) + \sum_{i=1}^{n-r} [\log(\mu^{z_i}) + \log(e^{-\mu}) - \log(z_i!)] - (n - r) \log(1 - e^{-\mu}) \\ \ell(\mu, \pi) &= r \log(\pi) + (n - r) \log(1 - \pi) + \sum_{i=1}^{n-r} z_i \log(\mu) - \sum_{i=1}^{n-r} \mu - \sum_{i=1}^{n-r} \log(z_i!) - (n - r) \log(1 - e^{-\mu}) \\ \ell(\mu, \pi) &= r \log(\pi) + (n - r) \log(1 - \pi) + \log(\mu) \sum_{i=1}^{n-r} z_i - (n - r) \mu - \sum_{i=1}^{n-r} \log(z_i!) - (n - r) \log(1 - e^{-\mu}) \end{aligned}$$

Note que como $z_i = 0$ para $i = 1, \dots, r$, $\sum_{i=1}^{n-r} z_i = \sum_{i=1}^n z_i$ e $\sum_{i=1}^{n-r} \log(z_i!) = \sum_{i=1}^n \log(z_i!)$.

$$\ell(\mu, \pi) = r \log(\pi) + (n - r) \log(1 - \pi) + n \log(\mu) \bar{z} - (n - r) \mu - \sum_{i=1}^n \log(z_i!) - (n - r) \log(1 - e^{-\mu})$$

$$\frac{d\ell(\mu, \pi)}{d\mu} = \frac{n}{\mu} \bar{z} - (n - 1) - \frac{(n - r)e^{-\mu}}{1 - e^{-\mu}} = \boxed{\frac{1}{\mu} n \bar{z} - (n - r) - \frac{n - r}{e^\mu - 1}}$$

Quando $\frac{d\ell(\mu, \pi)}{d\mu} = 0$,

$\frac{1}{\hat{\mu}} n \bar{z} - (n - r) - \frac{n - r}{e^{\hat{\mu}} - 1} = 0$, não pode ser resolvido analiticamente, portanto utilizamos o método de Newton-Raphson para encontrar numericamente $\hat{\mu}$.

$$\begin{aligned}
\text{Seja } g(\hat{\mu}) &= \frac{n}{\hat{\mu}}\bar{z} - \frac{n-r}{e^{\hat{\mu}}-1} - (n-r) \\
G(\hat{\mu}) &= \frac{dg(\hat{\mu})}{d\hat{\mu}} = -\frac{n}{\hat{\mu}^2}\bar{z} - \frac{(n-r)e^{\hat{\mu}}}{(e^{\hat{\mu}}-1)^2} \\
\hat{\mu}^{(m+1)} &= \hat{\mu}^{(m)} - \frac{g(\hat{\mu}^{(m)})}{G(\hat{\mu}^{(m)})}, \quad m = 0, 1, 2, 3, \dots \\
\hat{\mu}^{(m+1)} &= \hat{\mu}^{(m)} - \frac{g(\hat{\mu}^{(m)})}{G(\hat{\mu}^{(m)})}, \quad m = 0, 1, 2, 3, \dots \\
\hat{\mu}^{(m+1)} &= \hat{\mu}^{(m)} - \frac{\frac{n}{\hat{\mu}^{(m)}}\bar{z} - \frac{(n-r)}{e^{\hat{\mu}^{(m)}}-1} - (n-r)}{-\frac{n}{(\hat{\mu}^{(m)})^2}\bar{z} + \frac{(n-r)e^{\hat{\mu}^{(m)}}}{(e^{\hat{\mu}^{(m)}}-1)^2}}, \quad m = 0, 1, 2, 3, \dots
\end{aligned}$$

O sobrescrito (m) indica que as expressões são avaliadas no valor de μ na iteração m . Repetimos o procedimento até que o seguinte critério de convergência seja satisfeito:

$$\left| \frac{\hat{\mu}^{(m+1)} - \hat{\mu}^{(m)}}{\hat{\mu}^{(m)}} \right| < \epsilon,$$

para algum $\epsilon > 0$ suficientemente pequeno.

É importante destacar que procedimentos iterativos tais como o de Newton Raphson (NR) requerem um chute inicial. Nesse caso, sugerimos utilizar a média amostral como valor inicial para a estimativa de μ , ou seja,

$$\hat{\mu}^{(0)} = \frac{1}{n} \sum_{i=1}^n z_i.$$

Seja $\hat{\mu}$ o estimador de máxima verossimilhança encontrado em ou após $m+1$ iterações, em que se alcança a convergência.

Razão de Verossimilhanças

A estatística do teste de verossimilhança é dada por

$$\xi_{RV} = 2\{\ell(\hat{\mu}, \hat{\pi}) - \ell(\mu^0, \hat{\pi}^0)\}$$

Para acharmos $\hat{\pi}$ e $\hat{\pi}^0$ segue que

$$\begin{aligned}
\ell(\mu, \pi) &= r \log(\pi) + (n-r) \log(1-\pi) + n \log(\mu) \bar{z} - (n-r)\mu - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-\mu}) \\
\frac{d\ell(\mu, \pi)}{d\pi} = 0 &\iff \frac{r}{\hat{\pi}} - \frac{n-r}{1-\hat{\pi}} = 0 \iff \frac{r}{\hat{\pi}} = \frac{n-r}{1-\hat{\pi}} \iff \frac{1-\hat{\pi}}{\hat{\pi}} = \frac{n-r}{r} \iff \frac{1}{\hat{\pi}} - 1 = \frac{n-r}{r} \\
\frac{1}{\hat{\pi}} &= \frac{n-r}{r} + 1 = \frac{n}{r} \\
\Rightarrow \boxed{\hat{\pi} = \frac{r}{n}, \quad n \in \mathbb{N}^*}, \quad \text{observe que } \hat{\pi} \text{ não depende de } \mu, \text{ logo, } \hat{\pi}^0 = \hat{\pi}.
\end{aligned}$$

Segue então que

$$\boxed{\Rightarrow \ell(\hat{\mu}, \hat{\pi}) = r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) + n \log(\hat{\mu}) \bar{z} - (n-r)\hat{\mu} - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-\hat{\mu}}).}$$

Também,

$$\begin{aligned}
\ell(\mu^0, \hat{\pi}^0) &= r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) + n \log(\mu^0) \bar{z} - (n-r)\mu^0 - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-\mu^0}) \\
\ell(\mu^0, \hat{\pi}^0) &= r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) + n \log(1) \bar{z} - (n-r) \cdot 1 - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-1}) \\
\implies \boxed{\ell(\mu^0, \hat{\pi}^0) &= r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) - (n-r) - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-1})} \\
\xi_{RV} &= 2\{\ell(\hat{\mu}, \hat{\pi}) - \ell(\mu^0, \hat{\pi}^0)\} \\
\xi_{RV} &= 2 \left\{ r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) + n \log(\hat{\mu}) \bar{z} - (n-r)\hat{\mu} - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-\hat{\mu}}) \right. \\
&\quad \left. - \left[r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) - (n-r) - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-1}) \right] \right\} \\
\xi_{RV} &= 2 \left\{ r \log(\hat{\pi}) + (n-r) \log(1-\hat{\pi}) + n \log(\hat{\mu}) \bar{z} - (n-r)\hat{\mu} - \sum_{i=1}^n \log(z_i!) - (n-r) \log(1-e^{-\hat{\mu}}) \right. \\
&\quad \left. - r \log(\hat{\pi}) - (n-r) \log(1-\hat{\pi}) + (n-r) + \sum_{i=1}^n \log(z_i!) + (n-r) \log(1-e^{-1}) \right\} \\
\xi_{RV} &= 2 \left\{ n \log(\hat{\mu}) \bar{z} - (n-r)\hat{\mu} - (n-r) \log(1-e^{-\hat{\mu}}) + (n-r) + (n-r) \log(1-e^{-1}) \right\} \\
\implies \xi_{RV} &\xrightarrow[n \rightarrow \infty]{H_0} \chi^2_{(1)},
\end{aligned}$$

ou seja, sob H_0 , quando o número de amostra tende ao infinito ($n \rightarrow \infty$), a estatística do teste da razão de verossimilhanças segue, assintoticamente, uma distribuição qui-quadrado com graus de liberdade (*g.l.*) iguais à diferença no número de parâmetros livres entre os dois modelos comparados. No modelo sob H_0 , temos 1 parâmetro livre (π). Já no modelo sob H_A , temos 2 parâmetros livres (μ e π). Portanto, a diferença no número de parâmetros é $2 - 1 = 1$, resultando em 1 grau de liberdade para a distribuição da estatística do teste.

4. Supor que $Z \sim \text{ZANBI}(\mu, \nu, \pi)$ e $U \sim \text{ZINBI}(\mu, \nu, \pi)$. Mostrar que ambas as distribuições são funções de probabilidade (fp). Obter $\mathbb{E}(Z)$, $\text{Var}(Z)$, $\mathbb{E}(U)$ e $\text{Var}(U)$ deixando essas quantidades em função dos parâmetros (μ, ν, π) .

Resolução

\implies Se $Z \sim \text{ZANBI } (\mu, \nu, \pi)$,

$$f_z(z_i; \mu, \nu, \pi) = \begin{cases} \pi & \text{se } z_i = 0 \\ (1 - \pi) \frac{f_y(z_i; \mu, \nu)}{1 - f_y(0; \mu, \nu)} & \text{se } z_i = 1, 2, \dots, \end{cases}$$

em que $f_y(z_i; \mu, \nu)$ denota a função de probabilidade de uma BN (μ, ν) .

$$f_y(z; \mu, \nu) = \frac{\Gamma(z + \nu)}{\Gamma(\nu)\Gamma(z + 1)} \left(\frac{\mu}{\mu + \nu}\right)^z \left(\frac{\nu}{\mu + \nu}\right)^\nu$$

$$f_y(0; \mu, \nu) = \frac{\Gamma(0 + \nu)}{\Gamma(\nu)\Gamma(1)} \left(\frac{\mu}{\mu + \nu}\right)^0 \left(\frac{\nu}{\mu + \nu}\right)^\nu = \left(\frac{\nu}{\mu + \nu}\right)^\nu, \quad \Gamma(n) = (n - 1)!, \quad 0! = 1$$

$$\implies \text{Para ser fp devem satisfazer: 1)} f_z(z_i; \mu, \nu, \pi) \geq 0 \text{ e 2)} \sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = 1$$

\implies Condição 1)

$$\sum_{-\infty}^{+\infty} f_y(z_i; \mu, \nu) = f_y(0; \mu, \nu) + \sum_{i=1}^{+\infty} f_y(z_i; \mu, \nu) = 1 \implies 0 \leq f_y(0; \mu, \nu) \leq 1 \text{ e } 0 \leq 1 - f_y(0; \mu, \nu) \leq 1$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = f_z(0; \mu, \nu, \pi) + \sum_{i=1}^{+\infty} f_z(z_i; \mu, \nu, \pi) = \pi + \sum_{i=1}^{+\infty} f_z(z_i; \mu, \nu, \pi) = 1$$

$$\sum_{i=1}^{+\infty} f_z(z_i; \mu, \nu, \pi) = 1 - \pi \iff [0 \leq 1 - \pi \leq 1]$$

$$[f_y(z_i; \mu, \nu) \geq 0], \text{ porque é fp}$$

Pelas desigualdades apresentadas acima, se nota que:

$$0 \leq (1 - \pi) \frac{f_y(z_i; \mu, \nu)}{1 - f_y(0; \mu, \nu)} \leq 1, \text{ e como consequência } [f_z(z_i; \mu, \nu, \pi) \geq 0]$$

\implies Condição 2)

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = 1$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = f_z(0; \mu, \nu, \pi) + \sum_{z_i=1}^{+\infty} f_z(z_i; \mu, \nu, \pi)$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = \pi + \frac{(1 - \pi)}{1 - f_y(0; \mu, \nu)} \sum_{z_i=1}^{+\infty} f_y(z_i; \mu, \nu)$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = \pi + \frac{(1 - \pi)}{1 - f_y(0; \mu, \nu)} (1 - f_y(0; \mu, \nu)), \text{ porque } \sum_{z_i=0}^{+\infty} f_y(z_i; \mu, \nu) = f_y(0; \mu, \nu) + \sum_{z_i=1}^{+\infty} f_y(z_i; \mu, \nu) = 1$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = \pi + 1 - \pi$$

$$\sum_{-\infty}^{+\infty} f_z(z_i; \mu, \nu, \pi) = 1$$

Logo, como as duas condições foram satisfeitas,

$$f_z(z_i; \mu, \nu, \pi) = \begin{cases} \pi & \text{se } z_i = 0 \\ (1 - \pi) \frac{\frac{\Gamma(z + \nu)}{\Gamma(\nu)\Gamma(z + 1)} \left(\frac{\mu}{\mu + \nu}\right)^z \left(\frac{\nu}{\mu + \nu}\right)^\nu}{1 - \left(\frac{\nu}{\mu + \nu}\right)^\nu} & \text{se } z_i = 1, 2, \dots, \end{cases}$$

é fp.

\implies Esperança de Z

$$\begin{aligned}
\mathbb{E}(Z) &= \sum_{z_i=0}^{+\infty} z f_z(z_i; \mu, \nu, \pi) = \sum_{z_i=0}^{+\infty} z f_z(z_i; \mu, \nu, \pi) = 0 \cdot f_z(0; \mu, \nu, \pi) + \sum_{z_i=1}^{+\infty} z f_z(z_i; \mu, \nu, \pi) \\
\mathbb{E}(Z) &= \sum_{z_i=1}^{+\infty} z f_z(z_i; \mu, \nu, \pi) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} \sum_{z_i=1}^{+\infty} z f_y(z_i; \mu, \nu) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} [\mathbb{E}(Y) - 0 \cdot f_y(0; \mu, \nu)], \quad (**)
\end{aligned}$$

$$\mathbb{E}(Z) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} \mathbb{E}(Y)$$

$$f_y(z; \mu, \nu) = \frac{\Gamma(z+\nu)}{\Gamma(\nu)\Gamma(z+1)} \left(\frac{\mu}{\mu+\nu}\right)^z \left(\frac{\nu}{\mu+\nu}\right)^\nu, \quad Y \sim BN(\mu, \nu)$$

$$f_y(z; \mu, \nu) = \exp \left\{ z \log \left(\frac{\mu}{\mu+\nu} \right) + \log \left(\frac{\nu}{\mu+\nu} \right)^\nu + \log \left(\frac{\Gamma(z+\nu)}{\Gamma(\nu)\Gamma(z+1)} \right) \right\}, \text{F.E de } \phi = 1$$

$$\begin{cases} b(\theta) = -\log \left(\frac{\nu}{\mu+\nu} \right)^\nu \\ \theta = \log \left(\frac{\mu}{\mu+\nu} \right) \end{cases} \iff \begin{cases} b(\theta) = \log \left(\frac{\mu+\nu}{\nu} \right)^\nu \\ e^\theta = \frac{\mu}{\mu+\nu} \end{cases} \iff \begin{cases} b(\theta) = \nu \log \left(1 + \frac{\mu}{\nu} \right) \\ \frac{1}{e^\theta} = 1 + \frac{\nu}{\mu} \end{cases} \iff \dots \begin{cases} b(\theta) = \nu \log \left(1 + \frac{\mu}{\nu} \right) \\ \frac{e^\theta}{1-e^\theta} = 1 + \frac{\nu}{\mu} \end{cases} = \frac{\mu}{\nu}$$

$$b(\theta) = \nu \log \left(1 + \frac{e^\theta}{1-e^\theta} \right) = \nu \log \left(\frac{1}{1-e^\theta} \right) = -\nu \log (1-e^\theta)$$

$$\mathbb{E}(Y) = \frac{db(\theta)}{d(\theta)} = \frac{\nu e^\theta}{1-e^\theta} = \nu \frac{\mu}{\nu} = \mu \quad (1)$$

$$\mathbb{E}(Z) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} \mathbb{E}(Y) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} \mu = \frac{(1-\pi)\mu}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu}$$

$$\implies \text{Variância de Z : } Var(Z) = \mathbb{E}(Z^2) - \mathbb{E}^2(Z)$$

$$\mathbb{E}(Z^2) = \sum_{z_i=0}^{+\infty} z^2 f_z(z_i; \mu, \nu, \pi) = \dots = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} \mathbb{E}(Y^2) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} (Var(Y) + \mathbb{E}^2(Y)) \text{ vide E(Z)} \quad (**)$$

$$Var(Y) = \phi^{-1} \frac{d^2 b(\theta)}{d(\theta^2)} = 1 \cdot \nu \frac{e^\theta(1-e^\theta) + e^\theta \cdot e^\theta}{(1-e^\theta)^2} = \frac{\nu e^\theta}{(1-e^\theta)^2} = \frac{\nu \mu}{\nu(1-e^\theta)} = \frac{\mu}{(1-\frac{\mu}{\mu+\nu})} = \frac{\mu(\mu+\nu)}{\nu} \quad (2)$$

$$\mathbb{E}(Z^2) = \frac{(1-\pi)}{1-f_y(0; \mu, \nu)} (Var(Y) + \mathbb{E}^2(Y))$$

$$\mathbb{E}(Z^2) = \frac{(1-\pi)}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \left[\frac{\mu(\mu+\nu)}{\nu} + \mu^2 \right], \quad \mathbb{E}(Y^2) = \frac{\mu(\mu+\nu)}{\nu} + \mu^2 \quad (3)$$

$$Var(Z) = \mathbb{E}(Z^2) - \mathbb{E}^2(Z)$$

$$Var(Z) = \frac{(1-\pi)}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \left[\frac{\mu(\mu+\nu)}{\nu} + \mu^2 \right] - \left[\frac{(1-\pi)\mu}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \right]^2$$

$$Var(Z) = \frac{(1-\pi)}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \left[\frac{\mu(\mu+\nu)}{\nu} + \mu^2 - \frac{(1-\pi)\mu^2}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \right]$$

$$Var(Z) = \frac{(1-\pi)}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \left[\frac{\mu^2}{\nu} + \mu + \mu^2 - \frac{(1-\pi)\mu^2}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \right]$$

$$Var(Z) = \frac{(1-\pi)\mu}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} + \frac{(1-\pi)\mu^2}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \left[1 + \frac{1}{\nu} - \frac{(1-\pi)}{1-\left(\frac{\nu}{\mu+\nu}\right)^\nu} \right]$$

\implies Se $U \sim \text{ZINBI } (\mu, \nu, \pi)$

$$f_u(u_i; \mu, \nu, \pi) = \begin{cases} \pi + (1 - \pi)P(y = 0) & \text{se } u_i = 0 \\ (1 - \pi)f_y(u_i; \mu, \nu) & \text{se } u_i = 1, 2, \dots, \end{cases}$$

em que $f_y(u_i; \mu, \nu)$ denota a função de probabilidade de uma BN (μ, ν) .

\implies Condição 1) $f_u(u_i; \mu, \nu, \pi) \geq 0$

$$f_y(u; \mu, \nu) = \frac{\Gamma(u + \nu)}{\Gamma(\nu)\Gamma(u + 1)} \left(\frac{\mu}{\mu + \nu} \right)^u \left(\frac{\nu}{\mu + \nu} \right)^\nu$$

$$P(y = 0) = f_y(0; \mu, \nu) = \left(\frac{\nu}{\mu + \nu} \right)^\nu$$

$$\sum_{i=1}^{+\infty} f_y(u_i; \mu, \nu) = 1 - f_y(0; \mu, \nu) \text{ e } 0 \leq f_y(0; \mu, \nu) \leq 1$$

Se $f_y(0; \mu, \nu) = 0$, observa-se que $f_y(u_i; \mu, \nu) = 1$ e $f_u(u_i; \mu, \nu, \pi) = 1$

Se $f_y(0; \mu, \nu) = 1$, observa-se que $f_y(u_i; \mu, \nu) = 0$ e $f_u(u_i; \mu, \nu, \pi) = 1$

Se $0 < f_y(0; \mu, \nu) < 1$, observa-se que $0 < f_y(u_i; \mu, \nu) < 1$ e $0 \leq f_u(u_i; \mu, \nu, \pi) \leq 1$

Logo, $f_u(u_i; \mu, \nu, \pi) \geq 0$

$$\implies \text{Condição 2)} : \sum_{i=0}^{+\infty} f_y(u_i; \mu, \nu, \pi) = 1$$

$$\sum_{i=0}^{+\infty} f_y(u_i; \mu, \nu, \pi) = f_y(0; \mu, \nu, \pi) + \sum_{i=1}^{+\infty} f_y(u_i; \mu, \nu, \pi) = \pi + (1 - \pi)P(y = 0) + \sum_{i=1}^{+\infty} f_y(u_i; \mu, \nu, \pi)$$

$$\sum_{i=0}^{+\infty} f_y(u_i; \mu, \nu, \pi) = \pi + (1 - \pi)P(y = 0) + (1 - \pi) \sum_{i=1}^{+\infty} f_y(u_i; \mu, \nu)$$

$$\sum_{i=0}^{+\infty} f_y(u_i; \mu, \nu, \pi) = \pi + (1 - \pi)P(y = 0) + (1 - \pi)[1 - f_y(0; \mu, \nu)] = \pi + (1 - \pi)[P(y = 0) + 1 - P(y = 0)]$$

$$\sum_{i=0}^{+\infty} f_y(u_i; \mu, \nu, \pi) = \pi + 1 - \pi = 1, \quad \text{lembrando que: } f_y(0; \mu, \nu) = P(y = 0)$$

Como satisfez as duas condições, $f_u(u_i; \mu, \nu, \pi)$ é uma fp.

\implies Esperança de U

$$\mathbb{E}(U) = \sum_{u_i=0}^{+\infty} u f_u(u_i; \mu, \nu, \pi) = \sum_{u_i=0}^{+\infty} u f_u(u_i; \mu, \nu, \pi) = 0 \cdot f_u(0; \mu, \nu, \pi) + \sum_{u_i=1}^{+\infty} u f_u(u_i; \mu, \nu, \pi)$$

$$\mathbb{E}(U) = (1 - \pi) \sum_{u_i=1}^{+\infty} u f_u(u_i; \mu, \nu, \pi) = (1 - \pi)[E(Y) - 0 \cdot f_u(0; \mu, \nu, \pi)] = (1 - \pi)E(Y)$$

$$\text{vide (1) e lembre-se que, } E(Y) = \sum_{y=0}^{+\infty} y f_y(0; \mu, \nu) = 0 \cdot f_y(0; \mu, \nu) + \sum_{y=1}^{+\infty} y f_y(0; \mu, \nu)$$

$$\mathbb{E}(U) = (1 - \pi)\mu$$

\implies Variância de U: $Var(U) = \mathbb{E}(U^2) - \mathbb{E}^2(U)$

$$\begin{aligned}\mathbb{E}(U^2) &= \sum_{u_i=0}^{+\infty} u^2 f_u(u_i; \mu, \nu, \pi) = 0 \cdot f_u(0; \mu, \nu, \pi) + \sum_{u_i=1}^{+\infty} u^2 f_u(u_i; \mu, \nu, \pi) = \sum_{u_i=1}^{+\infty} u^2 (1-\pi) f_y(u_i; \mu, \nu) \\ \mathbb{E}(U^2) &= (1-\pi) \sum_{u_i=1}^{+\infty} u^2 f_y(u_i; \mu, \nu) = (1-\pi) [\mathbb{E}(Y^2) - 0 \cdot f_y(0; \mu, \nu)] = (1-\pi) \underbrace{\mathbb{E}(Y^2)}_{\text{vide (3)}} = (1-\pi) \left[\frac{\mu(\mu+\nu)}{\nu} + \mu^2 \right] \\ Var(U) &= \mathbb{E}(U^2) - \mathbb{E}^2(U) \\ Var(U) &= (1-\pi) \left[\frac{\mu(\mu+\nu)}{\nu} + \mu^2 \right] - [(1-\pi)\mu]^2 \\ Var(U) &= (1-\pi) \left[\frac{\mu^2}{\nu} + \mu + \mu^2 \right] - [(1-\pi)\mu]^2 \\ Var(U) &= (1-\pi)\mu + (1-\pi)\mu^2 \left[\frac{1}{\nu} + \pi \right]\end{aligned}$$

5. A função de probabilidade da Poisson truncada em zero é expressa na forma

$$f(y; \lambda) = \frac{e^{-\lambda} \lambda^y}{y!(1-e^{-\lambda})}, \quad y = 1, 2, \dots, \quad \lambda > 0$$

Obter $E(Y)$ e $Var(Y)$. Para uma amostra de tamanho n , desenvolver um processo iterativo para obter a estimativa de máxima verossimilhança $\hat{\lambda}$. Obter também a variância assintótica $Var(\hat{\lambda})$.

Resolução

$$f(y; \lambda) = \frac{e^{-\lambda} \lambda^y}{y!(1-e^{-\lambda})} = \frac{e^{-\lambda} e^{\log(\lambda^y)}}{e^{\log[y!(1-e^{-\lambda})]}} = \exp \left\{ -\lambda + \log(\lambda^y) - \log[y!(1-e^{-\lambda})] \right\}$$

$$f(y; \lambda) = \exp \left\{ y \log(\lambda) - \left[\lambda + \log(1-e^{-\lambda}) \right] + [-\log(y!)] \right\}$$

$$f(y; \lambda) \text{ pertence à família exponencial de } \begin{cases} \phi & = 1 \\ \theta & = \log(\lambda) \\ y_i & = y \\ b(\theta) & = \lambda + \log(1-e^{-\lambda}) \\ c(y, \phi) & = -\log(y!) \end{cases}$$

$$\lambda = e^\theta, \quad b(\theta) = e^\theta + \log(1-e^{-e^\theta})$$

$$\mathbb{E}(Y) = \mu = \frac{db(\theta)}{d\theta} = e^\theta + \frac{e^{-e^\theta} \cdot e^\theta}{1-e^{-e^\theta}} = \lambda + \frac{e^{-\lambda} \cdot \lambda}{1-e^{-\lambda}} = \frac{\lambda - \lambda e^{-\lambda} + \lambda e^{-\lambda}}{1-e^{-\lambda}} = \frac{\lambda}{1-e^{-\lambda}} = \frac{\lambda e^\lambda}{e^\lambda - 1}$$

$$Var(Y) = \phi^{-1} V(\mu) = (1)^{-1} \frac{d^2 b(\theta)}{d\theta^2} = \frac{d}{d\theta} \left(\frac{e^\theta}{1-e^{-e^\theta}} \right) = \frac{e^\theta (1-e^{-e^\theta}) - (-e^{-e^\theta}(-e^\theta)e^\theta)}{(1-e^{-e^\theta})^2}$$

$$Var(Y) = \frac{e^\theta(1 - e^{-e^\theta}) - (-e^{-e^\theta}(-e^\theta)e^\theta)}{(1 - e^{-e^\theta})^2} = \frac{e^\theta(1 - e^{-e^\theta}) - e^{-e^\theta}e^\theta e^\theta}{(1 - e^{-e^\theta})^2} = \frac{\lambda(1 - e^{-\lambda}) - e^{-\lambda}\lambda \cdot \lambda}{(1 - e^{-\lambda})^2}$$

$$Var(Y) = \frac{\lambda}{1 - e^{-\lambda}} \left(\frac{1 - e^{-\lambda}}{1 - e^{-\lambda}} - \frac{e^{-\lambda}\lambda}{1 - e^{-\lambda}} \right) = \mu(1 - \mu e^{-\lambda})$$

$$\mu = \frac{\lambda}{1 - e^{-\lambda}}$$

$$1 - e^{-\lambda} = \frac{\lambda}{\mu}$$

$$1 - \frac{\lambda}{\mu} = e^{-\lambda} \iff \mu - \lambda = \mu e^{-\lambda}$$

$Var(Y) = \mu [1 - (\mu - \lambda)] = \mu(1 - \mu + \lambda)$, podendo ser escrita também como:

$$Var(Y) = \frac{\lambda}{1 - e^{-\lambda}} \left(1 - \frac{e^{-\lambda}\lambda}{1 - e^{-\lambda}} \right)$$

⇒ Estimativa de máxima verossimilhança

$$f(y; \lambda) = \frac{e^{-\lambda}\lambda^y}{y!(1 - e^{-\lambda})}$$

$$f(\lambda; y) \stackrel{iid}{=} \prod_{i=1}^n \frac{e^{-\lambda}\lambda^{y_i}}{y_i!(1 - e^{-\lambda})} = e^{-n\lambda} \cdot \left(\frac{1}{1 - e^{-\lambda}} \right)^n \lambda^{\sum_{i=1}^n y_i} \prod_{i=1}^n \frac{1}{y_i!}$$

$$\ell(\lambda) = -n\lambda - n \log(1 - e^{-\lambda}) + \log(\lambda) \sum_{i=1}^n y_i - \sum_{i=1}^n \log(y_i!)$$

$$\frac{d\ell(\lambda)}{d\lambda} = -n - \frac{ne^{-\lambda}}{1 - e^{-\lambda}} + \frac{1}{\lambda} \sum_{i=1}^n y_i$$

$$\frac{d\ell(\lambda)}{d\lambda} = 0$$

$$-n - \frac{ne^{-\hat{\lambda}}}{1 - e^{-\hat{\lambda}}} + \frac{1}{\hat{\lambda}} \sum_{i=1}^n y_i = 0$$

$$-n - \frac{ne^{-\hat{\lambda}}}{1 - e^{-\hat{\lambda}}} + \frac{n}{\hat{\lambda}} \bar{y} = 0$$

$$-n - \frac{n}{e^{\hat{\lambda}} - 1} + \frac{n}{\hat{\lambda}} \bar{y} = 0$$

$$g(\lambda) = -n - \frac{n}{e^\lambda - 1} + \frac{n}{\lambda} \bar{y}$$

$$G(\lambda) = \frac{dg(\lambda)}{d\lambda} = \frac{n e^\lambda}{(e^\lambda - 1)^2} - \frac{n}{\lambda^2} \bar{y}$$

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{g[\lambda^{(m)}]}{G[\lambda^{(m)}]}, \quad m = 0, 1, 2, \dots$$

$$\lambda^{(m+1)} = \lambda^{(m)} - \frac{-n - \frac{n}{e^{\lambda^{(m)}} - 1} + \frac{n\bar{y}}{\lambda^{(m)}}}{\frac{ne^{\lambda^{(m)}}}{[e^{\lambda^{(m)}} - 1]^2} - \frac{n\bar{y}}{[\lambda^{(m)}]^2}}$$

O sobrescrito (m) indica que as expressões são avaliadas no valor de λ na iteração m . Repetimos o procedimento até que o seguinte critério de convergência seja satisfeito:

$$\left| \frac{\lambda^{(m+1)} - \lambda^{(m)}}{\lambda^{(m)}} \right| < \epsilon,$$

para algum $\epsilon > 0$ suficientemente pequeno.

\implies Estimador de máxima verossimilhança ($\hat{\lambda}$) de λ

Seja, \bar{y} , a média amostral da Poisson não truncada, o chute inicial ($\lambda^{(0)} = \bar{y}$). O estimador de máxima verossimilhança $\hat{\lambda}$ será aquele encontrado em ou após $m+1$ iterações, nas quais se alcança a convergência.

\implies Variância assintótica

$$\begin{aligned}
Var(\hat{\lambda}) &= \frac{1}{K_{\lambda\lambda}} \\
K_{\lambda\lambda} &= -\mathbb{E} \left\{ \frac{d^2 L(\lambda)}{d\lambda^2} \right\} = Var \left(U_\lambda = \frac{dL(\lambda)}{d\lambda} \right) \\
U_\lambda &= \frac{dL(\lambda)}{d\lambda} - n - \frac{ne^{-\lambda}}{1-e^{-\lambda}} + \frac{1}{\lambda} \sum_{i=1}^n y_i \\
K_{\lambda\lambda} &= Var(U_\lambda) = Var \left(-n - \frac{ne^{-\lambda}}{1-e^{-\lambda}} + \frac{1}{\lambda} \sum_{i=1}^n y_i \right) \\
K_{\lambda\lambda} &= \frac{1}{\lambda^2} \sum_{i=1}^n Var(y) = \frac{1}{\lambda^2} \sum_{i=1}^n \frac{\lambda}{1-e^{-\lambda}} \left(1 - \frac{e^{-\lambda}\lambda}{1-e^{-\lambda}} \right) \\
K_{\lambda\lambda} &= \frac{1}{\lambda^2} \frac{n\lambda e^\lambda}{e^\lambda - 1} \left(1 - \frac{\lambda}{e^\lambda - 1} \right) \\
K_{\lambda\lambda} &= \frac{ne^\lambda}{\lambda(e^\lambda - 1)} - \frac{ne^\lambda}{(e^\lambda - 1)^2} \\
K_{\lambda\lambda} &= \frac{ne^\lambda(e^\lambda - 1) - n\lambda e^\lambda}{\lambda(e^\lambda - 1)^2} \\
K_{\lambda\lambda} &= \frac{n(e^{2\lambda} - e^\lambda - \lambda e^\lambda)}{\lambda(e^\lambda - 1)^2} \\
Var(\hat{\lambda}) &= \frac{1}{K_{\lambda\lambda}} \\
Var(\hat{\lambda}) &= \frac{1}{\frac{n(e^{2\hat{\lambda}} - e^{\hat{\lambda}} - \hat{\lambda} e^{\hat{\lambda}})}{\hat{\lambda}(e^{\hat{\lambda}} - 1)^2}} \\
Var(\hat{\lambda}) &= \frac{\hat{\lambda}(e^{\hat{\lambda}} - 1)^2}{n(e^{2\hat{\lambda}} - e^{\hat{\lambda}} - \hat{\lambda} e^{\hat{\lambda}})},
\end{aligned}$$

em que $\hat{\lambda}$ é o estimador de máxima verossimilhança encontrado em ou após $m+1$ iterações, nas quais se alcança a convergência.

- Supor $Y_{ij} \stackrel{iid}{\sim} Ge(\mu_i)$ (distribuição geométrica), em que $\mu_i = \mathbb{E}(Y_i)$ e $Var(Y_i) = V(\mu_i) = \mu_i(\mu_i - 1)$, $i = 1, 2$, e $j = 1, \dots, m$, com $\log(\mu_1) = \eta_1 = \alpha$ e $\log(\mu_2) = \eta_2 = \alpha + \Delta$. Como ficam as matrizes \mathbf{X} e \mathbf{W} ? Obter as variâncias assintóticas $Var(\hat{\alpha})$ e $Var(\hat{\Delta})$ além da covariância assintótica $Cov(\hat{\alpha}, \hat{\Delta})$, deixando as expressões em função dos pesos \mathbf{W} . Mostre que a estatística do teste de escore para testar $H_0 : \Delta = 0$ contra $H_1 : \Delta \neq 0$ fica expressa na forma

$$\xi_{SR} = \frac{m(\bar{y}_2 - \bar{y}_1)^2}{2\bar{y}(\bar{y} - 1)}.$$

Qual a distribuição nula assintótica da estatística do teste?

Resolução

(i) Matrizes X e W:

Uma vez que $\eta = X\beta$, e

$$\eta = \begin{bmatrix} \eta_1 \\ \vdots \\ \eta_1 \\ \eta_2 \\ \vdots \\ \eta_2 \end{bmatrix}_{2m \times 1} = \begin{bmatrix} \alpha \\ \vdots \\ \alpha \\ \alpha + \Delta \\ \vdots \\ \alpha + \Delta \end{bmatrix}_{2m \times 1} \quad \text{e} \quad \beta = \begin{bmatrix} \alpha \\ \Delta \end{bmatrix}_{2 \times 1},$$

segue que

$$X = \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}_{2m \times 2}.$$

Como $\omega_i = \frac{(d\mu_i/d\eta_i)^2}{V(\mu_i)}$,

Para $i = 1$:

$d\mu_1/d\eta_1 = e^{\eta_1} = e^\alpha$, $V(\mu_1) = e^\alpha(e^\alpha - 1)$ e $\omega_1 = \frac{e^\alpha}{(e^\alpha - 1)}$.

Para $i = 2$:

$d\mu_2/d\eta_2 = e^{\eta_2} = e^{\alpha+\Delta}$, $V(\mu_2) = e^{\alpha+\Delta}(e^{\alpha+\Delta} - 1)$ e $\omega_2 = \frac{e^{\alpha+\Delta}}{(e^{\alpha+\Delta} - 1)}$.

Logo, segue que

$W = \text{diag}\{\omega_1, \dots, \omega_1, \omega_2, \dots, \omega_2\}$, e $V = \text{diag}\{V(\mu_1), \dots, V(\mu_1), V(\mu_2), \dots, V(\mu_2)\}$.

(ii) Variâncias Assintóticas:

Vale que a variância assintótica do vetor $\hat{\beta}$ é dada por

$$\text{Var}(\hat{\beta}) = \begin{bmatrix} \text{Var}(\hat{\beta}) & \text{Cov}(\hat{\beta}, \hat{\Delta}) \\ \text{Cov}(\hat{\beta}, \hat{\Delta}) & \text{Var}(\hat{\Delta}) \end{bmatrix} = \phi^{-1}(X^\top W X)^{-1}$$

Segue que

$$\phi = 1 \Rightarrow \phi^{-1} = 1$$

$$X^\top W = \begin{bmatrix} 1 & \cdots & 1 & 1 & \cdots & 1 \\ 0 & \cdots & 0 & 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \omega_1 & 0 & 0 & 0 & 0 & 0 \\ 0 & \cdots & 0 & 0 & 0 & 0 \\ 0 & 0 & \omega_1 & 0 & 0 & 0 \\ 0 & 0 & 0 & \omega_2 & 0 & 0 \\ 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & 0 & 0 & 0 & \omega_2 \end{bmatrix} = \begin{bmatrix} \omega_1 & \cdots & \omega_1 & \omega_2 & \cdots & \omega_2 \\ 0 & \cdots & 0 & \omega_2 & \cdots & \omega_2 \end{bmatrix}$$

$$X^\top W X = \begin{bmatrix} \omega_1 & \cdots & \omega_1 & \omega_2 & \cdots & \omega_2 \\ 0 & \cdots & 0 & \omega_2 & \cdots & \omega_2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 1 & 1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} m(\omega_1 + \omega_2) & m\omega_2 \\ m\omega_2 & m(\omega_1 + \omega_2) \end{bmatrix}$$

$$(X^\top W X)^{-1} = \frac{1}{m^2(\omega_1 + \omega_2)\omega_2 - m^2\omega_2^2} \begin{bmatrix} m\omega_2 & -m\omega_2 \\ -m\omega_2 & m(\omega_1 + \omega_2) \end{bmatrix}$$

$$(X^\top W X)^{-1} = \frac{1}{m^2\omega_1\omega_2} \begin{bmatrix} m\omega_2 & -m\omega_2 \\ -m\omega_2 & m(\omega_1 + \omega_2) \end{bmatrix}.$$

Logo, segue que

$$Var(\hat{\beta}) = \frac{1}{m\omega_1}, Var(\hat{\Delta}) = \frac{\omega_1 + \omega_2}{m\omega_1\omega_2}, \text{ e } Cov(\hat{\beta}, \hat{\Delta}) = -\frac{1}{m\omega_1}.$$

(iii) Estatística do teste de escore:

Sob as hipóteses $H_0 : \Delta = 0$ contra $H_1 : \Delta \neq 0$, a estatística do teste de escore é

$$\xi_{SR} = [U_\Delta^0]^2 \hat{Var}_0(\hat{\Delta}).$$

Segue que

$$\Delta = 0 \Rightarrow \omega_2 = \omega_1 \Rightarrow \hat{Var}_0(\hat{\Delta}) = 2\omega_1/m\omega_1^2 = 2/m\omega_1$$

Ainda

$$U_\Delta = \phi X_2^\top W^{1/2} V^{-1/2} (y - \mu) = X_2^\top W^{1/2} V^{-1/2} (y - \mu)$$

$$X_2^\top = [0 \ \cdots \ 0 \ 1 \ \cdots \ 1]$$

$$X_2^\top W^{1/2} = [0 \ \cdots \ 0 \ \sqrt{\omega_2} \ \cdots \ \sqrt{\omega_2}]$$

$$X_2^\top W^{1/2} V^{-1/2} = [0 \ \cdots \ 0 \ \sqrt{\omega_2/V(\mu_2)} \ \cdots \ \sqrt{\omega_2/V(\mu_2)}]$$

$$X_2^\top W^{1/2} V^{-1/2} (y - \mu) = \sum_{i=m+1}^{2m} y_i \sqrt{\omega_2/V(\mu_2)} - \sum_{i=m+1}^{2m} \mu_2 \sqrt{\omega_2/V(\mu_2)}$$

$$X_2^\top W^{1/2} V^{-1/2} (y - \mu) = m\bar{y}_2 \sqrt{\omega_2/V(\mu_2)} - m\mu_2 \sqrt{\omega_2/V(\mu_2)}.$$

$$X_2^\top W^{1/2} V^{-1/2} (y - \mu) = \frac{m\bar{y}_2}{\mu_2 - 1} - \frac{m\mu_2}{\mu_2 - 1}.$$

Sob H_0 ,

$$\mu_1 = \mu_2 \Rightarrow \hat{\mu}_0 = \bar{y}.$$

Portanto,

$$\xi_{SR} = \left[\frac{m}{\bar{y} - 1} (\bar{y}_2 - \bar{y}) \right]^2 \frac{2(\bar{y} - 1)}{m\bar{y}}$$

$$\xi_{SR} = \frac{2m(\bar{y}_2 - \bar{y})^2}{(\bar{y} - 1)\bar{y}}.$$

Como $\bar{y} = \frac{\bar{y}_1 + \bar{y}_2}{2}$,

$$\xi_{SR} = \frac{2m(\bar{y}_2/2 - \bar{y}_1/2)^2}{(\bar{y} - 1)\bar{y}}$$

$$\xi_{SR} = \frac{m(\bar{y}_2 - \bar{y}_1)^2}{2\bar{y}(\bar{y} - 1)}$$

$$\xi_{SR} \underset{m \rightarrow \infty}{\stackrel{H_0}{\sim}} \chi^2_{(1)}$$

Sob a hipótese nula $H_0 : \Delta = 0$, quando o tamanho da amostra tende ao infinito ($m \rightarrow \infty$), a estatística do teste da razão de verossimilhanças segue, assintoticamente, uma distribuição qui-quadrado com 1 grau de liberdade ($\chi^2_{(1)}$), pois estamos testando um único parâmetro (Δ).