

# UNIVERSIDADE DE SÃO PAULO

## Gabarito: MAE0261 – Introdução à Análise de dados

Alex Monito Nhancololo

### Critérios usados na correção

A correção da lista baseou-se nos seguintes aspectos: resolução correta dos exercícios e interpretação prática e não técnica dos resultados; organização, limpeza e boa estrutura; justificativas apresentadas sempre que necessárias; símbolos matemáticos e estatísticos escritos adequadamente; uso de régua em trabalhos feitos manualmente, em vez de simples traços à mão livre; presença obrigatória de legenda em todas as tabelas e gráficos; além de clareza e coerência na escrita, com linguagem objetiva e sem ambiguidades.

## 1 Introdução ao R e RStudio (mini tutorial)

**Nota:** Abra este documento em um computador e, onde aparecer **Clica aqui**, aproxime o cursor e clique: será aberto um vídeo.

### 1 O que é R?

R é uma linguagem de programação e um ambiente de software livre usado para analisar dados, criar gráficos e aplicar métodos estatísticos. Foi criado por Ross Ihaka e Robert Gentleman na Universidade de Auckland, Nova Zelândia, em 1993, inspirado na linguagem S. Hoje, é muito utilizado por estatísticos, cientistas de dados e pesquisadores em várias áreas, contando com uma grande comunidade que desenvolve pacotes e amplia suas funcionalidades.

### 1 O que é RStudio?

RStudio é um programa que facilita o uso do R. Ele oferece uma interface gráfica amigável, onde o usuário pode escrever e executar códigos, visualizar gráficos, organizar arquivos e acompanhar os objetos criados durante a análise. É um Ambiente de Desenvolvimento Integrado (IDE), ou seja, um espaço que reúne várias ferramentas para programar de forma mais prática e organizada. O RStudio foi desenvolvido pela empresa RStudio, PBC (atualmente Posit Software, PBC), fundada por Joseph J. Allaire, e teve sua primeira versão lançada em 2011.

Assista ao vídeo: **Clica aqui para ver o vídeo**. Para mais informações sobre R, você pode ler **Clica aqui** se quiser saber mais sobre R.

### 2 Instalação

Para usar o RStudio, você deve primeiro instalar o R.

#### 2 Passo 1: Instalar o R

1. Acesse o site oficial do R: **Clica aqui** e assista ao vídeo colocado no final destas instruções.
2. Escolha o link de download para o seu sistema operacional (Linux, MacOS ou Windows) (veja a Figura 1, onde selecione Windows porque é meu sistema operacional. Se não conhece o seu sistema operacional, veja o vídeo: **Clica aqui**. Se em algum lugar aparecer **Windows**, então você usa **Windows**).
3. Clique em "base"(ou na versão mais recente recomendada) para baixar o instalador principal.
4. Execute o arquivo baixado e siga as instruções, mantendo as configurações padrão.

Assista ao vídeo 1 da Fernanda Peres: **Clica aqui para ver o vídeo**.

The screenshot shows the CRAN R download page. On the left, there's a sidebar with links like 'About R', 'R Home Page', 'Search', and 'CRAN Team'. The main content area has a heading 'Download and Install R' and a sub-section 'Precompiled binary distributions of the base system and contributed packages'. It lists 'Windows and Mac users most likely want one of these versions of R:' with links to 'Download R for Linux (Debian, Fedora/Redhat, Ubuntu)', 'Download R for macOS', and 'Download R for Windows' (which is highlighted with a red arrow). Below this, there's a note about Linux distributions and a section for 'Source Code for all Platforms' with instructions for Windows and Mac users. Further down are sections for 'Questions About R' and 'Supporting CRAN', both with bullet points. At the bottom, there's a note about R and CRAN.

Figura 1: Página de download do R no CRAN.

## 2 Passo 2: Instalar o RStudio

- Visite a página de download do RStudio: [Clica aqui](#).
- A versão gratuita "RStudio Desktop" é a recomendada para iniciantes. Clique no botão de download (Figura 2 mostra isso e o vídeo contém o tutorial).
- O site geralmente detecta seu sistema operacional e sugere o instalador correto. Baixe-o.
- Execute o instalador e siga as instruções, mantendo as opções padrão.

The screenshot shows the Positron RStudio download page. At the top, it says 'Introducing Positron, the free code editor made for data science with Python, R, and you.' Below that is a navigation bar with 'PRODUCTS', 'FREE & OPEN SOURCE', 'USE CASES', 'PARTNERS', 'LEARN & SUPPORT', and 'ABOUT'. The main content is a table of download links:

OS	Download	Size	SHA-256
Windows 10/11	<a href="#">RSTUDIO-2025.05.1-513.EXE</a>	281.24 MB	<a href="#">3A553330</a>
macOS 13+	<a href="#">RSTUDIO-2025.05.1-513.DMG</a>	607.30 MB	<a href="#">76E1538B</a>
Ubuntu 22/Debian 12	<a href="#">RSTUDIO-2025.05.1-513-AMD64.DEB</a>	209.78 MB	<a href="#">89A6BB37</a>
Ubuntu 24	<a href="#">RSTUDIO-2025.05.1-513-AMD64.DEB</a>	209.78 MB	<a href="#">89A6BB37</a>
Fedor 41	<a href="#">RSTUDIO-2025.05.1-513-X86_64.RPM</a>	224.98 MB	<a href="#">6A97DF24</a>
Red Hat 9	<a href="#">RSTUDIO-2025.05.1-513-X86_64.RPM</a>	224.98 MB	<a href="#">6A97DF24</a>

A pink arrow points to the 'RSTUDIO-2025.05.1-513.EXE' link under Windows 10/11.

Figura 2: Página de download do RStudio.

**Nota:** Assim que instalar o R e o RStudio, sempre que quiser fazer análises, use o RStudio clicando nele duas vezes. Se não encontrar o RStudio na área de trabalho, pesquise por **Rstu** em uma das opções abaixo (1 ou 2) mostradas na Figura 3.

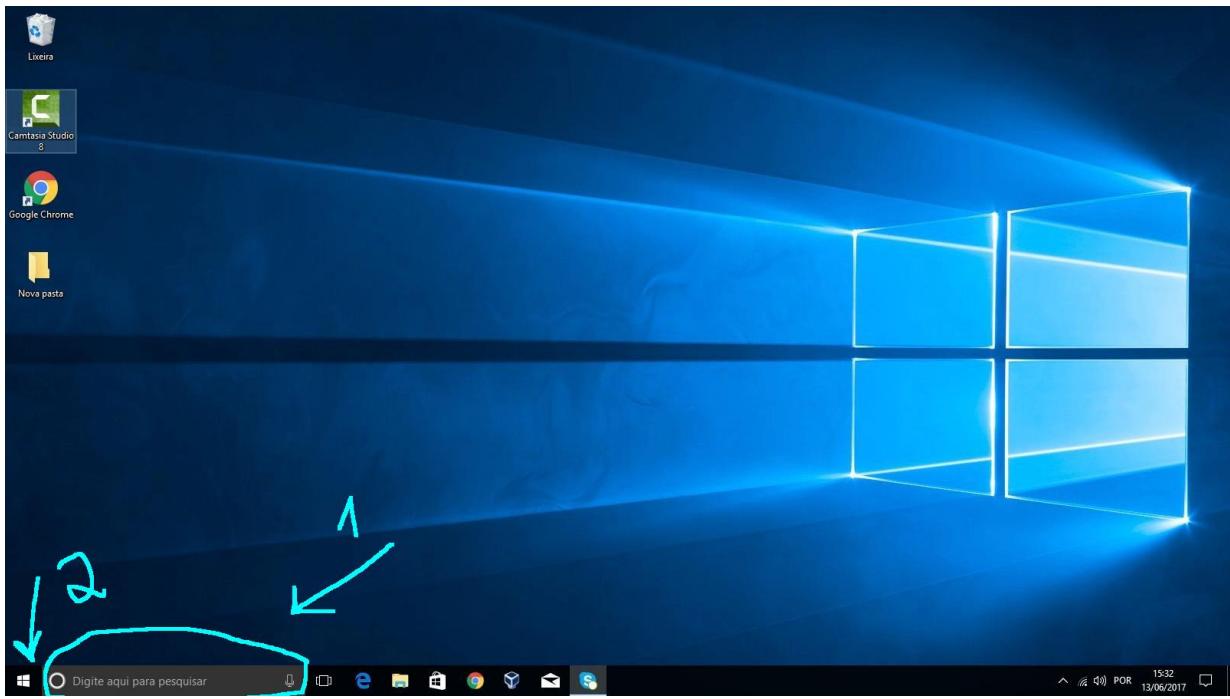


Figura 3: Encontrar aplicativo que sumiu.

**Nota:** O R diferencia letras minúsculas de maiúsculas (TOME CUIDADO). Para os próximos passos, assista aos vídeos da Fernanda Peres: [Clica aqui](#) para ver o Vídeo 2 (os demais também são interessantes).

## Questões e resolução

Link dos dados <https://hbiostat.org/data/>, base de dados **Diabetes data**.

**Questão 1:** Apresente medidas descritivas para a variável quantitativa Glicose (stab.glu). Inclua média, mediana, quartis, o número de observações e medidas de variabilidade como o desvio padrão e o erro padrão. Interprete a mediana e o primeiro quartil.

### Resolução

#### 1) Medidas Descritivas para Glicose (stab.glu)

Para a variável quantitativa Glicose (stab.glu), calcularíamos as seguintes medidas descritivas:

- Média ( $\bar{x}$ ): A soma de todas as observações  $x_i$  (isto é, todos os números da **stab.glu**) dividida pelo número total de observações  $n$  (quantidade de números existentes).

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{82 + 97 + 92 + 93 + 90 + \dots + 369 + 89 + 269 + 76 + 88}{403} = \frac{42989}{403} = 106.6725 \approx 106.67$$

- Mediana (Md): O valor que divide os dados ordenados, pelo meio.

$$\text{Mediana} = \begin{cases} x_{(\frac{n+1}{2})}, & \text{se } n \text{ é ímpar} \\ \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & \text{se } n \text{ é par} \end{cases}$$

Como  $n=403$  é ímpar (se dividir por dois fica um número com vírgula, isto é número decimal), mediana é o número que está na posição  $(403+1)/2 = 202$ . Isto é, **mediana** = 89

- Quartis: Dividem um conjunto de dados ordenados em quatro partes iguais, cada uma contendo 25% das observações.
- Desvio padrão ( $s$ ): Mede a dispersão dos dados em torno da média, isto é, o quanto distantes em média os valores  $x_i$  estão de  $\bar{x}$ .

$$s = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}} = \sqrt{\frac{\sum_{i=1}^{403} (82 - 106.67)^2 + \dots + (88 - 106.67)^2}{403-1}} = \sqrt{\frac{1132487}{402}} = \sqrt{2817.131} = 53.07665 \approx 53.08.$$

Note que 2817.131 é a variância, isto é, desvio padrão é raiz quadrada da variância.

- Erro Padrão (EP): Mede a variabilidade da média amostral ( $\bar{x}$ ) em relação à média populacional ( $\mu$ ), isto é, indica o quanto preciso é o valor de  $\bar{x}$  como estimador de  $\mu$ .

$$EP = \frac{s}{\sqrt{n}} = \frac{53.07665}{\sqrt{403}} = \frac{53.07665}{20.1} = 2.64$$

Tabela 1: Estatísticas descritivas da variável Glicose (*stab.glu*)

Variável	n	Média	Desvio padrão	Mín	Q1	Mediana (Q2)	Q3	Máx	Assimetria	Curtose	Erro padrão
stab.glu	403	106.67	53.08	48	81.0	89.0	106.0	385	2.75	8.10	2.64

**Nota:** Clica aqui para acessar o livro **The Epidemiologist R Handbook**, ele é bom e com várias análises no R/Rstudio.

**Interpretação:**

- **Mediana (Q2 = 89 mg/dL):** metade (50%) das pessoas tinham glicemia igual ou abaixo de 89 mg/dL.
- **Primeiro quartil (Q1 = 81 mg/dL):** 25% das pessoas tinham glicemia igual ou inferior a 81 mg/dL.

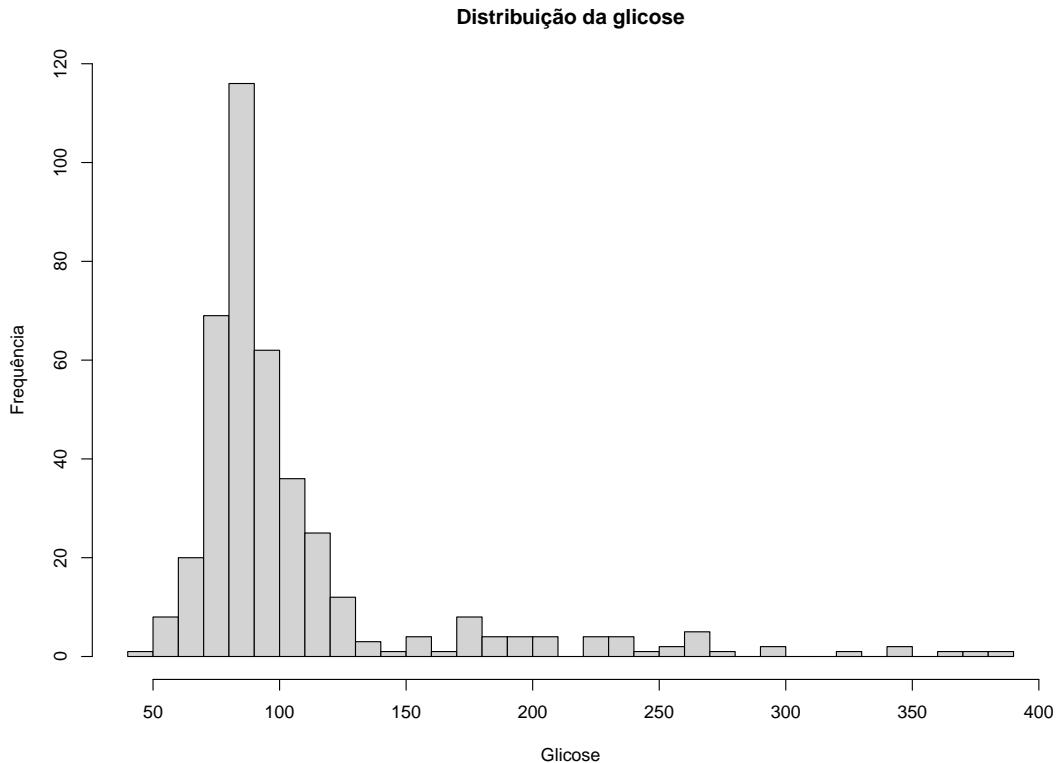
## 2) Histograma para a Variável Glicose

Um histograma seria construído para visualizar a distribuição dos dados de glicose. Caso feito manualmente os passos seriam:

1. Dividir a amplitude dos dados em intervalos de classe (bins) de igual tamanho.
2. Contar o número de observações (frequência) que caem em cada intervalo.
3. Desenhar barras para cada intervalo, onde a altura da barra corresponde à sua frequência.

**Nota:** Caso seja do seu interesse fazer manualmente, veja o vídeo: [Clica aqui](#)

Figura 4: Distribuição dos níveis de Glicose Sanguínea em Pacientes.



**Interpretação:** na Figura 4, observa-se que a maior parte das pessoas avaliadas apresenta glicose entre 80 e 110 mg/dL, faixa considerada dentro do esperado, mas há um grupo menor com valores mais altos, acima de 150 mg/dL, chegando em alguns casos a ultrapassar 300 mg/dL, o que mostra que embora a maioria esteja com níveis normais, existem indivíduos com glicemia bastante elevada que merecem atenção.

Note que neste gráfico temos assimetria à direita (cauda longa para valores altos), o que pode ser indício de ou valores atípicos (outliers).

## 3) Boxplot da Glicose por Gênero

O boxplot é baseado no chamado **resumo de cinco números**: o valor mínimo, o primeiro quartil ( $Q_1$ ), a mediana ( $Q_2$ ), o terceiro quartil ( $Q_3$ ) e o valor máximo.

**Nota:** Caso opte por construir manualmente, siga os passos abaixo: (1) veja o vídeo [Clica aqui](#) para manualmente e [clica aqui](#) e assista vídeo da Fernanda Peres.

**Passo 1** - Organize os dados em ordem crescente, do menor para o maior valor. Em seguida, calcule: o valor mínimo, o primeiro quartil ( $Q_1$ ), a mediana ( $Q_2$ ), o terceiro quartil ( $Q_3$ ) e o valor máximo.

**Passo 2** - Cálculo do Intervalo Interquartil (IQR):  $IQR = Q_3 - Q_1$

**Passo 3** - Calcule os limites inferior (LI) e superior (LS):  $LI = Q_1 - 1.5 \times IQR$  e  $LS = Q_3 + 1.5 \times IQR$   
Valores fora desses limites são considerados outliers.

**Passo 4:** Desenho do Boxplot

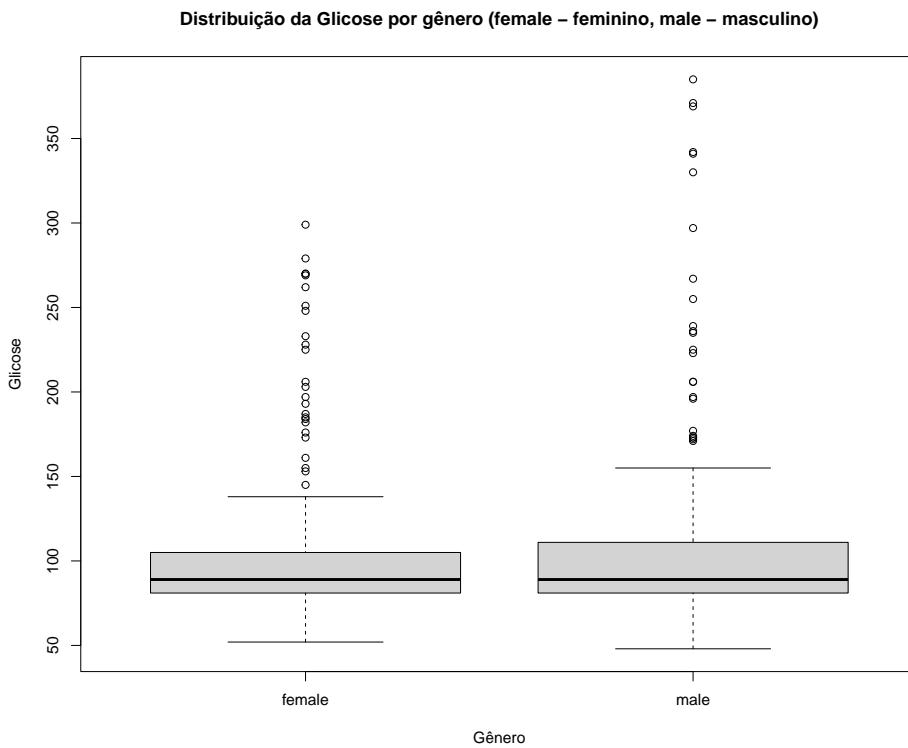


Figura 5: Figura 2: Boxplot dos níveis de Glicose sanguínea por gênero.

### Interpretação:

A Figura 5 mostra como os níveis de glicose no sangue variam entre homens e mulheres no estudo. Cada círculo representa uma pessoa, e a “caixa” mostra onde a maior parte das pessoas está concentrada. A mediana (o valor do meio) dos níveis de glicose é parecida para ambos os gêneros. Isso significa que, de modo geral, homens e mulheres têm níveis de glicose similares. Existem pessoas com níveis de glicose muito altos (os círculos acima da caixa) em ambos os grupos. A maioria das pessoas tem glicose em uma faixa mais baixa, mas os homens parecem ter um pouco mais de casos com níveis muito altos do que as mulheres.

### 4) Exercício 3

Para comparar a distribuição de gênero entre os locais (Buckingham e Louisa), construiríamos uma tabela de contingência. Como os dados não estão disponíveis, segue uma tabela hipotética para ilustrar o cálculo.

Tabela 2: Distribuição de gênero por localização

Característica	Buckingham N = 200 <sup>1</sup>	Louisa N = 203 <sup>1</sup>	Total N = 403 <sup>1</sup>
<b>Gênero</b>			
female	114 (57%)	120 (59%)	234 (58%)
male	86 (43%)	83 (41%)	169 (42%)

<sup>1</sup> n é total das observações existentes, seguido da porcentagem entre os parenteses(%)

**Interpretação:** Dos 403 participantes incluídos na análise, 234 ( $\approx 58\%$ ) eram mulheres. Separando por local, Buckingham teve 114 mulheres em 200 participantes (57%) e Louisa teve 120 mulheres em 203 participantes (59%). A diferença entre as proporções de mulheres nos dois locais é muito pequena ( $\approx 2\%$ ), o que indica que a composição por sexo é semelhante em Buckingham e em Louisa na amostra observada.

## Exercício 5

	Teste positivo	Teste negativo	Total
Doente	231	27	258
Não doente	32	54	86
Total	263	81	344

### Medidas de concordância

- **Sensibilidade (s):** Probabilidade de o teste ser positivo dado que a pessoa está doente.

$$s = P(\text{Teste positivo} | \text{Doente}) = \frac{\text{total } (\text{Teste positivo} \cap \text{Doente})}{\text{total Doente}} = \frac{231}{258} \approx 0,8953 = 89,53\%$$

Interpretação: O exame tem uma alta sensibilidade. Isso significa que ele é muito eficaz em detectar a doença quando ela está presente. Cerca de 89,5% das pessoas doentes receberão um resultado positivo, o que é excelente caso o objectivo seja detectar se existe a doença.

- **Especificidade (e):** O exame tem uma capacidade limitada de identificar corretamente as pessoas que não têm a doença. Uma especificidade de 62,8% implica uma taxa de falsos positivos de 37,2% ( $1 - 0,6279$ ). Ou seja, mais de um terço das pessoas saudáveis que fazem o teste receberão um resultado positivo (alarme falso). Isto é, é meio ruim se o objetivo é identificar se não existe a doença.

$$e = P(\text{Teste negativo} | \text{Não Doente}) = \frac{\text{total } (\text{Teste negativo} \cap \text{Não Doente})}{\text{total Não Doente}} = \frac{54}{86} \approx 0,6279 = 62,79\%$$

Interpretação: O teste identifica corretamente 62,79% dos indivíduos saudáveis.

### Probabilidade de estar doente dado teste positivo:

Seja  $p$  a prevalência da doença.

$$\begin{aligned} P(\text{Doente} | \text{Teste Positivo}) &= \frac{P(\text{Doente} \cap \text{Teste Positivo})}{P(\text{Teste Positivo})} = \frac{P(\text{Teste Positivo} | \text{Doente}) \cdot P(\text{Doente})}{P(\text{Teste Positivo} | \text{Doente}) + P(\text{Teste Positivo} | \text{Não doente})} \\ &= \frac{s \cdot p}{s \cdot p + (1 - e) \cdot (1 - p)}, \text{ em que } s \text{ é sensibilidade e, } e \text{ é especificidade calculados acima.} \\ &= \frac{0,8953 \cdot p}{0,8953 \cdot p + (1 - 0,6279) \cdot (1 - p)}, \text{ em que } p \text{ foi fornecido no exercício} \end{aligned}$$

- Para prevalência da doença igual a 25% ( $p = 0,25$ ):

$$\begin{aligned} P(\text{Doente} | \text{Teste Positivo}) &= \frac{0,8953 \cdot p}{0,8953 \cdot p + (1 - 0,6279) \cdot (1 - p)} = \frac{0,8953 \cdot 0,25}{0,8953 \cdot 0,25 + (1 - 0,6279) \cdot (1 - 0,25)} \\ &= \frac{0,223825}{0,5029} \approx 0,4451 = 44,51\% \end{aligned}$$

Interpretação: Com prevalência de 25%, a probabilidade de estar doente após um teste positivo é de aproximadamente 44,51%.

- Para prevalência de 75% ( $p = 0,75$ ):

$$\begin{aligned} P(\text{Doente} | \text{Teste Positivo}) &= \frac{0,8953 \cdot p}{0,8953 \cdot p + (1 - 0,6279) \cdot (1 - p)} = \frac{0,8953 \cdot 0,75}{0,8953 \cdot 0,75 + (1 - 0,6279) \cdot (1 - 0,75)} \\ &= \frac{0,671475}{0,7645} \approx 0,8783 = 87,83\% \end{aligned}$$

Interpretação: Com prevalência de 75%, a probabilidade de estar doente após um teste positivo é de aproximadamente 87,83%.

## Exercício 6

Seja  $X$  o número de canhotos em uma amostra de 10 pessoas. Temos  $X \sim \text{Bin}(n = 10, p = 0,1)$ , em que  $0,1 = 10\%$ . A fórmula da probabilidade binomial é:

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

- a) Nenhum canhoto ( $k = 0$ ):

$$P(X = 0) = \binom{10}{0} (0,1)^0 (0,9)^{10-0} = \binom{10}{0} (0,1)^0 (0,9)^{10} = 1 \times 1 \times 0,348678 \approx 0,3487 = 34,87\%$$

b) Exatamente 1 canhoto ( $k = 1$ ):

$$P(X = 1) = \binom{10}{1} (0.1)^1 (0.9)^{10-1} = \binom{10}{1} (0.1)^1 (0.9)^9 = 10 \times 0.1 \times 0.38742 \approx 0.3874 = 38.74\%$$

c) Exatamente 2 canhotos ( $k = 2$ ):

$$P(X = 2) = \binom{10}{2} (0.1)^2 (0.9)^{10-2} = \binom{10}{2} (0.1)^2 (0.9)^8 = \frac{10 \times 9}{2} \times 0.01 \times 0.430467 \approx 45 \times 0.00430467 \approx 0.1937 = 19.37\%$$

d) Mais que 2 canhotos ( $k > 2$ ):

$$P(X > 2) = 1 - P(X \leq 2) = 1 - [P(X = 0) + P(X = 1) + P(X = 2)]$$

$$P(X > 2) = 1 - (0.3487 + 0.3874 + 0.1937) = 1 - 0.9298 = 0.0702 = 7.02\%$$

### Exercício 7

Seja  $X \sim N(\mu = 10, \sigma = 1)$ . Usamos a transformação para a normal padrão  $Z = \frac{X-\mu}{\sigma}$ .

a)  $P(X > 12)$ :

$$Z = \frac{12 - 10}{1} = 2$$

$$P(X > 12) = P(Z > 2) = 1 - P(Z \leq 2)$$

Da tabela da normal padrão,  $P(Z \leq 2) \approx 0.9772$ .

$$P(X > 12) = 1 - 0.9772 = 0.0228$$

b)  $P(8 < X < 12)$ :

$$Z_1 = \frac{8 - 10}{1} = -2 \quad \text{e} \quad Z_2 = \frac{12 - 10}{1} = 2$$

$$P(8 < X < 12) = P(-2 < Z < 2) = P(Z < 2) - P(Z < -2)$$

$$P(-2 < Z < 2) = 0.9772 - 0.0228 = 0.9544$$

c)  $x$  tal que  $P(X < x) = 0.02$ :

Primeiro, encontramos o valor  $z$  na distribuição normal padrão tal que  $P(Z < z) = 0.02$ . Consultando a tabela Z (ou usando uma calculadora), encontramos  $z \approx -2.054$ . Agora, convertemos o valor  $z$  de volta para a escala de X:

$$x = \mu + z\sigma$$

$$x = 10 + (-2.054) \times 1 = 7.946$$

**NOTA:** É crucial ter atenção ao usar uma tabela de distribuição normal padrão (tabela Z), pois existem vários tipos. Antes de realizar seus cálculos, verifique sempre a área sob a curva que a sua tabela representa (Clica [aqui](#) e veja página 12-14). As mais comuns indicam a probabilidade acumulada à esquerda de um valor ( $P(Z < z)$ ), mas outras podem mostrar a área a partir da média ( $P(0 < Z < z)$  [clique aqui](#)) ou a área na cauda direita ( $P(Z > z)$ ). Para um guia visual sobre como ler uma tabela, você pode assistir ao vídeo clicando [aqui](#).

### 3 Script R

```
1 # =====
2 # Resolucao Lista 1
3 # =====
4 # Autor: Alex Monito Nhancololo
5 #
6 # Este script realiza uma analise exploratoria de dados de um conjunto de dados sobre
7 # diabetes.
8 # Os comentarios abaixo explicam o que cada parte do codigo faz.
9 #
10 #
11 # -----
12 # Como rodar os comandos no RStudio
13 #
14 # Para executar uma linha de codigo, coloque o cursor sobre ela e pressione CTRL + ENTER.
15 #
16 #
17 # -----
18 # Instalacao dos pacotes (so precisa rodar uma unica vez)
19 #
20 # Pacotes sao como "caixas de ferramentas" que adicionam novas funcoes ao R.
21 # A funcao install.packages() baixa e instala esses pacotes no seu computador.
22
23 install.packages("dplyr")      # Essencial para manipulacao de dados (filtros, selecao,
24 # etc.).
25 install.packages("tidyverse")    # Um "pacotao" que inclui o dplyr, ggplot2 e outras
26 # ferramentas uteis.
27 install.packages("flextable")   # Usado para criar tabelas com aparencia profissional.
28 install.packages("psych")       # Oferece funcoes avancadas de estatisticas descritivas.
29 install.packages("ggplot2")     # A ferramenta mais poderosa e popular para criar graficos
30 # em R.
31 install.packages("readxl")       # Para ler arquivos do Microsoft Excel (.xls, .xlsx).
32 install.packages("gtsummary")    # Cria tabelas de resumo estatistico prontas para
33 # publicacao.
34 install.packages("Hmisc")        # Outro pacote com muitas funcoes uteis para analise de
35 # dados.
36 install.packages("gt")          # Outra excelente ferramenta para construir tabelas.
37 install.packages("kableExtra")    # Ajuda a formatar tabelas para diferentes formatos, como
38 # PDF.
39 #
40 #
41 # Observacao: Uma vez que um pacote e instalado, ele fica no seu computador para sempre.
42 # Voce nao precisa instalar de novo, a menos que atualize o R.'
43
44 library(dplyr)
45 library(tidyverse)
46 library(flextable)
47 library(psych)
48 library(ggplot2)
49 library(readxl)
50 library(gtsummary)
51 library(Hmisc)
52 library(gt)
53 library(kableExtra)
54
55
56 # -----
57 # Diretorio de trabalho
58 #
59 # O diretorio de trabalho e a pasta no seu computador onde o R vai procurar
```

```

60 # arquivos para ler e onde ele vai salvar arquivos por padrao.
61
62 getwd()
63 # getwd() significa "get working directory" (obter diretorio de trabalho).
64 # Essa funcao MOSTRA qual e a pasta atual.
65
66 setwd("/home/posmae/amnhancololo/Rede IME/Monitoria Introducao a analise de dados")
67 # setwd() significa "set working directory" (definir diretorio de trabalho).
68 # Essa funcao ALTERA a pasta de trabalho para o caminho que voce especificar.
69 # Dica: Sempre use barras normais "/" ou "\\\"e coloque o caminho entre aspas.
70
71
72 # -----
73 # Importacao dos dados
74 #
75 # Agora vamos carregar nosso conjunto de dados para dentro do R.
76
77 dados_diabete <- read_csv("diabetes.csv")
78 # A funcao read_csv() le um arquivo de texto com valores separados por virgula (.csv).
79 # Ela transforma o arquivo em um objeto no R chamado "data frame" (uma tabela).
80 # O simbolo "<- " e o operador de atribuicao. Ele "salva" a tabela lida
81 # em um objeto com o nome "dados_diabete".
82
83
84 # -----
85 # Explorando os dados ("Conhecendo sua base de dados")
86 #
87 # Antes de fazer qualquer analise, e crucial entender a estrutura e o conteudo dos seus
88 # dados.
89
90 glimpse(dados_diabete)
91 # A funcao glimpse() (do pacote dplyr) oferece uma "espiada" rapida nos dados.
92 # Mostra o numero de linhas e colunas, o nome e o tipo de cada coluna,
93 # e os primeiros valores de cada uma. E otima para um primeiro contato.
94 # ===== Exerc cio 1: Analise da Variavel "Glicose" (stab.glu)
95 #
96 # Vamos focar em uma unica variavel para entender suas caracteristicas.
97
98 # Seleciona apenas a coluna "stab.glu" e a salva em um novo objeto chamado "Glicose".
99 Glicose <- dados_diabete["stab.glu"]
100
101 # A funcao str() (de "structure") mostra a estrutura do objeto.
102 # E util para confirmar o tipo de dado (numerico, texto, etc.).
103 str(Glicose)
104
105 # A funcao summary() e uma das mais uteis. Ela calcula as principais estatisticas
106 # descritivas para cada coluna: minimo, 1 quartil, mediana, media, 3 quartil e maximo.
107 summary(Glicose)
108
109 # A funcao describe() do pacote 'psych' da estatisticas ainda mais detalhadas,
110 # como desvio padrao, erro padrao, curtose e assimetria.
111 psych::describe(Glicose)
112
113 # A funcao describe() do pacote 'Hmisc' oferece outra visao descritiva.
114 Hmisc::describe(Glicose)
115
116 # A funcao quantile() calcula os percentis que voce especificar.
117 # Util para entender a distribuicao dos dados em pontos especificos.
118 quantile(Glicose$stab.glu, probs = c(0.05, 0.10, 0.25, 0.5, 0.75, 0.90, 0.95), na.rm = TRUE)
119 # O "Glicose$stab.glu" acessa a coluna "stab.glu" dentro do objeto "Glicose".
120 # "na.rm = TRUE" instrui a funcao a ignorar valores ausentes (NA) no calculo.
121
122 # A funcao head() mostra as 5 primeiras linhas dos dados.
123 # Bom para verificar se a importacao ocorreu como esperado.
124 head(Glicose, 5)
125

```

```

126 # A funcao tail() mostra as 5 ultimas linhas.
127 tail(Glicose, 5)
128
129 # A funcao nrow() conta o numero de linhas (casos/observacoes) no seu conjunto de dados.
130 n <- nrow(Glicose); n # Salva o numero de linhas em 'n' e depois o exibe.
131
132 # --- Calculos Manuais para Entendimento ---
133 # Embora o R tenha funcoes prontas, calcular "na mao" ajuda a fixar os conceitos.
134
135 # A funcao sum() calcula a soma de todos os valores na coluna.
136 soma <- sum(Glicose$stab.glu, na.rm = TRUE); soma
137 # A media e simplesmente a soma dividida pelo numero de observacoes.
138 media <- soma / n; media
139
140 # A mediana e o valor do meio quando os dados estao ordenados.
141 posicao <- (n + 1) / 2; posicao # Encontra a posicao do valor do meio.
142 sort(Glicose$stab.glu)[posicao] # sort() ordena os dados, e [posicao] seleciona o valor
naquela posicao.
143
144 # A funcao mean() faz o calculo da media diretamente.
145 mean(Glicose$stab.glu) # Comparando com o nosso calculo manual.
146
147 # Calculo da variancia.
148 variancia <- sum((Glicose$stab.glu - mean(Glicose$stab.glu))^2) / (n - 1); variancia
149 # A funcao sqrt() calcula a raiz quadrada (square root). O desvio padrao e a raiz da
variancia.
150 desvio_padrao <- sqrt(variancia); desvio_padrao
151 # O erro padrao e o desvio padrao dividido pela raiz quadrada do tamanho da amostra.
152 erro_padrao <- desvio_padrao / sqrt(n); erro_padrao
153
154
155 # ===== Exerc cio 2: Histograma (Visualizando a distribuicao)
156 # =====
157 # A funcao hist() cria um histograma, um grafico de barras que mostra a frequencia
# com que os valores aparecem em diferentes intervalos.
158 hist(Glicose$stab.glu,
159       main = "Distribuicao da Glicose", # Titulo do grafico
160       xlab = "Glicose", # Rotulo do eixo X
161       ylab = "Frequencia", # Rotulo do eixo Y
162       breaks = 40) # Numero de barras/intervalos a serem exibidos
163
164
165 # ===== Exerc cio 3: Boxplot (Comparando distribuicoes) =====
166 # A funcao boxplot() cria um diagrama de caixa. E excelente para comparar
167 # a distribuicao de uma variavel numerica entre diferentes grupos.
168 boxplot(stab.glu ~ gender, data = dados_diabete,
169           # A formula "stab.glu ~ gender" significa: "mostre a distribuicao de stab.glu para
cada grupo em gender".
170           main = "Distribuicao da Glicose por genero", # Titulo
171           xlab = "Genero", ylab = "Glicose") # Rotulos dos eixos
172
173
174 # ===== Exerc cio 4: Tabela de frequencias =====
175 # Aqui usamos o poder do 'tidyverse' e do 'gtsummary' para criar uma tabela profissional.
176
177 tabela_genero <- dados_diabete %>%
178   # O operador pipe (%>%) pega o resultado do que esta a esquerda e o "passa" como
# primeiro argumento para a funcao a direita. Ele torna o codigo mais legivel.
179
180   select(location, gender) %>%
181   # A funcao select() escolhe apenas as colunas que nos interessam: "location" e "gender".
182
183  tbl_summary(
184   # A funcao tbl_summary() (do gtsummary) cria a tabela de resumo.
185     by = location, # Agrupa os resultados pela variavel "location".
186     statistic = list(all_categorical() ~ "{n} ({p}%)"), # Define o que mostrar: contagem (
n) e porcentagem (p).
187     missing = "no" # Nao mostra uma linha para dados ausentes.
188   ) %>%

```

```
190  
191 add_overall() %>%  
192 # A funcao add_overall() adiciona uma coluna "Overall" com os totais gerais.  
193  
194 bold_labels()  
195 # A funcao bold_labels() coloca os nomes das variaveis em negrito, melhorando a estetica  
196  
197 # Finalmente, exibimos a tabela que criamos.  
198 tabela_genero
```